



Artigo

Um limiar de cor multinível baseado Abordagem de segmentação para identificação aprimorada da região defeituosa em superfícies de couro

M. Praveen Kumara e S. Denis Ashokb*

Escola de Engenharia Mecânica, Vellore Institute of Technology, Vellore, Índia

E-mail: apraveenkumar.m2016@vitstudent.ac.in, bdenisashok@vit.ac.in (autor correspondente)

Abstrato. Os sistemas de visão são amplamente adotados para a detecção de defeitos na superfície do couro para superar as dificuldades do processo de inspeção manual demorado e trabalhoso.

Técnicas adequadas de processamento de imagem precisam ser desenvolvidas para detecção precisa de defeitos de couro. As técnicas existentes de processamento de imagens baseadas em escala de cinza requerem a conversão de imagens coloridas usando um único valor limite e também carecem de sensibilidade para detectar os defeitos do couro devido à superfície aleatória e de textura do couro. Este trabalho apresenta uma abordagem de processamento de imagem colorida para melhorar a identificação de defeitos de couro usando uma função de limite de vários níveis. Neste trabalho, as imagens do couro são processadas no domínio de cor 'Lab' para melhorar a percepção humana de discriminar os defeitos do couro.

No presente trabalho, a faixa específica de valores para os atributos de cor é identificada usando o histograma de cores para detectar os diferentes defeitos do couro. A rotina do software MATLAB é desenvolvida para identificar defeitos em intervalos específicos de atributos de cor e os resultados são apresentados. A partir dos resultados, verifica-se que o método proposto fornece uma abordagem mais simples para identificar as regiões defeituosas com base nos atributos de cor da superfície com percepção humana aprimorada. A metodologia proposta pode ser implementada em unidades de processamento gráfico para detecção eficiente de vários tipos de defeitos usando limites específicos para a inspeção automatizada em tempo real de defeitos de couro.

Palavras-chave: Limitação de cor, imagem colorida, técnica de histograma, defeitos de couro.

REVISTA DE ENGENHARIA Volume 24 Edição 2

Recebido em 5 de setembro de 2019

Aceito em 13 de fevereiro de 2020

Publicado em 31 de março de 2020

Online em <https://engj.org/>

DOI:10.4186/ej.2020.24.2.101

1. Introdução

O couro é um material natural e é criado através de um processo de curtimento de couros e peles de vacas, ovelhas e cabras. O couro típico contém defeitos naturais e artificiais, como grão grosso, grão médio, grão leve, marcas de dobras, fio de pinto, veios, cortes, rugas etc.

A detecção de defeitos na superfície do couro desempenha um papel vital nas indústrias de couro para garantir a qualidade dos produtos de couro acabados, como luvas, sapatos, bolsas etc.

A inspeção manual é amplamente adotada e apresenta limitações em termos de precisão, coerência e eficiência na detecção de defeitos devido à textura aleatória da superfície do couro. Além disso, o processo de inspeção manual é demorado e muitas vezes está sujeito a erro humano.

Sistemas de inspeção automatizados baseados em visão são

recentemente empregados para detecção de defeitos na superfície do couro. No entanto, a detecção de defeitos usando um sistema de visão requer algoritmos de processamento de imagem adequados, pois a detecção de defeitos é afetada pela natureza aleatória da superfície da textura do couro e pelos tipos de defeitos.

Várias ferramentas de processamento de imagem foram propostas pelos pesquisadores para a detecção de defeitos no couro.

Nos primeiros anos, o algoritmo de processamento de imagem baseado em detecção de borda é usado para identificação de defeitos de couro usando uma câmera CCD. Em seguida, um processo de segmentação morfológica [1, 2] é aplicado nas imagens coletadas para extrair as características de orientação da textura do couro. Kohli et al. [3] propuseram uma abordagem de análise de histograma para extrair os recursos de imagem de baixo nível. Técnicas de limiarização e segmentação de imagem foram desenvolvidas para detecção de defeitos em couro [4, 5, 6]. A maioria dos algoritmos usa análise estatística dos níveis de cinza da imagem para detectar o defeito do couro, extraindo um conjunto de características texturais usando abordagens de matriz de co-ocorrência [7], a transformada de Fourier, a transformada de Gabor [8] e a transformada wavelet [9]. Técnicas tradicionais de análise de textura, como métodos de matriz de coocorrência [8, 9] no domínio espacial, e recursos de textura baseados em Fourier no domínio espectral [10, 11] são computacionalmente muito caros para desenvolver um sistema de inspeção eficiente.

Esses métodos são focados no processamento de escala de cinza de imagens para detecção de defeitos na superfície do couro que tem aleatório e textura na natureza.

Técnicas de processamento de imagem mais avançadas usando redes neurais (NNs), sistemas difusos (FSs) e máquinas de vetores de suporte (**SVM**) são apresentadas para superar as limitações das abordagens clássicas de processamento de imagens. Uma técnica de processamento de imagem baseada em lógica fuzzy é empregada para analisar o conjunto de características das imagens de couro para realizar o reconhecimento de defeitos de superfície [11]. Support vector machine (SVM) é um poderoso modelo computacional matemático para classificação de defeitos [12]. Uma abordagem de rede neural é adotada como um esforço para melhorar a precisão da classificação da abordagem da árvore de decisão e as redes neurais fornecem as soluções mais eficientes para um amplo espectro de problemas em muitos campos, particularmente problemas de classificação de padrões.

Recentemente, Winiarti et al. [13] descritores de recursos propostos

e arquitetura de rede neural de aprendizado profundo para classificação de defeitos usando um Alexnet pré-treinado. Uma nova abordagem é introduzida envolvendo o Pixel Intensity Analyzer

(PIA) juntamente com o classificador Extreme Learning Machines (ELM) para detecção e classificação de defeitos [14]. Um método automático de detecção de defeitos de couro para defeitos de forma e defeitos de cor é apresentado para os materiais impressos usando extração multifuncional de imagem [15]. Luo et al. [16] usaram árvores de decisão e redes neurais como um classificador de aprendizado para detecção e classificação de defeitos em superfícies de couro. O método inclui principalmente a transformada de Fourier e a transformada wavelet [17].

A identificação de defeitos de tecido reais é feita escolhendo um pequeno subconjunto de pixels da imagem como entrada usando rede neural [18-19]. Um método de campo aleatório multi-resolução é aplicado para segmentação em imagens [20]. Essas abordagens exigem fluxos de trabalho de processamento de imagem complexos e mais dados para melhorar a precisão da detecção de defeitos na superfície do couro.

Verifica-se que trabalhos recentes estão focados no desenvolvimento de algoritmos de processamento de imagem aprimorados para detecção de defeitos em superfícies de couro. No entanto, muitas das abordagens existentes se concentraram na detecção de defeitos no processamento em escala de cinza de imagens de couro com fluxos de trabalho e cálculos complexos. Como as abordagens de processamento de escala de cinza seguidas convencionalmente usam um único valor limite para os pixels, é difícil distinguir as regiões defeituosas na superfície do couro. Aproveitando as vantagens e benefícios da moderna unidade de processamento gráfico (GPU), este trabalho apresenta uma abordagem de processamento de cores com uma função de processamento de imagem baseada em limiarização multinível para a identificação de regiões defeituosas em imagens de couro.

2. Sistema de aquisição de visão para identificação de defeitos em couro

2.1. Aquisição de imagem

Em um couro típico, existem muitos tipos de defeitos como cicatrizes, ninhos de ácaros, verrugas, fissuras abertas, cicatrizes cicatrizadas, furos, orifícios de alfinetes, dobras. Como parte do desenvolvimento de um sistema automatizado de inspeção visual para identificação de defeitos de couro, um sistema de visão de máquina composto por uma câmera CMOS (BASLER acA4600), computador pessoal com software MATLAB (Versão. 2019a) é estabelecido no presente trabalho e é mostrado em Fig. 1. O sistema de iluminação de fibra ótica é usado para fornecer iluminação uniforme e sem ruído na superfície do couro. Também evita o efeito de cintilação do sistema de luz branca usado convencionalmente. A magnitude da luminância para a fibra a iluminação óptica é medida usando o medidor Lux e pode ser controlada usando um botão controlador de luz. Verificou-se que a magnitude da luminância varia na faixa de 1145-1150 Lux em condições de laboratório.



Fig. 1. Montagem experimental do sistema de inspeção visual para identificação de defeitos em amostras de couro.

A Tabela 1 lista as especificações gerais da câmera CMOS usada para a inspeção da amostra de couro. Imagens de amostras de couro de cores diferentes com vários defeitos são capturadas e armazenadas no PC para posterior processamento. A Fig. 2(a) mostra as imagens coloridas de três amostras de couro com defeitos marcados à mão, como marcas de dobras, fio de arame e grãos pesados.

Embora as marcas de dobra sejam visíveis na imagem mostrada na Fig. 2(b), é difícil identificar os outros defeitos, como fio de galinha e grãos pesados no couro pela percepção humana devido à textura não uniforme da superfície do couro. Daí a necessidade de desenvolver algoritmos de processamento de imagem para a detecção de defeitos nas amostras de couro.



(a) Diferentes amostras de couro com diferentes cores e defeitos sob iluminação natural



(b) Diferentes amostras de couro sob iluminação de fibra óptica



(c) Imagens em escala de cinza de diferentes amostras de couro.

Fig. 2. Imagens de amostras de couro defeituosas sob iluminação de fibra óptica.

Tabela 1. Principais especificações da câmera utilizada para aquisição de imagens em couro.

S.no	Especificações	1 Tipo	Descrição
1	Tamanho do sensor		CMOS
2			6,5 mm × 4,6 mm
3	Resolução (A × V)		4608 pixels × 3288 pixels
4	Resolução		14 MP
5	Tamanho do pixel (A × V)		1,4 μm × 1,4 μm
6	Taxa de quadros		10 fps
7	Mono/cor		cor
8	Interface		USB 3.0

2.2. Processamento em escala de cinza de imagens de couro

Devido à sua simplicidade de processamento das imagens usando um único valor limite, o processamento em escala de cinza de imagens de couro é convencionalmente seguido em muitas aplicações de processamento de imagens para identificação de defeitos. No presente trabalho, a imagem colorida de amostras de couro consistindo de 4608 × 3288 pixels é convertida em uma imagem em escala de cinza de 8 bits usando a média ponderada de três luminâncias ou intensidades para componentes de cores primárias (vermelho, verde e azul) para cada pixel. A imagem em escala de cinza de amostras de couro é mostrada na Fig. 3. Em uma imagem típica em escala de cinza de 8 bits, pode haver 256 diferentes magnitudes possíveis de intensidades para cada pixel e pode ser interpretada graficamente usando histograma e mapa de intensidade.

2.2.1. Análise de histograma e mapa de intensidade de imagens de couro

Pode-se ver que o histograma das imagens de couro tem formato gaussiano e é de natureza contínua, conforme mostrado na Fig. 3. Ele indica a variação de intensidade não uniforme dos pixels na imagem de couro devido à natureza aleatória de o padrão de textura da superfície do couro. O nível máximo de intensidade das imagens de couro é de cerca de 100.

2.2.2. Limiarização da imagem de couro em escala de cinza

A fim de identificar e distinguir a região defeituosa nas imagens em escala de cinza do couro, a limiarização binária convencionalmente seguida é seguida usando uma função de limiarização dada pela Eq. (1).

$$g(x, y) = \begin{cases} 0 & \text{se } f(x, y) > T \\ 1 & \text{se } f(x, y) \leq T \end{cases} \quad (1)$$

Na equação acima, $f(x, y)$ é a imagem de couro em escala de cinza de entrada e $g(x, y)$ é a imagem binária de saída T é a magnitude do limite. A Fig. 4 é a representação visual da função de limite e pode ser considerada como um mapeamento da imagem em escala de cinza de entrada $f(x, y)$ para a imagem binária de saída $g(x, y)$ para o limite dado T .

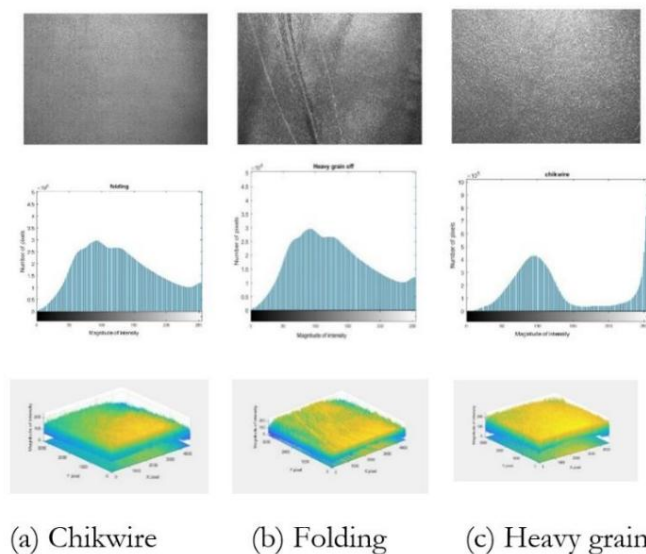


Fig. 3. Histograma e mapas de intensidade para análise variações de intensidade em imagens de couro.




Fig. 4. Função limiar para a imagem em escala de cinza.

No presente trabalho, diferentes valores de limite de 150, 138 e 129 são fixados para identificar os vários defeitos nas imagens de couro e os resultados de limite são mostrados na Fig. 5. Além da detecção de marcas de dobra na superfície do couro, conforme mostrado na Na Fig. 5, é difícil identificar as regiões defeituosas de arame de pinto e grãos pesados usando um limite binário. É devido à natureza aleatória dos defeitos e ao padrão de textura da superfície do couro.




Fig. 5. Limitação binária da imagem de couro em escala de cinza.

Verificou-se que as imagens limiarizadas usando a limiarização binária de diferentes imagens de couro carecem de sensibilidade e especificidade para a percepção humana na distinção dos defeitos do couro, pois se baseiam em um único valor limiar e na média da intensidade dos valores de pixels durante a conversão em escala de cinza.

3. Limiar de cor multinível proposto Abordagem para Detecção de Defeitos em Imagens de Couro

As cores são características importantes para o reconhecimento e discriminação visual. No presente trabalho, Lab color o espaço é utilizado para analisar as imagens do couro devido às suas vantagens de percepção humana natural. A Fig. 6 mostra o modelo de cor Lab que consiste em uma camada de luminosidade 'L', camada de cromaticidade 'a' e camada de cromaticidade 'b'. Aqui valores positivos e negativos de 'a' representam magnitude de vermelho e verde, respectivamente. Da mesma forma, valores positivos e negativos de 'b' representam amarelo e azul, respectivamente. O zero representa cinza neutro para ambos os eixos.




Fig. 6. Modelo de cores de laboratório.

Como os couros possuem cores diferentes e as regiões defeituosas da imagem do couro possuem a mesma magnitude de atributos de cor, este trabalho apresenta uma simples abordagem de processamento usando uma função de limiarização múltipla para a detecção aprimorada de regiões defeituosas nas imagens de couro. A Fig. 7 mostra as etapas seguidas na abordagem de processamento de cores proposta para detecção de defeitos em amostras de couro de cores diferentes. Na abordagem proposta, as imagens coloridas das amostras de couro são convertidas em espaço de cores Lab e

os atributos da imagem do couro são determinados no histograma de cores. Uma função de limiarização multinível baseada no atributo de cor é proposta para distinguir o defeito na imagem. Mais detalhes da abordagem proposta são descritos nesta seção.

3.1. Extração de recursos de cores usando histograma de cores para identificação de regiões

Um histograma de cores é usado para entender a magnitude das variações nos atributos de cores. Uma cor O histograma para determinada imagem de couro é representado por um vetor cujos componentes indicam as cores semelhantes em uma imagem conforme abaixo:

$$H = \{H[0], H[1], H[2], H[3], \dots, H[i], \dots, H[n]\} \quad (2)$$

onde i é a caixa de cores no histograma de cores e $H[i]$ representa o número de pixels da cor i na imagem e n é o número total de caixas usadas na cor

histograma.

Usando o histograma de cores da imagem do couro, as regiões de cores são identificadas usando picos (H_{max}) no

histograma que mostra as regiões de cores predominantes na imagem do defeito. Além disso, os recursos estatísticos, como faixa de magnitude de atributos de cor (Lmin, Lmax amin, amax, bmin, bmax) em luminosidade 'L', cromaticidade 'a' e cromaticidade 'b' do histograma de cores são úteis para limiarização da imagem de couro.

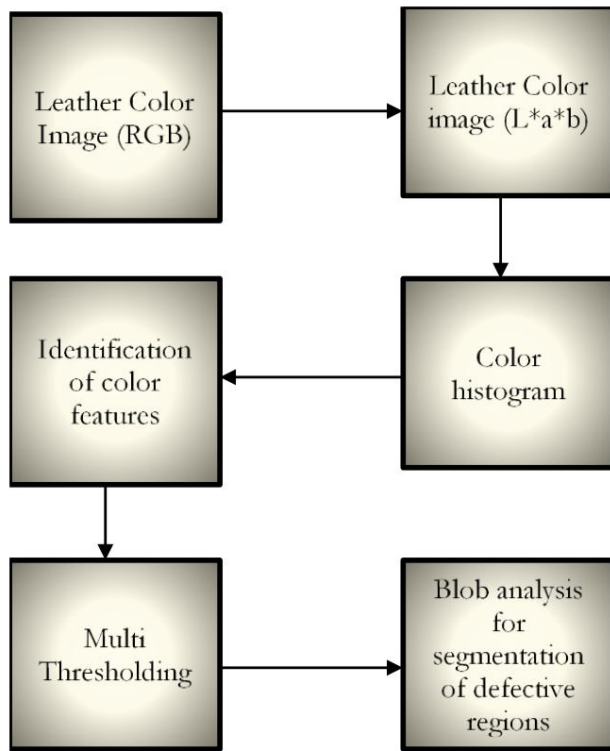


Fig.7. Metodologia proposta para detecção de regiões defeituosas em couro.

3.2. Segmentação de cores baseada em multilimiar da imagem térmica

Com base na magnitude dos atributos de cor, como luminosidade 'L', cromaticidade 'a' e cromaticidade 'b' no espaço de cores, uma função de limiarização múltipla é desenvolvida para agrupar os pixels semelhantes na imagem de couro como dada pela Eq. (3).

$$g(x,y) = \begin{matrix} \bar{y}^0 & f(x,y,T) & \bar{y} & 1 \\ \bar{y} & f(x,y,T) & \bar{y} & 2 \\ \bar{y}^0 & f(x,y,T) & \bar{y} & 2 \end{matrix} \quad (3)$$

Aqui T1 e T2 representam o valor limite inferior e superior para o atributo de cor, respectivamente.

A Figura 8 mostra a visualização da função de limiarização múltipla com um par de limiares.

Com base na faixa identificada de magnitude de cor atributos (Lmin, Lmax amin, amax, bmin, bmax) em luminosidade 'L', cromaticidade 'a' e cromaticidade 'b' na cor histograma, seguindo várias funções de limite são aplicadas à imagem de couro conforme dado pela Eq. (4), (5) (6) e (7) para segmentar as regiões de cores específicas

de acordo com os requisitos de identificação dos defeitos na imagem do couro.




Fig. 8. Função de limite múltiplo.

$$g(x,y) = \begin{matrix} \bar{y}^0 & f(x,y,T) & \bar{y} & \text{min} \\ \bar{y} & f(x,y,T) & \bar{y} & \text{máximo} \\ \bar{y}^0 & f(x,y,T) & \bar{y} & \text{máximo} \end{matrix} \quad (4)$$

$$g(x,y) = \begin{matrix} \bar{y}^0 & f(x,y,T) & \bar{y} & \text{min} \\ \bar{y} & f(x,y,T) & \bar{y} & \text{máximo} \\ \bar{y}^0 & f(x,y,T) & \bar{y} & \text{máximo} \end{matrix} \quad (5)$$

$$g(x,y) = \begin{matrix} \bar{y}^0 & f(x,y,T) & \bar{y} & \text{min} \\ \bar{y} & f(x,y,T) & \bar{y} & \text{máximo} \\ \bar{y}^0 & f(x,y,T) & \bar{y} & \text{máximo} \end{matrix} \quad (6)$$

$$G(x,y) = g1(x,y) * g2(x,y) * g3(x,y) \quad (7)$$

3.3. Segmentação e identificação de defeitos usando análise de blob

Após a limiarização da imagem de couro, a análise de objetos grandes binários (BLOB) é aplicada para segmentar regiões defeituosas que possuem propriedades semelhantes. O algoritmo de rotulagem de componentes conectados é aplicado para identificar a região do defeito e extraí-la da imagem segmentada. A região defeituosa extraída é posteriormente processada para estimativa de características como perímetro, comprimento, largura, centro de massa, etc. Com base na propriedade geométrica do BLOB, a detecção de defeitos pode ser feita. Ele fornece a região de interesse (ROI) e nos permite a tomada de decisão de defeitos de couro.

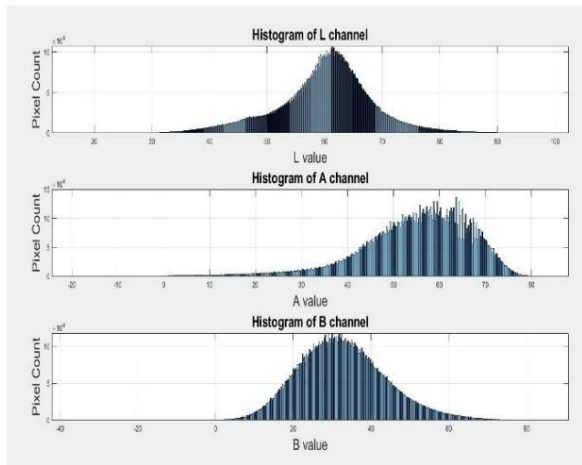
4. Resultados e discussão

A fim de comprovar a eficácia da abordagem proposta para a melhor identificação de regiões defeituosas em imagens de couro, ela é aplicada nas imagens de amostras de couro com diferentes cores e defeitos. Faixa específica de valores de atributos de cor, como para L, a, b, são fixados com base na cor dada da amostra de couro usando análise de histograma de cores. Um código de software é desenvolvido para a função multilimiarização proposta no ambiente MATLAB e aplicado para segmentação as regiões defeituosas em imagens de couro e os resultados são apresentados nesta seção.

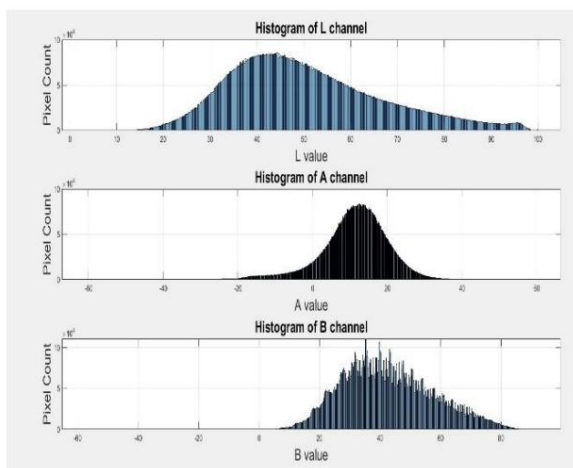
4.1. Identificação de característica de cor usando histograma em imagem de couro

A Fig. 9 mostra o gráfico do histograma de cores para as imagens de couro de diferentes amostras de cores. A magnitude das características de cor como L, a e b estão listadas na Tabela 2 para diferentes amostras de couro de cores diferentes. Pode-se notar que os valores máximos para a cor

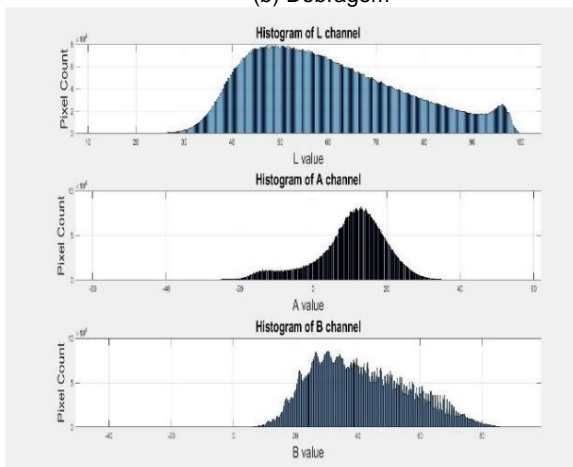
os atributos A e B diferem para cada amostra de couro, o que indica a diferença de cor das amostras de couro.



(a) Chikwire



(b) Dobragem



(c) Grão pesado

Fig. 9. Gráfico de histograma de cores de imagens de couro com diferentes defeitos.


Tabela 2. Magnitude dos atributos de cor para diferentes amostras de couro.

Couro	eu		UMA		B	
Amostras	Alcance máximo		Alcance máximo		Alcance máximo	
Chikwire	60	30-90	65	0-80	35	0-75
Dobrando	45	15-95	10	10-38	40	10-85
grão pesado	55	28-100	15	10-35	30	10-85


Para identificar os valores de cor para a percepção aprimorada da região defeituosa, a faixa de valores é fixada para limiarização de cada classe de defeitos e a função de multilimiarização é aplicada para segmentar as regiões defeituosas nas imagens de couro.

4.2. Limiarização Múltipla de Couro Diferente Defeitos


A abordagem proposta de limiarização e segmentação de cores é aplicada à imagem do couro de diferentes cores e defeitos. As regiões defeituosas são extraídas para os valores fornecidos de atributos de cor em cor Lab espaços conforme mostrado na Fig. 10.



(a) Dobragem



(b) Chikwire



(c) Grão pesado

Fig. 10. Segmentação da imagem colorida e região do defeito identificação.

A Tabela 3 mostra a faixa de valores de 'a' e 'b' para identificação de regiões defeituosas no espaço de cores Lab com a percepção humana aprimorada.

Tabela 3. Intervalo de valores para atributos de cor.

Amostras de couro	Faixa de magnitude de cor atributos		
	'L'	'a'	'b'
Chikwire	16 a 98	53 a 68	18 a 37
Dobrando	3 a 100	3 a 32	32 a 88
Grão pesado	11 a 100	6 a 32	28 a 79

Pode-se notar que não há variação significativa no valor de 'L' para as imagens de todas as amostras de couro, pois indica a luminosidade dos pixels no couro.

No entanto, existem variações significativas na faixa de valor de 'a' e 'b' para couro com marcas de dobra e fio de pinto, pois as cores das superfícies de couro são significativamente diferentes. A faixa de valores para as superfícies de couro com fio de pinto e grão pesado são semelhantes, o que se deve à semelhança de cor da amostra de couro e à semelhança na natureza do defeito.

4.3. Identificação de defeitos de couro usando análise de bolhas


As imagens limítrofes das amostras de couro são analisadas posteriormente usando a análise BLOB. A análise de componentes conectados é usada para extrair os recursos de BLOBs e segmentar as regiões defeituosas. Os resultados da segmentação de regiões defeituosas em imagens de couro são mostrados na Fig. 11.

5. Conclusão


Como a cor é um atributo importante para o reconhecimento visual da discriminação e também os couros possuem cores diferentes, este trabalho propôs uma abordagem de limiarização e segmentação baseada em cores para identificação de defeitos de couro. Em vez de analisar as imagens de couro em escala de cinza, as imagens coloridas de amostras de couro são analisadas no domínio de cores Lab usando a gama de atributos de cores para melhor identificação de defeitos nas imagens de couro. A função de limite de cores em vários níveis com uma determinada gama de recursos de cores é proposta com base em atributos de cor como L, aeb para distinguir a região defeituosa na imagem para melhorar a percepção humana. Diferentes defeitos de couro, como tela de pinto, grão pesado, marcas de dobras, são identificados usando a função multilimiar proposta e os resultados são analisados. A faixa de valores para os atributos de cor (L, a, b) para diferentes defeitos pode ser padronizada para melhorar a percepção humana e detectar defeitos de couro. Esses valores podem ser padronizados por meio da realização de aplicações de testes de campo na indústria do couro. A abordagem proposta melhora a análise subjetiva de defeitos de textura. O método proposto pode ser melhorado e

estendido para classificação de defeitos em couro com diferentes variações de cores.


Pode-se ver que a marca de dobra na imagem de couro é claramente visível e é muito melhor para a percepção humana em comparação com a imagem de couro limiarizada em escala de cinza, conforme mostrado na Fig. 11. Natureza do defeito de fio de pinto e defeito de grão alto no a amostra de couro é semelhante e é mostrada na Fig. 11. A abordagem proposta fornece uma abordagem interativa e subjetiva para discriminar as regiões defeituosas nas amostras de couro com percepção humana aprimorada. Esta abordagem será altamente útil para as indústrias de couro para a inspeção computadorizada de defeitos de couro.



(a) Dobragem



(b) Chikwire



(c) Grão pesado

Fig. 11. Regiões defeituosas em diferentes amostras de couro.

Referências

- [1] K. Hoang, W. Wen, A. Nachimuthu e XL Jiang, "Atingindo automação na inspeção de superfícies de couro," *Computers in Industry*, vol. 34, n.º. 1, pp. 43-54, 1997.
- [2] S. Winiarti, A. Prahara, DPI Murinto, "Rede neural convolucional pré-treinada para classificação da imagem de couro curtido", *rede (CNN)*, vol. 9, não. 1, 2018.
- [3] P. Kohli e S. Garg, "Estimativa da qualidade do couro usando um sistema automatizado de visão de máquina", *IOSR J. de Eletronics and Communication Engineering*, vol. 6, pp. 44-47, 2013.

- [4] Y. Li, J. Ai e C. Sun, "Inspeção online de defeitos de tecido usando sensores visuais inteligentes," *Sensors*, vol. 13, pp. 4659-4673, 2013.
- [5] E. Essa e X. Xie, "Segmentação automática de imagens arteriais coronárias transversais," *Visão computacional e compreensão de imagens*, vol. 165, pp. 97–110, 2017.
- [6] H. Liang, H. Jia, Z. Xing, J. Ma e X. Peng, "Limitação multinível baseada em algoritmo gafanhoto modificado para segmentação de imagem colorida," *Acesso IEEE*, vol. 7, pp. 11258–11295, 2019.
- [7] A. Amet, A. Ertuzun e A. Ercil, "Detecção de defeitos de textura usando matrizes de co-ocorrência de sub-bandas", no *IEEE Southwest Symposium on Image Analysis and Interpretation*, abril de 1998, pp. 205-210.
- [8] DM Tsai e SK Wu, "Inspeção de superfície automatizada usando filtros Gabor," *International Journal of Advanced Manufacturing Tehnology*, vol. 16, págs. 474 – 482, 2000.
- [9] M. Unser, "Classificação e segmentação de texturas usando quadros wavelet", *IEEE Transaction on Image Processing*, vol. 4, não. 11 de novembro de 1995.
- [10] C. Cortes e V. Vapnik, "Support-vector network," *Aprendizado de Máquina*, vol. 20, pp. 273-297, 1995.
- [11] CR Giardina e ER Dougherty, *Morphological Methods in Image and Signal Processing*. Engelwood Cliffs: Prentice Hall, 1988.
- [12] S. Kabeer, G. Attenburrow, P. Picton e M. Wilson, "Desenvolvimento de uma técnica de análise de imagem para medição da razão de Poisson para materiais viscoelásticos: aplicação em couro," *J. of Material Science*, vol. 48, pp. 744-749, 2013.
- [13] A. Branca, M. Tafuri, G. Attolico e A. Distante, "Sistema automatizado para detecção e classificação de defeitos de couro," *Optical Engineering*, vol. 35, não. 12, pp. 3485-3494, 1996.
- [14] C. Lee e S. Wong, "Uma abordagem morfológica matemática para segmentar imagens fortemente corrompidas por ruído," *Reconhecimento de padrões*, vol. 29, não. 8, pp. 1347–1358, 1996.
- [15] K. Krastev, L. Georgieva e N. Angelov, "Seleção de recursos de couro para reconhecimento de defeitos usando lógica difusa," *Energy*, vol. 2, não. 3, 2004.
- [16] GB. Huang, Q.-Y. Zhu e C.-K. Leia, "Extreme Learning Machine: Theory and Applications," *Neurocomputação*, vol. 70, não. 1-3, pp. 489–501 2006.
- [17] J. Cai e Z. Liu, "Reconhecimento de padrões usando modelos de campos aleatórios de Markov," *Pattern Recogn.*, vol. 35, não. 3, vol. 725-733, 2002.
- [18] FS Cohen, ZG Fan e S. Attali, "Inspeção automatizada de tecido têxtil usando modelos texturais," *IEEE Trans. Padrão Anal. Mach. Intel.*, vol. 13, não. 8, pp. 803–808, 1991.
- [19] S. Ozdemir e A. Ercil, "Campos aleatórios de Markov e transformada de Karhunen–Loeve para inspeção de defeitos de produtos têxteis," na *Conferência IEEE sobre Tecnologias Emergentes e Automação de Fábrica, EFTA*, 1996, pp. 697–703.
- [20] R. Wilson e C. Li, "Uma classe de campos aleatórios multirresolução discretos e sua aplicação à segmentação de imagens," *IEEE Trans. Padrão Anal. Mach. Intel.*, vol. 25, não. 1, pp. 42–56, 2003.

M. Praveen Kumar recebeu o título de Bacharel em Engenharia e Mestre em Engenharia Mecatrônica pela Anna University of Tamilnadu, durante o ano de 2013 e 2015, respectivamente. Ele está cursando doutorado em engenharia mecânica no Vellore Institute of Technology, Vellore, Tamil Nadu, Índia. Seus interesses de pesquisa incluem visão de máquina e robótica.

Dr. S. Denis Ashok recebeu seu diploma de doutorado em Engenharia Mecânica pelo Instituto Indiano de Tecnologia Madras Chennai e mestrado em Engenharia de Produção pelo Thiagarajar College of Engineering, Madurai. Ele obteve o título de bacharel em Engenharia Mecânica pela Madurai Kamaraj University, Madurai. Atualmente, ele trabalha como professor na Escola de Engenharia Mecânica, Departamento de Projeto e Automação, Vellore Institute of Technology, Vellore, Tamil Nadu, Índia. Seus interesses de pesquisa incluem visão de máquina, processamento de imagens e técnicas de computação leve.