



# Inspeção automatizada de defeitos de couro usando abordagem estatística sobre a intensidade da imagem

Y. S. Gan<sup>1</sup> · SueySien Chee<sup>2</sup> · YenYChang Huang<sup>3</sup> · SzeY Teng Liong<sup>4</sup> · WeiYChuen Yau<sup>2</sup>



Recebido: 15 de abril de 2020 / Aceito: 24 de outubro de 2020 / Publicado online: 20 de novembro de 2020  
© Springer-Verlag GmbH Alemanha, parte da Springer Nature 2020

## Abstrato

O couro é uma matéria-prima muito importante em muitas indústrias de manufatura. Por exemplo, para produzir calçados, roupas, bolsas e acessórios. Antes da produção em massa de determinado produto, um processo profissional de inspeção visual de couro para detecção de defeitos é essencial como etapa de controle de qualidade. No entanto, até o momento, há uma falta de sistemas de inspeção de couro totalmente automatizados na indústria, em que a maioria dos fabricantes confia em especialistas experientes e treinados para marcar os defeitos no couro. Esse tipo de trabalho de avaliação humana é ineficiente e inconsistente. Portanto, este trabalho propõe um método que se baseia em técnicas de processamento de imagem, a saber, análise de histograma de níveis de cinza, para detectar defeitos do couro. Especificamente, as características do histograma, como média e desvio padrão, são extraídas e tratadas como características. Em seguida, o teste estatístico de duas amostras de Kolmogorov–Smirnov é utilizado para realizar a seleção de atributos. Seguido por um método de limiarização para reduzir a dimensionalidade dos recursos. Finalmente, os recursos são categorizados por vários classificadores conhecidos. A melhor precisão de classificação obtida é de 99,16% e 77,13% em dois conjuntos de dados diferentes, respectivamente.

**Palavras-chave** Couro · Defeito · Estatística · Classificação · Seleção de recursos

## 1. Introdução

O couro é um material feito de couro animal que foi tratado com produtos químicos para preservá-los e torná-los adequados para uso como roupas, bolsas, equipamentos esportivos,

móveis, calçados e ferramentas. Um estudo recente de 2018 revela que o mercado mundial de artigos de couro está em 95,4 bilhões de dólares, e está previsto atingir 128,61 bilhões de dólares em 2022, com uma taxa de crescimento de 4,36% (APLF 2018). Devido à importância do couro na indústria de fabricação, é vital garantir a boa qualidade do couro para melhorar a satisfação do cliente.

Normalmente, uma peça de couro natural pode conter imperfeições como picadas de insetos, cortes, manchas e rugas, conforme ilustrado na Fig. 1. Para produzir produtos de couro de alta qualidade, esses defeitos devem ser identificados e removidos durante o processo de determinação de defeitos. Em resumo, a qualidade do couro pode ser julgada com base em padrões de qualidade estabelecidos, como o padrão listado pela SATRA (Technology 2020). A SATRA defende um sistema de classificação de couro de cinco pontos que atribui uma faixa específica a uma peça de couro que expressa a porcentagem de superfície utilizável (ou seja, não marcada por defeitos) do couro (Tabela 1).

O processo de identificação de defeitos é geralmente reconhecido como um dos aspectos mais demorados no processo de produção que envolve material de couro. Atualmente, ainda é uma prática comum realizar esse processo manual de detecção de defeitos por inspetores treinados. Durante o processo de inspeção de defeitos, os inspetores são obrigados a usar vários

\* Sze-Teng Liong

stliong@fcu.edu.tw

\* Wei-Chuen Yau

wcyau@xmu.edu.my

YS Gan

ysgan@fcu.edu.tw

Sue-Sien Chee

swe1609507@xmu.edu.my

Yen-Chang Huang

ychuang@mail.nutn.edu.tw

<sup>1</sup> Escola de Arquitetura, Universidade Feng Chia, Taichung, Taiwan

<sup>2</sup> Escola de Engenharia Elétrica e de Computação, Xiamen Universidade Malásia, Sepang, Malásia

<sup>3</sup> Departamento de Matemática Aplicada, Universidade Nacional de Tainan, Tainan, Taiwan

<sup>4</sup> Departamento de Engenharia Eletrônica, Universidade Feng Chia, Taichung, Taiwan

**Fig. 1** Falhas típicas vistas em peles de couro



(a) Scratch



(b) Wrinkle



(c) Stretch marks

**Tabela 1** Sistema de classificação de cinco pontos da SATRA para couro (Tecnologia 2020)

Coeficiente de qualidade	Avaliar	Coeficiente representativo
100 a 95,1	UMA	97%
95 a 90,1	B	93%
90 a 85,1	C	88%
85 a 80,1	D	83%
80 a 75,1	E	78%
75 a 70	F	73%

ângulos e distâncias para examinar a mesma seção de couro várias vezes (Liong et al. 2019a). Inspectores qualificados que tenham demonstrado consistência e competência na norma e procedimentos receberão certificado individual.

As soluções atuais são marcar as áreas de defeitos manualmente e, em seguida, classificar os defeitos com base no nível de dano (ou seja, menor, maior, grave, etc.) etc.) (Liong et al. 2019a). Os sistemas típicos de marcação de defeitos funcionam primeiro escaneando e detectando automaticamente o limite do couro.

Profissionais treinados usarão uma caneta eletrônica para marcar os defeitos no couro e classificar os defeitos de acordo.

As posições e gradações dessas marcações são registradas pelo sistema de marcação de defeitos e serão utilizadas no processo de corte do couro nas etapas posteriores.

Como o processo de inspeção depende de um especialista humano, é caro, demorado e subjetivo. Além disso, está sempre sujeito a erros humanos, pois requer um alto grau de concentração que pode levar à fadiga. Portanto, para eliminar a intervenção manual neste processo específico, é necessário estabelecer uma solução automática baseada em visão (Aslam et al. 2019). Até agora, existem muitas aplicações importantes de processamento de imagem no campo de inspeção de qualidade (Xie et al. 2018; Aslam et al. 2020). Atualmente, o processamento de imagens está sendo usado na classificação e classificação de produtos como peixes e frutas e até plásticos reciclados e produtos de madeira (Blum 2018). É um passo importante na automatização de todo o processo de inspeção, aumentando assim a produtividade (San-Payo et al. 2019).

Este artigo tenta propor um sistema automático de inspeção de couro que utiliza uma série de técnicas de processamento de imagem simples, porém poderosas. De forma sucinta, o processo de extração de características é baseado na análise do histograma de níveis de cinza das imagens de couro. Em resumo, o histograma fornece informações ricas sobre a superfície do couro, especialmente os detalhes que contêm irregularidades na superfície. É importante saber quais informações são pertinentes ou úteis para detectar a presença de certos tipos de defeitos. Portanto, este artigo explora como os mais relevantes

características do histograma podem ser escolhidas, que são então usadas para classificação das imagens de couro. Com as definições e observações acima, os principais objetivos deste artigo são resumidos da seguinte forma:

1. Proposta de um método de seleção e extração de características baseado na análise de histogramas em níveis de cinza.
2. Avaliação do algoritmo proposto em múltiplos classificadores de aprendizado de máquina para verificar a capacidade de adaptação do algoritmo.
3. É fornecida uma análise quantitativa detalhada dos resultados explorando várias métricas.
4. Demonstração da versatilidade do algoritmo aplicando-o a dois conjuntos de dados distintos de natureza e características distintas.

## 2 Revisão da literatura

A literatura existente sugeriu muitos métodos vastos e variados na classificação de defeitos em diferentes tipos de superfície. A maioria deles aplica alguma variação de abordagens estatísticas, espectrais ou de detecção de borda (Sundari 2017). Abordagens como Matriz de Coocorrência de Nível de Cinza (GLCM) (Mohanaiah et al. 2013), detecção de bordas (Kasi et al. 2014), operações morfológicas (Kwak et al. 2001), filtros de Gabor (Hu 2015), etc. têm sido propostos e usados na detecção de defeitos de couro.

No entanto, cada uma das abordagens propostas tem seus próprios méritos e fraquezas. Por exemplo, os métodos de detecção de bordas são excelentes para diferenciar defeitos que possuem bordas claras da área de fundo, mas são menos eficazes quando os defeitos são caracterizados por uma mudança gradual na textura.

Por outro lado, devido aos avanços da arquitetura de aprendizado profundo, a pesquisa em visão computacional vem crescendo nos últimos anos (Rajagopalan et al. 2020; Zavala-Mondragon et al. 2019). Redes de aprendizado profundo, como a rede neural convolucional (CNN), têm sido utilizadas recentemente para resolver diferentes tipos de problemas.

Muitas variantes da CNN também foram propostas, como AlexNet, VGG, NIN, Inceptions, Inception-Resnet e DenseNet (Krizhevsky et al. 2012; Simonyan e Zisserman 2014; Lin et al. 2013; Szegedy et al. 2015, 2017; Huang et al. 2017). As subseções a seguir revisam os métodos tradicionais de processamento de imagem e aprendizado profundo que foram empregados em trabalhos de pesquisa de inspeção automática de couro.

### 2.1 Método tradicional de processamento de imagem

Um dos primeiros trabalhos é proposto por Georgieva et al. (2003) que empregou o critério  $\chi^2$  para analisar as superfícies do couro. O autor compara áreas defeituosas na superfície do couro com um histograma médio de couro sem defeitos

amostras. A aplicação do critério  $\chi^2$  é então usada para cálculo de distância em relação ao histograma médio.

No entanto, o autor não forneceu nenhuma evidência concreta da eficácia desta abordagem.

Pereira et al. (2018) compara o desempenho de combinações de diferentes algoritmos para extração de características e classificação de couro de cabra. Os extratores de características como a Matriz de Coocorrência de Nível de Cinza (GLCM) (Haralick et al. 1973), Padrão Binário Local (LBP) (Ahonen et al. 2006) e (Pixel Intensity Analyzer) PIA são empregados e avaliados em muitos classificadores diferentes, como k-vizinhos mais próximos (kNN), máquinas de vetor de suporte (SVM) e mínima máquina de aprendizagem (MLM) (Cover e Hart 1967; de Souza Júnior et al. 2015). Os resultados deste artigo (Pereira et al. 2018) mostram que a combinação do descritor de características PIA e classificador ELM surge como o método mais econômico para o problema de classificação. A desvantagem é que o autor não descreveu a configuração na configuração dos experimentos.

Ele et al. (2006) descrevem um método para detectar defeitos de couro usando o procedimento de seleção de banda wavelet. Os autores visam eliminar todos os padrões de textura regulares e repetitivos, diminuindo os níveis de resolução das imagens de couro até que os padrões de textura sejam indetectáveis. A seleção dos níveis de decomposição pode ser realizada adotando-se o procedimento de seleção de bandas de onda. Isso é realizado usando a função de energia e diminuindo a resolução até que a relação de energia (relação de detalhes entre os níveis de resolução) seja menor que um determinado valor. Além disso, este trabalho afirma que este método pode atingir a mesma porcentagem de detecção que um profissional treinado e é capaz de implementar em inspeção em tempo real. No entanto, nenhum resultado quantitativo foi fornecido e relatado no artigo.

Por outro lado, Hu (2015) apresenta um filtro de Gabor elíptico (EGF) para analisar os padrões da superfície do couro com propriedades de orientação muito específicas. Durante o processo de treinamento, o Filtro Gabor elíptico otimizado é treinado usando algoritmo genético (Holland 1992). No processo de inspeção, o filtro selecionado é enrolado com cada amostra sob inspeção, seguido por um processo de limiarização de nível de cinza para gerar um resultado segmentado binário. Os resultados mostram que o EGF supera os filtros Gabor comuns em termos de precisão de detecção.

Bongo et al. (2018) propõe um método de inspeção em 6 etapas para detecção e classificação de defeitos de couro. Vários algoritmos de processamento de imagem são empregados como etapa de extração de características e para identificar a posição do defeito. Os recursos de defeito extraídos incluem momentos de cor, cor, correlogramas, momentos de Zernike e recursos de textura. A acurácia obtida ao avaliar o método proposto usando o classificador SVM é de 98,8% para detectar um tipo de defeito. Obtém-se uma precisão de 92,4% no caso de dois tipos diferentes de defeitos. No entanto, os resultados no caso de três ou mais defeitos não foram mostrados.

## 2.2 Método de aprendizado profundo

Uma rede neural supervisionada é adotada em (Villar et al. 2011) para distinguir imagens de couro defeituosas e não defeituosas. Antes disso, a extração de recursos, um método Sequential Forward Selection é realizado para identificar os recursos significativos. Particularmente, o tipo de defeito considerado no experimento é corte aberto, corte fechado e mordida aberta. A precisão média alcançada é notável, ou seja, ~ 96,5%. No entanto, as imagens defeituosas usadas no experimento são relativamente óbvias e, portanto, levam a resultados de alta classificação.

Uma abordagem semelhante é proposta por Jian et al. (2010) para identificar os defeitos do couro, como furo de faca, entalhes, ferimento por impressão e aberração. A precisão geral alcançada é superior a 92% quando testada em uma quantidade total de 200 imagens. No entanto, a imagem de amostra usada no experimento não apareceu no papel e não foi divulgada ao público. Portanto, é ambíguo quanto à dificuldade em classificar os defeitos.

Um trabalho recente apresentado por Liong et al. (2019b) é utilizar Mask-RCNN para realizar a segmentação de defeitos para detectar pequenos defeitos de picada de carrapato na superfície do couro. Além disso, o mesmo grupo de pesquisa (Liong et al. 2019c) propõe duas abordagens de rede neural para extrair os ricos recursos de imagem das imagens de couro: Rede Neural Artificial (RNA) e Rede Neural Convolutiva (CNN). Para CNN, uma rede neural pré-treinada (ou seja, AlexNet) é usada. A arquitetura da rede é composta por cinco tipos de operações: convolução, ReLU, pooling, totalmente conectado e dropout. O melhor desempenho exibido usando ANN é de 80%, enquanto a CNN atinge precisão de classificação de 76,2%. Deve-se notar que este artigo menciona que o conjunto de dados utilizado sofre de um grave problema de distribuição de classes desequilibradas.

O mesmo grupo de autores Liong et al. (2020) estende o trabalho de classificação de couros aplicando a arquitetura de rede AlexNet em outro tipo de couro que consiste em defeitos de linha preta e rugas. O resultado de acurácia obtido para a classificação de três categorias é de 94,67% ao empregar uma divisão de treinamento/teste de 80/20. Além disso, uma tarefa de segmentação é executada para ambos os defeitos. Como resultado, a precisão média geral de pixels (mPA) alcançada é de 88,34%. O desempenho do defeito de ruga é relativamente menor do que o do defeito de linha preta. Isso ocorre porque a aparência do defeito de rugas não é tão óbvia em comparação com o defeito de linha preta.

Em suma, o aprendizado profundo pode melhorar muito a precisão da classificação (até 95% (Liong et al. 2020)). No entanto, treinar uma rede de aprendizado profundo requer maior poder de computação e um tempo de processamento mais longo. Em contraste, a análise de histograma, o método de processamento de imagem convencional heurístico é útil porque é intuitivo, fácil de visualizar e entender. Portanto, este trabalho adotará essa abordagem de análise de histograma no processo de extração de características para classificar os defeitos do couro.



3 Conjunto de dados


Há dois conjuntos de dados envolvidos neste experimento. Ambos os conjuntos de dados foram obtidos usando um braço robótico de seis eixos, DRV70L da Delta, e uma câmera Canon EOS 77D. O couro é colocado sobre uma mesa e o braço do robô - com a câmera montada nele - percorre o comprimento do couro cap turando imagens do couro do ponto de vista de cima para baixo.

Uma fonte de iluminação profissional foi usada para fornecer uma fonte de iluminação consistente e contínua. A fonte de luz foi colocada e fixada a 45 graus do couro, apontando para baixo (Liong et al. 2019b).

Tabela 2 Análise estatística para os defeitos de linha preta nas manchas de couro no Dataset I

	Largura (pixel)	Área (pixel2)	Área (mm2 )
Mínimo	7,32	53,58	0,0754
Primeiro quartil	13.41	179,83	0,2529
Mediana	19.06	363,28	0,5109
Terceiro quartil	25.16	633,03	0,8902
Máximo	80,63	6501.2	9,1423
Significa	20,9	436,81	0,6143
Desvio padrão	9,79	95,84	0,1348

Fig. 2 Exemplo de imagens de couro com defeito e sem defeito no Dataset I



(a) Leather with no defects



(b) Leather with defects

3.1 Conjunto de dados I

O primeiro conjunto de dados contém vários tipos de defeitos, mas focaremos principalmente nos defeitos de linhas escuras. Esses defeitos são mais óbvios e podem ser facilmente identificados a olho nu. Este conjunto de dados contém 199 imagens com defeito e 199 imagens sem defeito. A análise do conjunto de dados na Tabela 2 revela que a largura dos defeitos da linha escura varia de  $\sim 7$  pixels até  $\sim 80$  pixels com uma média de  $\sim 20$  pixels. Essas informações são úteis durante a segmentação da imagem para determinar o melhor tamanho de segmento. O exemplo das imagens coletadas é mostrado na Fig. 2.

3.2 Conjunto de dados II

O segundo conjunto de dados usado é o mesmo que (Liong et al. 2019c). Em resumo, contém amostras de couro com defeitos circulares semelhantes a mordidas de carrapatos. Como visto na Tabela 3, esses defeitos variam muito em área, de 30 pixel2 a 3195 pixel2. A área média dos defeitos é de 480 pixel2. Esses defeitos são bastante difíceis de serem detectados mesmo por inspeção humana.

Este conjunto de dados contém 503 imagens com defeito e 1102 imagens sem defeito. O exemplo das imagens coletadas está ilustrado na Fig. 3.

**Tabela 3** Análise estatística para os defeitos de mordida de carrapato nas manchas de couro no conjunto de dados II

	eixo x (pixel)	eixo y (pixel)	Área (pixel2 )	Área (mm2 )
Mínimo	6	5	30	0,0422
Primeiro quartil	16	16	272	0,3825
Mediana	20	20	396	0,5569
Terceiro quartil	26	25	575	0,8086
Máximo	65	71	3195	4,4930
Significa	21,56	20,86	480,44	0,6756
Desvio padrão	8.22	7,58	347,29	0,4884



(a) Leather with no defects



(b) Leather with defects


**Fig. 3** Exemplo de imagens de couro com defeito e sem defeito no Dataset II

4 Método proposto


A Figura 4 mostra o histograma de níveis de cinza do segmento não defeituoso (ie, Fig. 4a) e segmento defeituoso (ie, Fig. 4b) de um pedaço de couro. Os dois histogramas são visivelmente diferentes em muitos aspectos, ou seja, o histograma defeituoso está tendo menor magnitude, deslocado mais para a esquerda e tem uma largura maior. Assim, a partir da apresentação gráfica apresentada, é possível determinar se uma imagem possui defeitos simplesmente analisando certas características de sua distribuição.

Nosso método proposto, portanto, gira em torno desse conceito de análise de histograma.

O algoritmo proposto é composto por seis etapas principais: (1) pré-processamento da imagem; (2) segmentação de imagem; (3) cálculo de características estatísticas; (4) seleção de recursos; (5) redução da dimensionalidade do recurso, e; (6) classificação de defeitos. O fluxograma do algoritmo é ilustrado na Fig. 5, e as descrições detalhadas de cada etapa são elaboradas nas subseções a seguir.



(a) Non-defect segment and corresponding histogram



(b) Defect segment and corresponding histogram

Fig. 4 Histograma do segmento com defeito versus segmento sem defeito usando imagens de couro Dataset II

#### 4.1 Pré-processamento de imagem

A imagem é convertida em escala de cinza e um filtro Gaussiano 2D é aplicado à imagem. O objetivo desta etapa é enfatizar o defeito o máximo possível. A imagem após a conversão para tons de cinza e aplicação do filtro Gaussiano é mostrada na Fig. 6. Observa-se que o ruído no fundo é reduzido, tornando o defeito da linha preta mais perceptível.

#### 4.2 Segmentação de imagem

A imagem original tem a solução espacial de  $400 \times 400$  pixels. Cada imagem é igualmente particionada em 100 pequenos fragmentos, de modo que cada fragmento tenha o tamanho de  $40 \times 40$  pixels. O objetivo desse particionamento é permitir a extração de características locais em processos posteriores. Desde o

área dos defeitos são muito menores em comparação com a área da superfície do couro, segmentar a imagem reduz consideravelmente essa proporção. Idealmente, os segmentos devem estar em torno do tamanho dos defeitos para maximizar a diferença entre segmentos defeituosos e segmentos não defeituosos.

#### 4.3 Cálculo de recursos estatísticos

Para reduzir a redundância de dados e ao mesmo tempo extrair informações importantes da imagem, cada imagem de couro é transformada em um conjunto de vetores/características. Comumente, existem seis características de distribuições envolvidas no processo geral de processamento de imagens:

1. Média: média das intensidades de todos os pixels em um imagem.




Fig. 5 Fluxograma do método proposto

$$\bar{y} = \frac{\sum_{x=1}^X \sum_{y=1}^Y I_{x,y}}{X \times Y}, x = 1, \dots, X; y = 1, \dots, Y \quad (1)$$

onde  $X \times Y$  são as dimensões (ou seja, largura por altura) da imagem de couro.

2. Variação: A dispersão das intensidades (claro a escuro) dos pixels na imagem.

$$\bar{y}^2 = \frac{\sum_{x=1}^X \sum_{y=1}^Y I_{x,y}^2}{X \times Y}, \quad x = 1, \dots, X; y = 1, \dots, Y \quad (2)$$

3. Skewness: O grau de distorção da distribuição dos pixels na imagem.

$$\bar{y} = \frac{X \times Y}{(X \times Y - 1)(X \times Y - 2)} \sum_{x=1}^X \sum_{y=1}^Y \frac{(I_{x,y} - \bar{y})^3}{\bar{y}^3}, \quad x = 1, \dots, X; y = 1, \dots, Y \quad (3)$$

4. Curtose: A medida da espessura ou peso de as caudas da distribuição dos pixels na imagem.

$$\bar{y} = \frac{n(n+1)}{(n-1)(X \times Y - 2)(n-3)} \sum_{x=1}^X \sum_{y=1}^Y \frac{(I_{x,y} - \bar{y})^4}{\bar{y}^4} - \frac{3(n-1)^2}{(n-2)(n-3)}, \quad x = 1, \dots, X; y = 1, \dots, Y; n = X \times Y \quad (4)$$

5. Valor do quartil inferior: o primeiro quartil do intervalo de intensidades dos pixels na imagem.

$$Q1 = (\text{Max} - \text{Min}) \times 0,25 \quad (5)$$

onde *Max* é o valor máximo das intensidades de pixel da imagem de couro e *Min* é o valor mínimo.

6. Valor do quartil superior: o terceiro quartil do intervalo de intensidades dos pixels na imagem.

$$Q3 = (\text{Max} - \text{Min}) \times 0,75 \quad (6)$$

Assim, haverá seis valores para representar um patch da imagem de couro. Em vez do original, os dados brutos de 160.000 (400 × 400), uma imagem agora pode ser representada usando 600 valores (ou seja, 6 valores × 100 patches). No entanto, deve-se notar que nem todos os tipos de recursos estatísticos são adequados para o classificador aprender, tanto na perspectiva da quantidade quanto da qualidade. Portanto, a seleção de características adequadas é realizada antes da etapa de classificação. Particularmente, aquelas características que têm maior influência na distribuição são consideradas propriedades significativas.

#### 4.4 Seleção de recursos

Como afirmado anteriormente, existem 6 características de distribuição a serem consideradas para seleção: média, variância, valor do quartil superior, valor do quartil inferior, inclinação e curtose. Para escolher qual característica é mais adequada para um dado conjunto de dados, uma série de procedimentos de seleção de características é proposta no Algoritmo 1.



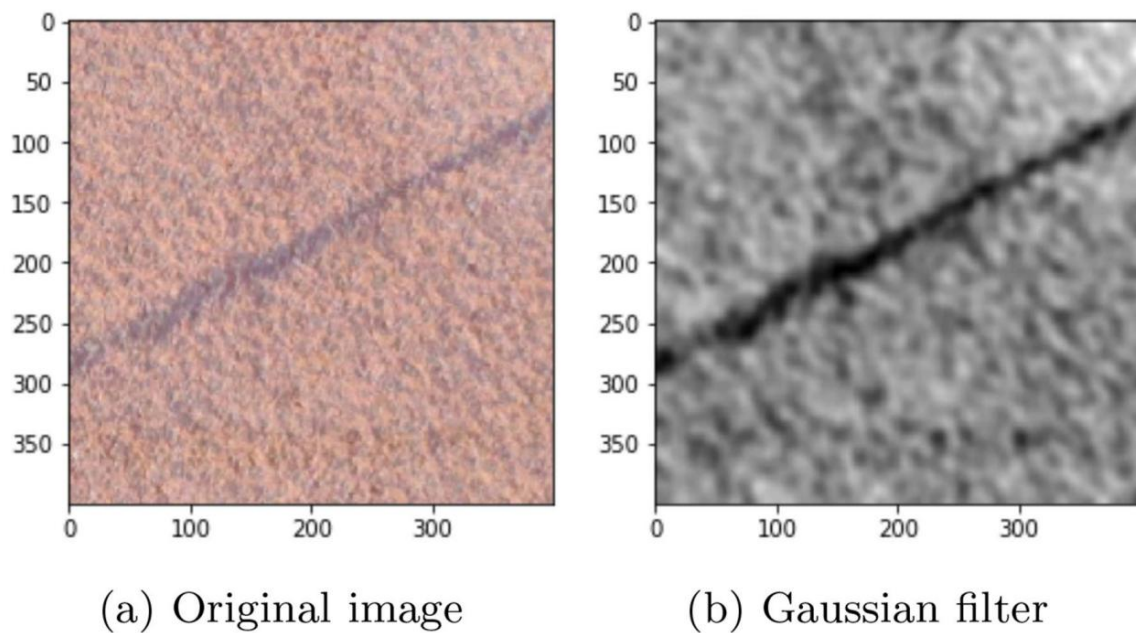


Fig. 6 Amostra de couro que é (a) antes e; (b) depois de realizar o processamento de imagem

---

### Algorithm 1 Feature Selection Process

---

```

1: for non-defect image, then defect image do
2:   for each section  $i$  in the image do
3:     calculate all 6 features of the pixel intensities in
       section  $i$ .
4:   end for
5: end for
6: for each feature  $f$  do
7:   perform the two-sample K-S test on the array of cal-
       culated feature  $f$  for the non-defect image, array of cal-
       culated feature  $f$  for the defect image.
8:   get  $pvalue$  of the test
9: end for
10: Select 3 features with the minimum  $pvalue$ 

```

---

Basicamente, o algoritmo usa o teste Kolmogorov Smirnov de 2 amostras para determinar quais recursos têm a maior influência. Uma amostra de imagens sem defeito e com defeito é escolhida, então a característica a ser comparada é computada a partir dos segmentos nas imagens, formando duas distribuições separadas: uma distribuição contendo a agregação da característica computada das imagens sem defeito, a outro contendo o

agregação do recurso computado das imagens do defeito.

As duas distribuições diferentes são submetidas ao teste de Kolmogorov de 2 amostras para determinar o grau de dissimilaridade das duas distribuições. Um valor  $p$  é retornado deste teste.

O algoritmo é repetido para cada uma das seis características, então as três características que retornam os valores- $p$  mais baixos são escolhidas como as características selecionadas.

O teste de Kolmogorov-Smirnov fornece uma ferramenta poderosa e não paramétrica para a análise estatística objetiva de seus dados de tograma (Conover 1965). O teste pode ser usado para testar se duas amostras de dados vêm da mesma distribuição.

Neste caso de duas amostras, a estatística Kolmogorov-Smirnov é definida como:

$$D_{n,m} = \sup_x |F_{1,n}(x) - F_{2,m}(x)|, \quad (7)$$

onde  $F_{1,n}$  e  $F_{2,m}$  são as funções de distribuição empíricas da primeira e da segunda amostra respectivamente, e  $\sup$  é a função suprema.

Para amostras grandes, a hipótese nula é rejeitada no nível  $\alpha$  se

$$D_{n,m} > c(\alpha) \sqrt{\frac{1}{n} + \frac{1}{m}}, \quad (8)$$

onde  $n$  e  $m$  são os tamanhos da primeira e segunda amostra, respectivamente. O valor de  $c(\alpha)$  é dado por:

$$c(\alpha) = \sqrt{-\ln \frac{\alpha}{2}} \quad (9)$$

#### 4.5 Redução da dimensionalidade do recurso

Quando as características foram extraídas de todos os segmentos, um valor representativo de cada característica é escolhido para representar a característica da imagem como um todo. Esse valor representativo deve ser capaz de revelar se a imagem contém defeitos ou não. Três métodos representativos foram examinados: limiar de percentil, modelo de mistura gaussiana (GMM) e agrupamento K-means:

1. O limiar de percentil é simplesmente calcular um valor de limiar seguindo a fórmula fornecida:

$$T = (Max - Min) \times 75\% + Min \quad (10)$$

onde  $Max$  e  $Min$  são o máximo e o mínimo

dos valores calculados de um recurso específico para cada segmento de uma imagem, respectivamente.

2. O algoritmo de agrupamento k-means é um algoritmo de aprendizado simples e adequado para identificar agrupamentos esféricos em dados. As vantagens do agrupamento k-means é que ele é rápido e eficiente, sendo razoavelmente preciso na identificação de agrupamentos nos dados. Neste método, os pontos do segmento foram divididos em 2 clusters (cluster normal e cluster outlier), então o valor representativo foi obtido tomando-se a diferença entre o valor máximo e o centróide do cluster principal.
3. O GMM é um modelo probabilístico que assume que todos os pontos de dados são gerados a partir de uma mistura de um número finito de distribuições gaussianas com parâmetros desconhecidos.

Concretamente, o GMM pode ser usado para agrupar dados não rotulados da mesma maneira que o k-means. A vantagem de usar o GMM sobre o clustering k-means é que ele pode lidar com clusters oblongos, enquanto o k-means funciona apenas em clusters circulares. O método do modelo de mistura gaussiana é semelhante ao método k-médias; Neste método, os pontos do segmento são divididos em 2 clusters (cluster normal e cluster outlier), então o valor representativo é obtido tomando-se a diferença entre o valor máximo e o centróide do cluster principal.

#### 4.6 Classificação

Agora que os recursos foram extraídos (3 recursos por imagem), esses recursos são colocados em um classificador. Vários classificadores amplamente conhecidos são selecionados, que são: SVM, kNN, árvore de decisão, classificador ensemble, regressão logística e Naive Bayes. As métricas de avaliação do modelo são então determinadas usando um 70/30 para a divisão de treinamento/teste (Liong et al. 2019a):

1. SVM (Burges 1998): Ele categoriza novos pontos de dados emitindo o hiperplano ótimo que classifica distintamente os pontos de dados.
2. Árvore de decisão (Fürnkranz 2010): Ela descreve todos os resultados possíveis em uma estrutura de árvore com raízes, nós e folhas. Os dados de entrada são classificados utilizando um conjunto de regras if-then.
3. NN (Cover e Hart 1967): Este é um algoritmo de aprendizado preguiçoso que determina a classe dos dados de entrada com base na votação majoritária de seus vizinhos mais próximos. A técnica NN mais comum é kNN.
4. Classificador de conjunto (Dietterich 2000): Gera vários classificadores de base e integra suas capacidades de discriminação combinando-os em um classificador novo e de melhor desempenho.
5. Naive Bayes (Rish et al. 5001): É uma classe probabilística inspirada no teorema de Bayes. As probabilidades são calculadas para cada fator e seleciona o resultado com maior probabilidade. Ele opera sob a suposição de que os atributos são condicionalmente independentes.
6. Regressão logística (Hosmer et al. 2013): Este classificador utiliza a equação de regressão linear para construir saídas binárias discretas. É um algoritmo simples e poderoso para muitos problemas de classificação de apenas duas classes.
7. Análise discriminante (Klecka et al. 1980): Este classificador modela a distribuição dos preditores separadamente em cada uma das classes de resposta e usa o teorema de Bayes para convertê-los em estimativas da probabilidade das classes de resposta. É útil para pequenos conjuntos de dados com preditores normais.

5 Métricas de desempenho

Seis métricas de desempenho são utilizadas para avaliar o desempenho do método proposto, a saber, especificidade, sensibilidade, precisão, F1-score, taxa de erro e acurácia. Essas métricas são definidas como:

Sensibilidade  $\tilde{y} = \frac{TP}{TP + FN},$  (11)

Especificidade  $\tilde{y} = \frac{TN}{TN + FP},$  (12)

Precisão  $\tilde{y} = \frac{TP}{TP + FP},$  (13)

F1-pontuação  $\tilde{y} = 2 \times \frac{\text{Precisão} \times \text{Especificidade}}{\text{Precisão} + \text{Especificidade}},$  (14)

Taxa de erro  $\tilde{y} = \frac{FP + FN}{TP + TN + FP + FN},$  (15)

Precisão  $\tilde{y} = \frac{TP + TN}{TP + FP + TN + FN}$  (16)

onde TP refere-se a verdadeiro positivo, onde uma imagem de defeito é corretamente identificada como contendo defeito. FP é o falso positivo, onde uma imagem sem defeito é erroneamente identificada como contendo defeitos. FN representa o falso negativo, onde uma imagem de defeito é erroneamente identificada como não contendo defeitos. TN é o verdadeiro negativo, onde uma imagem sem defeitos é corretamente identificada como não contendo defeitos.

6 Resultados e discussão

A Tabela 4 mostra os resultados de diferentes classificadores em ambos os conjuntos de dados. Para o Dataset I, as características selecionadas foram média, variância e intervalo de quartil inferior. O classificador Medium kNN e Cubic kNN apresentam os melhores resultados para precisão (99,16%), sensibilidade (100%) e taxa de erro (0,84%). Por outro lado, o classificador de análise discriminante linear e o classificador ensemble discriminante subespacial obtêm o melhor F1-score (100%). Em suma, o procedimento experimental realizado no Dataset I resultou em uma precisão média de 97,11% e F1-score de 97,39%.

Tabela 4 Métricas de desempenho de classificação (%) avaliadas em diferentes tipos de classificadores para o Dataset I

Classificador		Sensibilidade	Especificidade	Precisão	Pontuação F1	Taxa de erro	Precisão
Discriminar. Análise	Discriminante Linear	95	100	100	100	2,52	97,48
	Discriminante Quadrático	95	98,31	98,28	98,29	3,36	96,64
Conjunto	Árvores ensacadas	98,33	94,92	95,16	95,04	3,36	96,64
	Discriminante de Subespaço	95	100	100	100	2,52	97,48
KNN	Subespaço KNN	96,67	98,31	98,31	98,31	2,52	97,48
	KNN grosso	93,33	96,61	96,55	96,58	5,04	94,96
	KNN Médio	100	98,31	98,36	98,33	0,84	99,16
	KNN fino	95	88,14	89,06	88,6	8,4	91,6
	Cosseno KNN	93,33	98,31	98,25	98,28	4,2	95,8
	KNN Cúbico	100	98,31	98,36	98,33	0,84	99,16
	KNN ponderado	96,67	94,92	95,08	95	4,2	95,8
	Regressão Logística	96,67	98,31	98,31	98,31	2,52	97,48
	Bayas ingênuas	Gaussiano Naive Bayes	96,67	98,31	98,31	2,52	97,48
SVM	Kernel Naive Bayes	96,67	96,61	96,67	96,64	3,36	96,64
	SVM linear	98,33	98,31	98,33	98,32	1,68	98,32
Árvore de decisão	SVM quadrático	98,33	96,61	96,72	96,66	2,52	97,48
	SVM cúbico	96,67	98,31	98,31	98,31	2,52	97,48
	SVM gaussiana fina	98,33	96,61	96,72	96,66	2,52	97,48
	SVM Gaussiano Médio 98,33		98,31	98,33	98,32	1,68	98,32
	SVM Gaussiano Grosso	96,67	98,31	98,31	98,31	2,52	97,48
	Bela Árvore	98,33	96,61	96,72	96,66	2,52	97,48
	Árvore Média	98,33	96,61	96,72	96,66	2,52	97,48
Média	Árvore Grossa	96,67	100	100	100	1,68	98,32
		96,88	97,35	97,43	97,39	2,89	97,11

Tabela 5 Métricas de desempenho de classificação (%) avaliadas em diferentes tipos de classificadores para o Dataset II

Classificador		Sensibilidade	Especificidade	Precisão	Pontuação F1	Taxa de erro	Precisão
Discriminar. Análise	Discriminante Linear	32,91	96,9	83,87	89,92	24.12	75,88
	Discriminante Quadrático	36,71	95,98	81,69	88,26	23.49	76,51
Conjunto	Árvores ensacadas	39,87	89,16	64,29	74,71	27.03	72,97
	Discriminante de Subespaço	25,95	98,76	91.11	94,78	25.16	74,84
KNN	Subespaço KNN	37,97	81,73	50,42	62,37	32.64	67,36
	KNN grosso	23.42	98,14	86,05	91,7	26,4	73,6
	KNN Médio	34.18	94,43	75	83,6	25,36	74,64
	KNN fino	51,27	81,73	57,86	67,75	28,27	71,73
	Cosseno KNN	32,91	93.19	70,27	80.12	26,61	73,39
	KNN Cúbico	34,81	95,36	78,57	86,15	24,53	75,47
	KNN ponderado	44,94	89,47	67,62	77.03	25.16	74,84
	Regressão Logística	41.14	93.19	74,71	82,93	23,91	76,09
Baías ingênuas	Gaussiano Naive Bayes	39,24	95,67	81,58	88,06	22,87	77.13
	Kernel Naive Bayes	43,67	91,64	71,88	80,57	24.12	75,88
SVM	SVM linear	26,58	97,21	82,35	89,17	25,99	74.01
	SVM quadrático	29.11	97,21	83,64	89,92	25.16	74,84
	SVM cúbico	32,91	92,57	68,42	78,68	27.03	72,97
	SVM gaussiana fina	26,58	92,88	64,62	76,21	28,9	71.1
	SVM Gaussiano Médio 29.11		97,83	86,79	91,98	24,74	75,26
	SVM Gaussiano Grosso	22.15	99,38	94,59	96,93	25,99	74.01
Árvore de decisão	Bela Árvore	43,67	84,83	58,47	69,23	28,69	71,31
	Árvore Média	39,24	91,95	70,45	79,78	25,36	74,64
	Árvore Grossa	46,84	87,31	64,35	74,09	25,99	74.01
Média		35,44	92,89	74,29	82,35	25,98	74,02

Tabela 6 Matriz de confusão do sistema de classificação proposto na parte de teste do conjunto de dados I, que consiste em 119 imagens

		Previsto	
		Sem defeito	Tem defeito
Real	Sem defeito	60	1
	Tem defeito	0	58

Tabela 7 Matriz de confusão do sistema de classificação proposto na parte de teste do conjunto de dados II, que consiste em 481 imagens

		Previsto	
		Sem defeito	Tem defeito
Real	Sem defeito	62	14
	Tem defeito	96	309

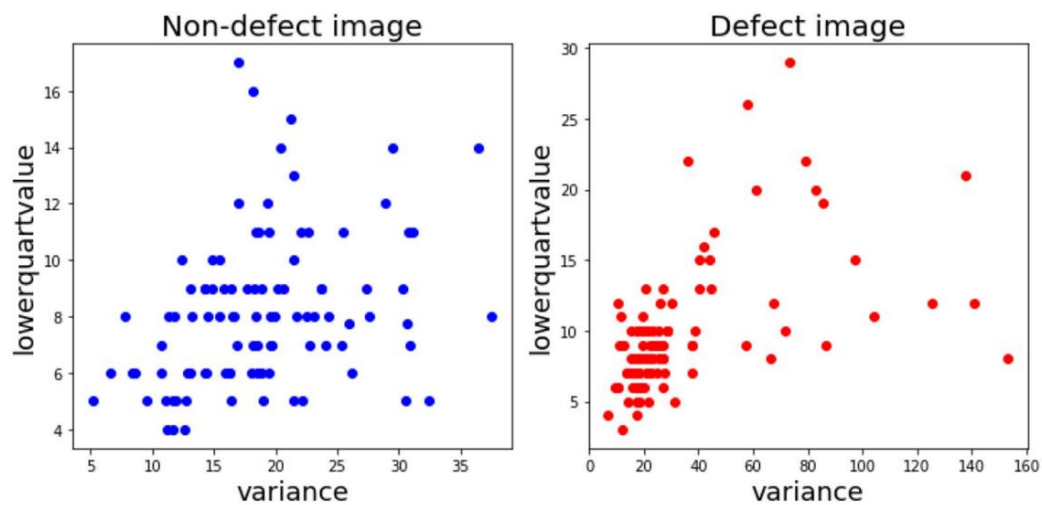
Para o Dataset II, as características selecionadas foram variância, média e assimetria. O classificador Gaussian Naive Bayes atinge a maior precisão de 77,13% e a menor taxa de erro de 22,87%. O F1-score para o classificador SVM Gaussiano grosseiro obtido é de 96,93%. Em geral, o classificador que apresenta os melhores resultados globais é o classificador gaussiano naive bayes. Para

Concluindo, o procedimento experimental realizado no Dataset II resultou em uma acurácia média de 74,02% e um F1-score médio de 82,35% (Tabela 5).


As matrizes de confusão mostradas nas Tabelas 6 e 7 ajudam a visualizar os resultados com mais clareza. Para o Dataset I, entre as 119 imagens, há apenas uma imagem (ou seja, imagem sem defeito) que foi classificada erroneamente. Por outro lado, o algoritmo não teve um desempenho tão bom no Dataset II. O número total de falsos negativos é relativamente alto, resultando em uma baixa sensibilidade. Mesmo assim, o alto total de verdadeiros negativos ajudou a aumentar a precisão para um valor razoável.

Para investigar a eficácia do método proposto, realizamos uma análise detalhada de algumas das etapas propostas. Por exemplo, a Fig. 7 mostra os gráficos de dispersão de características durante a terceira etapa do método proposto, a saber, extração de características estatísticas (etapa C na Seção 4). Especificamente, a Fig. 7a ilustra os gráficos de dispersão do valor do quartil inferior em relação à variância. Ele mostra uma diferença notável entre a distribuição de segmentos de uma imagem com defeito e uma imagem sem defeito, em que a maioria dos pontos no gráfico de dispersão da imagem com defeito são agrupados em direção ao gráfico inferior com vários pontos distantes do agrupamento (estes são os segmentos com defeito). Por outro lado, a Fig. 7b retrata os gráficos de dispersão para desvio em relação ao valor do quartil superior, onde





(a) Comparison of scatter plots of lower quartile value against variance for defect image and non-defect image



(b) Comparison of scatter plots of upper quartile value against skew for defect image and non-defect image


Fig. 7 Gráficos de dispersão de recursos para imagens com defeito e sem defeito

eles não mostram nenhuma diferença significativa entre a imagem não defeituosa e a defeituosa amostrada. Consequentemente, a variância e o valor do quartil inferior podem ser considerados como características úteis, enquanto o valor do quartil superior e a inclinação podem ser considerados como não significativos.


A seguir é feita a análise realizada na quinta etapa do método proposto, a saber, redução de características, que inclui as técnicas de: limiarização por percentil, agrupamento k-means e modelo de mistura gaussiana. As vantagens do método de limiar percentil é a sua simplicidade e eficácia. Uma imagem de defeito terá apenas uma ou duas seções com

defeitos (outliers na distribuição), portanto, é importante reconhecer esses outliers em nosso valor representativo. Este método de limiar de percentil efetivamente espalha o valor representativo muito mais baixo ou mais alto se um defeito estiver presente na imagem, como visto na Fig. 8. Em imagens sem defeito, o valor representativo está dentro do cluster principal, enquanto em imagens de defeito, os segmentos discrepantes farão com que o valor fora do cluster principal se torne mais esparsos.

O método de agrupamento k-means e o método GMM deram resultados semelhantes, como visto nas Figs. 9 e 10. Ambos eram razoavelmente hábeis em encontrar o centróide do cluster e




(a) non-defect image




(b) defect image

Fig. 8 Distribuição de recursos ao empregar limiar de percentil para redução de dimensionalidade



(a) non-defect image



(b) defect image

Fig. 9 Distribuição de recursos ao empregar agrupamento k-means para redução de dimensionalidade

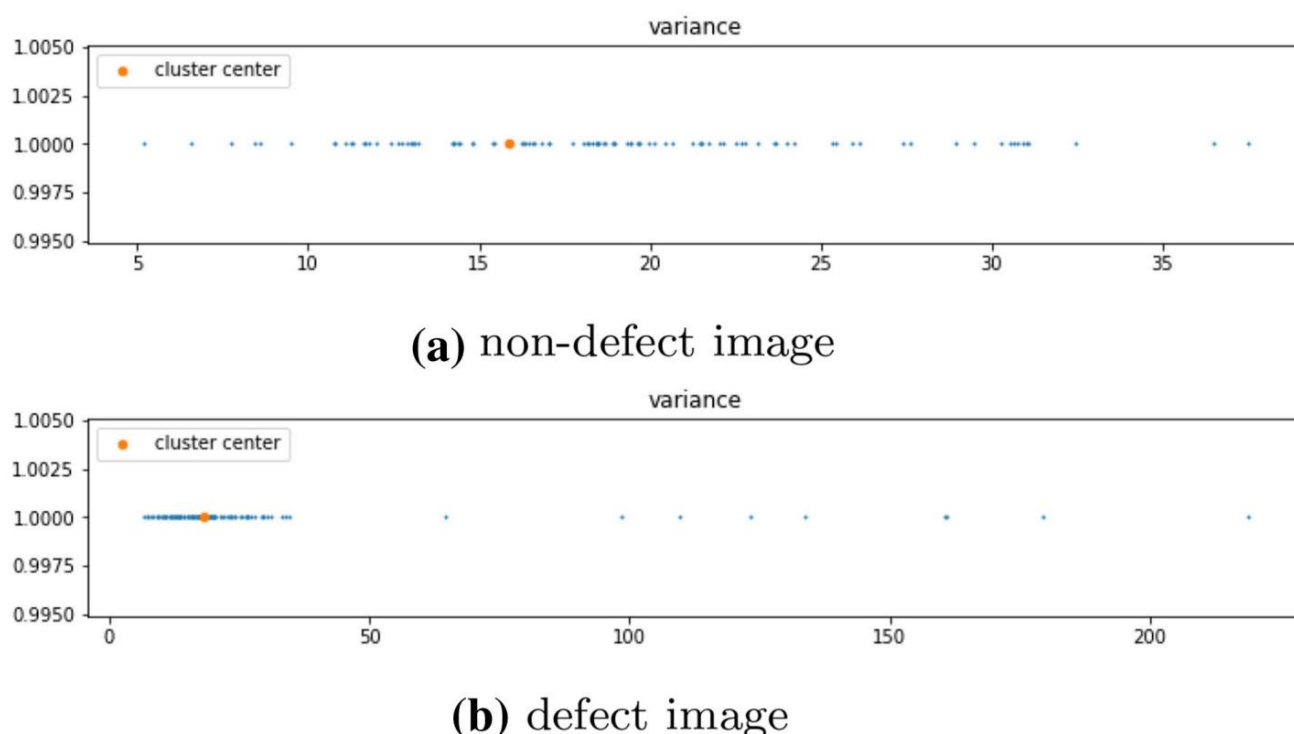


Fig. 10 Distribuição de recursos ao empregar o Modelo de Mistura Gaussiana para redução de dimensionalidade

Tabela 8 Comparação de desempenho com o estado da arte

	Método	Defeituoso: não defeituoso	Trem : Validação : Divisão de teste	Método	Precisão	Pontuação F1
Conjunto de dados I	(Liong et al. 2020)	300:75	80 : 0 : 20	AlexNet	94,67%	94,76%
	Nosso	199 : 199	70 : 0 : 30	Análise estatística + KNN	<b>99,16%</b>	<b>98,33%</b>
Conjunto de dados II	(Liong et al. 2019c)	370 : 1527	60 : 5 : 35	Artificial 80,30%		89,00%
	(Liong et al. 2019c)	233: 699	90 : 0 : 10	AlexNet	74,18%	84,03%
	Nosso	503: 1102	70 : 0 : 30	Análise estatística + SVM	<b>74,01%</b>	<b>96,93%</b>

<sup>1</sup> As imagens defeituosas incluem tanto a linha preta quanto os defeitos de rugas

obtendo assim um valor representativo útil. Para concluir os métodos de redução de características, todos os três métodos apresentaram precisões semelhantes, portanto, o método mais simples é preferível, que é o limiar percentual.

Para verificar a eficácia da abordagem proposta, uma comparação de desempenho é realizada para os conjuntos de dados I e II individualmente. Especificamente, as imagens usadas no conjunto de dados I são as mesmas de (Liong et al. 2020), exceto que elas realizaram a tarefa de uma classificação em três categorias, distinguindo uma imagem em defeito de linha preta, defeito de ruga, ou não defeituoso. No entanto, as imagens por categoria são menores em comparação com a do nosso experimento, ou seja, 125 linhas pretas, 125 rugas e 125 imagens sem defeitos. Para a divisão de treino/teste de 80/20, a precisão e o F1-score obtidos foram 94,67% e 94,76% na implementação

usando a arquitetura Alexnet como o descritor de recursos. A comparação de desempenho está resumida na Tabela 8.

Por outro lado, para o conjunto de dados II, o mesmo tipo de imagem defeituosa é usado em (Liong et al. 2019c). Observe que a divisão de treinamento/validação/teste foi de 60/ 5/ 35 com o número de imagem de 1138/ 95/ 664. A melhor precisão alcançada foi de 80,3% ao aplicar uma série de técnicas de pré-processamento antes de passar para uma rede neural artificial (ANN) com 50 neurônios ocultos. Além disso, Liong et al. (2019c) empregaram a arquitetura AlexNet para extrair o recurso e o resultado da classificação é um pouco menor. O detalhe da comparação é mostrado na Tabela 8. Nota-se que a acurácia superou os métodos propostos, mas não o F1-score. Isso ocorre porque há um problema de desequilíbrio de classe que existe no experimento (Liong et al. 2019c), pois imagens não defeituosas são cerca de 4

vezes mais do que a imagem defeituosa. Portanto, a maioria das imagens defeituosas classificadas erroneamente como não defeituosas uns.

## 7. Conclusão

Em poucas palavras, este artigo apresenta uma abordagem estatística baseada em histograma para realizar a detecção automatizada de defeitos em couro de vaca. Concretamente, as características comuns do histograma são propostas para serem usadas como características. Em seguida, um teste estatístico é utilizado e o teste de Kolmogorov-Smirnov é aplicado como etapa de seleção de atributos. Além disso, um método de limiarização simples, porém eficaz, é introduzido para realizar a redução da dimensionalidade das características extraídas. Como resultado, o algoritmo proposto tem baixa latência e produz resultados razoavelmente precisos, ou seja, precisão de 97,11% em um dos conjuntos de dados.

Trabalhos futuros incluem a incorporação de algoritmos de aprendizado de máquina para melhorar a robustez do modelo de classificação. Além disso, diferentes tipos de defeitos dentro da mesma superfície podem ser distinguidos. A segmentação de instância de vários defeitos pode ser implementada para identificar com precisão as áreas defeituosas.

**Agradecimentos** Este trabalho foi financiado pelo Ministério da Ciência e Tecnologia (MOST) (número de concessão: 109-2221-E-035-065-MY2, 108-2218-E-009-054-MY2, 108-2218-E-035-007-, 108-2218-E-227-002-).

## Referências

- Ahonen T, Hadid A, Pietikainen M (2006) Descrição de rosto com padrões binários locais: Aplicação ao reconhecimento de rosto. *IEEE Trans Padrão Mach Anal Intel* 12:2037–2041
- APLF (2018) Previsões - tamanho do mercado global de artigos de couro, previsões de demanda, tendências e atualizações do setor (2018–2025), <http://www.aplf.com/en-us/leather-fashion-news-and-blog/news/39758/forecasts-global-leather-goods-market-size-demand-forecasts-industry-trends-updates-2018-2025>
- Aslam M, Khan TM, Naqvi SS, Holmes G, Nafa R (2019) Sobre a aplicação de visão de máquina automatizada para inspeção e classificação de defeitos de couro: uma pesquisa. *Acesso IEEE* 7:176065–176086
- Aslam Y, Santhi N, Ramasamy N, Ramar K (2020) Localização e segmentação de trincas metálicas usando aprendizado profundo. *J Ambiente Intell Humaniz Comput*. <https://doi.org/10.1007/s12652-020-01803-8>
- Blum A (2018) Por que a análise de imagens pode criar um avanço na automação de fabricação, <https://www.b2bnn.com/2018/08/por-que-a-analise-de-imagem-poderia-criar-um-avanco-na-fabricacao-ing-automacao>
- Bong HQ, Truong QB, Nguyen HC, Nguyen MT (2018) Sistema de inspeção baseado em visão para detecção e classificação de defeitos na superfície do couro, Em: 2018 5ª Conferência NAFOSTED sobre Informação e Ciência da Computação (NICS), IEEE, pp. 300–304
- Burges CJ (1998) Um tutorial sobre máquinas vetoriais de suporte para reconhecimento de padrões. *Data Min Knowl Discov* 2(2):121–167
- Conover WJ (1965) Vários testes kolmogorov-smirnov de amostras k. *Ann Math Stat* 36(3): 1019–1026. <http://www.jstor.org/stable/2238210>
- Cover T, Hart P (1967) Classificação do padrão do vizinho mais próximo. *IEEE Trans Inf Theor* 13(1):21–27
- de Souza Júnior AH, Corona F, Barreto GA, Miche Y, Lendasse A (2015) Minimal learning machine: a new supervised distance based approach for regression and classification. *Neurocomputação* 164:34–44
- Dietterich TG (2000) Métodos de conjunto em aprendizado de máquina, In: Workshop internacional sobre sistemas de classificação múltipla, Springer, pp. 1–15
- Fürnkranz J (2010) *Árvore de Decisão*. Springer, Boston, pp 263–267
- Georgieva L, Krastev K, Angelov N (2003) Identificação de defeitos de superfície do couro, In: *CompSysTech*, Vol. 3, CiteSeer, pp. 303–307
- Haralick RM, Shanmugam K, Dinstein IH (1973) Características texturais para classificação de imagens. *IEEE Trans Syst Man Cybern* 6:610–621
- Ele FQ, Wang W, Chen ZC (2006) Inspeção visual automática para fabricação de couro, In: *Key Engineering Materials*, Vol. 326, Trans Tech Publ, pp. 469–472
- Holland JH et al (1992) Adaptação em sistemas naturais e artificiais: uma análise introdutória com aplicações em biologia, controle e inteligência artificial. Imprensa do MIT, Cambridge
- Hu DW Jr, Lemeshow S, Sturdivant RX (2013) *Logística aplicada regressão*, vol 398. Wiley, Hoboken
- Hu GH (2015) Detecção automatizada de defeitos em superfícies texturizadas usando filtros gabor elípticos ideais. *Optik* 126(14):1331–1340
- Huang G, Liu Z, Van Der Maaten L, Weinberger KQ (2017) Redes convolucionais densamente conectadas, In: *Anais da conferência IEEE sobre visão computacional e reconhecimento de padrões*, pp. 4700–4708
- Jian L, Wei H, Bin H (2010) Pesquisa sobre inspeção e classificação de defeitos de superfície de couro com base em rede neural e árvore de decisão, In: 2010 International Conference On Computer Design and Applications, Vol. 2, IEEE, pp. V2-381
- Kasi MK, Rao JB, Sahu VK (2014) Identificação de defeitos de couro usando um algoritmo de processamento de imagem de detecção de borda autoadaptável, In: 2014 International Conference on High Performance Computing and Applications (ICHPCA), IEEE, pp. 1–4
- Klecka WR, Iversen GR, Klecka WR (1980) *Análise discriminante*, vol 19. Sage, Thousand Oaks
- Krizhevsky A, Sutskever I, Hinton GE (2012) Classificação de Imagenet com redes neurais convolucionais profundas, In: *Advances in neural information processing systems*, pp. 1097–1105
- Kwak C, Ventura JA, Tofang-Sazi K (2001) Inspeção automatizada de defeitos e classificação de tecidos de couro. *Intell Data Anal* 5(4):355–370
- Lin M, Chen Q, Yan S (2013) 'Network in network', pré-impressão [arXiv:1312.4400](https://arxiv.org/abs/1312.4400)
- Liong ST, Zheng D, Huang YC, Gan Y (2020) Classificação e segmentação de defeitos de couro usando arquitetura de aprendizado profundo, *Int J Comput Integr Manuf*, pp. 1–13
- Liong S, Gan YS, Huang Y, Liu K, Yau W (2019) Rede neural integrada e abordagem de visão de máquina para classificação de defeitos de couro, *CoRR* [arXiv:1905.11731](https://arxiv.org/abs/1905.11731)
- Liong S, Gan YS, Huang Y, Yuan C, Chang H (2019) Segmentação automática de defeitos em couro com aprendizado profundo, *CoRR* [arXiv:1903.12139](https://arxiv.org/abs/1903.12139)
- Liong S, Gan YS, Liu K, Binh TQ, Le CT, Wu C, Yang C, Huang Y (2019) Abordagens de rede neural eficientes para classificação de defeitos de couro, *CoRR* [arXiv:1906.06446](https://arxiv.org/abs/1906.06446)
- Mohanaiah P, Sathyanarayana P, GuruKumar L (2013) Extração de recursos de textura de imagem usando a abordagem GLCM. *Int J Sci Res Publ* 3(5):1
- Pereira R, Dias M, Medeiros C, Filho PP (2018) Classificação de falhas em amostras de couro de cabra usando visão computacional e aprendizado de máquina
- Rajagopalan N, Narasimhan V, Vinjimoor SK, Aiyer J (2020) Estrutura profunda de cnn para diagnóstico de doenças da retina usando imagens de tomografia de coerência óptica, *J Ambient Intell Humaniz Comput*, pp. 1–12



- Rish I et al (2001) Um estudo empírico do classificador naive bayes, In: IJCAI 2001 workshop sobre métodos empíricos em inteligência artificial, Vol. 3, págs. 41–46
- San-Payo G, Ferreira JC, Santos P, Martins AL (2019) Machine learning para sistema de controle de qualidade. J Ambiente Intell Humaniz Comput. <https://doi.org/10.1007/s12652-019-01640-4>
- Simonyan K, Zisserman A (2014) Redes convolucionais muito profundas para reconhecimento de imagem em larga escala, pré -impressão [arXiv arXiv:1409.1556](https://arxiv.org/abs/1409.1556)
- Sundari K (2017) Uma pesquisa sobre as abordagens usadas para detecção de defeitos em superfícies de couro usando processamento de imagem. Int J Tendências Recentes Eng Res 3:374–379
- Szegedy C, Iofe S, Vanhoucke V, Alemi AA (2017) Inception-v4, inception-resnet e o impacto das conexões residuais na aprendizagem, In: Trigesima Primeira Conferência AAAI sobre Inteligência Artificial
- Szegedy C, Liu W, Jia Y, Sermanet P, Reed S, Anguelov D, Erhan D, Vanhoucke V, Rabinovich A (2015) Aprofundando com convoluções, In: Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 1–9
- Tecnologia S (2020) Acreditação de classificação de couro Satra, <https://www.satrapara.com.br/bulletin/article.php?id=1906>
- Villar P, Mora M, Gonzalez P (2011) Uma nova abordagem para segmentação de defeitos de couro wet blue, In: Congresso Iberoamericano de Reconhecimento de Padrões, Springer, pp. 591–598
- Xie X, Ge S, Xie M, Hu F, Jiang N, Cai T, Li B (2018) Algoritmo de correspondência de imagens de defeitos na superfície laranja do umbigo com base em sensoriamento comprimido. J Ambiente Intell Humaniz Comput. <https://doi.org/10.1007/s12652-018-0833-0>
- Zavala-Mondragon LA, Lamichhane B, Zhang L, de Haan G (2019) Cnn-skelpose: um algoritmo de estimativa de esqueleto baseado em cnn para aplicações clínicas. J Ambiente Intell Humaniz Comput, pp. 1–12

**Nota do editor** Springer Nature permanece neutro em relação a reivindicações jurisdicionais em mapas publicados e afiliações institucionais.