

## Artigo de Pesquisa

## Sistema de Classificação Automatizado para Defeito de Carrapato em Couro

YS Gan, <sup>1</sup> Wei-Chuen Yau, <sup>2</sup> Sze-Teng Liong, <sup>3</sup> e Chih-Cheng Chen <sup>4,5</sup><sup>1</sup>Escola de Arquitetura, Universidade Feng Chia, Taichung 407, Taiwan<sup>2</sup>Escola de Computação e Ciência de Dados, Xiamen University Malaysia, Jalan Sunsuria, Bandar Sunsuria, 43900 Sepang, Selangor Darul Ehsan, Malásia<sup>3</sup>Departamento de Engenharia Eletrônica, Universidade Feng Chia, Taichung 40724, Taiwan<sup>4</sup>Departamento de Engenharia de Controle Automático, Universidade Feng Chia, Taichung 40724, Taiwan<sup>5</sup>Departamento de Engenharia Aeronáutica, Universidade de Tecnologia de Chaoyang, Taichung 413, TaiwanA correspondência deve ser endereçada a Sze-Teng Liong; [stliong@fcu.edu.tw](mailto:stliong@fcu.edu.tw) e Chih-Cheng Chen; [ccc@gm.cyut.edu.tw](mailto:ccc@gm.cyut.edu.tw)

Recebido em 4 de fevereiro de 2021; Revisado em 5 de abril de 2021; Aceito em 25 de agosto de 2021; Publicado em 16 de fevereiro de 2022

Editor Acadêmico: Teen-Hang Meen

Copyright © 2022 YS Gan et al. .is é um artigo de acesso aberto distribuído sob a Licença Creative Commons Attribution, que permite uso, distribuição e reprodução irrestritos em qualquer meio, desde que o trabalho original seja devidamente citado.

O couro natural é um material durável, respirável, elástico e flexível que vem em vários estilos, cores, acabamentos e preços. É uma matéria-prima ideal para fabricar produtos de luxo como sapatos, vestidos e malas. O couro será categorizado em diferentes graus que são determinados pela aparência visual, maciez e defeitos naturais. .este processo de classificação requer uma inspeção visual manual de especialistas experientes para garantir a garantia e o controle de qualidade adequados. Para facilitar o processo de inspeção, este artigo apresenta uma estrutura de classificação automatizada de defeitos eficiente que é capaz de avaliar se os patches de amostra contêm segmentos defeituosos. Um procedimento de pré-processamento de seis etapas é introduzido para melhorar a qualidade da imagem do couro em termos de visibilidade e preservar a representação de características importantes. .pt, vários classificadores são utilizados para diferenciar entre remendos de couro defeituosos e não defeituosos. O framework proposto é capaz de gerar uma taxa de precisão de classificação de 94% a partir de uma coleção de amostras de 1600 peças de retalhos de couro de bezerro.

## 1. Introdução

O couro é a matéria-prima mais popular feita a partir de peles de animais (ou seja, vaca, cordeiro, veado, alce, porco, etc.) torná-lo desejável para vários tipos de produtos. No entanto, cada peça de couro vem com algumas imperfeições que podem resultar na superfície do grão ou na estrutura de uma pele. A aparência feia comum existente em superfícies de couro natural incluem cicatrizes, cortes esfolados, vaidade e coloração irregular. A aparência da superfície de uma peça de couro é um indicador importante para determinar sua classificação e, portanto, afetar o preço de venda. Até hoje, o método convencional de inspeção manual da qualidade das peças de couro ainda é adotado no processo de fabricação industrial.

Resumidamente, os procedimentos básicos para converter as peles cruas de animais em couro são os seguintes: (1) Imersão: para remover a sujeira e os sais de cura por imersão do couro em água por várias horas a vários dias; (2) calagem: para remover o

epiderme, cabelo e materiais subcutâneos; (3) curtimento: para criar as ligações cruzadas de proteínas no colágeno, penetrando os produtos químicos nas peles; (4) secagem: para eliminar o excesso de água; e (5) tingimento: para produzir a cor personalizada desejada. Alguns dos defeitos naturais são imperceptíveis antes do processo de curtimento e gradualmente aparecem durante o processo de acabamento do couro. Por outro lado, as áreas defeituosas com danos menores serão reparadas e lixadas com enchimentos para criar uma superfície lisa e uniforme. Por fim, as peças de couro de acabamento serão classificadas antes do envio ao cliente.

.o processo de classificação é um dos procedimentos mais críticos e exaustivos, pois envolve uma avaliação manual para inspecionar visualmente as partes defeituosas do couro. Particularmente, o tipo de defeito (ou seja, cortes, rugas e sarna), o tamanho do defeito e o nível de gravidade (ou seja, crítico, maior, menor ou trivial) são os principais aspectos do controle de qualidade. .e os inspetores exigem a realização de uma avaliação manual completa na mesma peça de couro várias

vezes, visualizando de vários ângulos, distâncias e condições de iluminação para garantir a exatidão e integridade.

No entanto, deve-se notar que cada julgamento é subjetivo, pois depende muito do indivíduo. .us, a inspeção humana é cara, demorada, ineficiente e inconsistente. Pode ser propenso a erros ou erros humanos devido a essa tarefa chata e repetitiva, ou quando o trabalho está estressado e correndo para concluir a tarefa. .portanto, é vital projetar um sistema automático de inspeção de defeitos de couro para melhorar os processos de classificação e inspeção, enquanto cortando custos desnecessários. O objetivo final deste artigo é classificar a amostra de couro em classes defeituosas e não defeituosas. Em resumo, as quatro principais contribuições deste trabalho de pesquisa são resumidas da seguinte forma:

- (1) Proposta de seis etapas de pré-processamento e classificador XBoost ANN para categorizar o remendo de couro defeituoso
- (2) Verificação da robustez do algoritmo proposto validando-os em vários classificadores distintos de aprendizado de máquina
- (3) Avaliação experimental abrangente e análise comparativa são realizadas em mais de 1600 imagens de couro
- (4) Demonstração dos resultados promissores da classificação, relatando os resultados qualitativos e quantitativos

.as seções subsequentes do artigo estão organizadas da seguinte forma. Uma revisão da literatura relacionada é apresentada na Seção 2. .en, a Seção 3 descreve a estrutura proposta em detalhes, que inclui a intuição e explicação das principais técnicas de processamento de imagem exploradas. as métricas e a configuração dos parâmetros no experimento são apresentadas na Seção 4. O desempenho da classificação é apresentado e discutido na Seção 5 com análises adicionais. Por fim, a conclusão é apresentada na Seção 6, acompanhada de recomendações metodológicas para pesquisas futuras.

## 2. Revisão da Literatura

Até o momento, a literatura que realizou as tarefas automáticas de classificação ou segmentação das peças de couro ainda é limitada [1–3]. Além disso, os dados experimentais são variados e, portanto, é difícil fazer um teste justo de desempenho para verificar a eficácia dos métodos propostos. Por exemplo, a referência [4] coleta o conjunto de dados do remendo de couro usando um braço robótico de modo que cada imagem seja capturada sob uma fonte de iluminação consistente, mesmo ângulo de visão e distância. No total, o conjunto de dados contém 584 imagens. .pt, uma série de procedimentos são introduzidos para localizar os defeitos de picada de carrapato em remendos de couro. De forma sucinta, um algoritmo de segmentação, a saber, Rede Neural Convolutacional Baseada em Região de Máscara (Máscara R-CNN) é adotado para aprender as características locais de 84 imagens defeituosas. Como resultado, uma precisão de classificação de  $\sim 70\%$  é obtida quando avaliada em 500 imagens de teste.

Mais tarde, a referência [5] emprega o mesmo processo de obtenção de dados para coletar uma peça diferente de couro de bezerro. Em resumo, 27

as imagens são coletadas e cada peça é dividida em 24 pequenos fragmentos. .us, no total, 648 imagens são usadas no experimento. Diferente da referência [4, 5] conduz tanto os processos de classificação quanto de segmentação para prever dois tipos de defeitos, a saber, linhas pretas e ruga. Uma técnica de aprendizado de transferência é adotada para ajustar os parâmetros na arquitetura AlexNet para a tarefa de classificação, enquanto a arquitetura UNet é empregada para a tarefa de segmentação. Como resultado, o desempenho de classificação alcançado é de 95% e a tarefa de segmentação obteve uma taxa de Interseção sobre União próxima a 100%. No entanto, deve-se notar que os defeitos de linha preta e ruga são relativamente óbvios e ocupam uma região maior. .us, um resultado de classificação razoavelmente mais alto pode ser alcançado.

A referência [6] projeta uma abordagem estatística baseada na intensidade da imagem para lidar com a tarefa de classificação para ambos os conjuntos de dados divulgados pelas referências [4, 5]. Resumidamente, este trabalho adota operações estatísticas simples como média, variância, variância, assimetria, curtose, valores do quartil inferior e superior. .en um método de seleção de características do teste Kolmogorov–Smirnov de 2 amostras é explorado para determinar características significativas. .en, três métodos são aplicados para eliminar recursos redundantes: limiar de percentil, modelo de mistura gaussiana (GMM) e agrupamento de K-means.

Por fim, sete tipos de classificadores são adotados para diferenciar entre os remendos de couro defeituosos e não defeituosos. .a melhor precisão de classificação gerada é de 99% e 77% em dois conjuntos de dados diferentes (ou seja, [4, 5]), respectivamente. Em suma, este artigo supera com sucesso a referência [4] em 7%, ao mesmo tempo em que obtém um desempenho comparável com a referência [5].

Por outro lado, métodos convencionais como extração e redução de características são adotados para tarefas de detecção de defeitos de couro em que métodos de aprendizado profundo não são aplicados. Por exemplo, a referência [7] utiliza a técnica de redução de feições FisherFace para projetar as feições locais das imagens de couro de um espaço de imagem de alta dimensão para um espaço de feições de menor dimensão, a fim de distinguir efetivamente as classes alvo. Concisamente, o tamanho do recurso de cada amostra de imagem foi reduzido de 4202 para 160. Os recursos extraídos incluem os atributos de detalhes de cor, histogramas da cor, matriz de co-ocorrência, filtros Gabor e os pixels originais. Para validar a eficácia do método proposto, o experimento foi testado em 2.000 amostras compostas por sete classes defeituosas. .en, três tipos de classificadores são empregados para prever o tipo defeituoso. .as melhores precisões de classificação obtidas são  $\sim 88\%$  para wet blue e  $\sim 92\%$  para imagens de couro cru.

Por outro lado, uma tarefa de classificação de tipo de couro foi realizada pela referência [8] que avaliou 1000 imagens de amostras de couro para diferenciar entre lagarto monitor, crocodilo, ovelha, cabra e vaca. Apesar de cada tipo de couro poder conter amostras com cores diferentes, o método proposto é capaz de distinguir a textura e as características de cada tipo de couro. .us, uma precisão de classificação de 99,9% foi alcançada com a adoção da arquitetura AlexNet pré-treinada. No entanto, nenhuma inspeção de defeitos ou tarefa de classificação de defeitos está envolvida no experimento.

Com base na discussão acima, os trabalhos de pesquisa realizados até agora são manejavelmente finitos. Inspirado por

referência [4, 6], este artigo visa melhorar o desempenho da classificação através da introdução de uma solução simples, mas eficaz. Particularmente, o tipo de classe de defeito nesta tarefa de classificação é estritamente limitado apenas à picada de carrapato. Resumidamente, seis etapas de pré-processamento são aplicadas para melhorar as imagens e extrair as informações locais das manchas de couro. Em seguida, os conjuntos de recursos são alimentados em vários modelos classificadores de duas classes independentemente, expondo os relacionamentos entre os recursos codificados, a fim de gerar rótulos previstos correspondentes. Os classificadores envolvidos no experimento aqui incluem árvore de decisão, SVM, k-NN, Rede Neural Artificial (ANN), XBoost ANN e outros que são empregados para categorizar os dados de teste.

### 3. Método proposto

Existem dois grandes passos propostos no algoritmo, a saber, o pré-processamento e a classificação. O fluxograma do processo é mostrado na Figura 1. Concisamente, as imagens são primeiro passadas para uma série de etapas de pré-processamento, como correspondência de histograma, redimensionamento, escala de cinza, detecção de borda de Canny, desfoque gaussiano e histograma de gradiente. Por outro lado, a tarefa de classificação emprega classificadores supervisionados de última geração, como árvore de decisão [9], análise discriminante [10], SVM [11], k-Nearest Neighbor (NN) [12], Rede Neural Artificial (RNA), Rede Neural Artificial XBoost, entre outros.

Os detalhes de derivações matemáticas dos métodos de pré-processamento e classificadores acima mencionados são elaborados na Seção 3.1 e Seção 3.2, respectivamente.

**3.1. Procedimento de pré-processamento.** As seis técnicas de pré-processamento empregadas no experimento são mostradas na Figura 2 e cada etapa é descrita a seguir. Além disso, imagens de amostra são mostradas na Figura 3 para ilustrar o efeito em cada etapa de pré-processamento.

Etapa 1. Correspondência de Histograma

As imagens são realizadas uma correspondência de histograma com a imagem do template de verdade para padronizar a nova imagem de modo a eliminar a diferença de brilho ou contração devido à situação ambiental. A ideia é mapear a função de densidade de probabilidade  $Pr(r)$  da imagem original na saída desejada  $Pz(z)$ , onde  $z$  são valores de intensidade de espaços de cores como HSV/HLS, YUV e YCbCr. O mapeamento é construído encontrando as melhores correspondências  $Pz(z)$  para cada entrada em  $Pr(r)$  tal que satisfaça a seguinte equação:

$$Pr(r) \approx Pz(z) \approx \text{vison } Pr(r) \approx Pz(k). \quad (1)$$

#### Passo 2.

**Redimensionamento** A imagem é então redimensionada de  $400 \times 400$  para  $100 \times 100$ . O passo de downsampling é minimizar a complexidade computacional; enquanto isso, a velocidade de execução é aumentada. Além disso, reduz o ruído de fundo.

Etapa 3. Escala de cinza

A imagem é convertida de cor em uma imagem em tons de cinza. Pode minimizar a redundância e a dimensionalidade; assim, os requisitos computacionais também são reduzidos.

#### Etapa 4. Filtro Gaussiano

Um desfoque Gaussiano é aplicado para suavizar a área de fundo e a área defeituosa. O desfoque gaussiano transforma cada pixel na imagem para produzir valores de pixel normalmente distribuídos por seu vizinho local por meio de uma função matemática definida da seguinte forma:

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}, \quad (2)$$

onde  $x$  é a distância do centro ao eixo horizontal,  $y$  é a distância do centro ao eixo vertical e  $\sigma$  é o desvio padrão da distribuição gaussiana. Os valores desta distribuição são usados para construir uma matriz de convolução que é aplicada à imagem original. Além disso, usando um tamanho de filtro adequado, produzirá mais intensidade de vulnerabilidade de novas imagens. Se as áreas de uma imagem forem iguais, ela gerará uma intensidade semelhante. Assim, aumenta o efeito discriminante das áreas defeituosas.

#### Etapa 5. Detecção de Borda

**Canny:** Até esta etapa, as áreas defeituosas e não defeituosas devem ser mais fáceis de diferenciar. A imagem é então aprimorada focando na diferença de gradiente na intensidade das imagens. De forma sucinta, o processo do algoritmo de detecção de bordas Canny pode ser implementado usando estas cinco etapas:

- (i) Um filtro Gaussiano é adotado para remover o ruído da imagem e suprimir as informações sem sentido.
- (ii) Os gradientes de intensidade da imagem são obtidos aplicando-se os operadores detectores de borda como Sobel, Prewitt e Robert. (iii) Uma supressão não máxima é empregada para eliminar a resposta espúria, como picos ou ruídos.

- (iv) Os valores de limite inferior e superior são especificados para identificar possíveis arestas.
- (v) As arestas são rastreadas por histerese, onde as arestas fracas que não estão conectadas às arestas fortes são minimizadas.

O experimento realizado neste artigo considera o operador de Sobel. Ele aplica a convolução na imagem com um filtro separável, inteiro e de valor pequeno nas direções horizontal/vertical. Particularmente, o operador Sobel aproxima o gradiente da imagem aplicando convolução na imagem com um kernel separável nas direções horizontal ou vertical. Em geral, kernels  $3 \times 3$  são usados na aproximação derivada horizontal e vertical que são denotados como  $G_x$  e  $G_y$ , respectivamente:

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad G_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \quad (3)$$

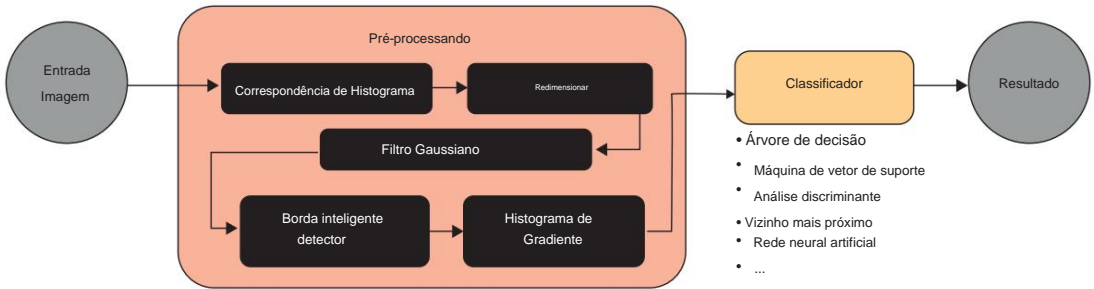


Figura 1: .e sistema de classificação de defeitos de picada de carrapato proposto.




Figura 2: .e exemplo de aplicação das etapas dos métodos de pré-processamento: (a) imagem original; (b) correspondência de histogramas; (c) redimensionamento; (d) tons de cinza; (e) Desfoque gaussiano; (f) Detecção de borda inteligente; e (g) histograma de gradiente.




Figura 3: Imagens de amostra de couro que contém (a) defeito e (b) nenhum defeito.

Em cada ponto de amostra regularmente espaçado, o gradiente aproximações podem ser derivadas e representadas para o magnitude do gradiente ( $\tilde{y}$ ) e direção do gradiente ( $\tilde{y}$ ):

$$\tilde{y} = \sqrt{G_x^2 + G_y^2} \quad (4)$$

$$\tilde{y} = \tan^{-1} \frac{G_y}{G_x} \quad (5)$$

Etapas 6. Histograma de Gradiente

.e O detector de bordas Canny no Passo 5 retorna um binário imagem. É então dividido em  $8 \times 8$  pixels por célula para calcular a histograma de gradiente das imagens binárias. .is revela o gradiente de histograma de frequência da orientação das bordas em cada patch local, especialmente para as áreas defeituosas. Com um grade uniforme de células, HOG resume os gradientes de intensidade com base em suas respectivas direções para derivar o local recursos de aparência que descrevem as informações de foco de a imagem correspondente. .en, o histograma do gradiente direções dentro das células conectadas é concatenada de tal forma que um vetor de características resultante enriquecido é construído. Devido às vantagens do descritor HOG, como rapidez



velocidade de computação e eficácia na codificação das informações de forma local, é um dos extratores de características que tem sido amplamente adotado na comunidade de pesquisa. Especificamente, os passos para realizar o algoritmo HOG são os seguintes.

3.1.1. Geração de Imagem Gradiente. O método de filtragem de imagem pode ser aplicado utilizando os kernels que contêm os kernels horizontal e vertical, a saber, janela deslizante  $\begin{bmatrix} 1 & 0 & 1 \end{bmatrix}$  e  $\begin{bmatrix} 1 & 1 & 0 \end{bmatrix}$ . Concisamente, o kernel convoluta com a imagem original da equação (4) para obter os mapas de orientação e magnitude pixel a pixel. Como resultado, as regiões com intensidade de cor constante e semelhante são eliminadas da imagem; enquanto isso, os contornos ou bordas importantes são mantidos sem alterações.

3.1.2. Computação HOG em células  $m \times n$ . Cada imagem é particionada em  $m \times n$  células de modo que uma representação de características mais compacta possa ser construída. Usando um histograma de 9 compartimentos que se enquadra na faixa de ângulos de  $0, 20, 40, 60, \dots, 180$  é calculado.

3.1.3. Normalização dos Blocos da Célula. A magnitude calculada pode ser vulnerável e sensível a mudanças na iluminação. Portanto, uma simples operação de normalização é implementada localmente para cada bloco. Finalmente, o vetor de características resultante é enriquecido pela concatenação de todos os histogramas.

3.2. Classificador. A subseção descreve brevemente as características dos classificadores. Concretamente, tanto as funções dos classificadores convencionais (ou seja, árvore de decisão, SVM, NN, análise discriminante, etc.) quanto as da RNA são apresentadas nas Subseções 3.2.1 e 3.2.2.

3.2.1. Classificador convencional. Depois de obter os vetores de características dos descritores de características discutidos na seção anterior, eles são então processados pelos classificadores para distinguir o status defeituoso. Alguns classificadores amplamente conhecidos que estão disponíveis no Pacote Sklearn são utilizados, a saber, árvore de decisão, SVM, NN e classificador de ensemble. Observe que os classificadores adotados aqui são uma abordagem de aprendizado de máquina supervisionado:

- (1) k-Nearest Neighbor (k-NN) [12]: este é um dos classificadores mais simples, pois é fácil de implementar e não requer tempo de treinamento. O resultado previsto é identificado com base no sistema de votação por maioria simples e na determinação do número de vizinhos mais próximos.
- (2) Support Vector Classification (SVC) [13]: pode ser utilizado tanto para a classificação quanto para a análise de regressão. Envolve pelo menos uma escala quadrática com o número de amostras.
- (3) Linear Support Vector Machine (SVM) [11]: um kernel linear é utilizado para projetar os dados de entrada para um

espaço dimensional. O processo de transformação de dados encontra um limite ideal entre os possíveis resultados.

- (4) Árvore de decisão [9]: constrói um modelo de classificação adotando regras de decisão simples. Um modelo estruturado em árvore é criado delineando todas as possíveis consequências. Em resumo, a árvore de decisão consiste na raiz, nós, ramos e folhas. A resposta prevista é gerada seguindo a decisão do nó raiz até o nó folha.
- (5) Floresta aleatória [14]: é uma coleção de estimador de árvore simples que processa várias subamostras do conjunto de dados e obtém os valores médios para aumentar a precisão da classificação e evitar o sobreajuste.
- (6) Multilayer perceptron (MLP) [15]: compõe três camadas básicas, a saber, as camadas de entrada, oculta e de saída. Cada camada pode conter um número diferente de neurônio. Especificamente, os neurônios na camada de entrada dependem da dimensão dos dados de entrada. O número de neurônios na camada oculta é subjetivo, pois depende da complexidade da função e das propriedades de atributo das classes alvo. Finalmente, o número de neurônios na camada de saída é o número de classes de saída.
- (7) Adaptive Boosting (AdaBoost) [16]: é um meta estimador que aprende um único "classificador forte" de vários classificadores "fracos". Ela produz um conjunto de características ótimas que consideram o fator de pesos antes da combinação dos classificadores.
- (8) Análise discriminante [10]: tem um limite de decisão quadrático para desenvolver funções discriminantes para examinar a diferença entre as variáveis preditoras.
- (9) Extreme gradient boosting [17]: treina muitos modelos de predição fracos sequencialmente e os agrupa. Os modelos típicos são árvores de decisão e o procedimento de aprendizado generaliza o novo modelo para fornecer um preditor mais preciso e otimizado.

3.2.2. Recursos de aprendizagem de redes neurais artificiais (ANN).

A RNA é uma parte significativa da inteligência artificial, pois imita os princípios computacionais das redes neurais de um animal. Devido à sua notável capacidade de generalização e promissor seletor de recursos baseado em correlação, ele tem sido amplamente utilizado no campo de pesquisa, como reconhecimento de texto manuscrito [18], previsão do tempo [19], economia financeira [20] e avaliação de terras agrícolas [21].

Basicamente, a RNA incorpora três camadas, a saber, as camadas de entrada, oculta e de saída. Concisamente, os neurônios nas camadas oculta e de saída adotam as funções de ativação sigmoide na execução da operação de retropropagação. A saída da ANN pode ser adquirida pela seguinte equação:

$$y_{out} = \frac{1}{1 + \exp(-\sum_{j=1}^n w_{ij} x_j - b_i)} \quad (6)$$

onde  $W1$ ,  $W2$ ,  $b1$ ,  $b2$  são parâmetros de pesos e desvios e  $X_n$  refere-se à entrada de dados. O algoritmo de otimização Adam [22] é adotado para atualizar de forma adaptativa as taxas de aprendizado durante o treinamento do modelo. Além disso, propomos o "XBoosting ANN" implementando um método de aumento de gradiente extremo nas saídas da ANN.

## 4. Experimente

4.1. Base de dados. Os dados experimentais adotam o banco de dados divulgado por referência [4]. Concretamente, o banco de dados é composto por 1605 remendos de couro que possuem o tamanho de  $90 \times 60 \text{ mm}^2$  (largura  $\times$  comprimento). Entre elas, 503 imagens contêm um ou mais defeitos de picada de carrapato, enquanto as 1102 imagens restantes são imagens sem defeitos. Em resumo, todas as imagens são coletadas usando um braço robótico articulado de 6 eixos DRV70L da Delta, cuja capacidade de carga é de 5 kg. O braço robótico está equipado com uma câmera Canon 77D equipada com uma lente de distância focal de 135 mm. Cada dado capturado tem uma resolução de imagem de  $2440 \times 1600$  pixels e é utilizada para garantir uma distribuição consistente de brilho nas peças de couro. Uma captura de tela da configuração experimental é ilustrada nas Figuras 3 e 4, que mostra as amostras para as imagens defeituosas e não defeituosas.

Um exemplo ilustrativo que descreve a caixa delimitadora com o tamanho estimado é mostrado na Figura 5. Além disso, as maiores e as menores amostras de defeitos estão representadas na Figura 6.

4.2. Configuração do experimento. Na fase de classificação, a validação cruzada de 5 vezes é aplicada para testar os dados não vistos. O conjunto de dados é pela primeira divisão para uma proporção de 7 : 3 para o trem: subconjuntos de teste. Então, o subconjunto de treinamento é ainda particionado em 7 : 3 em subconjuntos de treinamento e validação. Portanto, a divisão final do conjunto de dados é de cerca de uma proporção de 5 : 3:2 para os subconjuntos train:test:validation, que consistem em 785 : 483 : 337 imagens, respectivamente. Concretamente, as características do trem serão inseridas no modelo de classificação; entretanto, as imagens de validação são utilizadas para determinar a configuração experimental ótima e as definições dos parâmetros (ou seja, tamanho do filtro do filtro Gaussiano e valor limiar para o detector de bordas Canny). Por fim, o modelo refinado é usado para validar as imagens de teste, e as métricas de desempenho são descritas na subseção a seguir.

4.3. Métricas de Desempenho. Isso é um problema de classificação binária onde a saída deve produzir o rótulo de "defeito" ou "sem defeito". Assim, as quatro métricas a seguir podem ser derivadas da matriz de confusão  $2 \times 2$ :

$$\text{Precisão} = \frac{TP + TN}{TP + FP + TN + FN}, \quad (7)$$

onde TP é o pixel previsto que identificou corretamente o pixel defeituoso; TN é o pixel não defeituoso que foi previsto corretamente; FP é o pixel que é incorretamente previsto como pixel defeituoso; e FN são os pixels defeituosos não detectados.



Figura 4: Ilustração da montagem experimental.




Figura 5: Área de superfície do defeito com uma caixa delimitadora.

Por outro lado, a métrica de desempenho F1-score é calculada:

$$F1 \text{ \textasciitilde pontuação} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}, \quad (8)$$

por

$$\text{recall} = \frac{TP}{TP + FN}, \quad (9)$$

e

$$\text{precisão} = \frac{TP}{TP + FP}. \quad (10)$$

Existem dois tipos de pontuação F1, a saber, média macro e média ponderada. O primeiro é simplesmente a média da pontuação F1 por classe, que é semelhante à precisão média macro e ao recall médio macro, que são calculados pela média de precisão e recall, respectivamente. Para o F1-score médio ponderado, a precisão ponderada e o recall ponderado são calculados considerando os pesos para cada classe:




Figura 6: .e amostras defeituosas que apresentam (a) o maior e (b) o menor defeito de picada de carrapato.

$$\text{ponderada } \hat{y} \text{ média F1 } \hat{y} \text{ pontuação } \hat{y} = \frac{w_1 S_1 + w_2 S_2 + \dots + w_n S_n}{w_1 + w_2 + \dots + w_n}, \quad (11)$$

onde  $w_i$  é o número de amostras para a classe  $i$  e  $S_i$  pertence ao F1-score, precisão e recall para cada classe  $i$ .

## 5. Resultado e Discussão

Deve-se notar que, para o detector de bordas Canny, diferentes tamanhos de filtros Gaussianos detectarão características de tamanhos diferentes na imagem de entrada e produzirão mapas de características de tamanhos distintos. Para buscar uma configuração ótima do detector de borda, seu tamanho de kernel é primeiro fixado aos tamanhos comuns, a saber, (5,5), (7,7) e (9,9), respectivamente. .en, o intervalo dos valores de limite é definido como [80, 230]. .e precisão de validação da precisão de classificação em relação ao parâmetro de limite no detector de bordas Canny é retratado na Figura 7. .há uma tendência semelhante para os tamanhos de kernel de 7 e 9, em que os melhores resultados são obtidos quando o limite é mínimo ( ou seja, 84 a 104). Em contraste, quando o tamanho do kernel é 5, um limite baixo não superou, comparado ao do kernel 7 e 9. Além disso, também pode ser observado que quando o tamanho do kernel é 5, a maior precisão (quando o limite é 160 ) obtido é relativamente menor.

A partir do resultado preliminar realizado na Figura 7, optamos por selecionar o limiar ótimo de 92 para todos os tamanhos de kernel ao longo do restante dos experimentos. .e resultados da precisão ao adotar ANN e XBoost ANN são mostrados tabulados na Tabela 1, com o TP, FP, FN, TN e F1-score detalhados. Pode-se observar que quando as etapas de pré-processamento não envolvem HoG (as três primeiras linhas), a precisão no classificador ANN é de 69%, enquanto a maior precisão é alcançada quando se utiliza XBoost ANN (até 82%). Pelo contrário, quando HoG é adicionado como uma das etapas de pré-processamento, todas as precisões na ANN e na XBoost ANN melhoram. Especificamente, um resultado de classificação promissor de 94% é exibido quando o tamanho do kernel é 7.

Para analisar ainda mais o impacto do HoG na etapa de pré-processamento, uma característica de operação do receptor (ROC) pode ilustrar a eficácia do modelo estatístico do classificador. Particularmente, quando o HoG não é aplicado como uma das etapas de pré-processamento, a curva ROC é mostrada na Figura 8. Observa-se que a acurácia do ROC micromédio é de 69%, enquanto o ROC macromédio é de 50%. Por outro lado, quando o HoG é incluído no método proposto, as acurácias do ROC melhoram em até 95%, conforme demonstrado na Figura 9.

Além disso, optamos por ANN e Xboost ANN como classificadores em nosso experimento. A razão disso é porque outros classificadores não estão tendo desempenho superior com base nas características extraídas, especialmente nesta tarefa de classificação binária. Os resultados da classificação estão resumidos na Figura 10. Pode-se ver que tanto a ANN quanto a ANN Xboost atingem uma precisão de mais de 90%. Para SVM com kernel linear e classificadores de floresta aleatória, seus resultados também são promissores ( é 90%). Outros classificadores como k-NN, SVC, árvore de decisão, AdaBoost, gradient boosting e análise discriminante não parecem adequados para serem adotados neste experimento.

O framework proposto é comparado a três outros trabalhos que realizaram a classificação binária no mesmo conjunto de dados de couro. Concretamente, os outros três métodos utilizaram a RNA [4], AlexNet [4] e análise estatística [6] como descritores de características chave. A comparação dos resultados está resumida na Tabela 2, onde as métricas apresentadas são precisão e pontuação F1. É interessante destacar que a rede de aprendizado profundo como a AlexNet não tem um bom desempenho nesta tarefa de classificação. .é em parte devido aos fenômenos de overfitting. Com um conjunto de dados relativamente pequeno e dados altamente desbalanceados, onde o número de imagens não defeituosas é o dobro das defeituosas, a rede não é capaz de generalizar bem e, portanto, leva a um resultado de classificação ruim.

Notavelmente, os resultados gerados neste artigo superam o estado da arte, no qual a precisão e o F1-score relatados são ambos de 94%. No entanto, deve-se notar que as imagens de treinamento consideradas no experimento aqui são quase metade das

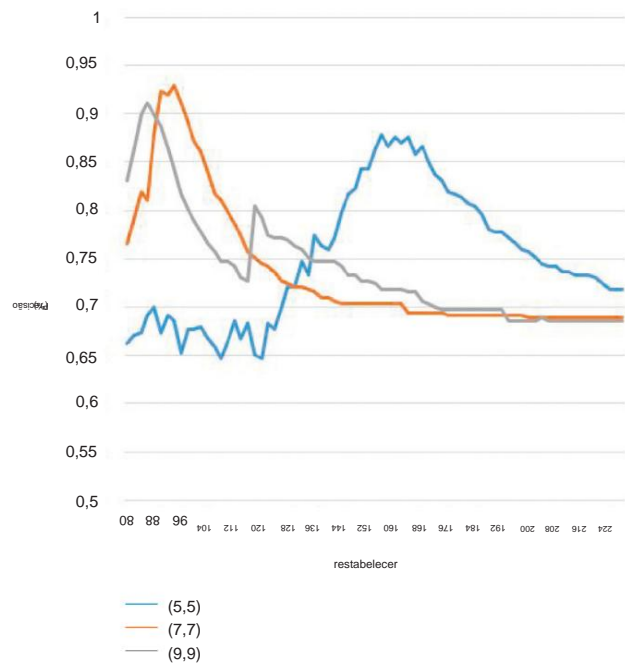


Figura 7: e precisão de validação da precisão de classificação em relação ao parâmetro de limiar no detector de bordas Canny.

Tabela 1: Comparação dos resultados ao empregar ANN (A) e XBoost ANN (X) como classificadores.

Métodos	TP		PF		FN		TN		Precisão		Média de macros Pontuação F1		Média ponderada Pontuação F1	
	UMA	XAXA				X	UMA	X	UMA	X	UMA	X	UMA	X
sem HoG (5,5)	331	266	0	65	151	114	0	37	0,69	0,63	0,41	0,52	0,56	0,61
sem HoG (7,7)	331	274	0	57	151	48	0	103	0,69	0,78	0,41	0,75	0,56	0,78
sem HoG (9,9)	331	281	0	50	151	35	0	116	0,69	0,82	0,41	0,8	0,56	0,83
Com HoG (5,5)	314	313	17	18	50	49	101	102	0,86	0,86	0,83	0,83	0,86	0,86
Com HoG (7,7)	325	325	6	6	21	25	130	126	<b>0,94</b>	<b>0,94</b>	0,93	0,92	<b>0,94</b>	0,93
Com HoG (9,9)	323	323	8	8	41	41	110	110	0,90	0,90	0,87	0,87	0,89	0,89

.e números em negrito representam os valores mais altos dentro dos resultados experimentais apresentados.

o conjunto de dados. No entanto, com a utilização de arquitetura de rede neural e recursos de gradiente, ele alcança melhorias sem precedentes nos resultados de classificação.

Em poucas palavras, este artigo propõe um novo pipeline de aprimoramento de recursos na classificação da imagem de couro defeituosa. Especificamente, uma grande parte da contribuição é atribuída à etapa de pré-processamento, na qual os processos incluem correspondência de histogramas, redimensionamento, normalização em tons de cinza, desfoque gaussiano e detecção de bordas Canny. a partir de então, a região defeituosa torna-se mais clara e

perceptível. e O descritor HOG é utilizado para converter o imagem em um vetor de recurso 1D. Finalmente, vários classificadores são empregados para avaliar a robustez da proposta mecanismo. Como um todo, o método proposto requer recursos computacionais relativamente menores, ao mesmo tempo em que prometendo precisão de classificação de até 94%. Uma carta comparação do estado da arte é fornecida na Tabela 3 para mostrar a principal diferença em lidar com este couro defeituoso problema de classificação. Observe que o número total de couro amostras para os experimentos é ligeiramente diferente.



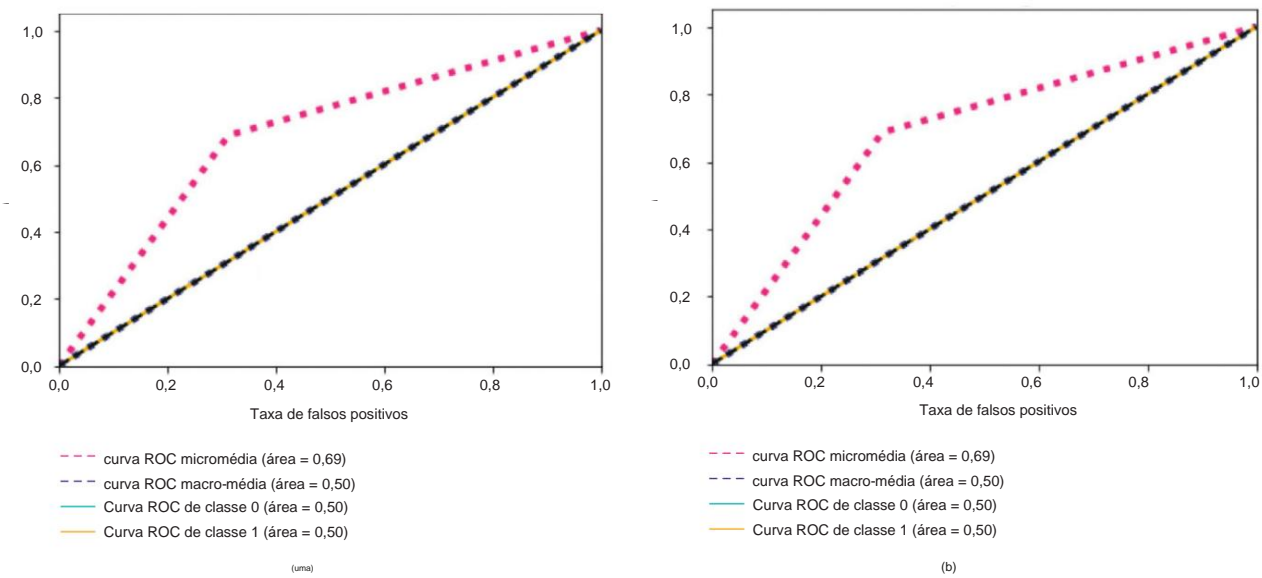


Figura 8: Curva ROC quando o histograma de gradiente não é incluído como uma das etapas de pré-processamento, quando avaliado em (a) conjunto de validação e (b) conjunto de teste.




Figura 9: Continuação.

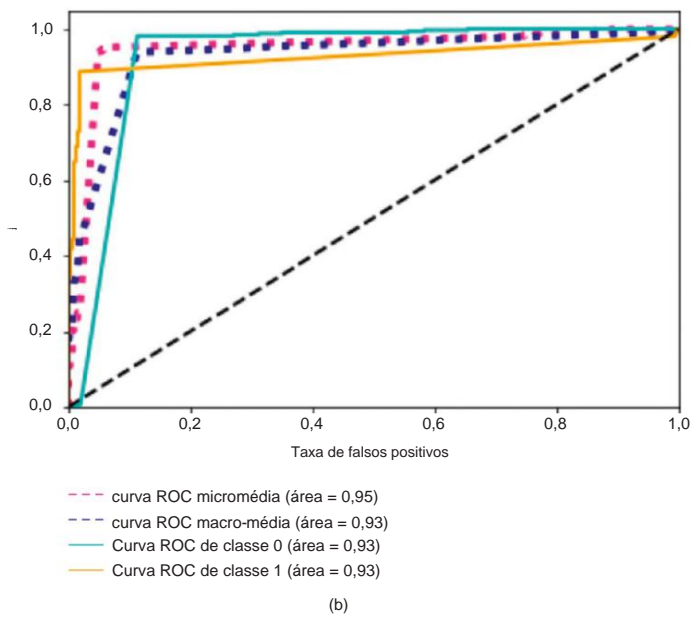


Figura 9: Curva ROC ao aplicar histograma de gradiente como uma das etapas de pré-processamento, quando avaliado em (a) conjunto de validação e (b) conjunto de teste.

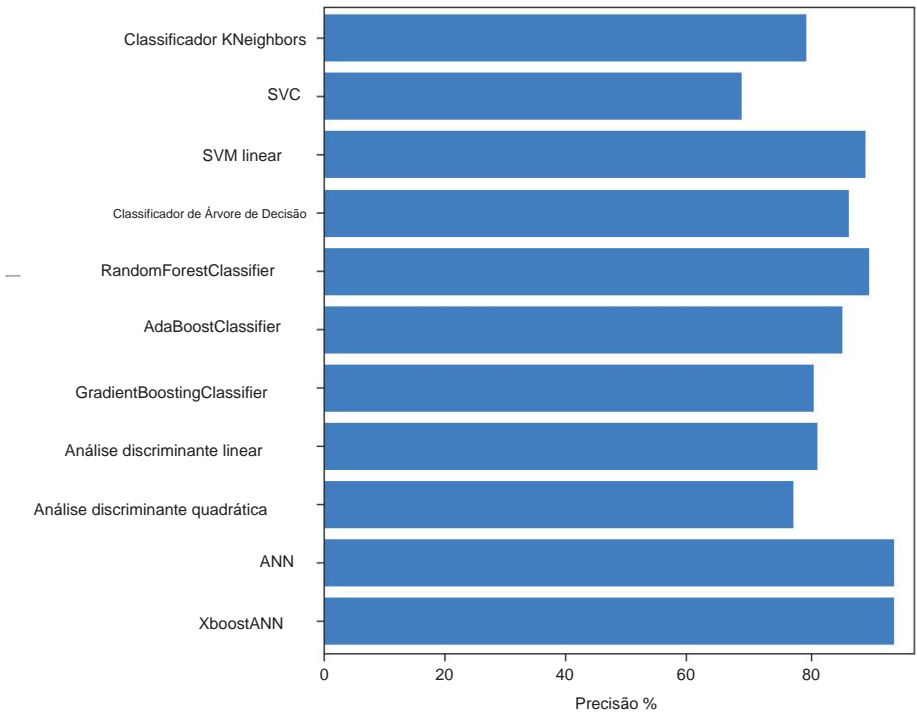


Figura 10: Desempenho de classificação do método proposto ao empregar diferentes classificadores.

Tabela 2: Comparação do desempenho da classificação com o estado da arte no mesmo conjunto de dados.

Método defeituoso: não defeituoso	Treinar: validação: divisão de teste		Método	Precisão (%)	Pontuação F1 (%)
[4]	370 :1527	60: 5:35	ANN	80	89
[4]	233: 699	90 : 0:10	AlexNet	74	84
[6]	503 :1102	70 : 0: 30	Análise estatística + SVM	74	97
Nosso	503 :1102	49 : 21: 30	XBoost ANN + HOG	<b>94</b>	<b>94</b>

.e números em negrito representam os valores mais altos dentro dos resultados experimentais apresentados.

Tabela 3: Comparação do desempenho da classificação com o estado da arte no mesmo conjunto de dados.

Método	Pré-processando	Extrator de recursos	Classificador	Precisão (%)
[6]	Normalização em tons de cinza, filtro gaussiano	Características estatísticas (média, variância, assimetria, curtose, valor do quartil inferior e superior)	SVM	74
[23]	Normalização em escala de cinza, redimensionamento, Detecção de borda inteligente, partição de bloco		ANN	80
[23]	Normalização em escala de cinza, redimensionamento, Detecção de borda inteligente, partição de bloco		AlexNet	76
[4]			Máscara R-CNN	80
Nosso	Correspondência de histograma, redimensionamento, normalização em escala de cinza, desfoque gaussiano e detecção de borda Canny	Histograma de gradiente	k-NN, SVC, SVM, MLP, AdaBoost, árvore de decisão, floresta aleatória, análise discriminante, aumento de gradiente extremo	<b>94</b>

.e números em negrito representam os valores mais altos dentro dos resultados experimentais apresentados.

6. Conclusão

.esse estudo introduziu um sistema de classificação binária para distinguir se uma imagem de couro contém defeito de mordida de carrapato. Vários experimentos e análises foram conduzidos para verificar a robustez do algoritmo proposto. No geral, resultados promissores são exibidos ao explorar uma série de métodos de pré-processamento e dois classificadores de redes neurais. Como resultado, a melhor precisão de classificação obtida é de 94% ao empregar ANN e XBoost ANN como classificadores. Como este experimento está estritamente limitado ao tipo de defeito de picada de carrapato, a direção potencial para pesquisas futuras nessa área inclui o desenvolvimento de um sistema de classificação ou segmentação para determinar os tipos de defeitos, como cortes abertos, cortes fechados, rugas, buracos e sarna . Além de investigar o tipo de defeito, o experimento pode ser estendido para avaliar outros tipos de couro, como couros de outros animais, cordeiro, crocodilo e cobra. Por fim, uma configuração de hardware totalmente automatizada que consiste nas funções de captura de manchas de imagem de couro, identificação de áreas defeituosas e corte a laser do couro pode ser desenvolvida no futuro.

Disponibilidade de dados

.e natureza dos dados em um arquivo Excel, e os dados e o código podem ser acessados no seguinte site: <https://github.com/christy1206/XBoost-leather> . .não há restrições quanto ao acesso aos dados. .e Os dados do [Arquivo Excel] usados para apoiar as descobertas deste estudo estão incluídos no artigo.

Conflitos de interesse

.e autores declaram não ter conflitos de interesse.

Agradecimentos

.esse trabalho foi financiado pelo Ministério da Ciência e Tecnologia (MOST) (número de concessão: MOST 109-2221-E-035-065-MY2, MOST 110-2221-E-035-052).

Referências

[1] M. Aslam, TM Khan, SS Naqvi, G. Holmes e R. Naffa, "Sobre a aplicação da visão automatizada de máquina para inspeção e classificação de defeitos de couro: uma pesquisa", IEEE Access, vol. 7, Artigo ID 176065, 2019.

[2] M. Jawahar, NK Babu, KLJA Vani, LJ Anbarasi e S. Geetha, "Sistema de Inspeção Baseado em Visão para Detecção de Defeitos em Superfícies de Couro Usando a Abordagem do Classificador de Conjunto de Otimização de Enxame de Partículas de Convergência Rápida", Ferramentas e Aplicações Multimídia, vol. 80, não. 3, págs. 4203–4235, 2020.

[3] MK Kasi, JB Rao e VK Sahu, "Identificação de defeitos de couro usando um algoritmo de processamento de imagem de detecção de borda autoadaptável", em Anais da Conferência Internacional de 2014 sobre Computação e Aplicativos de Alto Desempenho (ICHPCA), pp. 1– 4, IEEE, Bhubaneswar, Índia, dezembro de 2014.

[4] ST Liong, YS Gan, YC Huang, CA Yuan e HC Chang, "Automatic Defect Segmentation on Leather with Deep Learning", março de 2019, <https://arxiv.org/abs/1903.12139>.

[5] S.-T. Liong, D. Zheng, Y.ȳC. Huang e Y. Gan, "Classificação e segmentação de defeitos de couro usando arquitetura de aprendizado profundo", International Journal of Computer Integrated Manufacturing, vol. 33, nº. 10-11, pp. 1105-1117, 2020.

[6] Y. Gan, S.-S. Chee, Y.ȳC. Huang, S.-T. Liong e W.ȳC. Yau, "Inspeção automatizada de defeitos de couro usando abordagem estatística na intensidade da imagem", Journal of Ambient Intelligence and Humanized Computing, vol. 12, pp. 1–17, 2020.

[7] WP Amorim, H. Pistori, MC Pereira e MAC Jacinto, "Redução de atributos aplicada à classificação de defeitos de couro", em Anais da 23ª Conferência SIBGRAPI de 2010 sobre Gráficos, Padrões e Imagens, pp. 353–359, IEEE, Gramado, Brasil, agosto de 2010.

[8] S. Winiarti, A. Prahara e DPI Murinto, "Rede neural convolucional pré-treinada para classificação de imagem de couro curtido", Network (CNN), vol. 9, não. 1, 2018.

[9] SR Safavian e D. Landgrebe, "Uma pesquisa sobre a metodologia do classificador de árvore de decisão", transações IEEE em sistemas, homem e cibernética, vol. 21, não. 3, pp. 660-674, 1991.

[10] WR Klecka, GR Iversen e WR Klecka, Análise discriminante, Sage, Califórnia, CA, EUA, 1980.

- [11] JAK Suykens e J. Vandewalle, "Mínimos quadrados suportam classificadores de máquinas vetoriais," *Neural Processing Letters*, vol. 9, não. 3, pp. 293-300, 1999.
- [12] T. Cover e P. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, não. 1, pp. 21-27, 1967.
- [13] SR Gunn, "Máquinas de vetor de suporte para classificação e regressão", relatório técnico do ISIS, vol. 14, não. 1, pp. 5-16, 1998.
- [14] A. Liaw e M. Wiener, "Classificação e regressão por floresta aleatória", *R News*, vol. 2, não. 3, pp. 18–22, 2002.
- [15] MW Gardner e S. Dorling, "Redes neurais artificiais (o perceptron multicamada)—uma revisão de aplicações nas ciências atmosféricas", *Ambiente Atmosférico*, vol. 32, não. 14-15, pp. 2627-2636, 1998.
- [16] G. Ratsch, T. Onoda e K.-R. Müller, "Soft margins for adaboost", *Machine Learning*, vol. 42, não. 3, pp. 287-320, 2001.
- [17] T. Chen, T. He, M. Benesty et al., *Xgboost: Extreme Gradient Boosting*, R Package Version, vol. 1, não. 4, pp. 1–4, 2015.
- [18] S. España-Boquera, MJ Castro-Bleda, J. Gorbé-Moya e F. Zamora-Martínez, "Melhorando o reconhecimento de texto manuscrito offline com modelos híbridos hmm/ann", *Transações IEEE em Análise de Padrões e Inteligência de Máquina*, vol. 33, nº. 4, pp. 767-779, 2011.
- [19] JW Taylor e R. Buizza, "Previsão de carga de rede neural com previsões de conjuntos climáticos", *IEEE Transactions on Power Systems*, vol. 17, não. 3, pp. 626-632, 2002.
- [20] Y. Li e W. Ma, "Aplicações de redes neurais artificiais em economia financeira: uma pesquisa", vol. 1, pp. 211–214, em *Proceedings of the 2010 International symposium on computational intelligence and design*, vol. 1, IEEE, Hangzhou, China, outubro de 2010.
- [21] F. Wang, "O uso de redes neurais artificiais em um sistema de informação geográfica para avaliação de adequação de terras agrícolas," *Ambiente e Planejamento A: Economia e Espaço*, vol. 26, não. 2, pp. 265-284, 1994.
- [22] DP Kingma e J. Ba, "Adam: A Method for Stochastic Optimization", dezembro de 2014, <https://arxiv.org/abs/1412.6980>.
- [23] S.-T. Liong, YS Gan, K.-H. Liu et al., "Abordagens de rede neural eficientes para classificação de defeitos de couro", junho de 2019, <https://arxiv.org/abs/1906.06446>.