

## Análise

# Uma revisão sistemática da superfície de couro baseada em visão de máquina

## Inspeção de Defeitos

Zhiqiang Chen 1, Jiehang Deng 2, Qiuqin Zhu 1, Hailun Wang 1 e Yi Chen 1,3,\*

1 Faculdade de Engenharia Elétrica e de Informação, Universidade de Quzhou, Quzhou 324000, China; czq@qzc.edu.cn (ZC); zhuqq@qzc.edu.cn (QZ); wangl@qzc.edu.cn (HW)

2 Escola de Computadores, Universidade de Tecnologia de Guangdong, Guangzhou 510006, China; dengjiehang@gdut.edu.cn

3 Escola de Engenharia, Universidade de Newcastle, Newcastle NE1 7RU, Reino

Unido \* Correspondência: leo.chen@ieee.org

**Resumo:** A inspeção de defeitos de superfície baseada em visão de máquina é uma das principais tecnologias para realizar a fabricação inteligente. Este artigo fornece uma revisão sistemática sobre defeitos de superfície de couro em especificações baseadas em visão de máquina. Os produtos de couro são considerados os produtos mais comercializados em todo o mundo. A detecção automática, localização e reconhecimento de defeitos na superfície do couro são muito importantes para a fabricação inteligente de produtos de couro e são tarefas desafiadoras, mas notáveis. Este trabalho investiga uma grande quantidade de literatura relacionada ao defeito superficial do couro em inspeção. Além disso, também investigamos e avaliamos o desempenho de alguns detectores de borda e detectores de limiar para detecção de defeitos de couro e a precisão de identificação do método clássico de aprendizado de máquina SVM para identificação de defeitos de superfície de couro. Uma revisão detalhada e metódica da inspeção de defeitos na superfície do couro com análise de imagens e aprendizado de máquina. Os principais desafios e tendências de desenvolvimento futuro são discutidos para inspeção de defeitos de superfície de couro, que pode ser usado como fonte de diretrizes para projetar e desenvolver novas soluções neste campo.

**Citação:** Chen, Z.; Deng, J.; Zhu, Q.; Wang,

H.; Chen, Y. A Sistemático

Revisão de baseado em visão de máquina

Inspeção de Defeitos na Superfície de Couro.

*Electronics* **2022**, *11*, 2383. [https://](https://doi.org/10.3390/electronics11152383)

[doi.org/10.3390/electronics11152383](https://doi.org/10.3390/electronics11152383)

Editor Acadêmico: George A.

Papakostas

Recebido: 7 de julho de 2022

Aceito: 25 de julho de 2022

Publicado: 30 de julho de 2022

**Nota do editor:** MDPI permanece neutro em relação a reivindicações jurisdicionais em mapas publicados e instituições afiliadas institucionais.



**Direitos autorais:** © 2022 pelos autores.

Licenciado MDPI, Basileia, Suíça.

Este artigo é um artigo de acesso aberto distribuídos nos termos e

condições do Creative Commons

Licença de atribuição (CC BY) ([https://](https://creativecommons.org/licenses/by/4.0/)

[creativecommons.org/licenses](https://creativecommons.org/licenses/by/4.0/)

[s/by/4.0/](https://creativecommons.org/licenses/by/4.0/)).

**Palavras-chave:** couro; inspeção de defeitos; detecção; identificação; visão de máquina

### 1. Introdução

O couro e seus produtos são considerados os produtos mais comercializados em todo o mundo, com um comércio internacional anual de mais de US\$ 80 bilhões [1]. Para produzir produtos de couro com design inovador e conforto, a escolha do couro tornou-se o fator chave para determinar o sucesso ou fracasso dos fabricantes. Esse processo de inspeção inclui principalmente detecção de defeitos de couro, localização, identificação, divisão de área indisponível e determinação do grau de qualidade. A inspeção confiável e eficaz, incluindo a detecção e classificação de defeitos superficiais do couro, é muito importante para a indústria coureira que tem o couro como principal matéria-prima, como fabricantes de calçados de couro e bolsas [2]. A detecção e classificação tradicionais de defeitos da superfície do couro são realizadas por inspetores humanos que tendem a perder um número considerável de defeitos porque os seres humanos são basicamente inconsistentes e inadequados para tarefas tão simples e repetitivas [3]. Além disso, as inspeções manuais são tarefas lentas e trabalhosas. Esses fatores tornaram-se gargalos que restringem a indústria do couro [4].

Nas últimas décadas, progressos surpreendentes foram feitos na aplicação de sistemas inteligentes para resolver problemas práticos nas áreas de medicina, telecomunicações, finanças, diagnóstico médico, transporte, recuperação de informações, energia e assim por diante [5]. As exigências da automação revolucionaram o modo de produção da indústria manufatureira. Da otimização de recursos à inspeção industrial, especialistas e sistemas inteligentes têm sido aplicados em quase todos os tipos de processamento industrial. Defeito automático

a inspeção de produtos industriais é um dos cenários de aplicação importantes de tais sistemas inteligentes, e é também uma das tecnologias-chave para realizar a fabricação inteligente [6]. Algumas pesquisas foram realizadas em inspeção automatizada de superfícies metálicas [7], tecidos têxteis [8–10], monitoramento da saúde estrutural e assim por diante [11–13]. Com o rápido desenvolvimento da fabricação inteligente, a fabricação de produtos de couro também entrou em um novo estágio de desenvolvimento [3–5].

Desde a década de 1990, alguns estudiosos e fornecedores de equipamentos de inspeção automática começaram a prestar atenção comum à inspeção automática de defeitos na superfície do couro. No entanto, investigamos empresas relevantes em áreas desenvolvidas de produtos de couro, como as províncias de Guangdong e Zhejiang na China (o maior produtor, importador e exportador de produtos de couro em todo o mundo [1]), e descobrimos que muitas empresas ainda mantêm a tradicional inspeção manual de defeitos do couro. Algumas empresas realizaram inspeção de defeitos semi-automática e semi-manual, e um sistema de inspeção de defeitos totalmente automático real não foi realizado. Relativamente poucos trabalhos foram realizados na inspeção automatizada de defeitos na superfície do couro, principalmente devido à natureza difícil do problema [3]. É muito difícil construir modelos de inspeção exatos porque sua aparência e tamanho variam muito [3–5]. É quase impossível encontrar dois defeitos com a mesma forma e tamanho, mesmo que pertençam à mesma classe de defeitos [3]. A detecção automática, localização e reconhecimento de defeitos na superfície do couro são problemas interessantes, mas desafiadores. Espera-se que o defeito automático do couro no sistema de inspeção faça um rápido progresso em breve.

Neste trabalho, revisamos sistematicamente uma grande quantidade de literatura nas últimas três décadas e fornecemos uma ampla visão geral da pesquisa sobre detecção automática e reconhecimento de defeitos de couro com base no processamento de imagens e aprendizado de máquina.

Ao fazer isso, investigamos e avaliamos o desempenho de alguns detectores de borda e detectores de limiar para detecção de defeitos de couro, bem como a precisão da identificação de defeitos de superfície de couro com base em SVM, e nos esforçamos para fornecer uma orientação clara para pesquisadores e engenheiros selecionar, projetar ou implementar a arquitetura de detecção visual e reconhecimento de defeitos na superfície do couro.

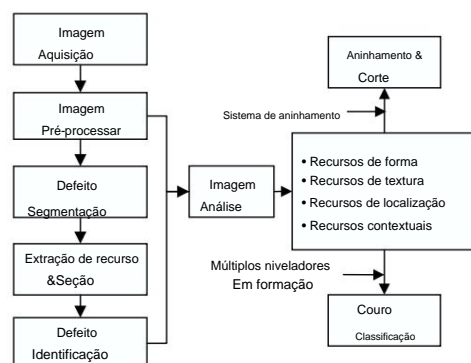
## 2. Sistema de Inspeção de Defeitos de Superfície de Couro Baseado em Visão

Os requisitos para inspeção de defeitos na superfície do couro podem ser divididos em três níveis diferentes: “qual é o defeito” (classificação), “onde está o defeito” (localização) e “qual é a forma do defeito e qual é o tamanho da área” (segmentação). A tecnologia de inspeção de defeitos de superfície de couro é baseada principalmente em métodos de inspeção por visão de máquina [14].

Conforme mostrado na Figura 1, semelhante a outros sistemas de inspeção visual de defeitos de superfície, os componentes básicos de um sistema de visão de máquina para inspeção automática de defeitos de couro incluem aquisição de imagem de superfície de couro, processamento de imagem, análise de imagem, gerenciamento de dados e interface homem-máquina [2]. Com base na localização do defeito, forma e área detectada pelo módulo de detecção de defeitos, bem como o tipo de defeito detectado pelo módulo de identificação de defeitos, combinado com a localização e várias características contextuais, as aplicações de classificação automática da qualidade do couro e layout inteligente de couro são realizados com a ajuda do sistema especialista em qualidade de couro. A detecção e o reconhecimento automáticos estáveis, confiáveis e eficazes de defeitos na superfície do couro são as principais técnicas para realizar a fabricação inteligente de produtos de couro.

Na última década, muitas técnicas baseadas em visão de máquina foram desenvolvidas na inspeção de defeitos superficiais, não se limitando à superfície do couro. Esses métodos podem ser divididos principalmente em duas categorias, a saber, o método tradicional de processamento de imagens e o método de aprendizado de máquina, que é baseado em recursos artesanais ou técnicas de aprendizado superficial. Os métodos baseados em aprendizado de máquina geralmente incluem dois estágios de extração de recursos e classificação de padrões. Ao analisar as características da imagem de entrada, o vetor de características que descreve as informações do defeito é projetado e, em seguida, o vetor de características é colocado em um modelo classificador que é treinado antecipadamente para determinar se a entrada

imagem tem um defeito ou não. Nos últimos anos, os métodos de redes neurais profundas alcançaram excelentes resultados em muitas aplicações de visão computacional, como classificação de cenas naturais, reconhecimento facial, diagnóstico de falhas, rastreamento de alvos, etc.



**Figura 1.** Pipeline geral para o sistema de inspeção visual de defeitos de couro.

Esta revisão se concentra na aplicação dos métodos acima no campo de defeitos de superfície do couro. Tomando “detecção de defeitos de couro”, “identificação de defeitos de couro”, “superfície de couro” e “inspeção de defeitos” como palavras-chave, recuperamos mais de 65 documentos em inglês e mais de 20 documentos em chinês nos bancos de dados Science Direct, IEEE Explore e CNKI desde 1990. A Figura 2 apresenta os métodos de inspeção de defeitos na superfície do couro utilizados nestas literaturas. Nas próximas seções, analisaremos e compararemos as tecnologias relevantes e suas aplicações neste campo.



**Figura 2.** Métodos utilizados na inspeção visual de defeitos na superfície do couro em literaturas anteriores.

### 3. Aquisição de Imagem

Uma imagem de superfície de couro abrange três características [15]: (i) grande área de imagem, ou seja, uma área de pele inteira pode atingir  $2 \times 3$  m; (ii) tamanho do defeito pequeno, ou seja, a área do defeito pode ser pequena,  $150 \mu\text{m} \times 150 \mu\text{m}$ , o diâmetro médio da área de defeito é de  $1,20 \text{ cm}^2$ ; (iii) a superfície de couro pertence à superfície de textura, e os defeitos geralmente estão ocultos no fundo de textura irregular da superfície do couro. Portanto, a aquisição de imagens de couro requer uma visão de câmera grande e alta resolução. Os principais fatores que afetam a aquisição de imagens defeituosas na superfície do couro são a câmera e o iluminante.

#### 3.1. Câmera

Na produção real, o couro geralmente é movido uniformemente em uma única direção para um local designado antes do processamento. Portanto, a inspeção on-line geralmente adota a câmera de varredura de linha para aquisição de imagens. Atualmente, a inspeção on-line de defeitos de superfície para couro e outros produtos planos, largos e contínuos adota principalmente o modo de varredura de linha, que pode detectar a maioria dos defeitos. No entanto, alguns defeitos da superfície do couro, como estampagem e tinta, são anisotropia. Se imagens de defeitos anisotrópicos semelhantes fossem coletadas apenas em uma câmera de varredura de linha, a taxa de detecção de vazamento de defeitos atingiria 22% [16].

A câmera aérea pode obter informações bidimensionais e medir imagens de forma intuitiva. Assim, muitos pesquisadores optaram por usar a câmera CCD tradicional para coletar imagens de couro. Para evitar as fraquezas do pequeno campo de visão e obter imagens de alta resolução, um esquema é mover a câmera CCD através de um sistema de controle complexo e escanear a área efetiva de todo o couro; outra alternativa é tirar várias imagens da câmera. Ambos os esquemas requerem a aplicação de fusão de imagens para obter toda a imagem do couro. Ele et al. [17] propuseram a tecnologia de emenda de imagem baseada em momentos de Gabor Zernike do bloco de textura de triângulo de resumo geométrico. Eles tentaram resolver os problemas do algoritmo de mosaico de imagens complexo e de baixa velocidade, e realizar a emenda rápida e precisa de imagens sequenciais em inspeção visual de couro de grande área. Ho et al. [18] apresentaram um sistema de captura de imagens em tempo real usando quatro câmeras a 30 fps e uniram suas visualizações para criar um vídeo panorâmico com resolução de  $1280 \times 960$  pix. No entanto, essas aquisições de imagens baseadas na fusão de imagens aumentariam a complexidade do algoritmo de processamento de imagens e exigiriam um sistema de controle complexo.

Com o desenvolvimento da tecnologia de câmera aérea CCD de ultra-alta definição (UHD), surgiu a tecnologia de imagem de couro inteira baseada em UHD. Deng et al. [19] tentou usar uma câmera aérea CCD ultra-alta para obter imagens de todo o couro de uma só vez. O sistema tem as características de imagem rápida, processo de imagem simples, sem fusão de imagem de múltiplas visualizações e bom efeito de imagem. Devido à redução de custos da câmera CCD de ultra-alta definição, ela se tornará o principal método de aquisição de imagens de couro. No entanto, ainda é necessário resolver os problemas de iluminação desigual e sobreposição de sombra de borda de couro e fundo [20].

Chen et al. [5] realizaram um estudo de pesquisa piloto no qual usaram imagens hiperespectrais (HSI) para implementar a inspeção de superfície na detecção de nível de pixel, que empregou a informação espectral de defeitos de couro em vez de técnicas de processamento de informações espaciais para identificar efetivamente defeitos de couro. A imagem hiperespectral tornou-se uma tecnologia emergente e tem sido amplamente utilizada nos domínios da geologia, agricultura, mudança global e defesa nacional, com potencial industrial altamente promissor [5].

Como o volume de dados hiperespectrais é muito grande, é necessária uma alta capacidade de armazenamento de dados, e a redução do volume de dados também é um tópico que vale a pena explorar. Seu trabalho [5] é um estudo piloto e uma diretriz para HSI na detecção de couro wet blue para projetar algoritmos apropriados.

#### 3.2. Iluminante

A fonte de luz e seu modo de iluminação afetarão diretamente a qualidade da aquisição da imagem e a eficiência da inspeção. A uniformidade da iluminação e o brilho do tar-

obter superfície são indicadores importantes da fonte de luz. Devido à influência da textura, os métodos convencionais de iluminação têm dificuldade em identificar com precisão os defeitos de impressão e tingimento ou indentação do couro com estrutura de textura. Fan et al. [20] descobriram que o brilho era diferente onde havia uma distância diferente entre o plano de imagem e a fonte de luz, resultando em iluminação irregular.

Na inspeção de defeitos de couro, as fontes de iluminação comuns incluem lâmpada fluorescente de alta frequência, lâmpada de economia de energia e lâmpada de LED. As lâmpadas fluorescentes de alta frequência e as lâmpadas economizadoras de energia são adequadas para iluminação de grandes áreas com uniformidade relativamente baixa. A fonte de luz LED possui alta eficiência luminosa e boa estabilidade, especialmente a pequena superfície luminosa, o que facilita a realização do design óptico secundário. Atualmente, o método de iluminação uniforme usando LED é principalmente LED com distribuição em matriz, cuja uniformidade pode chegar a mais de 90%. LED de anel, fonte de luz plana e de tira e fonte de luz em arco podem realizar iluminação uniforme e alta, mas todos pertencem ao sistema de iluminação coaxial, ou seja, a luz de iluminação geralmente é distribuída simetricamente. Wang et al. [21] sugeriram que os defeitos de impressão e tingimento de alguns couros texturizados podem ser destacados apenas por meio de iluminação uniforme assimétrica unilateral, ou seja, iluminação fora do eixo, e eles projetaram um conjunto de iluminação de matriz de superfície curva LED fora do eixo para inspeção de defeitos de couro, que fornece uma nova ideia para melhorar a qualidade de aquisição de imagem de defeitos de superfície de couro. Infelizmente, na maior parte da literatura sobre inspeção de defeitos na superfície do couro, o projeto de iluminação da imagem coletada não foi descrito em detalhes.

#### 4. Inspeção Visual de Couro Baseada em Processamento de Imagem

**Tradicional** Conforme mostrado nas Figuras 1 e 2, a tecnologia de inspeção visual de couro inicial era baseada principalmente em métodos tradicionais de processamento de imagem. Esses métodos usam os atributos primitivos refletidos por anomalias locais para detectar e segmentar defeitos, que podem ser ainda divididos em método estrutural [22–24], método de limiar, método espectral, método de análise de textura [25] e alguns outros métodos de segmentação. baseado em teorias específicas (como método de agrupamento fuzzy [26], método de saliência), etc. Esses métodos têm sido aplicados à inspeção de defeitos de superfície de couro em diferentes cenários.

##### 4.1. Método de estrutura

O método estrutural inclui operações de aresta e morfológicas. A detecção de bordas é uma técnica de segmentação de imagens comumente usada, usando uma série de métodos matemáticos para determinar a presença de bordas ou linhas (formalmente conhecidas como descontinuidades) e delinear-las em imagens digitais de maneira adequada. No início da década de 1990, Limas-Serafim [22–24] aplicou o algoritmo de pirâmide multi-resolução para segmentar defeitos de couro, e a ideia principal é aprimorar as bordas do objeto através de um método de multi-resolução e eliminar a maioria das bordas. com base na textura de fundo. Limas-Serafim et al. [23] construíram três pirâmides para dividir em imagens de caracterização. A primeira pirâmide foi construída com base na média dos dois maiores valores do bairro. A segunda pirâmide tinha um cone RosenfeldS com 16 direções da primeira pirâmide. A terceira pirâmide foi construída com um pequeno número de arestas, mas teve que satisfazer certas vantagens de consistência e resistência direcional. A segmentação de defeitos foi realizada conectando os nós da pirâmide de arestas, e uma função ponderada por arestas foi definida para vincular os nós com diferentes resoluções. Essas arestas podem ser vinculadas se as arestas em diferentes resoluções da imagem pertencerem ao mesmo objeto. Eles podem ser rejeitados se pertencerem a um plano de fundo aleatório. O algoritmo foi aplicado a defeitos de couro de bezerro (segmentação de vênulas de pele de bezerro e defeitos cicatriciais causados por doença animal). Neste cenário de aplicação, nem o algoritmo de segmentação baseado em limiar nem o algoritmo de segmentação de borda comum podem segmentar com sucesso o defeito do couro. Limas-Serafim [22–24] simplesmente verificou o método proposto, prometendo reconstruir os limites do objeto, mas não fez uma avaliação minuciosa e detalhada de sua eficácia.


No campo da detecção de defeitos de couro, Kasi et al. [24] avaliaram detectores de borda convencionais como Sobel, Canny, Prewitt e Roberts et al. Nesses métodos convencionais, as arestas detectadas são mais frequentemente falsas e têm dificuldade em atender às necessidades reais.

O operador Sobel fornece uma saída relativamente melhor, mas não pode fornecer bordas claras ou bem definidas para uma determinada imagem de entrada e ainda não é adequado para amostras de couro.

Kasi et al. [24] apresentaram uma técnica para identificar os defeitos em couro usando um algoritmo de detecção de bordas auto-adaptativo. Aqui, as bordas foram detectadas usando o operador Sobel. Os valores máximo e mínimo do gradiente absoluto são tomados como condições de limiar. Se o limite estiver acima do valor real, as bordas são máximas e, se o limite estiver abaixo, não há bordas. Finalmente, as bordas foram refinadas para obter bordas de imagem claras e contínuas. Durante este refinamento, a interpolação foi usada para obter os máximos locais. O algoritmo de detecção de borda adaptável para imagens de couro ajuda a encontrar bordas claras e contínuas. O algoritmo detectou centenas de defeitos na imagem da superfície do couro e as bordas do couro detectadas são claras e contínuas em comparação com o detector de bordas tradicional. Apenas a detecção de borda de um tipo de defeito foi mostrada; novamente, o método de detecção carece de validação mais ampla.

Liong et al. [14] utilizaram detectores de borda e abordagens estatísticas como extratores de características e obtiveram uma taxa de precisão de classificação de 84% a partir de uma amostra de aproximadamente 2.500 peças de 400 × 400 remendos de couro. Qingyuan et al. [27], Popov et al. [28], Lovergine et al. [29], e Kwak et al. [3] aplicaram operações morfológicas à inspeção de defeitos de couro, muitas vezes combinadas com outros algoritmos de segmentação gráfica.

Neste trabalho, avaliamos os detectores Sobel, Canny, Prewitt e Roberts combinados com operações morfológicas para a inspeção de quatro tipos de defeitos de couro (arranhões, superfícies podres, furos e olho de agulha) conforme mostrado na Figura 3. O código é implementado usando o kit de ferramentas Halcon, que é um famoso kit de desenvolvimento de software de visão de máquina no campo industrial. Os resultados detectados usando quatro tipos de detectores de borda são mostrados na Tabela 1, onde cada tipo de detecção possui 20 pedaços de imagens. Conforme mostrado na Tabela 1, os detectores de borda com operação morfológica não conseguem detectar muito bem os defeitos do couro. Entre os quatro defeitos, apenas buracos podem ser completamente detectados, e a taxa de sucesso fica entre 60 e 75%. Para os outros três defeitos, apenas parte da informação do defeito pode ser detectada na imagem. Portanto, podemos concluir que o algoritmo tradicional de detecção de bordas só pode ser usado para detecção de defeitos na superfície do couro com poucos desafios.



**Figura 3.** Quatro defeitos de couro diferentes: (a) furo; (b) ruga; (c) cicatrização de feridas; e (d) olho de agulha.

**Tabela 1.** Os resultados detectados usando detectores de borda.

Métodos	Buraco		Ruga		Olho de agulha de cicatrização de feridas			
	Tudo	Papel	Tudo	Papel	Tudo	Papel	Tudo	Papel
UMA	65%	15%	0%	65%	0%	70%	0%	60%

B	60%	15%	0%	70%	0%	0%	0%	60%
C	60%	20%	0%	50%	0%	35%	0%	70%
D	75%	10%	0%	0%	0%	65%	0%	60%

Método A—Filtragem média + Sobel + operações morfológicas; B—filtragem média + Roberts + operações morfológicas; C—filtragem média + Prewitt + operações morfológicas; e D—filtragem média + Canny + operações morfológicas.

#### 4.2. Método de limite

A segmentação baseada em limiares tem sido amplamente utilizada como ferramenta para segmentação de imagens. O método é baseado na suposição de que defeitos na imagem e pixels de fundo (tecido de couro normal) podem ser distinguidos por seus valores de escala de cinza. Como os valores de tons de cinza dos pixels pertencentes à região do defeito são mais escuros ou mais claros do que o fundo, pode ser possível separar o defeito do couro fino usando técnicas de limiarização. Teoricamente, uma vez que os objetos defeituosos são geralmente mais escuros e/ou mais claros do que o fundo, a função de densidade de distribuição dos valores de escala de cinza do pixel para imagens de superfície de couro pode ser aproximadamente expressa como uma combinação de três distribuições normais, dadas por [30]:

$$p(y) = \frac{1}{\sigma_1^2 \sqrt{2\pi}} \exp\left(-\frac{(y - \mu_1)^2}{2\sigma_1^2}\right) + \frac{1}{\sigma_2^2 \sqrt{2\pi}} \exp\left(-\frac{(y - \mu_2)^2}{2\sigma_2^2}\right) + \frac{1}{\sigma_3^2 \sqrt{2\pi}} \exp\left(-\frac{(y - \mu_3)^2}{2\sigma_3^2}\right) \quad (1)$$

Onde  $\mu_1$ ,  $\sigma_1^2$ ,  $\mu_2$ ,  $\sigma_2^2$ ,  $\mu_3$ ,  $\sigma_3^2$  e  $(\mu_1, \sigma_1^2)$  são a média e variâncias para o fundo,  $(\mu_2, \sigma_2^2)$  e  $(\mu_3, \sigma_3^2)$  são a média e variâncias para a parte mais escura e mais clara dos defeitos, respectivamente. No entanto, devido à pequena população de defeitos, a parte das distribuições no histograma que refletem os defeitos não é significativa o suficiente para formar picos dependentes [30]. Os métodos de limiar incluem o método de Otsu [31], método de histograma [3,32], decomposição em quadtree [33], etc.

O método Otsu é o método de limiar ótimo baseado na análise discriminante. Yeh et al. [31] estiveram envolvidos no estabelecimento de um padrão de compensação de comércio de couro usando o método Otsu para detectar defeitos. No entanto, o método Otsu pode falhar quando a proporção de pixels de fundo e objetos defeituosos em uma imagem for muito grande [31]. Portanto, o método Otsu não é adequado para inspeção de defeitos na superfície do couro.

A maioria dos estudos sobre métodos automáticos de limiar envolve a distribuição bimodal ou multimodal. histogramas de tributos. Na prática, as informações globais não podem descrever com precisão a região local devido à iluminação irregular e às mudanças de cor na superfície do couro. As pequenas vizinhanças dos pixels de interesse são geralmente consideradas. No entanto, devido à pequena proporção de regiões de defeitos em toda a superfície do couro, a maioria dos histogramas das pequenas sub-imagens permanecem unimodais mesmo que essas pequenas vizinhanças contenham defeitos. Alguns métodos de limiarização aproveitam o fato de que os histogramas em muitas sub-imagens se tornam bimodais ou multimodais para segmentação de defeitos de couro [3].

As distribuições em tons de cinza dos defeitos e ruídos da superfície do couro geralmente se sobrepõem, e as únicas duas diferenças distintas entre ruído e defeitos são sua densidade e tamanho. Isso complica a separação de defeitos de ruído usando apenas métodos tradicionais de limiar baseados em histograma (como limiares fixos ou adaptativos). Uma vez que uma única técnica de limiar baseada em histograma não poderia atender aos requisitos de inspeção de defeitos de couro, Kwak et al. [3] usam um procedimento de segmentação em duas etapas para inspeção com base em limiarização e processamento morfológico. Após o limiar da imagem de nível de cinza, a imagem binária resultante é processada por uma combinação de operações de dilatação e erosão morfológica binária juntamente com filtros medianos para remover o ruído e preencher os buracos nos defeitos detectados. Uma análise de componentes conectados binários é então aplicada à imagem binária processada.

A análise de imagem baseada em histograma permanece inalterada na rotação e dimensionamento da imagem, com as vantagens de pouca influência na perspectiva e rápido processamento de informações, mas a classificação pode dar errado devido à ausência de informações para a distribuição espacial de cores. Existem muitos critérios de classificação—teste  $\chi^2$ , interseção

coeficientes de relação, distância de Kolmogorov–Smirnov, divergência, etc. Georgieva et al. [32] discutiram a aplicação do critério  $\chi^2$  para análise de imagens de superfícies de couro e obtenção de seus histogramas padrão e pensaram que um dos critérios mais aplicáveis para os grandes tamanhos de imagem é o critério  $\chi^2$ .

Krastev et al. [33] investigaram 12 histogramas e características estatísticas e decomposição quadtree para análise de imagens de superfície de couro. Eles usaram uma técnica que particiona uma imagem em blocos homogêneos. Este método tem a possibilidade de investigar as alterações dos valores das feições em função do tamanho da área. O quadtree de composição é um método adequado para localizar rapidamente regiões defeituosas, mas a análise local adicional é necessária para a determinação exata do contorno do defeito. A maior diferença de valor de feições é obtida com uma maior proporção de pixels defeituosos/não defeituosos na área examinada. Os conjuntos de recursos mais apropriados para inspeção de defeitos na superfície do couro são as extremidades do histograma (borda esquerda e direita), mediana e valores médios.

Como a cor é um atributo importante para o reconhecimento visual da discriminação, e também os couros possuem cores diferentes, assim Kumar et al. [34] apresentaram uma abordagem de segmentação de limiar baseada em cores para identificação de defeitos de couro usando uma função de limiar multinível com uma determinada gama de características de cores. No trabalho apresentado, a faixa específica de valores para os atributos de cor é identificada usando o histograma de cores para detectar os diferentes defeitos do couro, o que poderia detectar com eficiência vários tipos de defeitos, como arame de pintinho, grão pesado e marcas de dobras usando limites para a inspeção automatizada em tempo real de defeitos de couro.

Neste trabalho, avaliamos o limiar local e o método de Otsu combinados com operações morfológicas para a inspeção de quatro tipos de defeitos de couro conforme mostrado na Figura 3. O código é implementado usando o kit de ferramentas Halcon. Os resultados detectados usando dois tipos de detectores de limiar são mostrados na Tabela 2. Conforme mostrado na Tabela 2, os dois tipos de métodos de detecção de limiar não são bons para detecção de defeitos de couro, ou são ainda piores do que a detecção de borda anterior.

**Tabela 2.** O resultado detectado usando o detector de borda.

Métodos	Buraco		Ruga		Olho de agulha de cicatrização de feridas			
	Tudo	Papel	Tudo	Papel	Tudo	Papel	Tudo	Papel
E	30%	50%	15%	40%	0%	70%	0%	60%
F	35%	0%	0%	10%	0%	0%	0%	0%

Método E—Filtragem gaussiana + limiar local + operações morfológicas; F—Filtragem Gaussiana + Otsu + operações morfológicas.

#### 4.3. Método de textura

A maioria das superfícies naturais tem um rico conteúdo textural, e essas macrotexturas de fundo podem ser finas e convexas, produzindo muitas arestas que são tão valiosas quanto as arestas de outros objetos. Alguns sistemas de visão de máquina geralmente exigem inspeção de defeitos da perspectiva da análise de textura. Em cada ponto de uma imagem com textura direcional, o campo vetorial direcional pode ser avaliado como um vetor 2D cuja direção corresponde à direção local principal do gradiente e um comprimento proporcional à sua consistência (grau isotrópico).

Algumas literaturas [29,35,36] separaram os defeitos de um fundo não homogêneo complexo analisando as propriedades de textura do couro e sua estrutura fortemente orientada. Os padrões a serem analisados foram representados em um espaço de parâmetros apropriado usando uma rede neural [29]; desta forma, um vetor de parâmetros é associado a cada região texturizada diferente na imagem original. Por fim, um processo de filtragem, baseado no conhecimento dos vetores de parâmetros que representam o couro sem defeitos, detectou e classificou qualquer anormalidade [29]. Na literatura [35], Branca et al. desenvolveu um algoritmo que remove o fundo textural discriminando as singularidades do sinal através de uma análise dos máximos da transformada wavelet indicando a localização das arestas em



imagens. O trabalho apresentado [35] integrou um framework de detecção de singularidade orientada baseado na teoria wavelet analisando texturas composicionais através dos campos vetoriais de orientações de gradientes locais dominantes. Lovergine et al. [36] apresentaram alguns resultados obtidos utilizando um detector de defeitos baseado na análise de textura orientada, que se revela útil para algumas classes de defeitos do couro, como cicatrizes ou dobras. Esses tipos de defeitos podem ser detectados usando uma câmera em preto e branco que percorre o remendo de couro e classificando as texturas com base em suas orientações de gradiente e coerência local. Um procedimento de segmentação morfológica foi aplicado ao campo de textura orientado regularizado para extrair prováveis áreas defeituosas. Além disso, a literatura [27] e [37] também utilizam as propriedades de textura do couro para inspeção de defeitos de couro, a primeira combinando morfologia matemática e a segunda combinando o detector de borda com um método de análise de textura para extrair defeitos.

O trabalho de Branca et al., que demonstrou a eficácia de métodos de inspeção de defeitos baseados na análise da textura do couro, mas com um custo computacional um tanto alto e baixa resistência à interferência, não é adequado para inspeção de defeitos menores. A análise de textura extensiva pode tornar a computação cara e pode deixar de atender aos requisitos de produção. Além disso, alguns defeitos podem ser muito sutis para influenciar fortemente o parâmetro do modelo estatístico [30].

#### 4.4. Método Espectral

Os métodos espectrais geralmente incluem transformada de Fourier, transformada wavelet e transformada de Gabor. A imagem de textura tem uma certa periodicidade na distribuição espacial, e seu espectro de potência tem descrição e regularidade. Para textura direcional, a diretividade será bem mantida no espectro de Fourier. Para texturas aleatórias, a distribuição de resposta do espectro não se limita a algumas direções específicas [38]. Como uma transformada global, a transformada de Fourier pode refletir bem a integridade do sinal, mas não é sensível ao domínio de frequência local. É mais adequado para detectar defeitos globais e únicos, e tem dificuldade em detectar imagens de couro pequenas ou com vários defeitos [39].

A transformada de Gabor é uma das transformadas de Fourier de curta duração. Uma função de janela gaussiana é adicionada para extrair a informação local da imagem, o que supera a desvantagem de que a transformada de Fourier não pode ser analisada localmente. Este é um método de análise multiescala no qual a janela tempo-frequência pode ser ajustada e a janela muda com o domínio da frequência. Ele pode fornecer boa direção e as características de seleção de escala são insensíveis a mudanças de iluminação, portanto, é adequado para análise de textura. A vantagem dessa transformação é que ela tem um bom efeito na descrição de texturas e pode ser aplicada a texturas estruturais e estatísticas. A desvantagem é que é necessário obter antecipadamente amostras sem defeitos e obter os parâmetros ótimos, que têm pouca portabilidade e robustez. A transformada de Gabor é usada principalmente para detectar defeitos com tamanho grande, mas é impotente para defeitos de tamanho pequeno e segmentação de imagem de textura aleatória complexa [38,40]. Yin et al. [39] propuseram um algoritmo de especificação de defeitos de couro baseado na transformada wavelet com função Gabor como função base com base nas características multidirecionais da função Gabor e na multi-resolução da transformada wavelet.

Na transformada wavelet, os componentes de frequência da imagem são organizados de tal forma que as frequências mais baixas e mais altas são separadas, o que também dá à imagem variações em diferentes escalas devido à sua análise de multi-resolução e, portanto, torna a transformada wavelet mais adequada para inspeção de defeitos de couro [41]. Sobral et al. [42] apresentaram uma metodologia baseada na transformada wavelet para detectar defeitos de couro, onde foram utilizadas a wavelet Haar não dizimada e oito filtros otimizados. A metodologia utilizou um banco de filtros otimizados, onde cada filtro é ajustado para um tipo de defeito. A forma do filtro e a sub-banda wavelet foram selecionadas com base na maximização da razão entre os valores das características nas regiões de defeitos e nas regiões normais. A morfologia foi avaliada usando um banco de dados de cerca de 150 amostras. O autor afirmou que o método foi capaz de atingir a mesma taxa de reconhecimento de um operador humano experiente. Adamo et al. [43] apresentado

uma técnica de redução de ruído baseada em wavelets bidimensionais de imagens de couro de alta resolução. Este método produziu um número adequado de níveis de decomposição da imagem, e executou uma operação de limiarização em detalhes e, finalmente, usando os níveis de limiar, produziu uma estimativa considerando o nível de ruído real. Ele et al. [44] desenvolveram um procedimento de seleção de banda wavelet para determinar automaticamente o número de níveis de resolução e decompor sub-imagens para a melhor discriminação de defeitos e remoção de padrões de textura repetitivos na imagem. O limiar binário adaptativo foi então usado para separar as regiões defeituosas do plano de fundo uniforme em nível de cinza na imagem restaurada. A metodologia não depende de características texturais para detectar anomalias locais e alivia todas as limitações dos métodos de extração de características. Com a seleção adequada de uma sub-imagem suave ou a combinação de sub-imagens detalhadas em diferentes níveis de multi-resolução para reconstrução de imagem, o padrão de textura repetitiva global pode ser removido com eficiência e apenas anomalias locais são preservadas na imagem restaurada.

#### 4.5. Método de agrupamento

Os defeitos da superfície do couro também podem ser vistos como imagens texturizadas espacialmente compostas por alguma coleção de pontos irregulares locais, de modo que a detecção de defeitos também pode ser vista como um processo de agrupamento. O mais utilizado na prática é o algoritmo Fuzzy C-Means (FCM).

Com base na otimização de enxame de partículas (PSO) e algoritmos de agrupamento difuso, He et al. [17] propuseram um método de detecção de defeitos na superfície do couro. Este método faz pleno uso das vantagens da otimização global e rápida convergência do PSO, encontra rapidamente a atribuição de pontos de amostra e combina o algoritmo de agrupamento difuso para agrupar as informações de textura da superfície do couro. A metodologia foi validada usando uma imagem de defeito de couro de 2000 × 1500 pixels para segmentação de defeitos, que é superior aos métodos convencionais, como detecção de borda de Sobel, Canny, Prewitt e Roberts. No entanto, a generalização e estabilidade da metodologia acima requerem mais validação. Cui [45] aplicou um algoritmo de agrupamento difuso para realizar a detecção automática de defeitos e determinar automaticamente o número ótimo de agrupamento. Baseia-se nas características da imagem do couro da média das cinco medidas calculadas a partir das direções de simbiose como o vetor de características de textura no centro da vizinhança. No entanto, apenas uma imagem de couro em escala de cinza de 256 × 256 foi usada para verificar sua eficácia. Embora os resultados experimentais relatados sejam válidos, a metodologia também carece de generalização. Na verificação experimental da detecção de defeitos baseada em FCM para a cicatriz não cicatrizada do couro e

côncavo, Yan [46] descobriu que a precisão de detecção foi seriamente afetada pela interferência de textura, e o pós-processamento subsequente não conseguiu separar os defeitos, e os defeitos foram submersos na interferência de textura. Com base no trabalho de Cui [45] et al., Chen [47] avaliou ainda mais o algoritmo FCM melhorado. Após a segmentação da imagem, a diferença entre as regiões com defeito e as regiões sem defeito torna-se maior, mas o resultado final da separação dos defeitos não pode ser alcançado. As regiões do defeito são um pouco desconexas, o que pode trazer menos ruído no processo de segmentação.

#### 4.6. Método Visual Saliente

A detecção de objetos de saliência da imagem concentra-se principalmente na proeminência de toda a imagem, cujo objetivo é destacar uniformemente a área do objeto que pode atrair a atenção visual na imagem, suprimir a área de fundo que não pode atrair a atenção visual e exigir a detecção de objeto ter limites claros; é amplamente utilizado em campos de visão computacional, como segmentação de imagens [48].

Zhu et al. [49] segmentaram os defeitos da superfície do couro com base em um mapa visual saliente que é fundido pela extração das características salientes de cor e brilho das imagens de couro, respectivamente. A metodologia tem um bom efeito de inspeção para defeitos com limites claros, abrasões, cicatrização e escavação, manchas de insetos e área pequena, e seu desempenho é melhor do que FCM e inspeção baseada em limiar. Para os defeitos dispersos, como feridas por faca não cicatrizadas, seu desempenho é um pouco pior, o que se deve principalmente às diferenças em sua saliência interna que resulta em defeitos mais superficiais que não podem ser

em destaque. Embora este método de inspeção não seja perturbado pela textura e possa realizar a inspeção rápida e eficaz de imagens de textura, o couro é suscetível à influência de fatores como força da fonte de luz e temperatura de cor, e esse método não pode atender à versatilidade da inspeção de defeitos do couro. Além disso, a borda dos defeitos não pode ser bem identificada, principalmente para os defeitos mais dispersos.

Liu et al. [50] propuseram um sistema de detecção de defeitos de couro baseado em visão estereó fotométrica e saliência da imagem. A tecnologia estereó fotométrica foi usada para realizar o aprimoramento da imagem, o que efetivamente evita o defeito de que o couro é fácil de ser afetado pela luz devido a diferentes cores e texturas. Ao mesmo tempo, o algoritmo residual espectral da imagem remove efetivamente a influência da informação de fundo, o que compensa a desvantagem de que o algoritmo tradicional de inspeção de alvo de saliência não pode extrair efetivamente o primeiro plano. Na inspeção de defeitos de superfície de couro, furo, dobra e diferença cromática, a taxa de precisão atingiu 96,84%. O algoritmo proposto por Liu [50] possui certa robustez, versatilidade e resistência ao ruído.

Ding et al. [51] classificaram quantitativamente os defeitos de couro por meio de análise estatística de geometria e escala de cinza para obter características salientes de cada defeito. Em seguida, as características salientes são combinadas com aquelas extraídas pela rede neural convolucional para inspeção de defeitos, onde as características extraídas pela rede neural convolucional são dominantes, o que melhora a precisão da inspeção de defeitos usando redes neurais convolucionais.

#### 4.7. Segmentação de defeitos baseada em algoritmos heurísticos

Como uma alternativa à análise de textura, limiar de histograma, agrupamento e assim por diante, vários algoritmos de inspiração biológica foram explorados na segmentação de imagens. Jamadar et al. [52] desenvolveram um algoritmo de otimização de enxame de partículas de convergência rápida (FCPSO) para segmentar regiões defeituosas em imagens complexas de couro. O Particle Swarm Optimization (PSO) é um algoritmo heurístico vagamente inspirado em pássaros voando em busca de comida. Comparado com PSO convencional e outras variantes de PSO, o algoritmo acima mostrou-se eficiente para várias imagens de defeitos de couro. As características de textura da matriz de coocorrência de nível de cinza (GLCM) do couro segmentado foram extraídas como entrada para diferentes classificadores supervisionados, a saber, Rede Neural, Árvore de Decisão, Máquina de Vetor de Suporte, Naïve Bayes, k Vizinho Mais Próximo e Floresta Aleatória. O FCPSO, juntamente com o algoritmo Random Forest, usando o conjunto de recursos ótimo, teve boa discriminação entre couro defeituoso e não defeituoso.

#### 4.8. Resumo desta seção Os

métodos tradicionais de processamento de imagens geralmente precisam de vários limites visando vários defeitos nos algoritmos. Eles são muito sensíveis às condições de iluminação e cores de fundo. Quando surge um novo problema, esses limiares precisam ser ajustados, ou pode até ser necessário redesenhar os algoritmos [6]. Transformada wavelet, morfologia matemática, filtragem Gabor, agrupamento difuso, detecção de bordas, segmentação baseada em limiar e outros métodos convencionais de processamento de imagem têm sido aplicados à inspeção de defeitos na superfície do couro. Isso mostra alguma eficácia nos conjuntos de dados relatados. No entanto, existem poucos exemplos de literatura relacionados a esses estudos, a pesquisa não é profunda o suficiente, os conjuntos de dados de teste são relativamente pequenos, a diversidade de defeitos é insuficiente e a mudança dinâmica dos defeitos do couro não é considerada, por isso é difícil para garantir o desempenho de generalização desses algoritmos. Além da falta de um benchmark adequado, outro problema que dificulta a avaliação comparativa completa dos métodos de inspeção de defeitos de couro é a falta de software/código publicamente disponível em relação aos métodos relatados [2].

## 5. Métodos baseados em aprendizado de máquina

Nos últimos anos, muitas tarefas de inspeção de defeitos podem ser resolvidas projetando um conjunto de recursos para um determinado defeito e fornecendo esses recursos a um classificador simples; esses métodos também são chamados de abordagens baseadas em conhecimento [8]. Nesta seção, investigaremos esses métodos de aprendizado de máquina com base em recursos artesanais ou técnicas de aprendizado superficial para inspeção de defeitos na superfície do couro. Os métodos baseados em aprendizado de máquina geralmente incluem dois estágios de extração de recursos e classificação de padrões.

### 5.1. Extração de Característica de Defeito de Couro

As características do defeito da superfície do couro podem ser divididas em características estatísticas, características espectrais, características de textura estrutural, características de forma, características de cor e assim por diante. Essas características de cor, textura e formato do defeito são amplamente utilizadas para identificar a imagem do couro para realizar a inspeção do defeito [51]. Conforme mostrado na Tabela 3, os recursos mais utilizados são recursos estatísticos e recursos de cores.

#### (1) Características estatísticas

A inspeção do couro é considerada um problema muito complexo no campo da classificação de texturas. Como a maioria das texturas naturais, os autovalores mudam muito e é fácil formar uma estrutura pseudo-aleatória, mas ainda segue a lei da distribuição estatística.

Métodos estatísticos podem ser usados para analisar a distribuição de texturas. Na extração de recursos de textura de imagens de couro, os recursos estatísticos de textura amplamente utilizados incluem principalmente o recurso de histograma e o recurso de matriz de coocorrência de nível de cinza (GLCM).

O histograma de uma imagem é usado para representar a distribuição dos valores de pixel da imagem, o que fornece muitas informações sobre a imagem. Os recursos do histograma incluem máximo, mínimo, média, mediana, intervalo de valores, entropia, variância e entropia. Esses recursos de histograma são simples de calcular, insensíveis à distribuição espacial dos pixels de cor e têm as vantagens de invariância de translação e rotação. Assim, tem sido amplamente utilizado no campo da inspeção de defeitos de superfície [38].

A matriz de co-ocorrência de nível de cinza é uma técnica comum e amplamente utilizada na análise de texturas. Como a textura é formada pela ocorrência repetida de distribuição de cinza na posição espacial, haverá uma certa relação de cinza entre dois pixels separados por uma certa distância no espaço da imagem, ou seja, a correlação espacial de cinza na imagem. O GLCM descreve as características de correlação espacial do nível de cinza. Vários GLCMs devem ser construídos para cada janela deslizante que varre a imagem durante a segmentação. Cada GLCM possui um ângulo e deslocamento associados, relacionados à direção e frequência que serão representadas por este GLCM. Os recursos de textura artesanal mais bem sucedidos e usados na literatura são os recursos de Haralick [52] derivados do GLCM. Com base no GLCM, Haralick calculou 14 recursos estatísticos [51]: energia, entropia, contraste, uniformidade, correlação, variância, média de soma, variância de soma, entropia de soma, variância de diferença, média de diferença, entropia de diferença, medida de informação de correlação e coeficiente de correlação máximo. Esses recursos estatísticos se encaixam bem para capturar a correlação espacial dos valores de nível de cinza que contribuem para a percepção de textura.

As grandezas características comumente usadas são contraste, correlação, energia, entropia e autocorrelação.

#### (2) Recursos de cores

A cor é um parâmetro importante dos recursos externos da imagem. Os recursos de cor são sensíveis à mudança de rotação, translação e escala da imagem. Os modelos de cores incluem principalmente HSV, RGB, HSI, etc. Recursos de cores comuns incluem histograma de cores, conjunto de cores, momento de cores e vetor de agregação de cores.

Bongo et al. [53] dividiram a imagem RGB de couro em três canais de cores (vermelho, verde e azul), calcularam a média, o desvio padrão e o valor de assimetria em cada canal de cor e, em seguida, converteram a imagem RGB em uma imagem cinza para obter o cinza recurso de momento. Por fim, o momento de cor e o momento de cinza de cada canal de cor foram com-

combinados para formar o momento de cor da imagem. Ao mesmo tempo, os recursos da imagem central colorida na imagem cinza foram extraídos como parte do conjunto de recursos [54–57]. Amorim et al. [57] extraíram o valor médio de cada componente de cor de HSB e RGB e o valor do histograma 3D do espaço de cor HSB e RGB como parte do recurso de defeito de superfície de couro

definir.

### (3) Características

**espectrais** A transformação de filtro transforma a imagem do domínio espacial para o domínio da frequência ou domínio do tempo-frequência. A transformada de Fourier, a transformada wavelet e a transformada de Gabor são comumente usadas. A transformada de Fourier transforma a imagem em um domínio de frequência e usa energia espectral ou entropia espectral para expressar a textura. Periodicidade, direcionalidade e aleatoriedade são os três fatores importantes para caracterizar a textura [54].

A saída do filtro Gabor pode ser usada como um recurso de textura, mas a dimensão é alta.

Para reduzir a quantidade de dados no conjunto de recursos, métodos de pós-processamento como suavização, recurso de energia Gabor, recurso de momento complexo e análise de componentes independentes são frequentemente usados para a saída do filtro Gabor. A transformada wavelet organiza os componentes de frequência da imagem e separa a baixa frequência da alta frequência. Devido à análise multi-resolução da transformada wavelet, as características do extrato mudam em diferentes escalas. Uma série de imagens de sub-banda de alta frequência representando informações de diferentes direções constitui imagens com diferentes resoluções.

As imagens de sub-banda de alta frequência refletem as características de textura da imagem. Portanto, a transformada wavelet é adequada para o reconhecimento de defeitos de couro. As transformações wavelet tradicionais da pirâmide apenas decompõem a parte de baixa frequência, enquanto a parte de alta frequência da imagem de textura também pode conter informações importantes sobre recursos. A decomposição do pacote wavelet ou a decomposição wavelet da estrutura em árvore pode superar essa desvantagem. O método da transformada wavelet tem sido amplamente utilizado para extrair características da imagem para inspeção de defeitos de superfície [38]. Jawahar et al. [41] usaram a transformada wavelet para extrair características estatísticas wavelet e características da matriz de coocorrência wavelet de imagens de couro, como entropia, energia, contraste, correlação, significância de agrupamento, desvio padrão, valor médio e uniformidade local, que foram usados como a entrada do classificador. Sobral et al. [42] extraíram recursos de textura usando a transformada wavelet Hal e oito filtros otimizados para obter a mesma taxa de reconhecimento de um operador humano experiente.

### (4) Recursos de textura estrutural

O método de análise estrutural realiza a análise de texturas orientada de acordo com as características de periodicidade da textura e geometria espacial [38]. De um modo geral, os defeitos na superfície do couro são caracterizados por uma estrutura de orientação específica, que pode ser representada pelo campo de orientação. O campo de orientação de uma imagem compreende a imagem de ângulo e a imagem de coerência. O primeiro (representando a orientação local dominante) é calculado sobre uma vizinhança de cada ponto a partir das orientações dos gradientes avaliados na imagem original suavizada usando um filtro gaussiano. Com  $\theta_{ij}$  como a representação polar do vetor gradiente no ponto  $(i, j)$ , a direção principal do gradiente geralmente em  $(m, n)$  com vizinhança  $x$  pode ser estimada como Equação (2), e o local dominante direção é dada por  $\theta_{ij} + 2\pi$  [35].

$$\theta_{ij} = \frac{1}{2} \arctan \frac{\sum_{x \in N} \cos(\theta_{ij} - \theta_x) \cos(\theta_x)}{\sum_{x \in N} \cos(\theta_{ij} - \theta_x) \sin(\theta_x)} \quad (2)$$

Os métodos de análise estrutural comumente usados também incluem morfologia, teoria dos grafos, topologia e assim por diante. A literatura [27,28] aplicou a morfologia matemática para analisar as características de textura de estruturas complexas. Popov et al. [27] extraíram características fractais locais de uma série de escalas baseadas em morfologia matemática para classificação de textura de superfícies de couro escovado. Qing et al. [27] também propuseram um método de classificação de texturas baseado em morfologia matemática. As características globais foram complementadas pelas características locais para a classificação do couro do mesmo material. Branca et al. [29,35,36]

usou o método de estrutura para extrair as características de borda da imagem para inspeção de defeitos na superfície do couro. Ao analisar a estrutura orientada do defeito, o defeito foi separado do fundo não uniforme complexo.

### (5) Características de

**forma** Em termos de geometria, os defeitos do couro podem ser divididos em três tipos: ponto, linha e superfície. Cada tipo de defeito é dividido em diferentes categorias de acordo com a forma geométrica. Alguns defeitos podem ser distinguidos de outros por quatro características: circularidade, área, linearidade e largura [51]. Entre eles, a redondeza e a área podem ser usadas como característica saliente de manchas pretas e superfícies podres. Linearidade e largura podem ser usadas como características salientes de arranhões, decotes e tendões sanguíneos. A área de defeitos de superfície, como a marca, é muito maior do que a de outros defeitos de superfície, de modo que a área pode ser usada como a característica principal da marca. Os defeitos pontuais têm alta circularidade e pequena área, enquanto os defeitos lineares têm as características de pequena largura e alta linearidade. Ding et al. [51] produziram estatísticas matemáticas sobre as características geométricas e cinzas de defeitos, resumiram as características salientes de defeitos de couro e propuseram um método de inspeção combinando rede neural de convolução e características salientes para de

### (6) Mapas de interação

Viana et al. [55] usaram mapas de interação [56] como o descritor de recursos para identificação de defeitos de couro, que combinam com matrizes de coocorrência cinza, RGB e o espaço de cores HSB para extrair recursos de textura e cor de um determinado conjunto de imagens de couro cru. O termo “mapa de interação” foi originalmente introduzido por Gimelfarb em seu modelo de textura de Markov Gibbs com interações de pixel em pares [56]; refere-se à estrutura das interações estatísticas par a pixel avaliadas através da dependência espacial de uma característica do histograma de diferença de nível de cinza estendido (GLDH). As suposições básicas da abordagem do mapa de interação baseado em recursos são as seguintes: (1) As interações de pixel em pares carregam informações estruturais importantes. (2) As interações de curto e longo alcance são relevantes. (3) A resolução angular fina é essencial. (4) As informações estruturais podem ser obtidas por meio de recursos da EGLDH. Isso pode ser alcançado com mais eficiência analisando a dependência espacial dos recursos do que selecionando os recursos “ótimos” para um número limitado de espaçamentos predefinidos. (5) A orientação da textura pode ser definida pelos eixos de simetria estatística máxima [56].

#### 5.2. Seleção de recursos

A extração de características de imagens de superfície de couro implementa uma transformação do espaço de imagem para o espaço de características, mas nem todas as características são úteis para a identificação de defeitos subsequentes. Se o número de recursos extraídos for grande, é provável que haja informações redundantes nesses recursos, o que não só é incapaz de melhorar a precisão da inspeção, mas também de aumentar a complexidade do algoritmo de processamento de imagem. O objetivo da seleção de recursos é descobrir os recursos realmente úteis dos recursos da imagem original, reduzir a complexidade do algoritmo e melhorar a precisão da classificação e identificação. Os métodos de seleção de recursos comumente usados incluem Análise de Componentes Principais (PCA), Análise de Componentes Independentes (ICA), Análise Discriminante Linear de Fisher (FLDA), Seleção de Recursos Baseada em Correlação (CFS), Algoritmo Evolutivo e métodos populares de redução de dimensionalidade não linear, e assim por diante [38].

Amorim et al. [57] avaliaram cinco abordagens baseadas em FLDA para redução de atribuição. As técnicas foram testadas em combinação com quatro classificadores e diversos atributos baseados em matrizes de coocorrência, mapas de interação, bancos de filtros Gabor e dois espaços de cores diferentes. A Análise de Componentes Principais desempenha um papel importante nesses métodos. Experimentos mostraram que para a inspeção de defeito de couro molhado azul sem singularidade, o melhor caso é usar 24 atributos, e para a inspeção original de defeito de pele de animal sem singularidade, o melhor caso é usar 16 atributos.

Villar et al. [58] escolheram características baseadas no método Sequential Forward Selection (SFS), que permite uma grande redução do número de descritores. Esses descritores

são computadorizados a partir de imagem em tons de cinza, RGB e modelo de cores HSV, e há 2.002 recursos no total. Os descritores extraídos podem ser classificados em sete grupos: (i) estatísticas de primeira ordem; (ii) características de contraste; (iii) descritores Haralick; (iv) transformada de Fourier e cosseno; (v) Momentos Hu com informações sobre a intensidade; (vi) padrões binários locais; (vii) Características do Gabor. O SFS permite classificar os descritores com base em sua contribuição para a classificação. Para determinar o número de características necessárias para classificar, o seguinte procedimento é seguido: um classificador é vinculado a cada classe de interesse. Os classificadores são treinados com um determinado número de características e a porcentagem de sucesso na classificação é calculada. Treinamentos sucessivos dos classificadores são realizados, incrementando o número de características com base na classificação fornecida pelo SFS. São necessárias apenas 10 características, do universo de 2002 inicialmente computado.

### 5.3. Identificação baseada em aprendizado de máquina

A identificação de defeitos na superfície do couro é essencialmente um problema de classificação. Os defeitos devem ser classificados em classes apropriadas de acordo com sua causa e origem para localizar a fonte responsável por esses defeitos e tomar medidas corretivas [3]. Esse processo de classificação é necessário porque desempenha um papel importante no fornecimento de informações para a prevenção de defeitos. A identificação tradicional de defeitos na superfície do couro é usada para identificar defeitos usando um algoritmo de reconhecimento de padrões baseado na extração de características de imagem como medidas estatísticas de primeira ordem, medidas estatísticas de segunda ordem, medidas espectrais ou descritores de nível de imagem (padrões binários locais e características Gabor). Algoritmos comumente usados como k Nearest Neighbor (KNN), Neural Network (NN), Support Vector Machine (SVM), Bayesian Network (Bayes) e Decision Tree (DT) são amplamente utilizados na identificação de defeitos na superfície do couro. Com base nos resultados relatados em alguma literatura, a Tabela 3 apresenta alguns elementos de precisão de classificação utilizados por esses algoritmos para identificação de defeitos de couro.

Como pode ser visto na Tabela 4, a precisão de classificação da maioria dos métodos atingiu acima de 90% [59-68], e o método KNN na literatura [59] chegou a 100%. Esse desempenho pode ser parcialmente atribuído a todos esses métodos sendo avaliados em conjuntos de dados locais muito pequenos [2,60]. Conforme mostrado nas Tabelas 4 e 5, Pistori et al. [59] extraíram 2.000 amostras em 16 imagens para avaliar seu modelo, enquanto Viana et al. [55] extraíram 14.722 amostras em 15 imagens para avaliar seu método. O maior conjunto de teste usado para avaliação nesses estudos consistiu em apenas aproximadamente 200 imagens. Dadas as possíveis mudanças naturais nas amostras de couro durante o processamento industrial, este é o pequeno conjunto de dados de teste [2]. A maioria dos métodos de classificação de defeitos de couro na literatura relatam apenas as métricas de desempenho selecionadas em seus dados personalizados, o que é uma das principais razões para a dificuldade em realizar uma avaliação comparativa abrangente dos mesmos. Notavelmente, esses conjuntos de dados contêm no máximo 10 categorias de defeitos, mas a maioria inclui de três a quatro categorias.

Embora o conjunto de dados usado por Jawahar et al. [52,61,62] contêm 10 categorias de defeitos, é dividido em dois tipos: defeito e nenhum defeito. Todos os conjuntos de dados usados na literatura [14,41,63,66,68] contêm apenas um defeito, que é essencialmente uma classificação binária.

**Tabela 3.** Conjunto de dados utilizado na literatura.

Ref.	Tamanho da	Dados	Raw ou Wet Blue	Animal
1. Kwak et al. [3]	140	amostra 140 amostras de defeitos com janelas de aproximadamente 8 cm × 12 cm, 60 amostras para treinamento e 80 amostras para teste.	desconhecido	desconhecido
2. Pistori et al. [59]	2000	Amostras com janelas de 10 × 10, 20 × 20, 30 × 30 e 40 × 40 pixels de dezesseis imagens, 400 para cada defeito. 14722 amostras com janelas de 20 × 20	couro cru molhado azul	bovino
3. Viana e cols. [55]	14.722	pixels escaneando trinta segmentos extraídos de quinze imagens bovinas: 2819 carrapato, 3716 marca, 2804 corte e 5383 sarna.	couro cru	bovino
4. Amo. et al. [57]	2000	2.000 amostras, consistindo de uma janela de 40 × 40 pixels de 50 peças diferentes de couro wet blue, e	azul molhado	gado
5. Villar et al. [58]	1769		azul molhado	carne

718 normais				
6. Mandíbula. et ai. [41]	700	700 imagens de couro com 256 x 256 pixels compreendendo 500 amostras defeituosas e 200 não defeituosas.	desconhecido	desconhecido
7. Bong et al. [53]	2500	Os dados de treinamento consistem em 2.000 amostras; 400 amostras para cada tipo de defeito; teste em 500 amostras	desconhecido	desconhecido
8. Filho et al. [60]	350	foram construídas 350 peles de cabra contendo 50 imagens de cada classe. Cada imagem tem um tamanho original de 3456 x 4608 90 imagens de couro compreendendo	Azul molhado	cabra
9. Mandíbula. et ai. [61]	90	20 couro bom e 50 amostras defeituosas couro crust tingido desconhecido 1874 amostras de 150 imagens de couro de cabra; 882 amostras sem		
10. Pere. et ai. [63]	1874	defeito, 992 amostras com defeito com 10 tipos de defeito 115 com defeito e 85 amostras sem defeito Conjunto de dados I: 199 amostras com defeito e 199 amostras sem defeito Conjunto de dados II: 503 amostras com defeito e 1102 amostras sem defeito 1605 peças de bezerro	desconhecido	desconhecido
11. Mandíbula. et ai. [52]	200	remendos de couro com o tamanho de 90 x 60 mm2, 503 amostras com um ou mais defeitos de picada de carrapato, 1102	desconhecido	desconhecido
12. Gan et al. [65]	398	amostras não defeituosas 2378 amostras de remendos de amostra em um pedaço de couro de aproximadamente 90 x 60 mm, 475 amostras	azul molhado	desconhecido
	1605	têm pelo menos um defeito de picada de carrapato, 1903 amostras não defeituosas. 2000 amostras defeituosas e não defeituosas	azul molhado	bezerro
13. Gan et al. [66]	1605		azul molhado	bezerro
14. Liong et al. [14]	2378		azul molhado	bezerro
15. Moga. et ai. [67]	2000		desconhecido	desconhecido

Tabela 4. Identificações de defeitos de superfície de couro tradicionais baseadas em aprendizado de máquina.

Ref.	#Classe	Descritores de recursos	Classificadores	Melhor Ac.
1. Kwak et al. [3]	6	Medida de compacidade normalizada; medidas estatísticas de primeira ordem; matriz de coocorrências de nível de cinza	Árvore de decisão	91,3%
2. Pistori et al. [59]	5	Matrizes de coocorrência de nível de cinza; recursos de cores no espaço de cores HSB	SVM, NN, KNN	100%
3. Viana e cols. [55]	5	Mapas de Interação; matrizes de coocorrências em nível de cinza; Cores RGB e HSB	SVM	99,6%
4. Amo. et ai. [57]	7	Matriz de co-ocorrência cinza variando; mapas de iteração variando; Recursos de filtros Gabor; Recursos de cores RGB e HSB (redução de atributos para a seleção de recursos) (i) Estatísticas de primeira ordem; (ii) características de contraste; (iii) matrizes	C4.5, KNN, Naive Bayes, SVM	95,9%
5. Villar et al. [58]	4	de coocorrências em nível de cinza; (iv) transformada de Fourier e cosseno; (v) Momentos Hu com informações sobre intensidade; (vi) padrões binários locais; (vii) Recursos de filtros Gabor (método de seleção direta sequencial para a seleção de recursos)	NN	96,6%
6. Mandíbula. et ai. [41]	2	Características estatísticas wavelet; recursos de coocorrência wavelet	SVM	98,8%
7. Bong et al. [54]	4	Momentos de cor, correlogramas de cores, momentos de Zernike e histograma de nível de cinza	SVM	98,8%
8. Filho et al. [60]	6	Matrizes de coocorrências de nível de cinza	Naive Bayes, Floresta, SVM	93,2%
9. Mandíbula. et ai. [61]	2	12 recursos de textura; transformada discreta de cosseno	NN	88,6%
10. Pere. et ai. [63]	2	Matriz de coocorrências em nível de cinza; padrões binários locais (LBP); matriz de co-ocorrência estrutural (SCM)	MLP	90,3%
11. Mandíbula. et ai. [52]	2	Coocorrência de nível de cinza	MLP,DT, SVM, KNN, RF, Bayes	88,6%
12. Gan et al. [65]	2	Características estatísticas: média, variância, valor do quartil superior, valor do quartil inferior, inclinação e curtose Histograma de gradiente após seis etapas de pré-	SVM,DT,NN, Bayes, LR, KNN	99,8% 77,1%
13. Gan et al. [66]	2	processamento: correspondência de histograma, redimensionamento, normalização de escala de cinza, desfoque gaussiano e detecção de borda Canny.	NN, XBoost, KNN, SVM	94%
14. Liong et al. [14]	2	Detetores de borda e abordagem estatística, histograma de valores de intensidade de pixel, histograma de gradiente orientado, padrão binário local	SVM,DT,NN,KNN, Conjuntos	84%
15. Moga. et ai. [67]	6	Matriz de coocorrência de nível de cinza	NN	94,2%
16. Vaso. et ai. [68]	2	Combinando detecção de borda Canny, transformação de chapéu preto e transformação Hough	SVM	94,5%

#Class: Número de tipos de defeitos no conjunto de dados.

Tabela 5. Tipo de defeito utilizado na literatura.

Ref.	#Classe	Defeitos
1. Kwak et al. [3]	5	Linha, buraco, nó, mancha, desgaste
2. Pistori et al. [59]	4	Marcas feitas de ferro quente, marcas de carrapato, cortes e sarna



3. Viana e cols. [55]	4	Marcas de carrapato, marcas de ferro quente, cortes e sarna
4. Amo. et al. [57]	6	Marcas de ferro quente, carrapatos, cortes abertos, cortes fechados, sarna e larvas de mosca-
5. Villar et al. [58]	3	das-máquinas Corte aberto, corte fechado e picada de mosca
6. Mandíbula. et al. [41]	-	Problema de classificação de duas classes: defeito e sem defeito Cicatrizes,
7. Bong et al. [54]	3	arranhões, pinholes Sete classes de qualificação
8. Filho et al. [60]	-	diferenciadas de acordo com o nível de qualidade do couro Infecção bacteriana, marca de varíola, mancha
9. Mandíbula. et al. [61]	9	de cromo, arranhão, marca de crescimento, grão fora, aderência fúngica, mancha de corante, jateamento de cal Risco de fio e corte de faca, má conservação, sinal, bexiga,
10. Pere. et al. [63]	10	sarna, picada de mosquito, cicatriz, rufa, gordura vegetal, buraco. 9 tipos de defeitos Conjunto de dados I: defeitos de linha escura com largura de ~7 pixels a ~80 pixels com
11. Mandíbula. et al. [52]	9	média de ~20 pixels Conjunto de dados II: defeitos circulares
12. Gan et al. [65]	1	semelhantes a mordidas de carrapato que variam muito em área, de 30 pixels <sup>2</sup> a 3195 pixels <sup>2</sup> . A área média dos defeitos é de 480 pixels <sup>2</sup> Defeitos de mordida de carrapato
13. Gan et al. [66]	1	
14. Liong et al. [14]	1	
15. Moga. et al. [67]	5	Defeitos de mordida de carrapato
16. Vaso. et al. [68]	-	Marcas de dobra, granulação, marcas de crescimento, granulação solta e orifícios de pinos

#Class: Número de tipos de defeitos no conjunto de dados.

Para avaliar ainda mais o desempenho dos métodos tradicionais de aprendizado de máquina acima no reconhecimento de defeitos de couro, o SVM é selecionado para avaliação usando diferentes conjuntos de recursos listados na Tabela 6. É o método mais comumente usado para identificação de defeitos de couro, conforme mostrado na Tabela 5. O conjunto de dados da literatura [19] é usado para a avaliação. SVC com função de kernel gaussiana, linear e polinomial é avaliada, onde os parâmetros ótimos são selecionados pelo método de validação cruzada, respectivamente. O experimento resulta em três conjuntos de recursos conforme apresentado na Tabela 7. Conforme mostrado na Tabela 7, existem dois grupos de experimentos usando recursos de textura; a precisão de reconhecimento de SVC com função de kernel gaussiana, linear e polinomial não é alta. Quando o recurso de cor é adicionado, a precisão máxima atinge 86% e o desempenho é bastante aprimorado. A extração e seleção de recursos têm um grande impacto no desempenho do algoritmo. O projeto do extrator de recursos exige que os projetistas tenham um rico conhecimento prévio e geralmente é bem projetado manualmente por engenheiros experientes caso a caso, tornando o ciclo de desenvolvimento relativamente complexo e demorado. O desafio é que tal método dificilmente pode ser generalizado ou reutilizado e pode ser inaplicável em uma aplicação real.

Tabela 6. Descrições de recursos para avaliação experimental.

Nº do recurso	Descrições de recursos
F1	A média e variância do histograma da imagem cinza O contraste,
F2	correlação, energia, entropia e autocorrelação de GLCM de 0°, 45°, 90° e 135° Recursos estatísticos de wavelet e recursos
F3	de matriz de coocorrência de wavelet [41 ]
F4	A média, variância, assimetria e curtose do histograma de cores da imagem RGB e HSV A imagem RGB do
F5	primeiro, segundo e terceiro momento de cor.

Tabela 7. Identificação de defeitos de superfície de couro com base em SVM.

Defeito de recurso	SVC com Kernel Gaussiano SVC com Kernel Linear SVC com Kernel Polinomial F1.								
	Recuperação de precisão			Recuperação de precisão			F1.	Recuperação de precisão	
F2	Superfície podre	0,81	0,87	0,84	0,89	0,16	0,27	0,89	0,16
	Olho de agulha	0,42	0,25	0,31	0,27	0,21	0,23	0,27	0,21
	Arranhar	0,33	0,39	0,36	0,23	0,27	0,25	0,23	0,27

	Furos	0,78	0,71	0,74	0,98	0,87	0,92	0,98	0,87	0,92
	Sem defeito	0,74	0,93	0,82	0,34	0,68	0,45	0,34	0,68	0,45
		Precisão = 0,63			Precisão = 0,44			Precisão = 0,58		
F1 + F2 + F3	Superfície podre 0,90		1,0	0,99	0,87	1,00	0,93	0,90	1,00	0,94
	Olho de agulha	0,29	0,28	0,52	0,49	0,25	0,33	0,30	0,28	0,29
	Arranhar	0,26	0,25	0,26	0,33	0,55	0,41	0,28	0,28	0,28
	Furos	0,54	0,50	0,28	0,82	0,47	0,60	0,58	0,53	0,55
	Sem defeito	0,97	1,0	0,95	0,91	1,00	0,95	0,98	1,00	0,99
		Precisão = 0,61			Precisão = 0,65			Precisão = 0,62		
F1 + F2 + F3 + F4 + F5	Superfície podre 1,00		1,00	1,0	1,00	1,00	1,00	0,95	1,00	0,98
	Olho de agulha	0,85	0,87	0,86	0,96	0,46	0,62	0,97	0,70	0,81
	Arranhar	0,72	0,34	0,46	0,57	0,69	0,62	0,69	0,67	0,68
	Furos	0,72	0,87	0,79	0,78	1,00	0,87	0,75	0,93	0,83
	Sem defeito	0,76	1,00	0,87	0,99	1,00	1,00	0,98	1,00	0,99
		Precisão = 0,82			Precisão = 0,83			Precisão = 0,86		

Os produtos de couro vêm principalmente de gado, crocodilos, lagartos, cabras, ovelhas, búfalos e peles de vison. Cada tipo de couro animal tem uma textura diferente e um ambiente de vida diferente. Yeh [3] coletou e categorizou um conjunto de defeitos de couro de bezerro em 7 grandes categorias por forma, 24 defeitos em formas regulares e 17 defeitos de tipos irregulares. Mesmo o mesmo tipo de defeito varia muito em forma, tamanho e cor. Mais de 10 defeitos podem ser apresentados em uma imagem com diferentes contrastes. Portanto, os algoritmos mostrados na Tabela 3, tanto o número de conjuntos de amostras de teste quanto os tipos de defeitos identificados pela classificação, são muito diferentes dos defeitos da superfície do couro em aplicações industriais práticas. Embora o método tradicional de aprendizado de máquina mostrado na Tabela 3 tenha alta precisão de reconhecimento, nossos resultados experimentais mostram que o progresso do reconhecimento atingiu apenas 86%. A precisão do reconhecimento é muito afetada pelos dados de defeitos da superfície do couro e pelos recursos extraídos. Esses resultados devem ser considerados com cautela, pois cada defeito é retirado apenas de duas peças diferentes de couro e não representa todas as configurações possíveis de possíveis defeitos, por exemplo, tamanho, cor e orientação diferentes [2]. Isso também significa que, em termos de uso de métodos tradicionais de aprendizado de máquina, ainda há muito trabalho a ser feito.

## 6. Inspeção de Defeitos de Couro Baseada em Aprendizado

**Profundo** Conforme descrito na Seção 5, a forma da imagem do defeito na superfície do couro é variável e aleatória. Pode haver mais de dez defeitos em uma imagem. Mesmo o mesmo defeito é muito diferente na imagem. A extração de características estatísticas de textura representada pela matriz tradicional de coocorrência de níveis de cinza tem uma grande quantidade de cálculo, e sua eficácia também é desafiada pela alta variação de defeitos superficiais do couro. O aprendizado profundo (DL) adota a estrutura hierárquica de várias camadas neurais e extrai informações dos dados de entrada por meio do processamento camada por camada. Essa estrutura de camada “profunda” permite aprender a representação de dados originais complexos com vários níveis de abstração e aprender recursos diretamente da imagem original. Eles realizam engenharia de recursos para produzir recursos naturais de imagens, combinando as duas etapas tradicionais: extração e classificação de recursos, juntos como um paradigma de ponta a ponta [52]. Tem sido amplamente utilizado no campo do processamento de imagens e tem alcançado resultados notáveis. Aslam et al. [2] sugeriram que a arquitetura de aprendizado profundo pode ser usada como fonte de diretrizes para o projeto e desenvolvimento de novas soluções para inspeção de defeitos de couro. Atualmente, os métodos de aprendizado profundo (DL) estão avançando em ritmo acelerado e se tornaram uma estratégia de aprendizado baseada em dados promissora para inspeção de defeitos de superfície de couro [5,19,69-76]. Diferentes métodos baseados em DL foram aplicados para tarefas de inspeção de defeitos de couro, como detecção e identificação.

### 6.1. Deep Learning para Detecção de Defeitos de Couro

A Tabela 8 lista alguns aplicativos baseados em DL para detecção de defeitos na superfície do couro. Liong et al. [69] desenvolveram um sistema de identificação automática de inspeção de defeitos de mordida de carrapato baseado na Rede Neural Convolutiva Regional (Máscara R-CNN), que pode marcar automaticamente o limite da região do defeito. A picada do carrapato causa pequenos danos na superfície da pele do animal, que muitas vezes são ignorados pela inspeção humana. Mask R-CNN é um modelo de segmentação de imagem popular que construiu uma rede de pirâmide de recursos (FPN) [57] com um backbone Res Net-101 [70]. Este é um sistema de detecção de defeitos de ponta a ponta. O braço do robô é usado para coletar e marcar defeitos automaticamente. Para formar uma máscara delimitadora contínua para cada defeito, todos os pontos selecionados são conectados no sentido anti-horário usando o algoritmo Graham Scan. Um conjunto de coordenadas ótimas da forma irregular dos defeitos é obtido usando a derivação matemática de gráficos geométricos. O número de imagens de amostra nos conjuntos de dados de treinamento e teste é 84 e 500, respectivamente. Para compensar a escassez de dados de treinamento, o modelo Mask R-CNN foi pré-treinado extensivamente em um conjunto de dados Microsoft Common Objects in Context (MSCOCO) [71]. Além de realizar o aprendizado de transferência do modelo pré-treinado para detectar e segmentar os defeitos do couro, os parâmetros (ou seja, pesos e vieses) são ajustados iterativamente por meio do aprendizado dos recursos das imagens de entrada do couro. A precisão de segmentação do algoritmo é de 70,35%. Do ponto de vista da precisão da segmentação, a robustez e eficácia do algoritmo têm grande espaço para melhorias, sendo identificado apenas um defeito automaticamente. Após este trabalho, Liong et al. [74] desenvolveram técnicas de detecção automática de defeitos baseadas em AlexNet e U-Net. O U-Net foi utilizado para destacar a posição do defeito, onde os tipos de defeito focados neste estudo foram as linhas pretas e rugas. Entre 250 amostras defeituosas e 125 amostras não defeituosas, a taxa média de Intersecção sobre União (IoU) e a precisão média de pixels atingem 99,00% e 99,82% para a tarefa de segmentação de defeitos, respectivamente.

**Tabela 8.** Aprendizado profundo para detecção de defeitos de couro.

Não.	Ref.	#Classe	Tipo de defeito	Tamanho dos dados	Método	Melhor Ac.
1	Liong et al. [69]	1	Mordida de carrapato	584	Máscara R-CNN	70,35%
2	Liong et al. [74]	2	Linha preta e ruga	375	U-Net	99,82%
3	Gan et al. [75]	1	Corte aberto perceptível	560	R-CNN mais rápido, YOLOv2	96,88%
4	Chen et al. [5]	5	Máscaras de marca, grãos podres, ruptura, picadas de insetos e arranhões	373	1D-CNN, 2D-Unet, 3D-Unet	96%

**#Class:** Número de tipos de defeitos no conjunto de dados.

Chen et al. [5] projetaram três arquiteturas chamadas 1D-CNN, 2D-Unet e 3D-Unet para segmentar áreas de defeito de cinco defeitos de couro wet blue, incluindo máscaras de marca, grão podre, ruptura, picadas de insetos e arranhões na detecção de nível de pixel, respectivamente. Este trabalho é o primeiro estudo analítico usando imagens hiperespectral para couro wet blue no nível de pixel. Para várias características de defeitos, 1D-CNN enfatiza defeitos com características espectrais, 2D-Unet enfatiza defeitos com características espaciais e 3D-Unet processa simultaneamente informações espaciais e espectrais em imagens hiperespectrais. 1D-CNN tem o melhor resultado na detecção de picadas de insetos. O 2D-Unet aproveita a informação espacial para que tenha o melhor desempenho em uma máscara de marca. O 3D-Unet considera informação espacial e informação espectral simultaneamente. Portanto, tem o melhor desempenho em defeitos de grãos podres, rupturas e arranhões.

### 6.2. Aprendizado profundo para identificação de defeitos de

*couro* A Tabela 9 lista alguns aplicativos baseados em DL para identificação de defeitos de superfícies de couro. Murinto et al. [72] usaram um AlexNet [73] para extrair as características de imagem do couro curtido e usaram SVM para classificação. O conjunto de dados do modelo de validação contém 1.000 imagens de couro curtido impecável e cinco tipos de couro: lagarto gigante, crocodilo, ovelha, cabra e vaca. O desempenho da classificação mostra que o método de aprendizado profundo pode capturar melhor as características do couro, e a precisão geral é de 99,97%. No entanto, este artigo não envolve a identificação de defeitos.

Com base no ResNet-50, Deng et al. [19] realizaram pesquisas sobre a identificação de defeitos de couro, e efetivamente classificaram quatro tipos de defeitos de couro: arranhão, superfície podre, buraco quebrado e pinhole. A precisão média de classificação atingiu 92,34%, sendo que a precisão de reconhecimento de um pinhole foi de 87,2%, e ainda há muito espaço para melhorias. Este resultado é significativamente melhor do que a precisão do reconhecimento usando SVM mostrado na Tabela 7. Ding et al. [51] pegou nove defeitos comuns de couro como alvo de detecção e, em seguida, fundiu os recursos extraídos de uma rede neural convolucional com recursos salientes para formar um conjunto de recursos, e a precisão da classificação pode chegar a mais de 90%.

Liong et al. [74] aplicaram o AlexNet pré-treinado para classificar as imagens de couro de três categorias (sem defeito, linha preta e enrugada) com 250 amostras defeituosas e 125 amostras não defeituosas. O melhor desempenho obtido é de 94,67% para a tarefa de classificação; 375 dados de amostra não são suficientes para treinar um modelo de aprendizado profundo. Devido à questão da escassez de dados, Gan et al. [66] adotaram a Generative Adversarial Network (GAN) para descobrir as regularidades de recursos para produzir amostras de treinamento adicionais plausíveis, que é baseado no trabalho de Liong [74]. Com a ajuda da estratégia de aprimoramento de dados GAN, a precisão de classificação do modelo baseado em AlexNet [66] aumentou de 94,67% para 100%, que é treinado com uma quantidade relativamente pequena de dados de treinamento prontamente capturados.

**Tabela 9.** Aprendizado profundo para identificação de defeitos de couro.

Não.	Ref.	#Classe	Tipo de defeito	Método de tamanho de dados	Ace.
1	Murinto et al. [72]	5	Cinco tipos de couro sem defeito: lagarto gigante, crocodilo, ovelha, cabra e vaca	1000 AlexNet + SVM	99,97%
2	Dend et al. [19]		superfície podre, olho de agulha e nenhum defeito	15.000 Manchas pretas, superfícies	ResNet50 94,6% CNN +
3	Ding e cols. [51]	9	podres, arranhões, tendões de sangue, linhas do pescoço, buracos, marcas, cicatrizes podres, cortes	270 Saliente característica	90%
4	Liong et al. [74]	3	Linha preta, ruga e nenhum defeito	Linha preta, ruga e	375 AlexNet 94,67%
	[66] 3 6 Gan et al. [75]		nenhum defeito Corte aberto perceptível e nenhum	375 GAN + AlexNet	100%
		2	defeito #Classe: Número de tipos de defeitos no conjunto	560 AlexNet + SVM	100%

de dados.

Outro trabalho [75] é utilizar o AlexNet como descritor de recursos e usar o SVM como classificador para a identificação de defeitos perceptíveis de corte aberto, onde o conjunto de dados contém 560 imagens de couro com resolução espacial de  $140 \times 140 \times 3$ . Entre eles, 280 imagens têm defeitos perceptíveis de corte aberto na superfície, enquanto 280 imagens não têm nenhum defeito. O resultado alcançado é 100%.

### 6.3. Resumo desta seção Conforme

mostrado nas Tabelas 8 e 9, recuperamos oito peças de literatura sobre inspeção de defeitos na superfície do couro com base no modelo de aprendizado profundo. Entre eles, a rede neural convolucional desempenha um papel importante na engenharia de recursos. O processo de engenharia de recursos liderado pelo procedimento de treinamento da CNN é encontrado com alta adaptabilidade de paradigmas de aprendizado profundo. No entanto, o aprendizado profundo não funciona tão bem com dados pequenos. Com os conjuntos de dados menores disponíveis de imagens de couro, algoritmos de ML clássicos baseados em recursos artesanais, como regressões, floresta aleatória e SVM, geralmente superam o desempenho profundo

redes. Infelizmente para essas aplicações de detecção de defeitos de couro, tais conjuntos de dados grandes não estão prontamente disponíveis e são caros e demorados para adquirir. Além disso, entre a literatura investigada, a maioria dos defeitos de couro envolvidos no conjunto de dados são de 3 a 5 tipos, e apenas um documento possui 9 tipos; o trabalho acima mostra que o aprendizado profundo é uma ferramenta potencial na detecção de defeitos de couro. No entanto, a profundidade e a amplitude da detecção de defeitos de couro com base no aprendizado profundo não são suficientes. Liong e Gan [14,64-66,69,74-76] são uma equipe que realizou pesquisas relativamente aprofundadas neste campo, mas sua pesquisa é limitada apenas à detecção de alguns defeitos de couro, como linha preta, rugas, corte aberto perceptível e picada de carrapato.

De fato, a detecção de defeitos baseada em aprendizado profundo também tem sido amplamente utilizada em outras cenas industriais nos últimos anos. No campo da detecção de defeitos em superfícies metálicas, Nata rajan et al. [7] propuseram uma estrutura flexível de extração de recursos profundos em várias camadas com base em uma CNN por meio de aprendizado de transferência para detectar anomalias em conjuntos de dados de anomalias. Masci et al. [77] usaram uma rede de pooling piramidal multi-escala para a classificação de defeitos de aço, que é baseada em CNN e pode se adaptar às imagens de entrada de diferentes tamanhos. Xian Tao et al. [6] propuseram uma arquitetura baseada em CNN e autoencoder em cascata para uma superfície metálica contra cenários industriais complexos, que consiste em módulos de detecção e classificação. No campo da detecção de defeitos em superfícies texturizadas, Qiu et al. [8] propuseram uma estrutura em cascata baseada em rede totalmente convolucional para algoritmo de defeito de superfície pixel a pixel, que combina um estágio de segmentação, um estágio de detecção e um estágio de matização. Mei et al. [10] propuseram uma arquitetura de denoising convolucional ou to-encoder (MSCDAE) baseada em pirâmide gaussiana para detectar e localizar defeitos apenas com amostras livres de defeitos, que é uma abordagem de inspeção de defeitos baseada em aprendizado não supervisionado. Hu et al. [78] estende a rede adversarial generativa convolucional profunda padrão (DCGAN) e propôs o método não supervisionado baseado em DCGAN para detectar automaticamente defeitos em tecidos. Huang et al. [79] propuseram um modelo em tempo real baseado em U-Net para a inspeção de defeitos em placas cerâmicas, que consiste em três componentes principais: MCue, U-Net e rede Push. No campo da detecção de fissuras na superfície da construção, Cha et al. [80] desenvolveram dois modelos de detecção de danos estruturais baseados em CNN e Faster-Region-CNN sucessivamente para detectar cinco tipos de danos na superfície. Em outra detecção de defeitos diversos, Li et al. [81] realizaram uma revisão sistemática do aprendizado de transferência profunda para detecção de defeitos em máquinas. Chen et al. [82] desenvolveram um sistema baseado em visão que aplica as redes neurais convolucionais profundas (DCNNs) na detecção de defeitos de fixadores no dispositivo de suporte da catenária. Napoletano et al. [83] aplicaram CNNs baseadas em região para a detecção e localização de anomalias em imagens de microscópio eletrônico de varredura. Tabernik et al. [84] projetaram uma arquitetura de aprendizado profundo baseada em segmentação para detecção de rachaduras na superfície de um comutador elétrico. Longo et al. [85,86] apresentaram um método de aprendizado profundo semi-supervisionado de autotreinamento e uma abordagem de aprendizado híbrido profundo para diagnóstico de falhas de máquinas. Zhong et al. [87] propuseram um índice baseado em regressão residual ponderada para fornecer tendências monotônicas para avaliação de degradação de engrenagens e rolamentos. Liu et al. [86] construíram Deep Belief Networks que são combinadas com uma estratégia de aprendizagem de transferência para detecção de defeitos de

Em resumo, a detecção automatizada de anomalias de superfície usando aprendizado de máquina tornou-se uma área de pesquisa interessante e promissora, com um impacto muito alto e direto no domínio de aplicação da inspeção visual. Os métodos de aprendizagem profunda tornaram-se as abordagens mais adequadas para esta tarefa [84,88]. Esses trabalhos podem nos inspirar a projetar e desenvolver novas soluções para inspeção de defeitos na superfície do couro, como detecção e identificação.

## 7. Discussão e Conclusões

Até agora, resumimos e avaliamos a aplicação de métodos tradicionais de processamento de imagem e modelos de aprendizado de máquina no campo de inspeção de defeitos de superfície de couro, incluindo detecção, identificação e assim por diante. Nesta seção, discutimos os vários desafios que existem no projeto e implantação de sistemas baseados em visão de máquina.

luções para inspeção de defeitos de couro. Além disso, esta revisão lançará alguma luz sobre como esses desafios podem ser transformados em oportunidades, levando a futuras direções de pesquisa neste campo.

### 7.1. Desafios e oportunidades

Embora a inspeção de defeitos na superfície do couro seja um assunto importante na inspeção industrial, ela não tem recebido muita atenção. Entre a literatura revisada, cerca de 50% dos artigos em inglês recuperados são artigos de conferências, e 60% dos artigos chineses se enquadram em teses de mestrado. Pela distribuição dos autores, a nacionalidade dos principais pesquisadores é da China, Brasil, Chile, Austrália, Índia e outros locais com indústrias de couro relativamente desenvolvidas, havendo apenas um artigo dos Estados Unidos. Além da equipe de Liong e Gan [14,64–66,69,74–76] e da equipe de Jawahar [41,52,61], são poucas as equipes que realizam pesquisas contínuas e aprofundadas. Atualmente, a aplicação real do sistema de visão em couro não foi totalmente realizada com automação e inteligência, e ainda é necessária assistência manual para discriminação e identificação.

Na indústria do couro, o sistema de visão de máquina mais antigo é o LeaVis [89], que exige que operadores manuais tracem o limite da área do defeito de qualidade, marquem a área com carimbos especialmente projetados (chamados marca de qualidade ou marca Q) e indiquem defeitos. . O sistema de corte de couro Taurus XD lançado pela Gerber Technology Co., Ltd, tolland, conn., EUA realiza quatro níveis de inspeção de defeitos por meio de inspeção visual, mas ainda precisa de técnicos experientes para auxiliar na divisão do local do defeito. A Lectra, líder em tecnologia de corte e prestadora de serviços de suporte na indústria, desenvolveu o sistema de inspeção visual de couro Dig itLeather, que pode registrar informações de defeitos de couro e dividir o couro em seis graus de qualidade para processamento. De acordo com a literatura atual, esses sistemas de visão e métodos técnicos propostos visam categorias específicas de defeitos, e os tipos que podem ser reconhecidos são muito limitados. Teoricamente, os algoritmos mostrados na Tabela 5 obtiveram bom desempenho, mas ainda há uma lacuna em relação a uma aplicação real. Ainda existem muitos problemas na aplicação prática da inspeção automática de defeitos da superfície do couro e da tecnologia de visão de máquina correspondente. Relativamente pouco trabalho tem sido realizado na inspeção automatizada de defeitos de couro, principalmente devido à natureza difícil do problema. Afirmamos, portanto, que os desafios a seguir podem dificultar o progresso neste campo de pesquisa cintilante.

- (1) Problema de amostra pequena. Os conjuntos de dados de defeitos de couro são relativamente pequenos e os tipos de defeitos cobertos pelo conjunto de dados são incompletos, o que é difícil de representar para defeitos de couro com morfologia variável. Conforme mostrado nas Tabelas 3–5, os conjuntos de dados usados na maioria dos estudos são personalizados. O conjunto de dados de bovinos Nelore e Hereford utilizado por Amorim et al. [57] tem 50 imagens de couro azul molhado. A equipe de Campo Grande da Universidade Católica Dom Bosco no Brasil construiu um conjunto de dados que faz parte do projeto nacional brasileiro de pesquisa científica e desenvolvimento tecnológico DTCOURO, que prevê o desenvolvimento de um sistema informatizado totalmente automatizado para a classificação e classificação de couro cru e couro em bovinos. Todos os conjuntos de dados, exceto DTCOURO, são relativamente pequenos, o que limita a avaliação extensiva do algoritmo desenvolvido. Para resolver esses problemas, a equipe de Aslam [2] está construindo um conjunto de dados relativamente grande, assim como a equipe dos autores; ambas as equipes estão expandindo a categoria de defeitos e a escala de dados do conjunto de dados.
- (2) As amostras de dados têm um alto grau de variação em termos de defeitos. Imagens de couro mostram aleatoriedade em muitas mudanças na morfologia e defeitos. Pode haver mais de 10 defeitos em uma imagem. Mesmo um defeito em si é muito diferente em imagens diferentes. É praticamente difícil construir modelos exatos de defeitos da superfície do couro para classificação porque sua aparência e tamanho variam muito.
- (3) Não existe um padrão unificado para identificação e classificação de defeitos de couro na indústria. A avaliação inconsistente do desempenho dos algoritmos e a falta de conjuntos de dados de referência comuns são outro obstáculo ao progresso neste campo. Atualmente, o

a avaliação de desempenho dos algoritmos desenvolvidos é inconsistente e carece de um benchmark comum. A diferença no julgamento de defeitos entre a indústria de couro e a indústria de produtos de couro torna inconsistentes os indicadores técnicos de inspeção de qualidade de várias empresas, o que afeta seriamente a qualidade da produção de produtos de couro. Yeh [15] et al. estabeleceu um padrão de compensação para defeitos de couro para completar o comércio de couro e dividiu os defeitos de couro em sete tipos.

Hoang et al. [90] realizaram a informatização da regra do quarto, que é o método padrão para avaliar a qualidade do couro na indústria de calçados. Esses resultados de pesquisa fornecem uma boa base para estabelecer um padrão unificado para identificação e classificação de defeitos de couro, mas precisa ser mais refinado em favor da aplicação prática.

- (4) Problema em tempo real. Os métodos de inspeção de defeitos baseados em aprendizado de máquina incluem três links principais em aplicações industriais: anotação de dados, treinamento de modelo e inferência de modelo. O desempenho em tempo real em aplicações industriais reais se concentra mais nessa parte da inferência do modelo. A maioria dos métodos atuais de inspeção de defeitos se concentra na precisão da classificação ou identificação, com pouca atenção à eficiência da inferência do modelo.

## 7.2. Direções de Pesquisa Futura

- (1) Aumento de dados. Uma razão para não haver grandes conjuntos de dados de couro é que a maioria das indústrias reluta em compartilhar seus dados com pesquisadores. A classificação de defeitos de couro e a classificação de qualidade precisam se adaptar à alta variabilidade de defeitos de couro em ambientes industriais, portanto, dados suficientes devem ser coletados e variações de defeitos devem ser capturadas para avaliar e melhorar o desempenho do algoritmo. No campo da inspeção de defeitos de couro, existe a opção de obter grandes conjuntos de dados, que é o aumento de dados. O aumento de dados não apenas aumentará o número de defeitos no conjunto de dados, mas também aumentará a variação de defeitos. Visando o problema comum de pequenas amostras em inspeção de superfície, um algoritmo de geração de amostras de defeitos raros e expansão aleatória precisa ser construído. Uma importante direção de pesquisa será projetar um método exclusivo de aprimoramento de dados para geração de defeitos na superfície do couro. O método de amplificação de imagem de defeito mais comumente usado é obter mais amostras por operações de processamento de imagem, como imagem espelhada, rotação, tradução, distorção, filtragem, ajuste de contraste e assim por diante. Outro método comum é a síntese de dados, na qual defeitos individuais são frequentemente fundidos e sobrepostos a amostras normais (sem defeitos) para formar amostras de defeitos. Vale a pena praticar esses métodos de aprimoramento de dados no campo da inspeção de defeitos de couro.
- (2) Aprendizagem referente à rede e transferência. De um modo geral, treinar redes de aprendizado profundo com pequenas amostras pode facilmente levar a overfitting. Portanto, o método baseado em rede pré-treinamento ou aprendizagem por transferência é um dos métodos mais comumente usados para um problema de pequena amostra. No campo de defeitos de couro em inspeção, não existem muitos modelos pré-treinados disponíveis. O mais relacionado é a inspeção de superfície texturizada, como inspeção têxtil, inspeção de madeira e inspeção de cerâmica. Os pesos desses modelos podem ser usados para transferência de aprendizado, que é um problema de pesquisa que precisa ser investigado.
- (3) Projeto de estrutura de rede razoável. Ao projetar uma estrutura de rede razoável, a demanda por amostras também pode ser bastante reduzida. Com base no teorema da amostragem compactada para compactar e expandir os dados de amostra pequena, a CNN é usada para extrair diretamente os recursos de dados da amostragem compactada. Comparado com a entrada de imagem original, a amostragem compactada pode reduzir bastante a demanda de amostra da rede. Além disso, o método de inspeção de defeitos de superfície baseado em uma rede dupla também pode ser considerado um projeto de rede especial, o que pode reduzir bastante a demanda da amostra.
- (4) Aprendizagem não supervisionada ou semi-supervisionada. No modelo não supervisionado, apenas amostras normais são usadas para treinamento, portanto, não há necessidade de amostras defeituosas.

O método semi-supervisionado pode resolver o problema de treinamento de rede no caso de pequenas amostras usando amostras não marcadas. As estratégias têm sido utilizadas para a inspeção de defeitos de outros cenários industriais, e valem a pena ser testadas na inspeção de defeitos de couro.

- (5) Segmentação semântica precisa. Além de poder identificar defeitos, é necessário segmentar com precisão as informações detalhadas extraídas, como forma, tamanho, posição, cor e tipo do defeito. A segmentação semântica é uma estratégia eficaz para conseguir isso em redes neurais profundas. Full Convolution Networks (FCNs) fizeram um bom progresso na segmentação semântica em cenas práticas, segmentação de imagens médicas e inspeção de defeitos industriais. Outros modelos de segmentação semântica baseados em deep learning são desenvolvidos principalmente com base em FCN. Eles podem ser adequados para segmentação de defeitos de couro. As redes baseadas na arquitetura AlexNet e ResNet podem se adaptar à tarefa de segmentação de defeitos de couro, mas também precisam ser profundamente estudadas em combinação com a situação real dos defeitos de couro.

**Contribuições dos Autores:** Elaboração do rascunho original: ZC; Conceituação e metodologia, JD e ZC; Software, QZ; Curadoria de dados de defeitos de couro: JD e YC; Investigação: HW; Redação-revisão e edição, YC; aquisição de financiamento, YC Todos os autores leram e concordaram com a versão publicada do manuscrito.

**Financiamento:** Este trabalho foi apoiado em parte pelo Projeto de Plano Básico de Pesquisa de Bem-Estar Público da Província de Zhejiang (No. LGG22F010011, No. LGG22F030013), a Fundação de Ciências Naturais da Província de Zhejiang (No. LZY22E050003) financiado pelo Departamento de Ciência e Tecnologia da Província de Zhejiang, China, e Startup Research Found Plan Project (Nº BSYJ202107) financiado pela Universidade de Quzhou, China.

**Agradecimentos:** Os autores gostariam de agradecer aos revisores anônimos por seus comentários e sugestões construtivas, que fortaleceram muito este artigo.

**Conflitos de interesse:** Os autores declaram não haver conflito de interesse.

## Referências

1. Omoloso, O.; Mortimer, K.; Sábio, WR; Jraisat, L. Pesquisa em sustentabilidade na indústria do couro: uma revisão crítica do progresso e oportunidades para pesquisas futuras. *J. Limpo. Prod.* **2021**, *285*, 125441.
2. Aslam, M.; Khan, TM; Naqvi, SS; Holmes, G.; Naffa, R. Sobre a aplicação de visão automática automatizada para defeito de couro inspeção e classificação: Uma pesquisa. *Acesso IEEE* **2019**, *7*, 176065–176086.
3. Kwak, C.; Ventura, JA; Tofang-Sazi, K. Inspeção automatizada de defeitos e classificação de tecidos de couro. *Intel. Dados Anais.* **2001**, *5*, 355-370.
4. Kohli, P.; Garg, S. Estimativa da qualidade do couro usando um sistema automatizado de visão de máquina. *IOSR J. Electron. Comun. Eng.* **2013**, *6*, 44-47.
5. Chen, S.-Y.; Cheng, Y.-C.; Yang, W.-L.; Wang, M.-Y. Detecção de defeitos de superfície de couro wet-blue usando imagem hiperespectral. *Acesso IEEE* **2021**, *9*, 127685–127702.
6. Tao, X.; Zhang, D.; Ma, W.; Liu, X.; Xu, D. Detecção automática de defeitos de superfície metálica e reconhecimento com convolucional redes neurais. *Aplic. Sci.* **2018**, *8*, 1575. <https://doi.org/10.3390/app8091575>.
7. Natarajan, V.; Hung, T.-Y.; Vaikundam, S.; Chia, L.-T. Redes convolucionais para classificação de anomalias baseadas em votação em inspeção de superfícies metálicas. In Proceedings of the IEEE International Conference on Industrial Technology (ICIT), Toronto, ON, Canadá, 22 a 25 de março de 2017; págs. 22-25.
8. Qiu, L.; Wu, X.; Yu, Z. Redes totalmente convolucionais de alta eficiência para detecção de defeitos de superfície pixel a pixel. *Acesso IEEE* **2019**, *7*, 15884-15893.
9. Wang, T.; Chen, Y.; Qiao, M.; Snoussi, H. Um modelo de detecção de defeitos baseado em rede neural convolucional rápido e robusto em controle de qualidade do produto. *Int. J. Av. Manuf. Tecnol.* **2017**, *94*, 3465-3471.
10. Mei, S.; Yang, H.; Yin, Z. Uma abordagem baseada em aprendizado não supervisionado para inspeção automatizada de defeitos em superfícies texturizadas. *Trans. IEEE Instrumento Medir.* **2018**, *67*, 1266-1277.
11. Zhang, L.; Shen, J.; Zhu, B. Uma pesquisa sobre um algoritmo aprimorado de detecção de trincas de concreto baseado em Unet. *Estrutura. Monito de Saúde.* **2020**, *20*, 1864-1879. <https://doi.org/10.1177/1475921720940068>.
12. Zhou, X.; Gong, Q.; Liu, Y.; Yin, L. Segmentação automática de imagens muck TBM por meio de uma abordagem de aprendizado profundo para estimar o tamanho e a forma de fragmentos de rocha. *Autom. Constr.* **2021**, *126*, 103685.
13. Cha, Y.-J.; Choi, W.; Büyüköztürk, O. Detecção de dano de crack baseado em aprendizado profundo usando redes neurais convolucionais. *Computar. Civil Infraestrutura. Eng.* **2017**, *32*, 361-378.



14. Liong, S.-T.; Gan, YS; Huang, YC; Liu, KH; Yau, WC Rede neural integrada e abordagem de visão de máquina para couro classificação de defeitos. *arXiv* **2019**, arXiv:1905.11731. <https://doi.org/10.48550/arXiv.1905.11731>.
15. Sim, C.; Perng, D.-B. Estabelecer um padrão de referência de contagem de deméritos para a classificação e classificação de couros. *Int. J. Av. Manuf. Tecnol.* **2001**, *18*, 731-738.
16. Wang, X.; Wenwen, YU; Hong, C.; Cao, J. Sistema de detecção on-line de visão de máquina para eliminar eficazmente a zona de não detecção de defeitos de superfície. *J. Appl. Optar.* **2020**, *41*, 1190-1196.
17. He, F. *Pesquisa e Aplicação de Tecnologia de Inspeção Visual para Grande Área de Superfície de Couro*; Universidade de Zhejiang: Hangzhou, China, 2012. (em chinês)
18. Ho, CC; Li, JC; Kuo, TH; Peng, CC Sistema de marcação de defeitos de couro baseado em fusão multicâmera. *Av. Mec. Eng.* **2013**, *5*, 347921. <https://doi.org/10.1155/2013/347921>.
19. Deng, J.; Liu, J.; Wu, C.; Zhong, T.; Ling, WK Uma nova estrutura para classificar defeitos de superfície de couro com base em um parâmetro rede residual otimizada. *Acesso IEEE* **2020**, *8*, 192209–192218.
20. Ventilador, D.-H.; Ding, L.; Deng, J. Detecção automática e localização de defeitos de superfície para uma peça inteira de imagem de couro de alta definição. *Softw. Guia* **2019**, *18*, 146–150. (Em chinês)
21. Wang, D.; Wang, X.; Yu, W.; Cao, J.; Qian, W.; Gao, S. Projeto de iluminação de matriz curva LED fora do eixo para detecção de defeitos de couro. *Laser Optoelectron. Prog.* **2019**, *56*, pp.082202-1–082202-7. (Em chinês)
22. Limas-Serafim, AF Pirâmides multiresolução para segmentação de imagens naturais com base em modelos autorregressivos: Aplicação à classificação de couro de bezerro. In Proceedings of the 1991 International Conference on Industrial Electronics, Control and Instrumentation, Kobe, Japão, 28 de outubro a 1 de novembro de 1991.
23. Limas-Serafim, AF Segmentação de imagens naturais com base em pirâmides multiresolução vinculando os parâmetros de um modelo invariante de rotação auto regressiva. In Proceedings of the 11th International Conference on Pattern Recognition, Haia, Holanda, 30 de agosto a 3 de setembro de 1992.
24. Limas-Serafim, AF Segmentação de imagens naturais para reconhecimento de padrões usando pirâmides de bordas e sua aplicação nos defeitos do couro. In Proceedings of the 19th Annual Conference IEEE Industrial Electronics (IECON), Maui, HI, EUA, 15–19 de novembro de 1993; págs. 1357-1360.
25. Kasi, MK; Rao, JB; Sahu, VK Identificação de defeitos de couro usando um algoritmo de processamento de imagem de detecção de bordas autoadaptável. In Proceedings of the International Conference on High Performance Computing and Applications (ICHPCA), Bhubaneswar, Índia, 22–24 de dezembro de 2014. <https://doi.org/10.1109/ICHPCA.2014.7045326>.
26. Kwon, JW; Choo, YY; Choi, HH; Cho, JM; Kii, GS Desenvolvimento de sistema de discriminação de qualidade de couro por análise de textura. In Proceedings of the IEEE Region 10 Conference, Chiang Mai, Tailândia, 21–24 de novembro de 2004; pp. 327-330.
27. Wang, Q.; Hong, L.; Liu, J.; Tian, W. Um novo método para classificação de imagem de textura de couro. In Proceedings of the IEEE International Symposium on Industrial Electronics (Cat. No. 92ThO371-5), Vigo, Espanha, 25-29 de maio de 1992; págs. 304-307.
28. Popov, AT; Hall, AG Análise de textura multiresolução baseada em técnicas morfológicas. Nos Anais do IEEE Colloquium on Morphological and Nonlinear Image Processing Techniques, Londres, Reino Unido, 10 de junho de 1993.
29. Branca, A.; Atólico, G.; Distante, A. Inspeção de couro por análise de textura orientada com abordagem morfológica. In Proceedings of the International Conference on Image Processing, Santa Barbara, CA, EUA, 26–29 de outubro de 1997.
30. Hoang, K.; Wen, W.; Nachimuthu, A.; Jiang, XL Obtendo automação na inspeção de superfícies de couro. *Computar. Ind.* **1997**, *34*, 43-54.
31. Sim, C.; Perng, DB Um padrão de referência de compensação de defeitos para transações de couro. *Int. J. Av. Manuf. Tecnol.* **2005**, *25*, 1197-1204.
32. Georgieva, L.; Krastev, K.; Angelov, N. Identificação de defeitos de couro de superfície. In Proceedings of the International Conference on Computer Systems and Technologies—CompSysTech, Rousse, Bulgária, 19–20 de junho de 2003.
33. Krastev, K.; Georgieva, L.; Angelov, N. Seleção de recursos de couro para reconhecimento de defeitos usando lógica difusa. In Proceedings of the International Conference on Computer Systems and Technologies—CompSysTech, Rousse, Bulgária, 17–18 de junho de 2004.
34. Kumar, MP; Ashok, SD Uma abordagem de segmentação baseada em limites de cores de vários níveis para melhor identificação da região defeituosa em superfícies de couro. *Eng. J.* **2019**, *24*, 102-108.
35. Branca, A.; Tafuri, M.; Atólico, G.; Distante, A. Sistema automatizado para detecção e classificação de defeitos de couro. *Optar. Eng.* **1996**, *35*, 3485-3494.
36. Branca, A.; Lovergine, FP; Atólico, G.; Distante, A. Detecção de defeitos em couro por singularidades orientadas. In Proceedings of the 7th International Conference on Computer Analysis of Images and Patterns, Kiel, Alemanha, 10-12 de setembro de 1997; pp. 223-230.
37. Poelzleitner, W.; Niel, A. *Inspeção Automática de Superfícies de Couro*; Sociedade Internacional de Engenharia Óptica: Bellingham, WA, EUA, 1994.
38. Tang, B.; Kong, J.; Wu, S. Revisão da detecção de defeitos de superfície com base na visão de máquina. *J. Gráfico de imagem.* **2017**, *22*, 1640-1663.
39. Feng, YZ *Pesquisa e Desenvolvimento para Sistema de Inspeção de Defeitos de Couro Baseado em Tecnologia de Detecção de Visão de Máquina*; Guangdong Universidade de Tecnologia: Guangzhou, China, 2019. (em chinês)
40. Jian, L.; Wei, H.; Ele, B. Pesquisa em inspeção e classificação de defeitos de superfície de couro com base em rede neural e árvore de decisão. In Proceedings of the 2010 International Conference on Computer Design and Applications, Qinghuangdao, China, 25–27 de junho de 2010; Volume 2, pág. 381. <https://doi.org/10.1109/ICDA.2010.5541405>.
41. Jawahar, M.; Babu, NKC; Vani, K. Classificação da textura do couro usando a técnica de extração de características wavelet. In Proceedings of the IEEE International Conference on Computational Intelligence and Computing Research, Bhopal, Índia, 14–16 de novembro de 2014.

42. Sobral, J.L. *Inspeção de Couro Baseada em Wavelets*; Marques, JS, Pérez de la Blanca, N., Pina, P., Eds.; Springer: Berlim/Heidelberg, Alemanha, 2005; págs. 682-688.
43. Adamo, F.; Attivissimo, F.; Cavone, G.; Giaquinto, N.; Lanzolla, AML Inspeção de visão artificial aplicada à qualidade do couro ao controle. In Proceedings of the XVIII IMEKO World Congress Metrology for a Sustainable Development, Rio de Janeiro, Brasil, 17–22 de setembro de 2006; pp. 17-22.
44. Ele, F.; Wen, W.; Chen, Z. Inspeção visual automática para fabricação de couro. *Chave Eng. Mater.* **2006**, 326-328, pp. 469-472.
45. Yang, C. *Estudo sobre a técnica de detecção de imagem e sua aplicação na detecção de defeitos de couro*; Universidade de Zhejiang: Hangzhou, China, 2004. (em chinês)
46. Feihua, Y. *Pesquisa sobre Métodos Inteligentes de Detecção de Defeitos de Couro de Veículo*; Universidade de Tecnologia de Chongqing: Chongqing, China, 2016. (em chinês)
47. Chen, H. *A Pesquisa de Detecção de Defeitos de Couro Usando Técnicas de Análise de Textura*; Universidade Normal de SiChuan: Chengdu, China, 2011. (Em chinês)
48. Yue, KJ; Zheng, MC; Xiao, JH; Jiong-Xing, WU Detecção de saliência através da combinação de antecedentes de fundo e anteriores de objeto. *J. Aplic. Sci.* **2016**, 34, 451-460.
49. Zhu, LY; Yan, FH; Wen-Song, LI Detecção de defeitos na superfície do couro com base no grau de saliência visual. *Computar. Eng. Sci.* **2016**, 38, 549-556.
50. Liu, G.; Cai, N.; Xiao, P.; Lin, J. Detecção de defeitos de couro com base em estéreo fotométrico e detecção de objetos de saliência. *Computar. Eng. Aplic.* **2019**, 55, 215-219.
51. Ding, C.; Huang, H.; Ming, P. Método de inspeção de defeito de couro baseado em rede neural convolucional e característica saliente. *J. Donghua Univ. Nat. Sci.* **2020**, 46, 408-203.
52. Jawahar, M.; Babu, NKC; Vani, K.; Anbarasi, LJ; Geetha, S. Sistema de inspeção baseado em visão para detecção de defeitos de superfície de couro usando abordagem de classificador de conjunto de otimização de enxame de partículas de convergência rápida. *Multimed. Ferramentas Aplic.* **2021**, 80, 4203-4235.
53. [54]Bong, QG; Truong, QB; Nguyen, HC; Nguyen, MT Sistema de inspeção baseado em visão para detecção e classificação de defeitos na superfície do couro. In Proceedings of the 5th NAFOSTED Conference on Information and Computer Science (NICS), Ho Chi Minh, Vietnã, 23 a 24 de novembro de 2018.
54. [53]Rao, AR; Lohse, GL Identificando características de alto nível de percepção de textura. *Gráfico. Models Image Processing* **1993**, 55, 218–233.
55. [58]Viana, R.; Rodrigues, RB; Álvarez, MA; Pistori, H. SVM com seleção de parâmetros estocásticos para classificação de defeitos de couro bovino. In Proceedings of the Advances in Image & Video Technology, Segundo Simpósio da Orla do Pacífico, PSIVT, Santiago, Chile, 17–19 de dezembro de 2007; págs. 600-612.
56. [93]Chetverikov, D. Análise de textura usando mapas de interação de pares baseados em recursos. *Reconhecimento de padrões.* **1999**, 32, 487-502.
57. Amorim, WP; Pistori, H.; Pereira, MC; Jacinto, MAC Redução de atributos aplicada à classificação de defeitos de couro. Anais da 23ª Conferência SIBGRAP sobre Gráficos, Padrões e Imagens, Gramado, Brasil, 30 de agosto a 3 de setembro de 2010; págs. 353-359.
58. Villar, P.; Mora, M.; Gonzalez, P. Uma nova abordagem para segmentação de defeitos de couro wet blue. Em *andamento em Reconhecimento de Padrões, Análise de Imagens, Visão Computacional e Aplicações, Anais do 16º Congresso Iberoamericano de Reconhecimento de Padrões, CIARP 2011, Pucón, Chile, 15–18 de novembro de 2011*; São Martinho. C., Kim, S.-W., Eds.; Springer: Berlim/Heidelberg, Alemanha, 2011; págs. 591-598.
59. Pistori, H.; Paraguai, WA; Martins, PS; Conti, MP; Jacinto, MA Detecção de defeitos em couro cru e couro wet blue. In Proceedings of the Computational Modeling of Objects Represented in Images: Fundamentals, Methods and Applications (CompIMAGE), Coimbra, Portugal, 20–21 de Outubro de 2006.
60. Filho, EQS; Sousa, PHFD; Filho, PPR; Barreto, GA; Albuquerque, VHCD Avaliação da qualidade do couro caprino com base na técnicas de visão computacional. *Circuitos Sist. Processamento de sinal* **2020**, 39, 651-673.
61. Jawahar, M. Sistema de inspeção de visão de máquina para detecção de defeitos de superfície de couro. *Amer. Química de Couro. Associação* **2019**, 114, 10-19.
62. Jawahar, M.; Babu, NKC; Ismail, MM; Vani, K. Compressão de imagens de couro para sistema automático de classificação de couro usando multiwavelet. In Proceedings of the IEEE International Conference on Computational Intelligence and Computing Research (ICCIC), Tamil Nadu, Índia, 15–17 de dezembro de 2016; págs. 1–7.
63. Pereira, RF; Medeiros, CMS; Filho, PPR Classificação da qualidade do couro de cabra usando visão computacional e aprendizado de máquina. Nos Anais da Conferência Conjunta Internacional sobre Redes Neurais (IJCNN) de 2018, Rio de Janeiro, Brasil, 8–13 de julho de 2018; págs. 1–8.
64. Wen, W.; Hoang, K. Inspeção de superfície de couro usando critérios de agrupamento. Em *Computação Digital de Imagens: Técnicas e Aplicação*; Maeder A., Ed. Universidade de Queensland, Queensland, Austrália, 1995; págs. 479-484.
65. Gan, YS; Che, SS; Huang, YC; Liong, ST; Yau, WC Inspeção automatizada de defeitos de couro usando abordagem estatística em intensidade da imagem. *J. Ambiente. Intel. Humanizar. Computar.* **2021**, 12, 9269-9285.
66. Gan, YS; Yau, W.-C.; Liong, S.-T.; Chen, C.-C. Sistema automatizado de classificação para defeitos de picada de carrapato em couro. *Matemática. Problema Eng.* **2022**, 2022, 5549879. <https://doi.org/10.1155/2022/5549879>.
67. Moganam, PK; Ashok, SD Perceptron abordagens de aprendizado de máquina baseadas em rede neural para detecção e classificação de defeitos de couro. *Instrumento Mes. Metrologia* **2021**, 19, 421-429.
68. Vasagam, SN; Sornam, M. Detecção intermitente de defeitos de couro com base em algoritmos de conjunto derivados da transformação do chapéu preto e da transformação do gancho. Em *Análise e Aplicações de TIC*; Fong, S, Dey, N., Joshi, A., Eds.; Springer Nature: Sin gapore, 2022; Volume 314, pp. 35–45.

69. Liong, S.-T.; Gan, YS; Huang, Y.-CG; Huang, YC; Chang, H.-C. Segmentação automática de defeitos em couro com aprendizado profundo. *arXiv* **2019**, arXiv:1903.12139.
70. Ele, K.; Zhang, X.; Ren, S.; Sun, J. Aprendizagem residual profunda para reconhecimento de imagem. Nos Anais da Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões, Las Vegas, NV, EUA, 26 de junho a 1º de julho de 2016; págs. 770-778.
71. Lin, TY; Maire, M.; Pertence, S.; Hays, J.; Zitnick, CL Microsoft coco: Objetos comuns em contexto. Em *Anais do Europeu Conferência sobre Visão Computacional*; Springer: Berlim/Heidelberg, Alemanha, 2014; págs. 740-755.
72. Murinto, M.; Prahara, A.; Winiari, S.; Ismi, DP Rede neural convolucional pré-treinada para classificação de imagem de couro curtido. *Int. J. Av. Computar. Sci. Aplic.* **2018**, *9*, 211-216.
73. Krizhevsky, A.; Sutskever, I.; Hinton, G. Classificação ImageNet com redes neurais convolucionais profundas. In *Proceedings of the 25th International Conference on Neural Information Processing Systems*; Curran Associates Inc.: Red Hook, NY, EUA, 2012; págs. 1097-1105.
74. Liong, S.-T.; Zheng, D.; Huang, Y.-C.; Gan, YS Classificação e segmentação de defeitos de couro usando arquitetura de aprendizado profundo. *Int. J. Computação. Integr. Manuf.* **2020**, *33*, 1105-1117.
75. Gan, YS; Liong, ST; Zheng, D.; Xia, Y.; Huang, YC Detecção e localização de defeitos em superfícies de couro natural. *J. Ambiente. Intel. Humanizar. Computar.* **2021**, *1*–15, no prelo <https://doi.org/10.1007/s12652-021-03396-2>.
76. Gan, YS; Liong, ST; Wang, S.-Y.; Cheng, CT Um sistema aprimorado de identificação automática de defeitos em couro natural por meio de uma rede generativa de adversários. *Int. J. Computação. Integr. Manuf.* **2022**, *1*-17. <https://doi.org/10.1080/0951192X.2022.2048421>.
77. Masci, J.; Meier, U.; Fricout, G.; Schmidhuber, J. Rede de pooling piramidal multi-escala para classificação genérica de defeitos de aço. In Proceedings of the International Joint Conference on Neural Networks, Dallas, TX, EUA, 4–9 de agosto de 2013; págs. 4–9.
78. Hu, G.; Huang, J.; Wang, Q.; Li, J.; Xu, Z. Detecção de defeitos de tecido não supervisionado com base em um anúncio generativo convolucional profundo rede versarial. *Texto. Res. J.* **2020**, *90*, 1-24. <https://doi.org/10.1177/0040517519862880>.
79. Huang, Y.; Qiu, C.; Guo, Y.; Wang, X.; Yuan, K. Saliência de defeito de superfície de telha magnética. In Proceedings of the IEEE 14th International Conference on Automation Science and Engineering (CASE), Munique, Alemanha, 20 a 24 de agosto de 2018.
80. Cha, YJ; Choi, W.; Suh, G.; Mahmoudkhani, S.; Buyukozturk, O. Inspeção visual estrutural autônoma com base na região aprendizado profundo para detectar vários tipos de danos. *Civ. Auxiliada por Computador. Infraestrutura. Eng.* **2018**, *9*, 731-747.
81. Li, C.; Zhang, S.; Qin, Y.; Estupinan, E. Uma revisão sistemática de aprendizado de transferência profunda para diagnóstico de falhas de máquinas. *Neuro computação* **2020**, *40*, 122-135.
82. Chen, J.; Liu, Z.; Wang, H.; Alfredo, N.; Han, Z. Detecção automática de defeitos de fixadores no dispositivo de suporte de catenária usando rede neural convolucional profunda. *Trans. IEEE Instrumento Medir.* **2018**, *67*, 257-269.
83. Napoletano, P.; Piccoli, F.; Schettini, R. Detecção de anomalias em materiais nanofibrosos por auto-semelhança baseada em CNN. *Sensores* **2018**, *18*, 209. <https://doi.org/10.3390/s18010209>.
84. Tabernik, D.; Šela, S.; Skvar, J.; Skocaj, D. Abordagem de aprendizagem profunda baseada em segmentação para detecção de defeitos de superfície. *J. Intel. Manuf.* **2020**, *31*, 759-776.
85. Ling, M.; Yue, L.; Xiao, FN; Yu, ML; Hui, QJ Detecção de defeitos da superfície do telefone móvel com base na rede neural de convolução. In Proceedings of the 2nd International Conference on Manufacturing Science and Information Engineering, Chengdu, China, 17-19 de fevereiro de 2017.
86. Ri-Xian, L.; Ming-Hai, Y.; Xian-Bao, W. Detecção de defeitos com base em aprendizado profundo e aprendizado de transferência. *Metal. Min. Ind.* **2015**, *7*, 312-321.
87. Zhong, JJ; Wang, D.; Guo, JE; Cabrera, D.; Li, C. Investigações teóricas sobre curtose e entropia e suas melhorias para monitoramento de integridade do sistema 1184. *Trans. IEEE Instrumento Medir.* **2020**, *70*, 3503710.
88. Li, C.; Cabrera, D.; Sancho, F.; Sanchez, R.; Cerrada, M.; Longo, J.; Oliveira, J. Fusão de codificadores generativos convolucionais para detecção de falhas em impressoras 3D com apenas sinais de condição normal. *Mec. Sistema Processamento de sinal* **2021**, *147*, 107108.
89. Lerch, A.; Chetverikov, D. Regras de correção de linha baseadas em conhecimento em um sistema de visão de máquina para a indústria de couro. *Eng. Aplic. Artif. Intel.* **1991**, *4*, 433-438.
90. Hoang, K.; Nachimuthu, A. Técnicas de processamento de imagem para classificação de couro na indústria calçadista. *Mach. Vis. Aplic.* **1996**, *9*, 119-129.