



Abordagens de aprendizado de máquina baseadas em rede neural Perceptron para defeitos de couro Detecção e Classificação

Praveen Kumar Moganam*, Denis Ashok Sathia Seelan

Departamento de Projeto e Automação, Laboratório de Sistemas Ciberfísicos, Escola de Engenharia Mecânica, Vellore Institute of
Tecnologia, Vellore 632014, Índia

E-mail do autor correspondente: denisashok@vit.ac.in

<https://doi.org/10.18280/i2m.190603>

Recebido: 28 de junho de 2020

Aceito: 6 de novembro de 2020

Palavras-chave:

visão de máquina, defeitos de couro, matriz de
ocorrência de nível de cinza, rede neural perceptron

ABSTRATO

A detecção de defeitos em uma superfície típica de couro é uma tarefa difícil devido à natureza complexa, não homogênea e aleatória do padrão de textura. Este artigo apresenta uma abordagem de identificação de defeitos de couro baseada em análise de textura usando uma classificação de rede neural de couro defeituoso e não defeituoso. Neste trabalho, a Matriz de Coocorrência de Nível de Cinza (GLCM) é utilizada para extrair diferentes características estatísticas de textura de couros defeituosos e não defeituosos. Com base no conjunto de dados rotulados de recursos de textura, o classificador de rede neural perceptron é treinado para identificação de defeitos. Foram detectados cinco defeitos de couro comuns, como marcas de dobra, granulação, marcas de crescimento, grã solta e orifícios de alfinete, e os resultados da classificação da rede perceptron são apresentados. O método proposto foi testado para a biblioteca de imagens de 1232 amostras de couro e a precisão da classificação para a detecção de defeitos usando a matriz de confusão é de 94,2%. O método proposto pode ser implementado no ambiente industrial para a automação do processo de inspeção de couro.

1. INTRODUÇÃO

O couro é considerado um material natural complexo, pois possui diferentes aparências visuais devido à natureza não homogênea e aleatória da textura da cor [1]. A produção de produtos de couro de alta qualidade e livres de defeitos é afetada por muitos defeitos, tais como defeitos naturais, mecânicos, de esfolia, cura e curtimento que são introduzidos durante a produção de couro em larga escala. A presença de defeitos no couro é considerada um fator crítico, pois aumenta os custos de rejeição em uma indústria típica de tecidos de couro. Atualmente, inspetores humanos são empregados para inspeção de superfícies de couro e geralmente perdem um número significativo de defeitos devido a vários fatores, como fadiga, tarefas repetitivas, condições de iluminação e daltonismo. A fim de obter maior produtividade com alta qualidade na produção de couro em larga escala, há a necessidade de um sistema de inspeção automatizado para garantir a qualidade do couro nas fábricas de couro [2].

Uma ampla variedade de métodos de processamento e análise de imagem é proposta por vários pesquisadores para inspeção automatizada de defeitos em couro [3]. Krastev et al. [4] mostraram um método de detecção baseado em histogramas, usando o critério χ^2 para análise de imagens e construção de histogramas. A matriz de co-ocorrência de nível de cinza espacial (GLCM) é amplamente utilizada como método de extração de recursos de textura para identificação de defeitos em superfícies texturizadas [5]. Como as características do domínio da frequência são geralmente menos sensíveis ao ruído do que as características do domínio espacial, os filtros de Gabor multicanal são usados como representações conjuntas de frequência espacial/espacial para analisar imagens texturizadas com características de orientação e frequência altamente específicas [6]. Em abordagens de domínio de frequência, as características texturais são geralmente derivadas da transformada de Fourier para entender a periodicidade nos padrões de textura.

[7]. A transformada wavelet é aplicada para extração de características e segmentação de regiões defeituosas [8]. Verificou-se que muitas técnicas de processamento de imagem, incluindo histograma, detecção de borda, filtros de Gabor, transformada de Fourier, transformada de wavelet, foram aplicadas para entender texturas e defeitos em couro para inspeção visual baseada em visão de máquina. No entanto, esses métodos têm altos requisitos computacionais e baixa precisão na detecção de defeitos devido à complexidade e à natureza dos defeitos do couro no padrão de textura da superfície do couro.

A fim de melhorar a precisão da detecção de defeitos de couro, poucos pesquisadores tentaram abordagens baseadas em inteligência artificial, aprendizado de máquina e classificador. Kwak et al. apresentaram um método baseado em árvores de decisão para a classificação de superfícies de couro usando descritores geométricos e estatísticos de textura de couro. A técnica de processamento de imagem baseada em lógica fuzzy é empregada para analisar o conjunto de características das imagens de couro para realizar o reconhecimento de defeitos de superfície [9]. Uma abordagem de aprendizado profundo usando rede neural convolucional é proposta para um sistema automático de classificação de couro [10]. Lovergin et al. usou um remendo de couro como uma unidade para a classificação da superfície do couro com base na consistência local e na orientação do gradiente [11]. O método de detecção de borda auto adaptável é desenvolvido para detecção de defeitos de couro [12]. Viana et al. máquina de vetores de suporte adotada para classificação de defeitos de couro [13]. Liu et al. [14] desenvolveram rede neural feedforward com árvore de decisão para obtenção de atributos e classificação de defeitos superficiais de couro. Amorim et al utilizaram diferentes classificadores como árvore de decisão C4.5, vizinhança mais próxima, Naïve Bayes e máquina de vetores de suporte para classificação de defeitos de couro [15]. Pereira e cols. aplicação de vizinhança mais próxima, perceptron multicamada e máquina de vetor de suporte para identificação de defeitos de couro [16]. O método proposto para a classificação de falhas, método baseado em

o Support Vector Machines Classifier (SVC) com decomposição de pacote wavelet (WPD) é apresentado para executar uma tarefa de classificação multiclasse [17].

Verificou-se que há avanços rápidos em aplicações de processamento de imagem baseadas em visão de máquina para inspeção de defeitos de couro. Muitas técnicas de processamento de imagem e técnicas de classificação baseadas em aprendizado de máquina foram propostas por vários pesquisadores para classificação de couro e aplicações de classificação de defeitos. No entanto, a precisão da detecção de defeitos ainda é uma preocupação devido à complexidade, natureza aleatória dos defeitos e padrões de textura de cor do couro. Com foco em melhorar a precisão da detecção de defeitos na superfície do couro e reduzir os requisitos computacionais, este artigo apresenta uma abordagem de classificador baseado em rede neural perceptron para detecção de defeitos em couro usando extração estatística de características de textura.

2. DESCRIÇÃO DO SISTEMA DE VISÃO PARA AQUISIÇÃO E ANÁLISE DE IMAGENS DE COURO

Neste trabalho, as imagens de couro são adquiridas por um sistema de visão de máquina em um ambiente controlado, pré-processadas antes de realizar a extração de características usando a matriz de co-ocorrência de nível de cinza (GLCM). Uma rede neural perceptron é desenvolvida por treinamento para classificar a amostra de imagem de couro defeituosa e não defeituosa.

2.1 Aquisição de imagem de couro

No presente trabalho, um sistema de visão de máquina composto por uma câmera CMOS de alta resolução (BASLER acA4600), computador pessoal com software MATLAB (Versão. 2019a) é estabelecido para aquisição de imagens de couro. As imagens de couro foram capturadas sob condições de iluminação controlada e a câmera foi montada em um suporte ajustável a uma distância de 10 cm, conforme mostrado na Figura 1.




Figura 1. Sistema de inspeção de visão de máquina para identificação de defeitos em amostras de couro

A especificação técnica da câmera de alta resolução utilizada para a aquisição das imagens do couro é apresentada na Tabela 1. Ela é capaz de adquirir imagens com resolução de 4608 pixels x 3288 pixels e é adequada para identificar detalhes mais finos de diferentes defeitos no couro.

Neste trabalho, uma biblioteca de imagens composta por 2.000 imagens de couros defeituosos e não defeituosos é construída usando a máquina

Sistema de visão. A Figura 2 mostra as amostras de imagens de couro adquiridas com defeitos típicos, como marcas de dobra, granulação, marcas de crescimento, granulação solta, furos de alfinete. A natureza dos padrões de textura desses defeitos de couro é diferente para a percepção visual. A fim de reduzir os cálculos de identificação de defeitos em couro, as imagens coloridas adquiridas das amostras de couro são convertidas em escala de cinza e suas variações de intensidade são analisadas e explicadas na próxima seção.

Tabela 1. Especificações da câmera usada para aquisição de imagens de couro

Especificações	Descrição
Tipo de sensor	CMOS
Tamanho do sensor	6,5 mm x 4,6 mm
Resolução (A x V)	4608 pixels x 3288 pixels
Resolução	14MP
Tamanho do pixel (A x V)	1,4 μm x 1,4 μm
Taxa de quadros	10fps
Mono/cor	cor
Interface	USB 3.0



Figura 2. Imagens adquiridas de amostras de couro

2.2 Análise de intensidade de cinza de defeitos de couro

A Figura 3 mostra os respectivos valores de intensidade de nível de cinza de diferentes defeitos de couro para as imagens de couro mostradas na Figura 2. As marcas de dobra na superfície do couro mostram uma grande mudança nos valores de intensidade para uma curta distância, conforme visualizado na Figura 3(a). Grain off, marcas de crescimento e defeitos pinhole mostram a variação aleatória e não uniforme na intensidade nas regiões espaciais isoladas dos pixels conforme representado na Figura 3 (b), (c) e 3(e) respectivamente. O defeito de grão solto é considerado mais fino por natureza e mostra um nível de cinza uniforme nas localizações espaciais específicas dos pixels, conforme mostrado na Figura 3(d).

Embora a marca de dobra possa ser identificada facilmente pela percepção visual nas imagens de couro, a detecção de outros defeitos de couro, como granulação, marcas de crescimento, granulação solta e furos de alfinete, requer algoritmos de processamento de imagem mais detalhados devido ao tamanho mais fino e ao natureza dos padrões de textura.

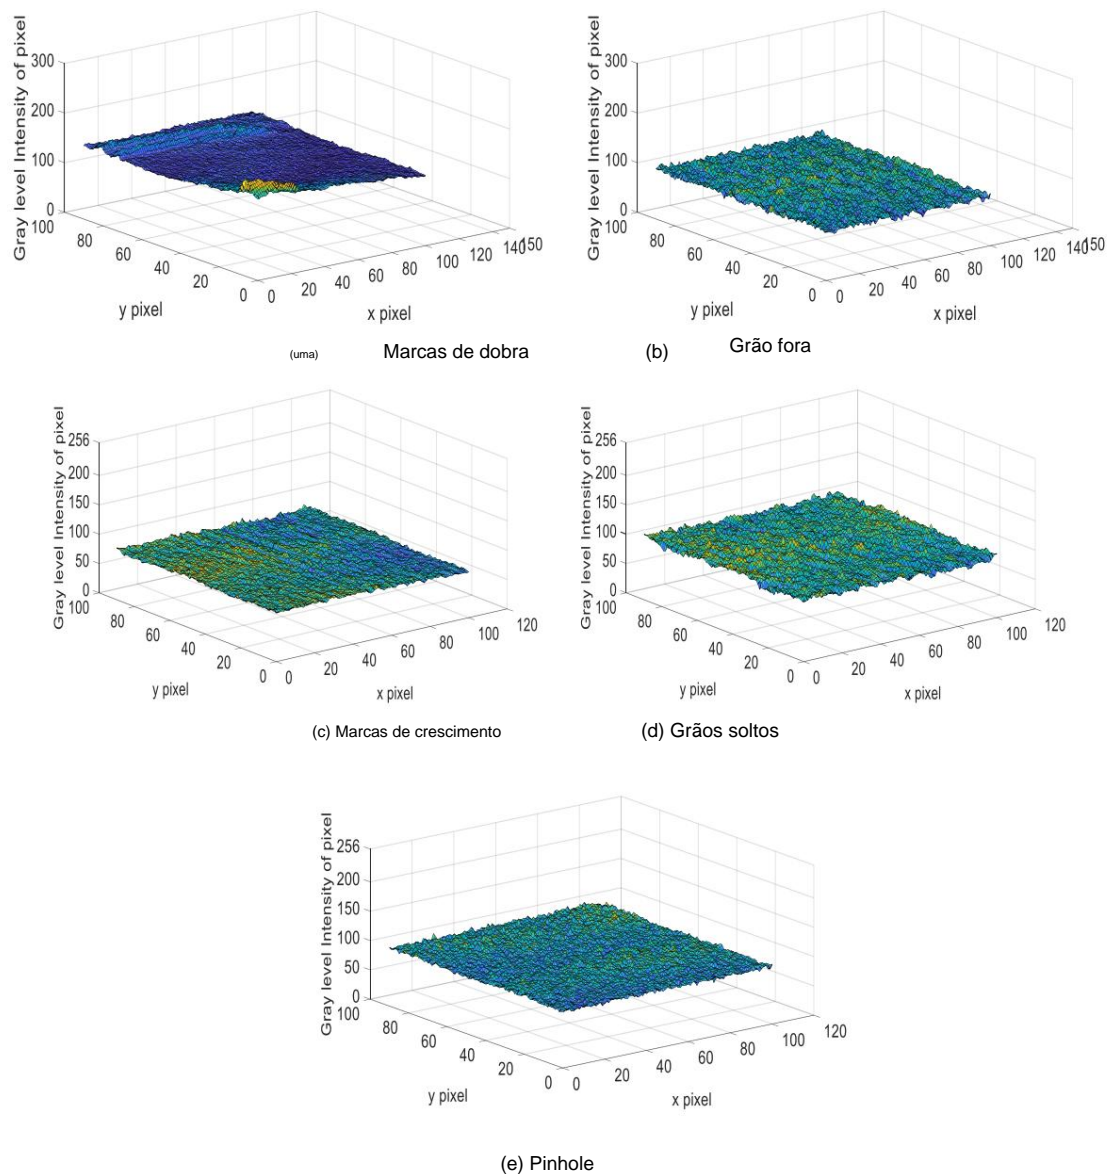


Figura 3. Amostras de couro com defeito e suas variações de intensidade de nível de cinza

3. MÉTODO PROPOSTO PARA DETECÇÃO DE DEFEITOS DE COURO

Como as estatísticas de pixel único não fornecem descrições suficientemente ricas de texturas para aplicações práticas, a Matriz de Coocorrência de Nível de Cinza (GLCM) é usada para interpretar a natureza do padrão de textura da superfície do couro no presente trabalho. Para implementar uma inspeção visual automatizada e classificação de amostras de couro em um ambiente industrial, uma rede neural perceptron é estabelecida para classificar as amostras de couro defeituosas e não defeituosas.

As etapas envolvidas no método proposto são mostradas na Figura 4 e são explicadas nesta seção.

3.1 Divisão e indexação de imagens em couro

Para identificar a localização dos defeitos na imagem de couro fornecida, a imagem de couro fornecida de tamanho $(M \times N)$ 4608 pixels \times 3288 pixels é dividida com um bloco não sobreposto de tamanho (mxn) 200 \times 150 e é indexada como $f(i,j)$. Aqui $i = 1,2,3,\dots,M/m$, $j = 1,2,3,\dots,N/n$.




Figura 4. Diagrama de blocos da abordagem de classificação de defeitos de couro usando a rede neural perceptron

3.2 GLCM para amostras de couro com diferentes defeitos

Para bloco de imagem de tamanho mxn , co-ocorrência de nível de cinza A matriz é construída contando todos os pares de uma referência e pixel vizinho separados por um deslocamento (d) com os níveis de cinza i e j na orientação relativa especificada (\bar{y}) conforme indicado abaixo:

$$P[i,j|d,\bar{y}] = n_{ij} \quad (1)$$

onde, n_{ij} é o número de ocorrências de referência e pixels vizinhos (i,j) situados no deslocamento (d) na imagem.

Além disso, os elementos de GLCM $P[i,j]$ são normalizados dividindo cada entrada pelo número total de pares de pixels.

O número de linhas e colunas da matriz de coocorrência $P[i,j]$ é igual ao número de níveis de cinza distintos (n). Um GLCM é calculado em quatro orientações diferentes (0°, 90°, 45° e 135°) e deslocamentos ($d=-3,-2,-1,0,1,2,3$) para a imagem em escala de cinza fornecida. Para reduzir a carga computacional do cálculo do GLCM para a imagem fornecida, o nível de cinza foi definido como 32. Uma matriz GLCM típica converte as contagens brutas em valores de probabilidade dividindo cada contagem pela soma de todas as contagens para produzir uma matriz de coocorrência normalizada.

A Figura 5 mostra o GLCM calculado para as amostras de imagem de couro fornecidas com diferentes defeitos, conforme representado na Figura 2. A partir da Figura 5(a), pode-se notar que há maior número de ocorrências para pixels com níveis de cinza entre 0-15 para o defeito de marca de dobra na superfície do couro em relação aos demais níveis de cinza. O grão do defeito mostrou diferentes variações de nível de cinza entre 5-15 em comparação com o defeito da marca de dobra e indica a mudança na natureza da textura para

diferentes defeitos na superfície do couro. O número de ocorrências de níveis de cinza entre 10-20 é maior para as marcas de crescimento, conforme mostrado na Figura 5(c). Embora os defeitos de grão solto e pinhole tenham mostrado variações de nível de cinza semelhantes entre 5-15, a magnitude do número de ocorrências dos níveis de cinza é diferente.

Embora o GLCM forneça dados numéricos sobre a textura em uma matriz, não é diretamente útil para a comparação de texturas de amostras de couro defeituosas e não defeituosas. Portanto, as características de textura numérica são extraídas do GLCM, pois representam a textura da superfície do couro de forma mais compacta.

3.3 Extração de características de textura da imagem de couro

Entre os vários recursos de textura, como contraste, correlação, dissimilaridade, energia, entropia, homogeneidade, média e variância, são calculados usando GLCM, pois esses recursos são estatisticamente significativos para a classificação de amostras de couro. As fórmulas para calcular os diferentes recursos de textura do GLCM de uma imagem são destacadas na Tabela 2.

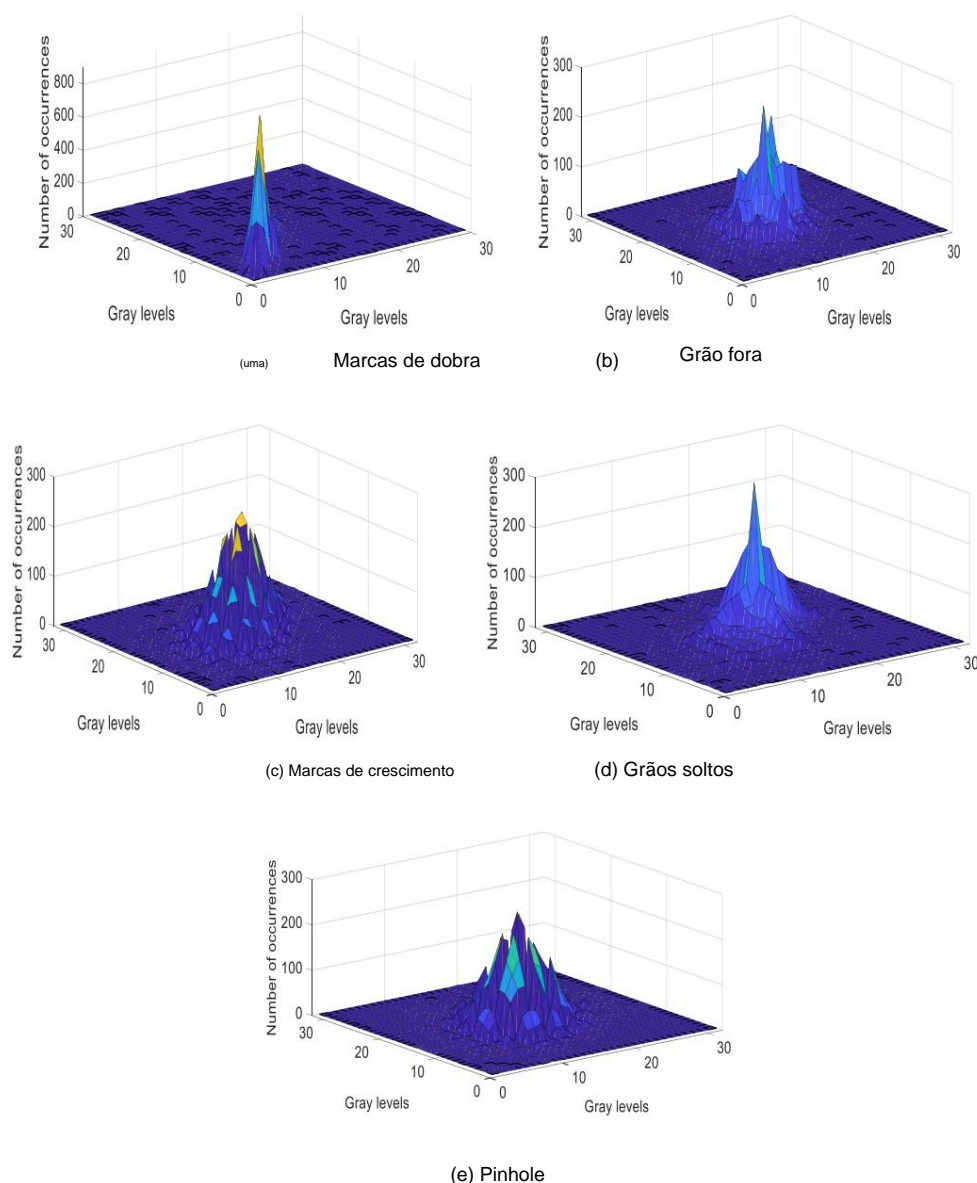


Figura 5. GLCM para as diferentes amostras de couro com defeito

Tabela 2. Características de textura usadas para identificação de defeitos de couro

Parâmetros de textura	Descrição
Registro de entropia $H_p = -\sum_{j=0}^{ng-1} p_j \log_2 p_j$	aleatoriedade estatística da superfície do couro
Correlação $r_{yy} = \frac{\sum_{j=0}^{ng-1} \sum_{i=0}^{ng-1} (y_{ij} - \bar{y})(y_{i+1,j} - \bar{y})}{\sqrt{\sum_{j=0}^{ng-1} (y_{ij} - \bar{y})^2 \sum_{i=0}^{ng-1} (y_{i+1,j} - \bar{y})^2}}$	dependência linear de níveis de cinza de pixels vizinhos
Jipe de contraste $J = \sum_{j=0}^{ng-1} j^2 p_j$	medida da intensidade entre um pixel e seu vizinho
Energia $E = \sum_{j=0}^{ng-1} p_j$	ordem de pixels
Homogeneidade $H = \sum_{j=0}^{ng-1} \frac{1}{1 + j^2}$	suavidade da distribuição do nível de cinza
Distância diferente $D = \sum_{j=0}^{ng-1} j - \bar{j} p_j$	medida de distância entre pares de pixels
Significância $S = \sum_{j=0}^{ng-1} p_j$	estimativa da intensidade média de todos os pixels
variância $V = \sum_{j=0}^{ng-1} j^2 p_j - (\sum_{j=0}^{ng-1} j p_j)^2$	dispersão de distribuição de nível de cinza de pixels

Neste trabalho, as características de textura são extraídas da biblioteca de amostras de imagens de couro usando GLCM e posteriormente analisadas para a classificação de amostras defeituosas e não defeituosas usando a rede neural perceptron.

3.4 Abordagens da rede neural Perceptron

No presente trabalho, abordagens neurais perceptron de camada única e multicamada foram desenvolvidas para aplicações de detecção e classificação de defeitos em couro.

3.4.1 Rede neural perceptron de camada única

Devido à sua simplicidade de computação e eficácia em aplicações práticas em tempo real, uma rede neural perceptron de um único neurônio é estabelecida para a classificação de imagens de couro defeituosas e não defeituosas usando as características de textura extraídas do couro imagens. O diagrama esquemático da rede neural perceptron com os neurônios de entrada (x_1, x_2, \dots, x_n), pesos associados (w_1, w_2, \dots, w_n), junção de soma, função de ativação (f) e a saída (y) é mostrado na Figura 6.

Aqui, a entrada refere-se ao vetor de recursos de textura (x_1, x_2, \dots, x_n), como contraste, correlação, dissimilaridade, energia, entropia, homogeneidade, média, variância. O Perceptron produz a saída binária (y) usando uma função de ativação (f) baseada na soma ponderada dos valores de entrada conforme dados pela Eq. (2).

$$y = f(w_1 x_1 + \dots + w_n x_n) = f(WX) \quad (2)$$

Aqui $W = (w_1, w_2, \dots, w_n)$ e é o vetor peso.

$X = (x_1, x_2, \dots, x_n)$ e é o vetor de características de textura da imagem de couro, f é a função de ativação do passo, y é a saída da rede neural.

Nesta abordagem, a rede neural perceptron é treinada com uma grande quantidade de dados de imagem de couro para melhor descrever os recursos dos dados de entrada para ajustar os pesos. O treinamento da rede neural perceptron é inicializado com um conjunto de dados rotulados ($x_1, x_2, \dots, x_n, y_{target}$) e os pesos aleatórios (w_1, w_2, \dots, w_n) para alcançar a classificação desejada ($y = 0$ ou 1). O erro (e) na classificação é calculado e a correção é realizada alterando os pesos de magnitude ($\dot{y}w$) iterativamente usando o algoritmo de aprendizado perceptron até que a classificação desejada seja alcançada.





Figura 6. Diagrama esquemático da rede neural perceptron

3.4.2 Rede neural perceptron multicamada Para

classificar os defeitos do couro nas imagens do couro, um perceptron multicamada com camadas ocultas é desenvolvido e a arquitetura típica é mostrada na Figura 6(b). Um esquema de codificação quente é usado para definir os valores-alvo para os diferentes defeitos de couro, conforme mostrado na Tabela 4. Com base na função de custo de erro quadrático médio, conforme fornecido pela Eq. (3), A arquitetura feedforward com método de gradiente descendente é usada para otimizar os pesos para reduzir os erros na camada de saída usando funções de ativação sigmoide.

$$b_{kk} = \frac{1}{2n} \sum_{x=1}^n \| \mathbf{y}_x - \mathbf{y}_{\hat{x}} \|^2$$

Aqui, w refere-se aos pesos da rede, b denota vieses, n é o número total de entradas de treinamento, \mathbf{a} é o vetor de saídas da rede quando \mathbf{x} é a entrada.

A regra de atualização do gradiente descendente para os pesos e vieses é dada pelas seguintes equações

$$w_{kk} = w_{kk} - \eta \frac{\partial C}{\partial w_{kk}} \quad (4)$$

$$b_{kk} = b_{kk} - \eta \frac{\partial C}{\partial b_{kk}} \quad (5)$$

O perceptron multicamada proposto tem cinco neurônios para classificar os defeitos do couro: grão solto, grão solto, marcas de crescimento, furo de alfinete junto com o couro não defeituoso. Para o desenvolvimento robusto da rede neural perceptron proposta, a rede neural perceptron precisa ser validada e testada usando um conjunto de dados não visto. Os dados de validação são usados para generalização da rede para evitar que a arquitetura seja superajustada ou subajustada. As amostras de teste são usadas para avaliar o desempenho de classificação dos dados de entrada não vistos para examinar a robustez da arquitetura da rede neural. É assegurado que não haja sobreposição das imagens.

4. RESULTADOS E DISCUSSÕES

Proposta de rede neural perceptron para classificação de imagens de couro e rotinas de processamento de imagem usando rede neural perceptron são implementadas em ambiente MATLAB. Esta seção apresenta os resultados do processamento de imagem para extração de características de textura de amostras de couro e os resultados da classificação do perceptron para imagens de couro. Essas imagens são convertidas para o formato de escala de cinza antes do processamento para extrair os recursos estatísticos de textura usando a matriz GLCM. Os resultados de teste e validação do classificador perceptron proposto também são apresentados nesta seção.

4.1 Características de textura extraídas de amostras de couro defeituosas e não defeituosas

A Figura 7 mostra os valores típicos das características de textura extraídas, como contraste, correlação, dissimilaridade, energia, entropia, homogeneidade, média e variação para as 50 amostras de couro usando GLCM. Pode-se notar que há variações de magnitude claras entre diferentes características para as amostras de couro defeituosas e não defeituosas

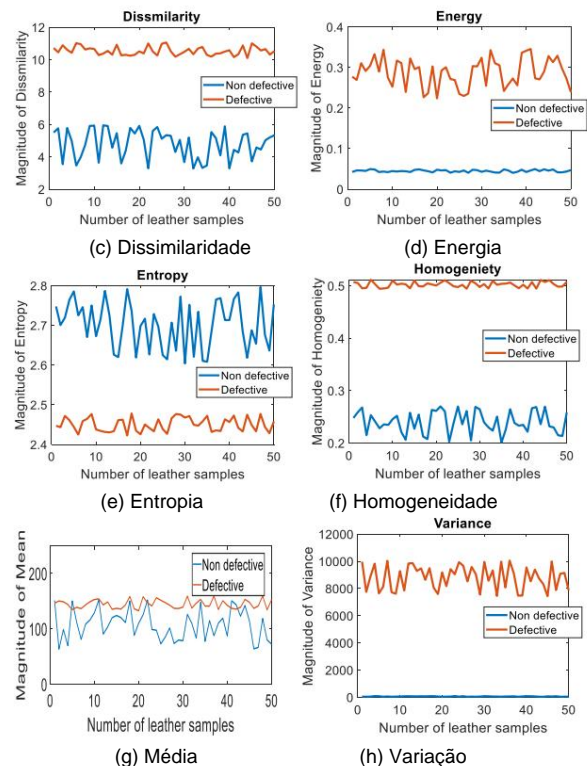
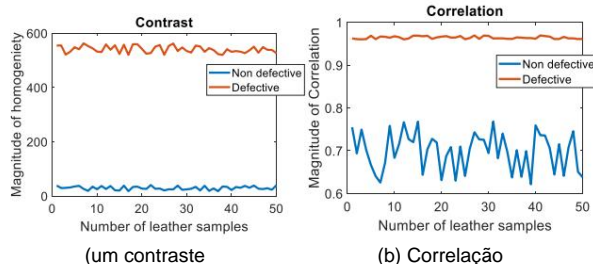


Figura 7. Comparação das características estatísticas de textura extraídas de amostras de couro

4.2 Treinamento da rede neural perceptron

A fim de garantir a classificação robusta e precisa de amostras defeituosas e não defeituosas, o conjunto de dados rotulados de 1232 imagens de couro é considerado para treinar a rede neural. Os valores de amostra do conjunto de dados de treinamento e o alvo correspondente do perceptron são mostrados na Tabela 3. Aqui, as classes defeituosas e não defeituosas de amostras de couro são identificadas como 0 e 1, respectivamente.

O algoritmo de aprendizado Perceptron é aplicado para treinar a rede para os dados de entrada fornecidos e a convergência da iteração é alcançada em 21 épocas. O melhor desempenho de treinamento é alcançado em 25 épocas para os erros absolutos mínimos, conforme mostrado na Figura 8.




Figura 8. Resultados do treinamento e desempenho da rede neural perceptron proposta

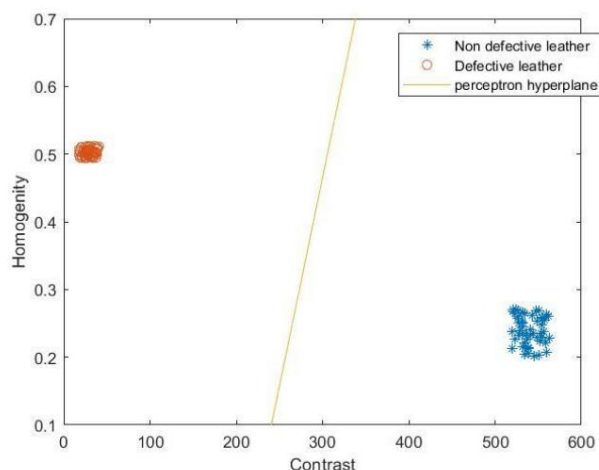
Tabela 3. Valores de amostra do conjunto de dados de treinamento para a rede neural perceptron de camada única

Parâmetros de textura								
Contraste	Dissimilaridade	Homogeneidade	Entropia	Energia GLCM média	GLCM variância	GLCM correlação	Classe	
41,26	4,796	0,200	2,832	0,047	63,37	55,33	0,627	0
66,64	6,036	0,167	3,022	0,038	71,70	87,94	0,621	0
52,82	5,343	0,186	2,953	0,041	85,20	78,71	0,664	0
23,25	3,726	0,237	2,626	0,057	151,13	33,46	0,652	0
17,60	3,196	0,272	2,611	0,058	154,92	38,96	0,774	0
62,47	5,725	0,178	3,004	0,039	69,30	89,29	0,650	1
25,87	3,777	0,244	2,708	0,054	130,16	46,94	0,724	1
63,69	5,882	0,171	3,020	0,038	78,22	90,34	0,647	1
31,50	4,298	0,213	2,752	0,050	185,08	45,84	0,656	1
82,41	6,648	0,156	3,108	0,034	69,42	110,77	0,628	1

Tabela 4. Valores de amostra do conjunto de dados de treinamento para a rede neural perceptron multicamada


Nome dos defeitos	Parâmetros de textura				variação		correlação GLCM	Classificação
	Contraste	Dissimilaridade	Homogeneidade	Entropia	GLCM significa	GLCM		
sem defeito	41,26	4,79	0,21	2,83	63,37	55,33	0,62	1 0 0 0 0
grãos soltos	519,7	10,7	0,51	2,42	150,91	9583,7	0,97	0 1 0 0 0
Grão fora	350,0	14,73	0,06	3,46	38,49	198,96	350,04	0 0 1 0 0
Marcas de crescimento	801,0	22,50	0,04	3,79	52,84	479,62	801,04	0 0 0 1 0
Pinhole	498,1	17,06	0,06	3,59	68,93	271,71	0,08	0 0 0 0 1

O vetor de peso estimado para as amostras de treinamento fornecidas do vetor de recursos de entrada usando o algoritmo perceptron é $W = [-2387,63 -289,793 -165,742 -4735,84 5524,64 -36.517 -2.185 -10.654]^T$. Usando esses valores de peso, um hiperplano é calculado para os vetores de recursos fornecidos para classificar as amostras de couro defeituosas e não defeituosas. A Figura 9 mostra o hiperplano calculado para os recursos de entrada, como contraste e homogeneidade. Pode-se notar que todas as amostras de couro estão classificadas entre a classe defeituosa e não defeituosa.

**Figura 9.** Hiperplano estimado para classificação de amostras de couro defeituosas e não defeituosas

Além disso, um conjunto de dados rotulados de 1232 imagens de couro é considerado para treinamento de rede neural multicamada para a classificação de defeitos de couro. Os valores de amostra do conjunto de dados de treinamento e o alvo correspondente do perceptron são mostrados na Tabela 4.

A Figura 10 mostra o desempenho de treinamento e validação da rede neural proposta. Verificou-se que o melhor desempenho de validação é alcançado em 68 épocas com o valor mínimo de erro quadrático médio de 0,040453.

**Figura 10.** Desempenho de treinamento e validação da rede neural proposta

4.3 Desempenho de classificação do perceptron multicamadas

A fim de quantificar o desempenho de classificação da rede neural proposta, a matriz de confusão é construída, pois fornece as informações sobre as classificações reais e previstas de superfícies de couro. Com base na matriz de confusão, métricas como precisão, taxa de descoberta falsa, sensibilidade, taxa de falso positivo e precisão são calculadas conforme as seguintes equações:

$$\text{Precisão (valor de previsão positiva)} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (6)$$

$$\text{Taxa de descoberta falsa} = \frac{\text{FP}}{\text{FP} + \text{TP}} \quad (7)$$

$$\text{Sensibilidade (taxa de verdadeiros positivos)} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (8)$$

$$\text{taxa de falso positivo} = \frac{\text{FP}}{\text{FP} + \text{TN}} \quad (9)$$

$$\text{Precisão geral} = \frac{+}{+++} \quad (10)$$

onde, TP (verdadeiro positivo) são as amostras de couro positivas classificadas corretamente, TN (verdadeiro negativo) são as amostras de couro negativas corretamente classificadas FP (falsos positivos) são as amostras negativas classificadas incorretamente e FN (falso negativo) são as amostras de couro positivas incorretamente classificadas amostras.

A Figura 11 mostra a matriz de confusão da rede neural perceptron proposta para os dados de treinamento, teste e validação. Aqui, os elementos diagonais representam as classificações corretas, enquanto todas as outras entradas mostram classificações incorretas. Números altos em células verdes representam respostas corretas e os números baixos em células vermelhas correspondem a respostas incorretas. Os valores percentuais na coluna da extrema direita da matriz de confusão mostram a precisão (ou valor preditivo positivo) e a taxa de descoberta falsa da rede neural proposta para a classificação de cada classe de couro.

Além disso, a linha inferior da matriz de confusão mostra a sensibilidade e a taxa de falsos positivos. A célula inferior direita da matriz de confusão mostra a precisão geral da previsão e é de 94,2%.

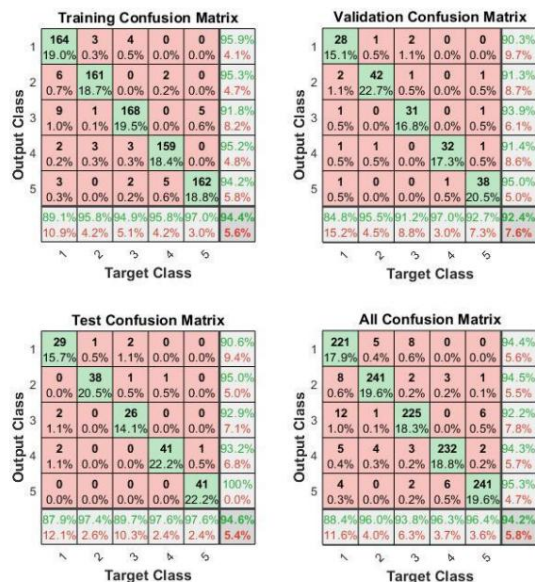


Figura 11. Matriz de confusão do classificador de rede neural proposto para conjuntos de dados de treinamento, teste e validação

4.4 Teste e validação da rede neural perceptron

Para testar e validar o desempenho da rede neural perceptron proposta, um conjunto de dados composto por 1232 amostras de couro defeituoso e não defeituoso é apresentado e os resultados da classificação são analisados. Um sistema de computação de 64 bits, 8 GB de RAM, 2,70 GHz é usado para aplicações de detecção e classificação de defeitos no MATLAB Versão 2020. O tempo de detecção para a classificação de defeitos de couro é de 0,5 s. A Tabela 5 mostra a precisão de classificação do método proposto para diferentes defeitos e é superior às técnicas existentes, como máquina de vetores de suporte [16], rede neural feed forward [15].

Observa-se que a rede neural perceptron treinada é capaz de reconhecer defeitos de couro e a precisão geral da classificação é de 94,2%. Esses resultados indicam o melhor desempenho de classificação do método proposto para detecção de defeitos de couro e aplicações de classificação.

Tabela 5. Precisão da classificação dos defeitos do couro

Tipo de amostra	Amostras do conjunto de treinamento	Precisão
sem defeito	251	94,4%
Grão fora	250	94,5%
Marcas de crescimento	240	92,2%
grãos soltos	241	94,3%
Pinhole	250	95,3%

4.5 Detecção de defeitos em imagens de couro

No método proposto, a imagem fornecida é dividida e indexada usando blocos de imagem não sobrepostos de tamanho 200 x 150 para detectar os defeitos do couro. A presença de defeito no bloco de imagem fornecido é identificada pela rede neural perceptron e é marcada na cor vermelha, conforme mostrado na Figura 12.



Figura 12. Detecção de defeitos em imagens de couro usando o método proposto

A partir desses resultados, verifica-se que o método proposto é útil na detecção e localização de defeitos nas imagens de couro. O método baseado em visão de máquina proposto usando a rede neural perceptron pode ser implementado em um ambiente industrial para aplicações de detecção e classificação de defeitos em couro.

5. CONCLUSÕES

Este artigo apresentou abordagens de redes neurais baseadas em perceptron para a detecção e classificação de defeitos de couro usando análise de textura baseada em GLCM. A natureza do padrão de textura de diferentes defeitos de couro, como marcas de dobra, granulação, marcas de crescimento, granulação solta, furos de alfinetes, são distintos e são claramente identificados usando GLCM com um nível de cinza de 32 para o tamanho da janela de 200 x 150. Uma mudança significativa no número de ocorrências de níveis de cinza é visualizada no GLCM para diferentes defeitos de couro. Estes resultados comprovam a eficácia do GLCM para distinguir os diferentes defeitos do couro.

A rede neural perceptron de camada única e multicamada é aplicada para discriminar as amostras de couro defeituosas e não defeituosas usando um conjunto de dados rotulados de características de textura extraídas como contraste, correlação, dissimilaridade, energia, entropia, homogeneidade, média e variância e a convergência da iteração é alcançada em 68 épocas. No método proposto, a imagem fornecida é dividida e indexada usando blocos de imagem não sobrepostos de tamanho 200 x 150 para detectar os defeitos do couro.

O método proposto atinge uma precisão de classificação melhorada de 94,2% em comparação com os métodos existentes. O método de detecção e classificação de defeitos de couro proposto requer menos requisitos computacionais e pode ser adequadamente implementado para inspeção visual automatizada de defeitos de couro.

RECONHECIMENTOS

Os autores agradecem ao Conselho de Pesquisa em Engenharia Científica, Nova Delhi, por fornecer financiamento de pesquisa para estabelecer o sistema de visão de máquina por meio da Bolsa de pesquisa inicial de carreira (DST No: SB/FTP/ETA-276/2012). Os autores agradecem à administração do Vellore Institute of Technology, Vellore e KH Leather Private Limited, Vellore, Tamil Nadu, Índia, por fornecer as instalações infra-estruturais necessárias e amostras de couro, respectivamente.

REFERÊNCIAS

- [1] He, FQ, Wang, W., Chen, ZC (2006). Inspeção visual automática para fabricação de couro. Key Engineering Materials, 326-328: 469-472. <http://dx.doi.org/10.4028/www.scientific.net/KEM.326-328.469>
- [2] Kohli, P., Garg, S. (2013). Estimativa da qualidade do couro usando um sistema automatizado de visão de máquina. IOSR Journal of Electronics and Communication Engineering (IOSR-JECE), 6(3): 44-47. <http://dx.doi.org/10.9790/2834-0634447>
- [3] Aslam, M., Khan, TM, Naqvi, SS, Holmes, G., Naffa, R. (2019). Sobre a aplicação de visão de máquina automatizada para inspeção e classificação de defeitos de couro: uma pesquisa. IEEE Access, 7: 76065-76078. <http://dx.doi.org/10.1109/ACCESS.2019.2957427>
- [4] Krastev, K., Georgieva, L., Angelov, L. (2004). Seleção de características de couro para reconhecimento de defeitos usando lógica fuzzy. CompSysTech '04: Proceedings of the 5th International Conference on Computer Systems and technologies, 1-6. <https://doi.org/10.1145/1050330.1050367>
- [5] Haralick, RM, Shanmugam, K., Dinstein, I. (1973). Recursos de textura para classificação de imagens. IEEE Transactions on Systems, Man and Cybernetics, 3(6): 610-621. <https://doi.org/10.1109/TSMC.1973.4309314>
- [6] Daugman, JG (1985). Relação de incerteza para resolução no espaço, frequência espacial e orientação otimizada por filtros corticais visuais bidimensionais. Journal of the Optical Society of America, 2(7): 1160-1169. <https://doi.org/10.1364/JOSAA.2.001160>
- [7] Azencott, R., Wang, JP, Younes, L. (1997). Classificação de texturas usando filtros de Fourier em janela. IEEE Transactions on Pattern Analysis and Machine Intelligence, 19(2): 148-153. <https://doi.org/10.1109/34.574796>
- [8] Unser, M. (1995). Classificação e segmentação de texturas usando transformadas wavelet. IEEE Transaction on Image Processing, 4(11): 1549-1560. <http://dx.doi.org/10.1109/83.469936>
- [9] Kwak, C., Ventura, JA, Tofang-Sazi, K. (2001). Inspeção automatizada de defeitos e classificação de tecido de couro. Intelligent Data Analysis, 5(4): 355-370. <http://dx.doi.org/10.3233/ida-2001-5406>
- [10] Liong, ST, Gan, YS, Huang, YC, Yuan, CA, Chang, CH (2019). Segmentação automática de defeitos em couro com aprendizado profundo. <https://arxiv.org/abs/arXiv:1903.12139>
- [11] Lovergine, FP, Branca, A., Attolico, G., Distante, A. (1997). Inspeção de couro por análise de textura orientada com abordagem morfológica. Anais da Conferência Internacional sobre Processamento de Imagens, pp. 669-671. <http://dx.doi.org/10.1109/ICIP.1997.638584>
- [12] Kasi, MK, Rao, JB, Sahu, VK (2014). Identificação de defeitos de couro usando um algoritmo de processamento de imagem de detecção de borda autoadaptável. 2014 Conferência Internacional sobre Computação e Aplicações de Alto Desempenho (ICHPCA), 1-4. <http://dx.doi.org/10.1109/ICHPCA.2014.7045526>
- [13] Viana, R., Rodrigues, RB, Alvarez, MA, Pistori, H. (2007). SVM com seleção estocástica de parâmetros para classificação de defeitos em couro bovino. PSIVT 2007: Avanços em Tecnologia de Imagem e Vídeo, 600-612. http://dx.doi.org/10.1007/978-3-540-77129-6_52
- [14] Liu, B., Wu, SJ, Zou, SF (2010). Tecnologia de detecção automática de defeitos de superfície em produtos plásticos com base em visão de máquina. 2010 Conferência Internacional sobre Automação Mecânica e Engenharia de Controle, Wuhan, pp. <https://doi.org/10.1109/MACE.2010.5536470> 2213-2216.
- [15] Amorim, WP, Pistori, H., Pereira, MC, Jacinto, MAC (2010). Redução de atributos aplicada à classificação de defeitos de couro. 2010 23ª Jornada SIBGRAPI de Gráficos, Padrões e Imagens, pp. 353-359. <http://dx.doi.org/10.1109/SIBGRAPI.2010.54>
- [16] Pereira, RF, Medeiros, CMS, Filho, PPR (2018). Classificação da qualidade do couro de cabra usando visão computacional e aprendizado de máquina. 2018 Conferência Conjunta Internacional sobre Redes Neurais (IJCNN), pp. 1-8. <http://dx.doi.org/10.1109/IJCNN.2018.8489265>
- [17] Cui, J., Wang, YR (2010). Uma nova abordagem de classificação analógica de falhas usando um classificador de máquinas de vetores de suporte. Metrologia e Sistemas de Medição, XVII(4): 561-582. <http://dx.doi.org/10.2478/v10178-010-0046-0>