



Sistema de inspeção baseado em visão para detecção de defeitos de superfície de couro usando abordagem de classificador de conjunto de otimização de enxame de partículas de convergência rápida

Malathy Jawahar^{1,2} & NK Chandra Babu^{1,2} & K. Vani³ & L. Jani Anbarasi⁴ & S. Geetha⁴

Recebido: 19 de outubro de 2019 /Revisado: 11 de julho de 2020 /Aprovado: 25 de agosto de 2020 /

Publicado on-line: 28 de setembro de 2020

Springer Science+Business Media, LLC, parte da Springer Nature 2020

Abstrato

A inspeção de defeitos de superfície desempenha um papel vital na fabricação de couro. A prática atual envolve um especialista para inspecionar cada peça de couro individualmente e detectar defeitos manualmente. No entanto, tal inspeção manual é altamente subjetiva e varia consideravelmente de um classificador para outro. O sistema de visão computacional para materiais naturais como couro é um problema de pesquisa desafiador. Este estudo descreve a aplicação do sistema de visão computacional para capturar imagens da superfície do couro e o uso de um novo algoritmo de Fast Convergence Particle Swarm Optimization (FCPSO) em um conjunto de recursos de textura artesanais, como GLCM e classificados usando classificadores supervisionados, como Multi Layer Perceptron (MLP), Árvore de Decisão (DT), SVM, Naïve Bayes, K-Nearest Neighbors (KNN) e Random Forest (RF). O FCPSO usando função de aptidão modificada pela entropia de Shannon de banda seletiva é implementado para segmentar imagens de couro industrial. A eficiência de segmentação do algoritmo FCPSO proposto é avaliada e seu desempenho é comparado com outros algoritmos de otimização. A eficiência dos algoritmos de segmentação é avaliada usando medidas de desempenho, como diferença média (AD), Taxa de erro de área (AER), índice de similaridade estrutural baseado em borda (ESSIM), F-Score, coeficiente de correlação normalizado (NK), erro de sobreposição (OE), conteúdo estrutural (SC), índice de similaridade estrutural (SSIM) e índice de similaridade de Zijdenbos (ZSI). A correlação da área segmentada usando FCPSO com a verdade do terreno dos especialistas é alta com valor de R de 0,84. A extração de recursos é realizada usando recursos de textura GLCM e os recursos mais proeminentes foram selecionados usando teste t estatístico e coeficiente de correlação. Os resultados experimentais mostraram resultados encorajadores para classificador florestal aleatório confirmando o potencial do sistema proposto para classificação automática de defeitos de couro.

Palavras-chave Análise de imagem. Detecção de defeitos na superfície do couro, segmentação. Otimização de enxame de partículas de convergência rápida. Classificador de conjunto

* Malathy Jawahar
malathy.jawahar@gmail.com

1. Introdução

Os couros e peles, matéria-prima para a indústria do couro, por serem materiais naturais, sofrem de muitos defeitos ou manchas superficiais, que degradam a qualidade dos couros produzidos a partir deles. Defeitos em couros e peles são amplamente classificados como ante-mortem (defeitos causados antes da morte do animal) e post-mortem (defeitos causados após a morte do animal). Além disso, defeitos podem se manifestar em couros devido a métodos de processamento de couro defeituosos. Defeitos comuns encontrados no couro são marcas de marca, marcas de carrapato, marcas de varíola, picada de inseto, feridas, arranhões, marcas de crescimento, cortes de esfolia, veias, rugas, dobras de gordura, mancha de sal, jateamento de cal, manchas de cromo ou corante, grão desenhado, abertura cortes, danos nos orifícios dos pinos, etc.

A inspeção de qualidade para classificação é um passo importante na avaliação da área útil dos couros. Cada peça de couro é classificada com base em seu valor de corte efetivo, que é decidido levando em consideração o número, tamanho e localização dos defeitos superficiais. O preço do couro varia de acordo com o valor efetivo de corte e, portanto, a classificação é feita com muito cuidado por classificadores experientes. Mas a inspeção visual é tediosa e repetitiva e, portanto, a fadiga pode levar a defeitos que passam despercebidos, levando à imprecisão e inconsistência. Os avanços científicos feitos na área de processamento digital de imagens (DIP) podem ser explorados de forma lucrativa para o desenvolvimento de um sistema automático de inspeção de defeitos de couro preciso e objetivo [3, 26]. O primeiro passo nessa direção seria conceber um método de processamento de imagem adequado para fins de identificação e classificação de defeitos. A própria superfície do couro natural tem uma textura inerente devido aos arranjos dos poros do cabelo e outros recortes de grãos naturais, que variam consideravelmente de um tipo de couro para outro e, portanto, a separação de defeitos de um fundo tão complexo é uma tarefa bastante desafiadora. Vários pesquisadores desenvolveram métodos para classificação de defeitos de couro baseados em visão computacional. Muitos métodos de segmentação foram propostos ao longo dos anos para imagens médicas [2, 32, 58] e naturais [10, 20, 44, 56, 72]. Uma segmentação de contorno [4, 9] usando regra heurística foi aplicada para segmentação de defeitos de couro. O limiar de Otsu, uma das técnicas de segmentação simples e robustas, tem sido usada por muitos pesquisadores e aplicada para imagens de couro [71]. Segmentação de imagem de couro com base no limiar de erro mínimo [25], morfologia matemática [65], segmentação estrutural de imagem [36], distribuição de histograma [68], estrutura de pirâmide multi-resolução [41], pirâmide de arestas de ligação de nós [42], segmentação sintática bruta [52], segmentação de imagem multibanda [12] e esquemas que envolviam segmentação baseada em limiar e morfologia [38, 39], métodos de detecção de borda autoadaptativa [31] foram propostos por vários pesquisadores. Para simplificar o processo de segmentação de couros, alguns pesquisadores recorreram à marcação manual de defeitos e classificação das regiões usando processamento de imagem [24, 47, 51, 64]. Esquema de decomposição Quadtree para particionar imagens de couro em blocos homogêneos usando thresholding também foi proposto [36]. Segmentação baseada em wavelet e segmentação usando filtro Gabor ajustado em diferentes escalas para vários defeitos [5-7, 22, 23, 44, 60] também foram tentadas para segmentação de defeitos de couro. Para resolver problemas de otimização, o algoritmo Particle Swarm Optimization (PSO) foi introduzido por Kennedy & Eberhart [33]. Muitos pesquisadores tentaram abordar o problema de encontrar valores de limiar ideais para segmentar imagens usando algoritmos inspirados biologicamente [16, 18, 37, 43, 45, 46, 54, 55, 58]. A segmentação usando métodos de aprendizado profundo está sendo praticada nas indústrias de manufatura [14, 53]. Couro sendo material natural, muitos dos defeitos são encontrados dispersos na natureza e vários tipos variados de defeitos ocorrem juntos. Portanto, gerar um grande número de imagens de verdade do terreno anotadas para treinamento de aprendizado profundo [35] é um desafio. Os métodos de segmentação para imagens de defeitos de couro são frequentemente avaliados empregando imagens de couro paradas de tamanho de janela pequeno ou número reduzido de

amostras e, portanto, muito longe das condições de operação industrial. Este estudo se concentra principalmente no desenvolvimento da variante PSO com melhor desempenho em termos de tempo quando aplicada a imagens de couro industrial.

Em seus primórdios, a detecção de defeitos em imagens de couro foi muito influenciada pela escolha de recursos pré-definidos adequados e o subsequente uso de classificadores tradicionais de aprendizado de máquina. De fato, esse processo de identificação e extração de características é sem dúvida a fase mais significativa no procedimento de detecção de defeitos, onde o principal trabalho é descrever as características defeituosas do couro de uma maneira mais distinta. O processo de extração de recursos usa pixels de imagem como entradas e produz como saída - um vetor de recursos 'FV' que codifica um aspecto específico da imagem, como forma, textura, cor, etc. Esses vetores de recursos são usados para construir um classificador treinando no padrões subjacentes denotados pelos vetores de recursos extraídos. A percepção de textura tem um papel muito importante a desempenhar no sistema visual humano de reconhecimento. Semelhanças e diferenças nas variações de intensidade são bem descritas pelo recurso de textura. Os recursos de textura artesanais mais bem-sucedidos e usados na literatura são os recursos de Haralick [21] derivados da Matriz de Coocorrência de Nível de Cinza (GLCM), que extraem os padrões locais na imagem e contam sua distribuição por toda a imagem. Eles fornecem uma boa codificação discriminativa das informações baseadas em textura e gradiente, na forma de valores de recursos. Neste trabalho, consideramos as características de Haralick representativas de melhor desempenho a partir de valores GLCM e investigamos seu poder discriminativo e robustez.

Atualmente, os métodos de aprendizado profundo [17, 40] estão avançando em ritmo acelerado e se tornaram uma estratégia de aprendizado orientada a dados para inúmeras tarefas de visão computacional. Eles realizam engenharia de recursos para produzir recursos naturais de imagens, combinando as duas etapas tradicionais: extração e classificação de recursos, juntas como um paradigma de ponta a ponta.

A Rede Neural Convolutiva (CNN) é um modelo típico de aprendizado profundo para engenharia de recursos. A CNN é construída empilhando várias camadas de rede neural umas sobre as outras. Eles possuem um conjunto de filtros que identificam as características discriminativas das imagens alimentadas como entradas para a CNN. As camadas inferiores da CNN contêm filtros que aprendem características mais genéricas das imagens, como bordas e cantos, enquanto as camadas superiores contêm filtros que usam os recursos de baixo nível e aprendem características mais abstratas e complexas, que diferenciam imagens de uma classe das imagens de outra classe. As CNNs operam diretamente nos pixels da imagem bruta e, assim, aprendem automaticamente as características discriminativas das imagens, durante o procedimento de treinamento da CNN. Com esta situação, a CNN é aberta e livre para utilizar recursos de todos os níveis (baixo e alto) e assim aprender melhor as informações semânticas das imagens fornecidas. Além disso, um procedimento de treinamento profundo da CNN tem uma vantagem adicional - ou seja, refinar a representação dos dados de entrada para corresponder ao requisito de um problema específico.

Além disso, o processo de engenharia de recursos liderado pelo procedimento de treinamento da CNN se depara com a alta adaptabilidade dos paradigmas de aprendizado profundo.

O aprendizado profundo não funciona tão bem com dados pequenos. Os modelos da CNN que alcançam desempenho superior nas pesquisas mais recentes são frequentemente treinados em centenas de milhares e até milhões de amostras. A fim de aprender melhores representações visuais e chegar a boas características de discriminação e, portanto, melhorar o desempenho de detecção de defeitos, as CNNs profundas exigem grandes conjuntos de dados rotulados [62], talvez até da ordem de dez mil.

Os recursos derivados provam ser eficazes apenas quando o conjunto de dados de treinamento é volumoso e contém representações consideráveis para imagens em todas as classes. O desempenho do modelo é melhor, quando temos mais dados rotulados. Como no paradigma de aprendizado profundo, os dados são o recurso mais valioso e o conjunto de imagens de couro enfrenta o problema de apenas menos imagens não rotuladas.

No entanto, existem situações práticas, ao resolver problemas do mundo real como o nosso, conjunto de imagens de couro, onde a disponibilidade de tais dados de treinamento rotulados é restrita e limitada e grandes conjuntos de dados não existem. Nesses casos, o uso de métodos de aprendizado profundo é uma opção inviável, e as técnicas convencionais de extração e classificação de recursos se tornarão a solução adequada. Infelizmente, para essas aplicações de detecção de defeitos de couro, esses grandes conjuntos de dados não estão prontamente disponíveis e são caros e demorados para adquirir. Com os conjuntos de dados menores disponíveis de imagens de couro, os algoritmos clássicos de ML, como regressões, floresta aleatória e SVM, geralmente superam as redes profundas.

Além disso, redes profundas não são facilmente compreendidas. As redes profundas são uma espécie de “caixa preta” na qual não é possível entender completamente o “interior” das redes profundas. Seu poder preditivo é alto, mas eles vêm com baixa capacidade abrangente. ou seja, a capacidade de interpretação. Os hiperparâmetros e o design de rede também são bastante desafiadores devido ao entendimento da semana da fundamentação teórica. Existem muitas ferramentas recentes, como mapas de saliência e diferenças de ativação, que funcionam muito bem para alguns domínios, como detecção de objetos.

Infelizmente esse conhecimento não se transfere completamente para todas as aplicações, no mesmo nível de desempenho. Essas ferramentas são projetadas principalmente para garantir que o modelo de rede não seja superajustado no conjunto de dados ou não se concentre em determinados recursos que são espúrios. Além disso, ainda é difícil compreender a importância por recurso para a decisão geral tomada pela deep net.

Por outro lado, algoritmos clássicos de ML, como SVM, Random Forests, etc., vêm com capacidade abrangente e são compreensíveis devido ao processo direto de engenharia de recursos.

Além disso, o ajuste de hiperparâmetros e as modificações do design do modelo são feitas diretamente, pois há uma boa compreensão dos algoritmos subjacentes e dos dados. Isso é particularmente importante quando os resultados do modelo precisam ser traduzidos e entregues à plataforma de domínio, onde às vezes há audiência não técnica, como tarefa de detecção de defeitos de couro.

Este problema de detecção de defeitos de couro é um problema do mundo real, onde a disponibilidade de um enorme conjunto de imagens rotuladas é uma restrição e uma compreensão de como a detecção é alcançada prova ser mais útil [27, 28]. Assim, na presente investigação, foi feita uma tentativa de derivar o algoritmo de Otimização de Enxame de Partículas de Convergência Rápida (FCPSO) baseado em multi-limiar para determinar o nível de limiar ideal para segmentar imagem de superfície de couro complexa e foi comparado com vários algoritmos de segmentação. Efetividade da área segmentada pelo algoritmo FCPSO e variantes PSO, GA foram validadas em comparação com área segmentada manualmente pelos especialistas usando correlação (valor R). As características de Haralick extraídas de matrizes de coocorrência foram computadas a partir de imagens de couro segmentadas. Realizou-se a seleção de características com base no coeficiente de correlação e teste t. Classificação Supervisionada usando Multi Layer Perceptron (MLP), Decision Tree (DT), SVM, Naïve Bayes, KNN e classificadores Random Forest (RF) foram usados para classificar as regiões de couro defeituosas e não defeituosas [26]. As principais contribuições do método proposto são

eu. Algoritmo FCPSO para segmentar os defeitos de couro do fundo complexo. ii. Analisando o desempenho de vários algoritmos de segmentação PSO usando estatísticas medidas.

iii. Seleção de recursos com base no coeficiente de correlação e teste t para escolher os recursos de textura GLCM mais proeminentes. 4. Classificação e validação de desempenho de vários supervisionados com base no discriminante vetor de recursos.

2. Materiais e métodos

2.1 Aquisição de imagens

As imagens de couro usadas neste estudo foram capturadas usando um couro industrial especialmente projetado sistema de aquisição de imagens. A amostra de couro foi transportada usando uma alimentação e um rolo de entrega. A câmera colorida CCD industrial da Sony com interface USB 3.0 foi montada horizontalmente carruagem em movimento. À medida que o couro é transportado, a carruagem move a câmera horizontalmente de esquerda para a direita e as imagens foram capturadas. Número de quadros capturados para cada amostra de couro varia consideravelmente dependendo do tamanho do couro e cada imagem de couro adquirida foi 1600 × 1200 pixels. Banco de dados composto por 115 quadros de imagem com defeito e 85 sem defeito foram desenvolvidos para uso no estudo. As imagens de verdade (GT) foram segmentadas manualmente por selecionadores de couro experientes. Destas, 140 imagens de amostra foram usadas para o treinamento e restantes 60 amostras para teste. As técnicas de processamento de imagem propostas neste estudo foram programado em ambiente Scilab.

2.2 Pré-processamento de imagem

O couro sendo um material natural possui grandes variações de intensidades de tons de cinza devido à textura e recortes de grãos naturais. O filtro Wiener oferece uma compensação ideal na restauração os efeitos de brilho e contraste desiguais, bem como suavização de ruído nas imagens de couro. As imagens de couro pré-processadas foram analisadas qualitativamente por MSE (Eq. 1) e PSNR (Eq. 2) e posteriormente sujeitos a segmentação usando FCPSO.

$$MSE = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (C_{ij} - \hat{C}_{ij})^2 \quad (1)$$

$$PSNR = 10 \log_{10} \frac{255^2}{MSE} \text{ dB} \quad (2)$$

2.3 Segmentação de imagem

A segmentação de imagem atribui um rótulo a cada pixel na imagem, de modo que pixels com o mesmo rótulo compartilham certas características visuais. Eliminando o background e extraindo o regiões defeituosas é a Região de Interesse. análise de textura, limiar de histograma, agrupamento métodos baseados e métodos de divisão e fusão baseados em região foram os vários algoritmos de segmentação de imagem. O método de busca exaustiva baseado no critério Otsu é simples, mas tem a desvantagem de ser computacionalmente caro. Alternativa a Otsu, vários algoritmos de inspiração biológica foram explorados na segmentação de imagens. A Otimização de Enxame de Partículas (PSO) é uma técnica de aprendizado de máquina vagamente inspirada em pássaros voando em busca de Comida. Basicamente consiste em um número de partículas que se movem coletivamente no espaço de busca. Para uma melhor modelagem da seleção natural, variantes de PSO como DPSO, FODPSO e evolução O PSO otimizado [59] tem melhor taxa de convergência. Um PSO paralelo foi apresentado para três diferentes estratégias de comunicação por [11, 19]. Otimizando o projeto de topologia de distribuição rede de área local é analisada por Salman e Andries [13, 15, 34] usando fuzzy PSO onde operador de agregação fuzzy é usado para agregar o objetivo [30]. O problema da cobertura em

sensor sem fio é aprimorado usando otimização de enxame de partículas com base no coeficiente de aceleração dinâmica por Teng et al. [63]. Resumidamente, todos os métodos PSO existentes mencionados acima possuem respectivas vantagens como convergência rápida, compartilhamento e robustez de informações e adversidades como ótimo local, convergência prematura e maldição da dimensionalidade etc.

2.3.1 Algoritmo de segmentação de otimização de enxame de partículas de convergência rápida proposto

Neste estudo, um algoritmo modificado de Fast ConvergenceParticle Swarm Optimization foi adotado para segmentar regiões defeituosas nas imagens complexas de couro. A inteligência de enxame é um modelo útil para sistemas adaptativos. Deixe-me denotar a imagem de couro de tamanho $M \times N$ representada e o valor de intensidade da imagem como partículas individuais com níveis de cinza variando de 0 a 255. Cada partícula do enxame representa uma solução possível. PSO é aprender com a experiência individual das partículas e também com a experiência de sua vizinhança. Com base na distribuição de intensidade de probabilidade, as partículas se movem estocasticamente de acordo com sua posição (X_i^k) e velocidade (V_i^k) na direção de sua posição de partícula individual local lembrada (l_i^k) e a posição global de enxame mais lembrada de todo o enxame (g_i^k). O sucesso da partícula foi avaliado pela função de aptidão. Cada partícula no enxame é atualizada iterativamente de acordo com a posição da partícula, velocidade e melhor posição passada.

A velocidade e a posição da partícula individual foram calculadas conforme indicado nas equações [3, 4],

$$V_{i,k+1} = W V_i^k + \gamma_1 r_1 (l_i^k - X_i^k) + \gamma_2 r_2 (g_i^k - X_i^k) \quad (3)$$

$$X_i^{k+1} = X_i^k + V_{i,k+1} \quad (4)$$

A nova velocidade é determinada usando a influência da inércia (W), e os fatores de aprendizado γ_1 , γ_2 . Os vetores aleatórios (r_1 , r_2) geralmente são atribuídos a valores aleatórios que variam entre 0 e 1. O fator de aprendizagem γ_1 ajusta o movimento da partícula em direção à sua melhor posição local e γ_2 global. Segundo termo $\gamma_2 (g_i^k - X_i^k)$ na Eq. 3 é dito que o componente cognitivo é a influência da melhor posição encontrada pela partícula dada e o valor correspondente de melhor aptidão é representado como $pbest$ e é referido como memória ou autoconhecimento. $\gamma_1 (l_i^k - X_i^k)$ na Eq. 3 é dito ser um componente cognitivo social é uma atração linear para a melhor posição adequada em qual a partícula se encontra. A melhor adequação correspondente é representada como $gbest$ e como cooperação ou conhecimento social. No início da iteração, as partículas precisam ser inicializadas de forma que sejam distribuídas o mais uniformemente possível no espaço de busca do problema. Da mesma forma, um pequeno componente autocognitivo e um grande componente cognitivo social facilitariam a convergência, bem como evitariam a explosão do enxame.

No PSO convencional, a influência da inércia (W) receberia um valor constante ligeiramente menor que 1 para todas as iterações. A inércia é o parâmetro que equilibra e controla a exploração da busca. Um alto valor de inércia no início da iteração permite que a partícula se mova livremente para encontrar o ótimo global e depois de atingir a região ótima, o valor da inércia precisa ser reduzido para restringir a busca, mudando assim da abordagem exploratória para a abordagem exploratória. Assim, uma inércia que muda dinamicamente facilitará a convergência mais rápida das partículas [29, 48, 69, 70]. À medida que a partícula no enxame era atualizada, para cada iteração uma nova inércia modificada dinamicamente variável (W) com valor estritamente menor que 1 era calculada

(Eq. 5). O coeficiente diminui à medida que o número de iterações aumenta, garantindo que as partículas escapem dos mínimos locais e leve a uma convergência mais rápida.

$$\begin{aligned}
 & +1 \frac{jW_j}{V_k} \frac{V_k}{V_k} \frac{\tilde{y}1r1 \text{ gi } k\tilde{y}Xi \text{ k}}{V_k} \frac{\tilde{y}2r2 \text{ l } k\tilde{y}Xi \text{ k}}{V_k} j\tilde{y}k \\
 & \text{onde } jW_j1 \\
 & j \frac{V_{k+1}}{V_k} j\tilde{b}j \frac{\tilde{y}1r1 \text{ gi } k\tilde{y}Xi \text{ k}}{V_k} \frac{\tilde{y}2r2 \text{ l } k\tilde{y}Xi \text{ k}}{V_k} j\tilde{y}k \\
 & \delta \text{ b } j \text{ i: e } \frac{V_{k+1}}{V_k} j\tilde{y}k; j\tilde{V}i \text{ k } p1j\tilde{y}k^*V_k \quad \delta 5p \\
 & \frac{\tilde{y}1r1 \text{ gi } k\tilde{y}Xi \text{ k } j}{V_k} j\tilde{y}k; j\tilde{y}1r1 \text{ gi } k\tilde{y}Xi \text{ k } j\tilde{y}k^*V_k \\
 & \frac{\tilde{y}2r2 \text{ l } j \text{ k}\tilde{y}Xi \text{ k}}{V_k} k \text{ j}\tilde{y}k; j\tilde{y}2r2 \text{ l } j\tilde{y}k^*V_k
 \end{aligned}$$

A entropia de banda seletiva foi realizada para avaliar a pontuação de cada posição. Seja N o número j de ocorrência de O_i e sua frequência de L_{\min} e L_{\max} em cada categoria foi computado entre

Os valores de L_{\min} e L_{\max} foram calculados usando a função normal $f(x)$ dada na Eq. (6) analisando a distribuição das várias imagens de defeitos, onde a distribuição mínima e máxima são consideradas para melhor aleatoriedade.

$$\begin{aligned}
 f(x) &= \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\
 \text{O Caso contrário ()} & \quad \delta 6p
 \end{aligned}$$

onde 'x' se refere ao valor de intensidade do nível de cinza variando de 100 a 170 na curva normal e para não defeitos a linha fica na curva assintótica.

A função de aptidão F_{fc} foi calculada usando a entropia de Shannon [57] para o cálculo ocorrência de frequência dentro do intervalo dado na Eq. 7.

$$\begin{aligned}
 F_{fc} &= \frac{1}{N} \sum_{j=L_{\min}}^{L_{\max}} -j \log de \quad \delta 7p \\
 Do &= \frac{N}{L_{\max} - L_{\min}}
 \end{aligned}$$

O algoritmo FCPSO proposto (Fig. 5) inicializa as partículas e calcula o valor de aptidão de cada partícula usando entropia de banda seletiva (Eq. 7). p_{best} é atualizado quando o valor de fitness atual é melhor do que o valor de p_{best} assumido anteriormente. g_{best} para cada partícula é determinado pela escolha da partícula com o melhor valor de fitness de todos os vizinhos. Para cada partícula, a velocidade é atualizada (Eq. 3) usando a influência de inércia modificada (W) que muda dinamicamente para cada iteração para cada iteração (Eq. 5) em vez de valor fixo como no PSO convencional. Da mesma forma, a posição das partículas também é atualizada (Eq. 4). O processo continua até que a iteração máxima seja alcançada.

2.3.2 Medida de validação

A região segmentada FCPSO foi validada com a região de defeito segmentada manualmente por o especialista (Ground Truth - GT). Medidas de desempenho, como diferença média (AD), área Taxa de erro (AER), índice de similaridade estrutural baseado em borda (ESSIM), correlação normalizada coeficiente (NK), erro de sobreposição (OE), conteúdo estrutural (SC), índice de similaridade estrutural (SSIM) e Zijdenbos Similarity Index (ZSI) [2, 32] foram realizados para quantificar a precisão do algoritmo FCPSO como dado nas Eqs. 8-16.

$$AD = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N |x_j - y_j| \quad (8)$$

$$SC = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})^2 + (y_j - \bar{y})^2 - 2 \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})(y_j - \bar{y}) \quad (9)$$

$$SE = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})^2 + (y_j - \bar{y})^2 - 2 \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})(y_j - \bar{y}) \quad (10)$$

$$NK = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})^2 + (y_j - \bar{y})^2 - 2 \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})(y_j - \bar{y}) \quad (11)$$

$$SSIM = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})^2 + (y_j - \bar{y})^2 - 2 \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})(y_j - \bar{y}) \quad (12)$$

$$ESSIM = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})^2 + (y_j - \bar{y})^2 - 2 \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})(y_j - \bar{y}) \quad (13)$$

Onde X_j e y_j referem-se à região segmentada FCPSO e segmentação manual região, M,N refere-se ao tamanho da imagem, $l(x, y)$, $c(x, y)$, $s(x, y)$, $e(x, y)$ refere-se à luminância, contraste, componente estrutural e de borda da região segmentada FCPSO e região de segmentação manual e R_p representa a região segmentada usando FCPSO e R_m corresponde a região segmentada manual.

$$ZSI = \frac{2 \times \sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})(y_j - \bar{y})}{\sum_{j=1}^M \sum_{k=1}^N (x_j - \bar{x})^2 + \sum_{j=1}^M \sum_{k=1}^N (y_j - \bar{y})^2} \quad (14)$$

$$AER = \frac{\sum_{j=1}^M \sum_{k=1}^N (x_j - y_j)^2}{M \times N} \quad (15)$$

$$OE = \frac{1}{M \times N} \sum_{j=1}^M \sum_{k=1}^N (x_j - y_j)^2 \times 10 \quad (16)$$

onde 'M' representa a região segmentada manualmente pelos especialistas e 'P' representa a região do defeito segmentada pelo algoritmo FCPSO proposto.

O erro entre a região segmentada do FCPSO e a região segmentada manualmente é representado por AER e OE. Os resultados de segmentação são considerados precisos quando o índice de similaridade estrutural baseado em borda (ESSIM), coeficiente de correlação normalizado (NK), conteúdo estrutural (SC), índice de similaridade estrutural (SSIM), valor F-score e valores ZSI estão idealmente mais próximos de 1,0 enquanto os valores da Diferença média (AD), AER e OE estão mais próximos de zero. A segmentação de imagens usando PSO, DPSO, FODPSO e GA foi realizada para segmentar as regiões de defeito e foi comparada com o algoritmo FCPSO proposto.

2.4 Extração de recursos

O conjunto de vetores de recursos foi formado usando informações de textura de segunda ordem, construindo uma matriz de Coocorrência de Nível de Cinza (GLCM) a partir de imagens. GLCM envolve a estimativa da função de densidade de probabilidade $P(i, j / \ddot{y}x, \ddot{y}y)$ onde i e j indicam o nível de cinza de dois pixels e $\ddot{y}x$ e $\ddot{y}y$ denotam espaçamento entre os pixels nas dimensões x e y respectivamente [1, 3, 65–67]. Neste estudo, as matrizes de coocorrência foram calculadas para 4 ângulos de deslocamento de 0° , 45° , 90° e 135° mantendo a distância de deslocamento 'd' como 1. Por exemplo, recurso de contraste que representa a anormalidade local presente na imagem foi calculada com $d = 1$ e ângulos de deslocamento (0,45,90,135) o que resulta em quatro recursos (con_0, con_45, con_90, con_135). A média dessas quatro características (con_0, con_45, con_90, con_135) foi derivada como Contraste – Média (F2). Da mesma forma, a diferença entre o máximo (con_0, con_45, con_90, con_135) e o mínimo (con_0, con_45, con_90, con_135) foi derivado como Contraste – Faixa (F22). A Tabela 4 lista os 40 recursos de textura, ou seja, os 20 recursos de média e 20 de intervalo usados neste estudo.

A homogeneidade da superfície do couro foi evidenciada nas características Angular second moment (ASM), Inverse Difference Moment (IDM). A boa superfície do couro apresentou textura homogênea e apresentou valores de ASM e IDM maiores, enquanto a imagem de couro defeituoso não homogênea apresentou valores menores. As variações locais de intensidade presentes na imagem do couro foram indicadas no recurso Contraste. As dependências lineares de nível de cinza na imagem foram exibidas como recurso de correlação. A maioria das regiões defeituosas de couro tinha uma textura grosseira com alta aleatoriedade da distribuição do nível de cinza e foi capturada em Entropia, Variância. Embora todas as 40 características descrevam as características de textura da imagem, é difícil relacionar cada uma dessas características com características de textura específicas da imagem.

2.5 Classificação supervisionada

A classificação é definida como um processo de encontrar um conjunto de atributos para distinguir entre classes de dados com a finalidade de prever a classe de objetos, cujo rótulo de classe é desconhecido. O limite de decisão gerado pelo classificador separa os elementos no espaço de características em dois ou mais conjuntos de classes. Diferentes classificadores chegam a um limite de decisão único usando seu processo de trabalho específico. Os classificadores Supervisionados como Rede Neural (NN), Árvore de Decisão (DT), SVM, Naïve Bayes, KNN e os classificadores propostos Random Forest (RF) foram analisados para distinguir duas classes de características do couro [26, 50].

O classificador Random Forest (RF) é uma combinação de árvore de decisão múltipla proposta por Breiman [8]. Cada árvore pode ser vista como um classificador individual e lança um voto unitário para o

classificação final do conjunto de recursos de entrada. Random Forest divide cada nó usando o melhor subconjunto de recursos escolhido aleatoriamente. A medida de importância da variável de recurso, o erro de previsão na porção fora da sacola para cada árvore foi calculado. O mesmo cálculo foi realizado após permutar cada variável de característica. A média e o desvio padrão normalizado foram calculados.

A divisão da árvore para quando o desvio padrão da diferença na variável de recurso é igual a 0.

A floresta aleatória usa o índice Gini para medir a impureza do nó. É a medida mais comumente escolhido para problemas do tipo classificação. Gini(T) é definido como

$$\text{Gini}(T) = \sum_{j=1}^P p_j^2$$

Onde P_j representa a frequência relativa do conjunto de dados T com n classes.

O fluxo de trabalho do algoritmo de floresta aleatória é ilustrado na Fig. 6.

Para avaliar a precisão do classificador proposto, bem como sua capacidade de generalização, vetores de características foram embaralhados aleatoriamente em 10 grupos diferentes. Cada grupo continha 70% dos dados para treinamento e os 30% restantes para validação. A precisão da validação foi calculada em média em todos os 10 ensaios. Medidas de desempenho como Sensibilidade, Especificidade e Precisão/Valor Preditivo Positivo (VPP), Recall/Valor Preditivo Negativo (NPV) e pontuação F1 também foram computadas a partir da matriz de confusão [61, 73].

3 Resultados e discussão

Neste estudo, as imagens de couro foram obtidas usando um sistema de aquisição de imagens industriais especialmente projetado (ver Fig.1). Fast Convergence Particle Swarm Optimization (FCPSO) foi usado na segmentação de imagens de couro que foram pré-processadas usando filtro wiener. A extração de recursos foi feita usando o método de recursos de textura de Haralick que representa os recursos estatísticos de textura de segunda ordem. O coeficiente de correlação foi usado para selecionar as características ótimas.

A classificação foi realizada usando floresta aleatória para resolver a detecção de defeitos no couro. A metodologia proposta é descrita na Fig. 2.

Pode-se observar na Fig. 3 que as imagens de couro normal têm textura muito lisa e são de natureza altamente homogênea em comparação com as imagens de couro defeituoso que têm textura áspera e grosseira com manchas profundas. Isso mostra que o padrão da região defeituosa era diferente e não uniforme. Essas mudanças de padrão foram analisadas por segmentação e análise de recursos.



Fig. 1 Sistema de aquisição de imagem de couro

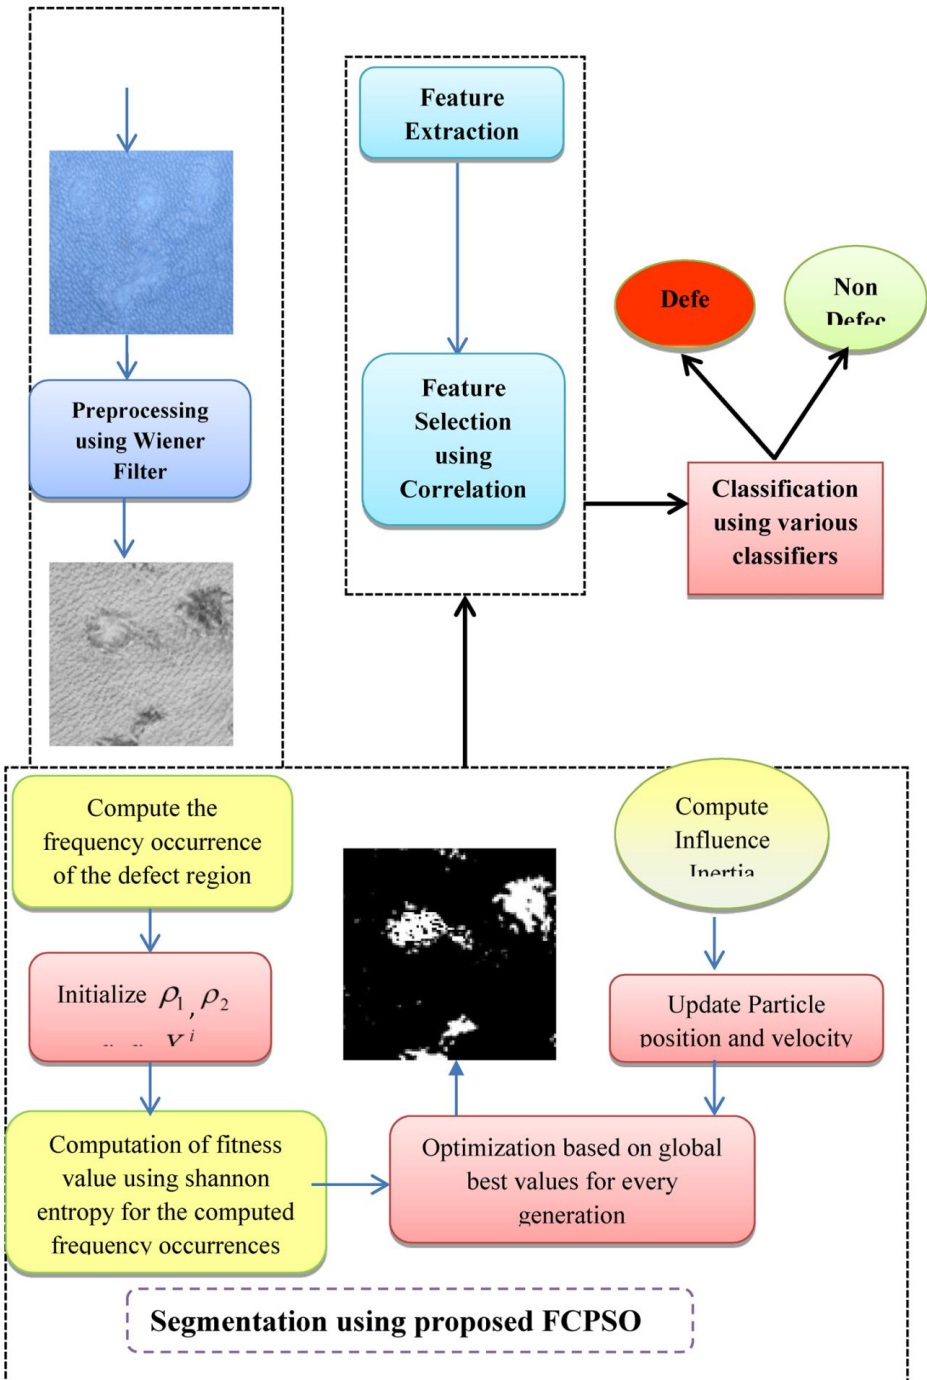


Fig. 2 Diagrama de blocos da metodologia proposta de detecção de defeitos FCPSO




Fig. 3 Imagens de couro originais representativas com defeito

As imagens aprimoradas pré-processadas usando o filtro Wiener estão representadas na Fig. 4. A imagem pré-processada também foi examinada visualmente. A análise qualitativa da imagem pré-processada mostrou um baixo MSE (22,86) e um alto valor de PSNR (71,16).

No PSO convencional, uma busca exaustiva com valores constantes para W é usada para encontrar os valores de limiar ótimos. Para encontrar um nível de limite ótimo, o número de iterações aumenta, resultando em maior tempo de computação. No FCPSO proposto (Fig. 5), para cada iteração, uma nova influência de inércia aleatória (W), que foi estritamente menor que 1 (Eq. 6), foi calculada para todas as partículas do enxame. A nova influência de inércia (W) evita o comportamento de deriva das partículas em torno de falsas soluções (Fig. 6). A distribuição do histograma da Figura 7 mostra que a região defeituosa está na faixa de 100 a 170. Aptidão baseada em entropia de banda seletiva


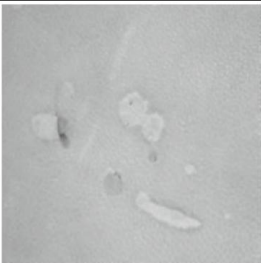


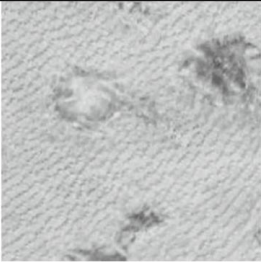
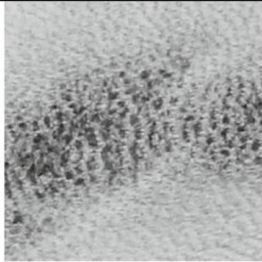
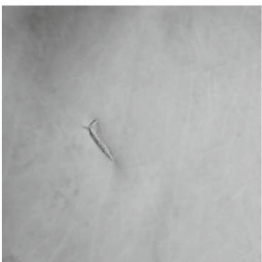

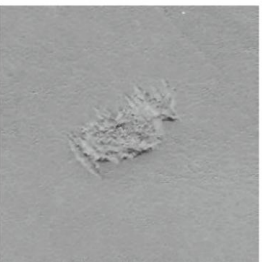
		
Defect1	Defect2	Defect 3
		
Defect 4	Defect 5	Defect 6
		
Defect 7	Defect 8	Defect 9

Fig. 4 Imagem aprimorada pré-processada usando filtro Wiener

função [Eq. 7] descreve a propriedade de textura da imagem do couro e converge no limite do defeito desejado. Portanto, o método FCPSO convergiu mais rápido que o PSO convencional. [Tabela 2]. Os parâmetros iniciais do PSO, DPSO, FODPSO e FCCPSO propostos foram apresentados na Tabela 1.

3.1 Complexidade de tempo

Como o tempo computacional é um dos fatores mais importantes e críticos para a aplicação de defeitos de couro industrial, este aspecto recebeu a devida importância neste estudo. Com relação ao tempo de processamento da CPU para encontrar o limiar otimizado, foi comprovado na literatura que o PSO requer menos tempo quando comparado ao GA e BF [54]. Assim, os tempos de CPU de PSO, DPSO, FODPSO e FCPSO foram apenas comparados. A partir da Tabela 2, pode-se

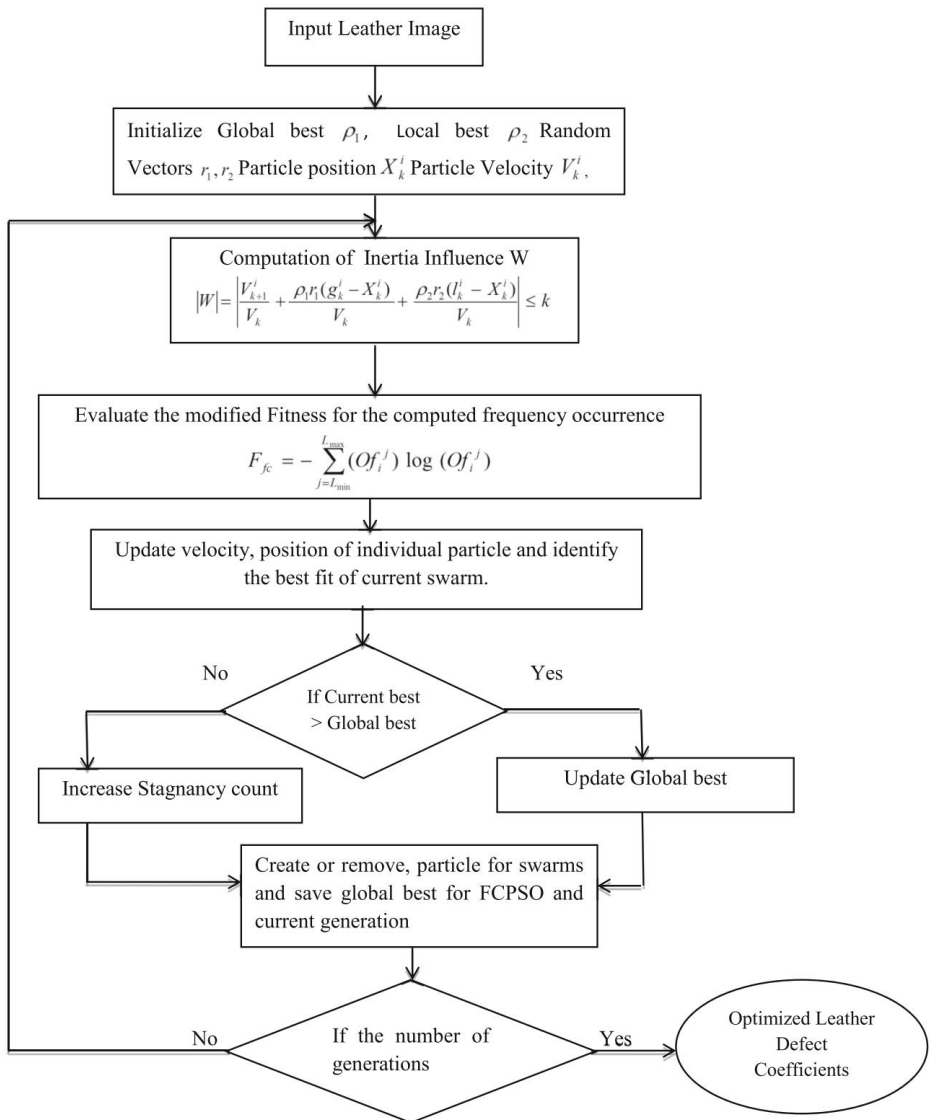


Fig. 5 Algoritmo FCPSO proposto

observaram que o tempo médio de computação para algoritmos de segmentação baseados em PSO variou de 0,33 a 0,45 s enquanto algoritmos de segmentação baseados em FCPSO variaram de 0,22 a 0,35 s. Do ponto de vista visual, a qualidade da imagem segmentada usando FCPSO foi superior para diferentes imagens defeituosas. Além disso, pode-se observar que o tempo computacional para algoritmos de segmentação baseados em PSO inicializados por partículas aleatórias foi maior do que o método proposto. Isso acontece porque o comportamento de deriva das partículas em torno de falsas soluções foi evitado inicializando as partículas usando os valores de entropia que descrevem a propriedade de textura da imagem do couro. PSO com um fi

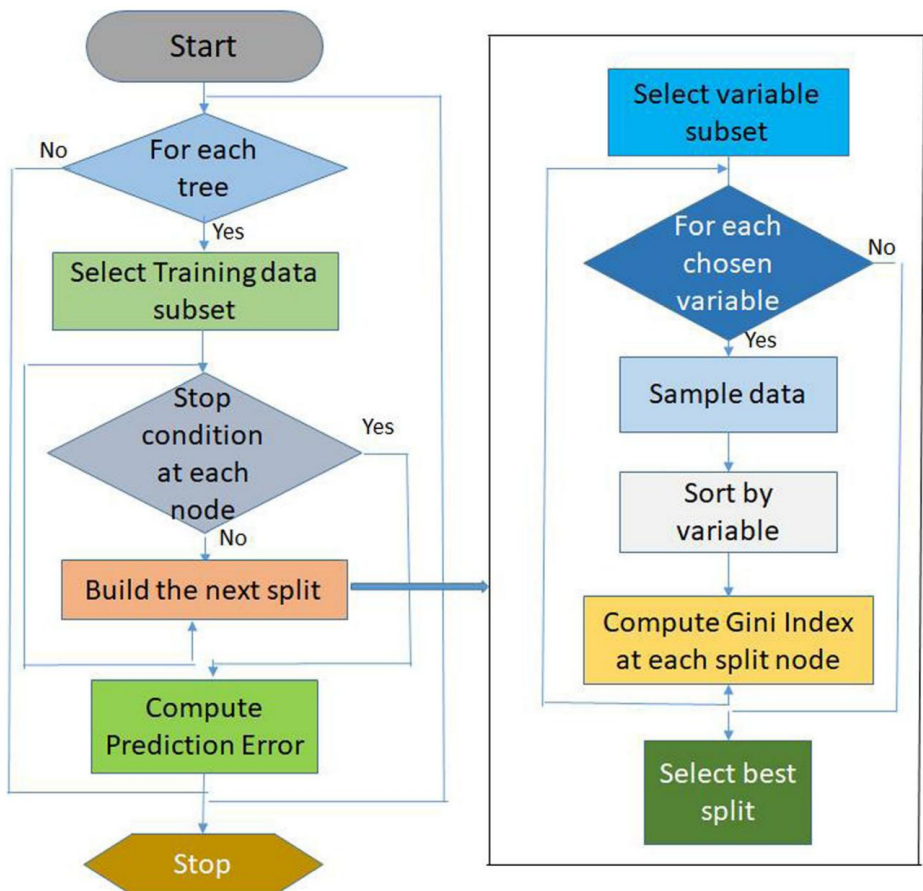


Fig. 6 Fluxograma do algoritmo de floresta aleatória

população (100 partículas) acaba avaliando 100 soluções dentro do mesmo enxame resultando em maior tempo de computação. Em comparação, FCPSO consistindo em enxames menores entre 2 e 6 de 10 e 50 partículas cada, levou a convergências mais rápidas para valores de limiar ótimos. O menor tempo de computação foi alcançado para segmentação baseada em FCPSO usando entropia de banda seletiva variou de 0,28 s a 0,33 s.

A saída segmentada de imagens de couro usando o método Fast Convergence Particle Swarm Optimization (FCPSO) para os diferentes tipos de defeitos são mostrados na Fig. 8. A correlação ($R = 0,84$) da área segmentada do FCPSO proposta com a verdade dos especialistas foi observada para ser alto (Fig. 9).

3.2 Análise de estabilidade

Métodos evolutivos bio-inspirados [49] são conhecidos por serem algoritmos de busca estocásticos e aleatórios. A capacidade de busca desses algoritmos varia para cada iteração, e os resultados absolutos não permanecem os mesmos. Para analisar a estabilidade, os valores de desvio padrão foram calculados e listados na Tabela 3. O valor mais baixo para o desvio padrão indica a

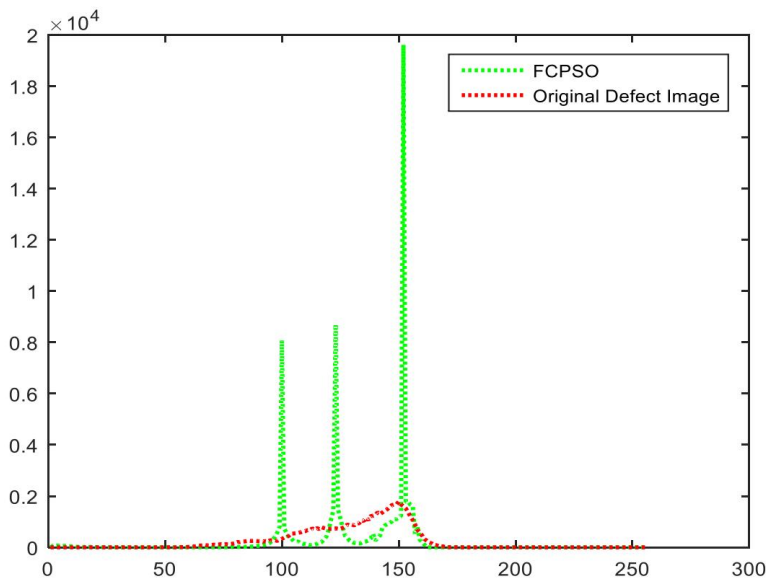


Fig. 7 Distribuição do histograma para imagens de couro do algoritmo FCPSO proposto

estabilidade do algoritmo. Pode-se observar na Tabela 3, que o método proposto foi mais estável do que os outros algoritmos para todas as imagens de defeitos.

$$DST \frac{1}{N} \sum_{i=1}^n \frac{\delta p_{iyy}^2}{s_i}$$

δ18p

Onde STD é o desvio padrão, analisando o melhor valor de fitness da ^a corrida do algoritmo proposto, N são os tempos repetidos de cada algoritmo (N = 30). A partir da Tabela 1, pode-se visto que FCPSO é o algoritmo evolucionário estável quando comparado com outros. FCPSO

Tabela 1 Parâmetros iniciais do PSO, DPSO, FODPSO e FCCPSO proposto

Parâmetro	PSO convencional	DPSO (Sec)	FODPSO (Sec)	FCCPSO proposto
Número de iterações	10	10	10	8
População	150	50	50	40
γ2 γ2	1,5	1,5	1,5	1,5
	1,5	1,5	1,5	1,5
C	1,2	1,2	1,2	Modificado em cada iteração
Vmáx	2 γ2	2	2	2
Vmin	255	γ2	γ2	-2
X max	0	255	255 0	255
X min		0 10	10	0
População mínima	-	50	50	10
População máxima	-			40
Número de enxames	-	4 44		
Mínimos enxames	-	2 22		
Enxames máximos	-	6 66		
Estagnação	-	10 10	10	
Coefficiente fracionário -		-	0,75	

Tabela 2 Tempo médio de execução de diferentes métodos de segmentação usando PSO convencional com a proposta FCPSO

Imagem de teste	PSO convencional	DPSO (Sec)	FODPSO (Sec)	FCPSO proposto
Defeito 1	0,4235	0,4382	0,3871	0,3143
Defeito 2	0,3895	0,4127	0,4044	0,2715
Defeito 3	0,4016	0,4112	0,3661	0,2452
Defeito 4	0,4212	0,4231	0,4038	0,5501
Defeito 5	0,3899	0,3879	0,3544	0,2471
Defeito 6	0,3987	0,3672	0,3298	0,2712
Defeito 7	0,3478	0,3321	0,3123	0,2216
Defeito 8	0,4122	0,3468	0,3123	0,2421
Defeito 9	0,3812	0,3912	0,3313	0,2502

segmentação baseada é capaz de convergir aproximadamente na mesma quantidade de tempo, independentemente da imagem do defeito e condição inicial das partículas.

A análise de desempenho na imagem segmentada foi ainda validada usando medidas de qualidade Índice de dados, índice de similaridade estrutural (SSIM), índice de similaridade estrutural baseado em borda (ESSIM), conteúdo estrutural (SC), coeficiente de correlação normalizado (NK), diferença média (AD), Erro de Sobreposição (OE), Taxa de Erro de Área (AER) e Índice de Similaridade de Zijdenbos (ZSI) e os resultados são apresentados nas Tabelas 4 e 5.

O índice de similaridade (ZSI) foi superior a 0,8 e as taxas de erro (AER, OE) foram de 0,2. Índice de similaridade estrutural baseado em bordas (ESSIM), coeficiente de correlação normalizado (NK), Erro de sobreposição (OE), conteúdo estrutural (SC), índice de similaridade estrutural (SSIM) foram encontrados acima de 0,9 e a diferença média (AD) encontrada em torno de 0,05. Assim, o medidas de desempenho resulta que o algoritmo FCPSO proposto pode ser usado para segmentação de defeitos de couro.

A extração de características foi realizada com as imagens segmentadas do FCPSO. Recursos de textura extraídos atuam como coeficientes preditores para identificar os defeitos da superfície do couro e fornecer informações que refletem a grosseria, suavidade, contraste, homogeneidade e aleatoriedade de distribuição de pixels. Os valores de média e desvio padrão do recurso GLCM extraído são mostrado na Tabela 6.

A Figura 10 mostra os coeficientes de correlação das quarenta variáveis características utilizadas neste estudo. O gráfico de correlação mostra a força e a direção das variáveis de recurso. Cor azul indica a variável a ser positivamente correlacionada, enquanto a cor vermelha indica a variável a ser negativamente correlacionados e a força da variável varia de +1 a -1 e aparecem como grandes círculo para círculo pequeno. Os elementos diagonais mostram como cada variável de recurso é bem positiva correlacionado consigo mesmo. A relação chave é a correlação da variável característica com o alvo a classe 'y' (não defeituosa ou defeituosa) é mostrada na última linha. Pode-se observar que o características Autocorrelação - Média (V1), Sombra de cluster - Média (V5), Probabilidade máxima Média (V10), Soma do quadrado (variância) - Média (V11), Soma média- Média (V12), Variação da soma - Média (V13), Medida de informação de correlação (1) - Média (V17), Medida de informação de correlação (2) - Média (V18), Correlação - Intervalo (V23), Cluster proeminência – Alcance (V24), Cluster Shade – Alcance (V25), Soma do quadrado (variância) - Alcance (V31), Soma média – Intervalo (V32) e Medida de informação de correlação (1) - Intervalo (V37) foram fracamente correlacionados com a variável alvo. Para validar ainda mais, todos os quarenta características foram submetidas ao teste t para determinar as características significativas que proporcionam melhor classificação de couros bons e defeituosos. O teste T mostra se o valor do recurso é estatisticamente




Fig. 8 Saída segmentada FCPSO para diferentes defeitos de couro

significativo para discriminar o valor alvo não defeituoso e defeituoso. Assim, com base no valor do coeficiente de correlação e no valor p do teste t , 24 recursos ótimos foram selecionados de 40 recursos de textura GLCM de Haralick e é mostrado na Fig. 11. Pode ser visto claramente que todos os 24 recursos selecionados têm boa capacidade discriminativa para categorizar a classe alvo defeituosa e não defeituosa. A boa superfície do couro tinha uma textura muito lisa e foi caracterizada com valores altos para variáveis de características como Homogeneidade, Diferença inversa normalizada (DCI)–Média, Diferença inversa de momento normalizada – Média e valores baixos para as demais características. Enquanto as imagens de regiões defeituosas apresentaram manchas porosas com textura áspera e grosseira, que se caracterizaram por altos valores de Contraste, Dissimilaridade, Entropia, etc.

Alguns dos defeitos visualmente pareciam ter textura suave, mas tinham manchas de intensidade variável, e as características de textura refletiam boa discriminação para esses defeitos também.

O gráfico de correlação (Fig. 12) também mostra que todos os 24 recursos de co-ocorrência selecionados foram bem correlacionados com a variável de classe de destino, enquanto as variáveis de recurso, como Homogeneidade,




Fig. 9 Gráfico de correlação do Ground Truth vs área segmentada do FCPSO proposta

Diferença inversa normalizada (DCI) – Média e Momento da diferença inversa normalizada – Média encontrada negativamente correlacionada com a variável resposta.

Neste trabalho, o desempenho de diferentes classificadores como MLP, Decision Tree, SVM, Naïve Bayes, KNN [51] e classificadores Random Forest com duas classes para classificar as imagens da superfície do couro como a classe defeituosa ou não defeituosa foram mostrados na Fig. 13. Inicialmente todos os GLCM extraídos (40 características) foram fornecidos para classificação. As medidas de desempenho como acurácia (86,11%), precisão (88%), recall (86%) e pontuação F1 (84%) do classificador Random Forest superaram significativamente todos os outros classificadores. O vetor de características discriminantes obtido do teste t e das abordagens de correlação descritas anteriormente foi dado como dados de entrada para todos os classificadores.

Como visto na Fig. 14, a maior precisão de 88,8% foi alcançada usando SVM e classificação de floresta aleatória. A precisão de classificação para o classificador Decision Tree, MLP foi de 83,33% e 77% usando o classificador Naïve Bayes. O desempenho do Random Forest foi considerado o mais alto antes e depois da seleção de recursos e, portanto, foi realizada uma otimização adicional dos parâmetros.

O classificador de floresta aleatória foi definido para treinamento com 250 árvores, cada árvore foi construída (Fig. 6) considerando 4 características aleatórias e o gráfico de treinamento (Fig. 15) mostrou que após 50 árvores, flutua um pouco, mas não houve muita mudança em termos de erro. O erro Out-of-Bag indica a estimativa imparcial do erro de classificação à medida que as árvores são adicionadas à floresta e foi encontrado para ser 7,2%. Medida de informação de correlação (2) - Intervalo (Recurso nº V21) foi encontrado como a variável mais importante em termos de “Mean DecreaseGini” bem como “Mean Decrease Accuracy” O restante das variáveis de recurso que tiveram o maior impacto em o modelo de classificação foi indicado na Fig. 15. Várias combinações de treinamento e teste de conjunto de recursos reduzidos foram fornecidas como entrada e a matriz de confusão é mostrada na Tabela 7. A precisão média geral do classificador de floresta aleatória foi de 88,64% com 95% sensibilidade, especificidade de 70%, precisão de 91% e escore F de 93%. Sensibilidade é a probabilidade de que o classificador classifique corretamente o couro defeituoso como defeituoso. Especificidade é a probabilidade de o classificador classificar corretamente o couro bom como normal. Devido à natureza inerente da textura do couro, o padrão de grão proeminente em regiões de couro bom pode ser interpretado erroneamente como regiões defeituosas. Assim, a especificidade do classificador é menor e isso também pode ser devido ao menor número de amostras não defeituosas no conjunto. A área sob as curvas ROC do classificador de floresta aleatória

 Springer

Tabela 4 Análise de desempenho na imagem segmentada usando o algoritmo FCPSO proposto

	Índice de dados	SSIM	ESSIM	SC	NK
Defeito 1	0,9967	0,9074	0,9978	0,9988	1.0000
Defeito 2	0,9962	0,9067	0,8977	0,9840	0,9964
Defeito 3	0,9967	0,9057	0,9177	0,9940	0,9953
Defeito 4	0,9960	0,9052	0,9377	0,9816	0,9945
Defeito 5	0,9778	0,9254	0,9232	0,9787	0,9967
Defeito 6	0,9567	0,9143	0,9342	0,9687	0,9978
Defeito 7	0,9596	0,9021	0,9223	0,9878	0,9934
Defeito 8	0,9921	0,9045	0,8912	0,9341	0,9876
Defeito 9	0,9446	0,9032	0,9443	0,9458	0,9911

treinado com características selecionadas do GLCM (Fig. 16) apresentou maior valor de Az de 0,883 mais próximo de o canto superior esquerdo.

3.3 Avaliação de desempenho usando matriz de confusão

A validação foi feita com um conjunto de dados não visto (amostras de teste) para avaliar a capacidade do classificador para discriminar as imagens de couro defeituosas de não defeituosas. O desempenho da classificação em imagens de couro usando Random Forest é medido em termos de Exatidão, Sensibilidade, Especificidade e Precisão/Valor Preditivo Positivo (PPV), Recall / Valor Preditivo Negativo (VPL) e pontuação F que são frequentemente calculados a partir de um matriz de confusão. Existem duas classes previstas possíveis: “presente” e “ausente” no matriz de confusão. Por exemplo, “presente” significaria que o couro é defeituoso e “ausente” significaria que o couro não tem o defeito. As definições de TP, TN, FP, e FN são os seguintes (Eq. 19,20,21,22,23,24,25):

& Verdadeiros positivos (TP): Armações de couro defeituosas corretamente classificadas como defeitos.

& True negativos (TN):Boas armações de couro corretamente classificadas como boas

& Falsos positivos (FP): Boa armação de couro classificada erroneamente como defeituosa.

& Falsos negativos (FN): Armação de couro defeituosa classificada erroneamente como boa.

$$\text{Precisão } \% = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Tabela 5 Medidas de qualidade do algoritmo FCPSO proposto

Defeito	Índice de dados	ZSI	AER	OE
Defeito 1	0,0160	0,7980	0,2119	0,2561
Defeito 2	0,0635	0,8356	0,2009	0,2103
Defeito 3	0,0390	0,7804	0,2131	0,2312
Defeito 4	0,0687	0,8323	0,1967	0,2201
Defeito 5	0,0342	0,7945	0,2215	0,2101
Defeito 6	0,0422	0,8034	0,2212	0,1898
Defeito 7	0,0456	0,8143	0,2123	0,2154
Defeito 8	0,0676	0,7803	0,1855	0,2245
Defeito 9	0,0551	0,7795	0,2491	0,2435

Tabela 6 Valores médios e desvio padrão das características extraídas

Recurso Nº Recurso		Média e desvio padrão valores de recurso		valor p
		Não defeituoso grupo	Grupo defeituoso	
F1	Autocorrelação - Média	22.97 ± 2.306	23,77 ± 4,994	0,490
F2	Contraste- Média	0.047 ± 0.032	0,009 ± 0,037 <0,005	
F3	Correlação- Média	0.626 ± 0.217	0,712 ± 0,092 <0,010	
F4	Proeminência do cluster - Média	0.707 ± 0.600	1,231 ± 0,761 0,005	
F5	Sombra do cluster - Média	0.195 ± 0.354	0,163 ± 0,361 0,731	
F6	Dissimilaridade - Média	0.047 ± 0.032	0,091 ± 0,037 <0,005	
F7	Energia - Média	0.730 ± 0.221	0,585 ± 0,167 0,002	
F8	Entropia- Média	0.511 ± 0.381	0,819 ± 0,277 <0,005	
F9	Homogeneidade - Média	0.976 ± 0.016	0,954 ± 0,018 <0,005	
F10	Probabilidade máxima - Média	0.815 ± 0.168	0,713 ± 0,149	0,010
F11	Soma do quadrado (variância) - Média	22.852 ± 2.284	23,670 ± 4,979	0,478
F12	Soma média - Média	9.554 ± 0.511	9,675 ± 0,987	0,600
F13	Variação da soma - Média	83.414 ± 14.308	81,231 ± 19,170 0,637	
F14	Soma entropia - Média	0.479 ± 0.359	0,756 ± 0,254 <0,005	
F15	Variação da diferença - Média	0.047 ± 0.032	0,091 ± 0,037 <0,005	
F16	Entropia de diferença - Média	0.174 ± 0.107	0,294 ± 0,086 <0,005	
F17	Medida de informação de correlação (1) - Média	0,420 ± 0,170	0,451 ± 0,090 0,280	
F18	Medida de informação de correlação (2) - Média	0,453 ± 0,276	0,598 ± 0,128	0,001
F19	Diferença inversa normalizada (DCI) - Média	0,994 ± 0,003	0,989 ± 0,004 <0,005	
F20	diferença inversa normalizado - Média	0,999 ± 0,0005	0,998 ± 0,0005 <0,005	
F21	Autocorrelação – Faixa 0,010 ± 0,007	Contraste – Faixa 0,024 ± 0,018	0,025 ± 0,013 <0,005	
F22	Correlação – Faixa 0,158 ± 0,067	Proeminência do agrupamento – Faixa 0,076 ± 0,053	0,053 ± 0,026 <0,005	
F23	Tonalidade do agrupamento – Faixa 0,034 ± 0,027	Dissimilaridade – Faixa 0,024 ± 0,016	0,161 ± 0,052 0,844	
F24	Entropia – Faixa 0,0570 ± 0,027.	Homogeneidade – Faixa 0,024 ± 0,009	0,198 ± 0,158 0,001	
F25	máxima – Faixa 0,012 ± 0,008	Soma do quadrado (variância) – Faixa 0,024 ± 0,011	0,052 ± 0,033 0,038	
F26	média – Faixa 0,0006 ± 0,0005	Variação da soma – Faixa 0,070 ± 0,041	0,053 ± 0,026 <0,005	
F27	soma – Faixa 0,040 ± 0,030	Variação da diferença – Faixa 0,039 ± 0,048	0,041 ± 0,017 <0,005	
F28	entropia – Faixa 0,065 ± 0,042	Medida de informação de correlação (1) – Faixa 0,040 ± 0,023	0,108 ± 0,046 <0,005	
F29	0,030 Medida de informação de correlação (2) - Faixa 0,065 ± 0,042	Diferença inversa normalizada – Faixa 0,002 ± 0,002	0,026 ± 0,013 <0,005	
F30	normalizada (DCI) – Faixa 0,002 ± 0,002	Momento de diferença normalizada – Faixa 0,0003 ± 0,0002	0,026 ± 0,0132 <0,005	
F31			0,012 ± 0,008	0,892
F32			0,0005 ± 0,0004	0,349
F33			1,326 ± 0,585	<0,005
F34			0,071 ± 0,028	<0,005
F35			0,053 ± 0,026	<0,005
F36			0,115 ± 0,039	<0,00
F37			0,204 ± 0,040	0,008
F38			0,109 ± 0,037	<0,005
F39			0,005 ± 0,002	<0,005
F40			0,0008 ± 0,0004	<0,005

Sensibilidade ¼

TP

TP þ FN

ð20Þ




Fig. 10 Gráfico de correlação para recursos GLCM - antes da seleção de recursos

$$\text{Especificidade} \propto \frac{TN}{TN + FP} \quad \delta 21^{\circ}$$

$$\text{Precisão ou PPV} \propto \frac{TP}{TP + FP} \quad \delta 22^{\circ}$$

$$\text{Recall ou VPL} \propto \frac{TN}{TN + FN} \quad \delta 23^{\circ}$$

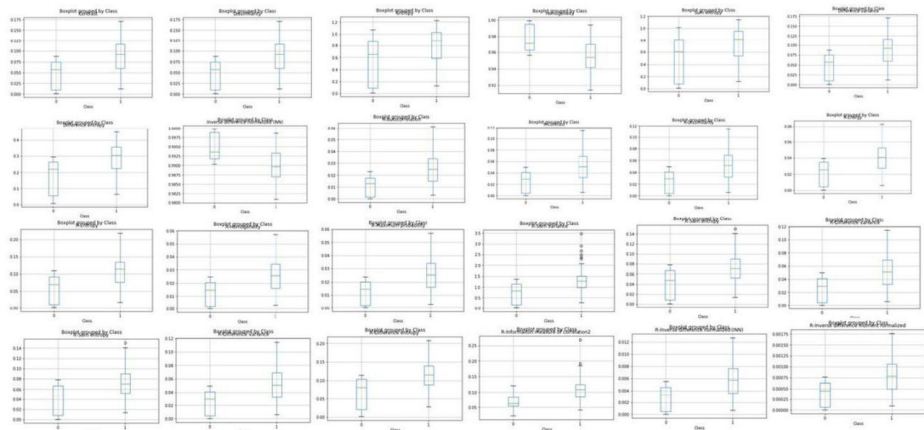


Fig. 11 Características de textura ideais selecionadas para classificação de defeitos de couro




Fig. 12 Gráfico de correlação para Haralick Co-ocorrência - recursos selecionados

$F1Score \frac{1}{2} * Recall * Precisão$ $\delta p = \delta \delta Recall \delta p Precisão$ $24p$

Além disso, o coeficiente de correlação de Matthews (Mcc) [Mathew B 1975], uma medida da qualidade de classificações binárias (duas classes) expressas como




Fig. 13 Desempenho dos classificadores antes da seleção de recursos




Fig. 14 Desempenho dos classificadores após a seleção de recursos

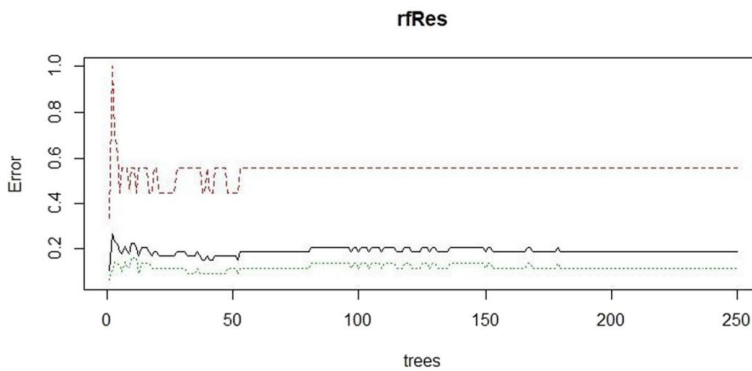


Fig. 15 Taxa de erro fora do pacote para classificador de floresta aleatória

Tabela 7 Matriz de confusão para floresta aleatória treinada usando recursos ideais GLCM

TN	FP	FN	TP	Precisão	Erro	TPR	TNR	Precisão	Pontuação F1
4	3	2	27	86,11	13,89	0,93	0,57	0,90	0,92
6	5	1	26	84,21	15,79	0,96	0,55	0,84	0,90
5	2	2	26	88,57	11,43	0,93	0,71	0,93	0,93
4	5	2	25	80,56	19,44	0,93	0,44	0,83	0,88
9	1	0	26	97,22	2,78	1,00	0,90	0,96	0,98
6	1	1	28	94,44	5,56	0,97	0,86	0,97	0,97
6	2	3	25	86,11	13,89	0,89	0,75	0,93	0,91
6	4	1	25	86,11	13,89	0,96	0,60	0,86	0,91
5	1	2	28	91,67	8,33	0,93	0,83	0,97	0,95
7	3	1	25	88,89	11,11	0,96	0,70	0,89	0,93
Média				88,64	11,36	0,95	0,70	0,91	0,93




Fig. 16 Gráfico de importância de variável de recurso

$$Mc \frac{1}{2} \frac{\delta \cdot TP \cdot TN \cdot \bar{\delta} \cdot FP \cdot FN}{TP \cdot FP \cdot \delta \cdot \bar{\delta} \cdot FP \cdot FN + \delta \cdot TP \cdot TN \cdot \bar{\delta} \cdot FP \cdot FN}$$

O valor mais alto de Mcc próximo ao valor de +1 representa uma previsão perfeita, enquanto 0 representa uma previsão aleatória média e \bar{y} 1 indica uma previsão inversa.

4. Conclusão

Neste estudo, uma detecção automatizada de defeitos de couro foi desenvolvida para detectar couro defeituos superficiais. A principal contribuição deste estudo está na imagem industrial do couro sistema de aquisição. Um algoritmo automático de segmentação de otimização de enxame de partículas de convergência rápida para segmentar as texturas em regiões homogêneas (normais) e não homogêneas (defeituosas) foi desenvolvido usando influência de inércia modificada juntamente com a nova função de aptidão para convergência mais rápida de partículas. Os resultados da segmentação do FCPSO foram comparados com o PSO convencional e outros algoritmos de variantes do PSO como DPSO, FODPSO e mostrou-se eficiente para várias imagens de defeitos de couro. As características de textura GLCM do couro segmentado foram extraídas. Mais proeminente características para defeitos automáticos de couro foram selecionados usando coeficiente de correlação e teste t. Os recursos extraídos foram dados como entrada para diferentes classificadores supervisionados, a saber Rede Neural (NN), Árvore de Decisão (DT), SVM, Naïve Bayes, KNN e Random Forest (RF) foram empregados para classificar regiões defeituosas e normais da imagem do couro. Os resultados obtidos concluíram que o FCPSO proposto juntamente com o algoritmo Random Forest usando o conjunto de recursos ideal teve boa discriminação de couro defeituoso e não defeituoso e levou a uma melhor precisão de classificação 88,64% com Az e F- valor de 0,883 e 0,93 respectivamente. O sistema proposto resolveu problemas de segmentação manual de couro defeitos e pode ser usado para detecção automática de defeitos de couro na indústria de couro.

Agradecimentos Os autores agradecem o apoio financeiro do CSIR, New Delhi sob o Supra Projeto Institucional S&T Revolution in Leather with a Green Touch (STRAIT) comunicação nº. A/2018/LPT/CSC0201/1275.

Apêndice

Derivação dos recursos de textura de Haralick da matriz de coocorrência de nível de cinza

$P(i,j)$ é (i,j) a entrada no GLCM normalizado; $P_x(i)$ é a i -ésima entrada na matriz de probabilidade marginal obtido pela soma das linhas de $P(i,j)$; $P_x(i) = \sum_j P(i,j)$; $P_y(j)$ é a j -ésima entrada na marginal matriz de probabilidade obtida pela soma das colunas de $P(i,j)$; $P_y(j) = \sum_i P(i,j)$; G é o número de níveis de cinza na imagem quantizada. \bar{x} , \bar{y} , \bar{xy} são as médias e desvio padrão de p_x e p_y , respectivamente.

Não.	Nome do recurso	Equação	Descrição
1	Autocorrelação	$\bar{y} = \sum_{i,j} P(i,j)$	Devolve a ocorrência de probabilidade do pixel específico
2	Contraste	$\bar{y} = \sum_{i,j} i-j P(i,j)$	Retorna o limite de variação local dos níveis de cinza em uma textura
3	Correlação	$\bar{y} = \sum_{i,j} (i-j)^2 P(i,j)$	Retorna a probabilidade de ocorrência do par de pixels específico
4	Proeminência do cluster	$\bar{y} = \sum_{i,j} i-j P(i,j)$	Mede a assimetria da matriz (assimetria)
5	Sombra de cluster	$\bar{y} = \sum_{i,j} i-j P(i,j)$	Mede a assimetria do GLCM (assimetria)
6	Dissimilaridade	$\bar{y} = \sum_{i,j} i-j P(i,j)$	Retorna o limite de variação local linear dos níveis de cinza em uma textura
7	Energia (uniformidade)	$\bar{y} = \sum_{i,j} P(i,j)^2$	Retorna a soma do quadrado elementos do GLCM.
8	Entropia	$\bar{y} = - \sum_{i,j} P(i,j) \log P(i,j)$	Retorna o grau de aleatoriedade e complexidade de uma textura
9	Homogeneidade	$\bar{y} = \frac{1}{1 + \sum_{i,j} i-j P(i,j)}$	Retorna a consistência da distribuição dos elementos GLCM
10	Probabilidade máxima	$\text{máximo}_{i,j} P(i,j)$	Retorna o maior valor $P(i,j)$ encontrado dentro da janela
11	Soma do quadrado (variação)	$\bar{y} = \sum_{i,j} (i-j)^2 P(i,j)$	Mede a dispersão dos valores em torno da média
12	Soma média	$\bar{y} = \sum_{i,j} i P_x(i)$	Mede o valor médio de P_x e P_y
13	Variação da soma	$\bar{y} = \sum_{i,j} (i-j)^2 P(i,j)$	Mede a variância da entropia da soma
14	Soma de entropia	$\bar{y} = \sum_{i,j} P_x(i) \log P_x(i) + P_y(j) \log P_y(j)$	Mede a soma de P_x e entropia
15	Variação da diferença	$\text{Variação } P(x+y)$	Mede a diferença de variância entre dois valores
16	Diferença de entropia	$\bar{y} = \sum_{i,j} P_x(i) - P_y(j) \log P_x(i) - P_y(j) $	Mede a diferença de P_x e entropia
17	Medida de informação de correlação (1)	$\frac{H(XY) - H(X) - H(Y)}{\max\{H(X), H(Y)\}}$	Mede a dependência linear de g níveis de raios nos pixels vizinhos.
18	Medida de informação de correlação (2)	$\bar{y} = \exp\left(-\frac{1}{2} \sum_{i,j} (i-j)^2 P(i,j)\right)$	Mede a dependência linear de níveis de cinza nos pixels vizinhos.
19	Diferença inversa normalizado (DCI)	$\bar{y} = \frac{1}{\sum_{i,j} i-j P(i,j)} \sum_{i,j} \frac{1}{ i-j } P(i,j)$	Retorna a distribuição linear normalizada consistência dos elementos GLCM

Não. Nome do recurso	Equação	Descrição
20 Momento de diferença inversa normalizado	$\frac{G}{\sum_{j=1}^N \sum_{i=1}^N p_i - p_j } = \frac{1}{G^2} \sum_{i=1}^N \sum_{j=1}^N p_i - p_j $	Retorna a consistência da distribuição normalizada dos elementos GLCM

Referências

- Ahmed N, Natarajan T, Rao KR (1974) Discrete cosine transform. *IEEE Trans Comput* 23:90–93
- Alkan A, Tuncer SA, Gunay A (2014) Análise comparativa de imagens de RM para detecção de nódulos de tireoide e quantificação. *Medição* 47:861–868
- Anil KJ, Mihran T (1998) Análise de textura. World Scientific Publishing Co, The Handbook of Pattern Recognition and Computer Vision, pp 207–248
- Attila L, Dmitry C (1991) Regras de correção de linha baseadas em conhecimento em um sistema de visão de máquina para a indústria do couro. *Aplicações de Engenharia de Inteligência Artificial* 4:433–438
- Branca A, Attolico G, Distante A (1996) Análise de dados multiescala para detecção de defeitos de couro. *Proc. SPIE* 2908, aplicativos, arquiteturas e sistemas de visão de máquina. *Integração.*: 97–108
- Branca A, Abbate MG, Lovergine FP, Attolico G, Distante A (1997a) Inspeção de couro através da detecção de singularidades usando transformadas wavelet. *Conferência Internacional sobre Análise e Processamento de Imagens* 2:584–592
- Branca A, Lovergine FP, Attolico G, Distante A (1997b) Detecção de defeitos em couro por singularidades orientadas. *Conferência Internacional sobre Análise Computacional de Imagens e Padrões* 1296:223–230
- Breiman L (2001) Florestas aleatórias. *Mach Learn* 45:5–32
- M. Bruder (junho de 2019) Para a qualificação de couro, você precisa de um humano! Esse é realmente o caso?," *Anais da XXXV International Union of Leather Technologists and Chemists Societies (IULTCS)*, PG. 93.
- Cao L, Bao P, Shi Z (2008) O GA de aprendizado de esquema mais forte e sua aplicação ao limiar multinível. *Image Vis Comput* 146:387–390
- Chang JF, et al. (2005) Um algoritmo de otimização de enxame de partículas paralelo com estratégias de comunicação. *Revista de Ciência da Informação e Engenharia*.
- Chris, CB, Peter JH, Wayne, PP, Michael, PH, Richard, PG (1996) Classificação de pele de ovelha usando varredura a laser e reconhecimento de padrões. *Proc. SPIE 2908, Machine Vision Applications, Architectures, and Systems Integration*, 33, <https://doi.org/10.1117/12.257274>.
- Deng, J.; Dong, W.; Socher, R.; Li, L.J.; Li, K.; Li, F.-F. (2009) ImageNet: um banco de dados hierárquico de imagens em larga escala. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Miami, FL, EUA, 20–25 de junho; págs. 248–255.
- Tabernik Domen, Sela Samo, Skvarc Jure, Skocaj Danijel, abordagem de aprendizagem profunda baseada em segmentação para detecção de defeitos de superfície, *J Intell Manuf*, Vol.31, no. 3, pág. 759–776, 2020.
- Dongping Tian EFPSO (2018) Uma otimização eficaz de enxame de partículas difusas e suas aplicações. *Diário de Ocultação de Informações e Processamento de Sinais Multimídia* 9(6):1365–1379
- Eberhart R, Shi Y, Kennedy J (2001) *Swarm intelligence*. Morgan Kaufmann, San Mateo
- Ge, W.; Yu, Y. (2017) Empréstimo de tesouros dos ricos: Aprendizagem de transferência profunda por meio de ajuste fino conjunto seletivo. In *Proceedings of the IEEE Computer Vision and Pattern Recognition (CVPR)*, Honolulu, HI, EUA, 21 a 26 de julho de 2017; págs. 1086–1095.
- Ghamisi P, Couceiro MS, Benediktsson JL, Ferreira NMF (2012) Um método eficiente para segmentação de imagens baseado em cálculo fracionário e seleção natural. *Expert Syst Appl* 39:12407–12417
- Girshick, R.; Donahue, J.; Darrel, T.; Malik, J. (junho de 2014) Hierarquias de recursos ricas para detecção precisa de objetos e segmentação semântica. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Columbus, OH, EUA, 23–28; págs. 580–587.
- Hammouche K, Diaf M, Siarry P (2008) Um método de limiarização automática multinível baseado em um algoritmo genético para uma segmentação rápida de imagens. *Computer Vision Image Understanding* 109:163–175
- Haralick RM, Shanmugam K, Dinstein I (1973) Características texturais para classificação de imagens. *IEEE Transações em sistemas, homem e cibernética* 6:610–621
- He, F., Wang, W., Chen, Z. (2006a). Detecção automática de defeitos com base em pacotes wavelet adaptativos para fabricação de couro. In *Technology and Innovation Conference (ITIC)*, IET International 23. He FQ, Wen W, Zi CC (2006b) Inspeção visual automática para fabricação de couro. Em: *Materiais de Engenharia Chave, Publicações Trans Tech*: 469–472

24. Hemerson, P., William PA, Priscila, SM, Mauro, CP, Pereira, MA, Jacinto, MAC (2006) Detecção de defeitos em couro cru e couro wet blue. *CompIMAGE, Modelação Computacional de Objectos Representados em Imagens: Fundamentos Métodos e Aplicações*, Coimbra, 355–360.
25. Hoang K, Nachimuthu A (1996) Técnicas de processamento de imagem para classificação de couro no calçado indústria. *Mach Vis App* 9:119–129
26. Malathy Jawahar, Chandra Babu NK, Vani, K. (2014) Classificação de textura de couro usando a técnica de extração de característica wavelet", *IEEE International Conference on Computational Intelligence and Computing Research*, pg. 1–4 27. Malathy Jawahar Chandra Babu NK, Vani, K. (2016) Compressão de imagens de couro para sistema automático de classificação de couro usando Multiwavelet", *IEEE International Conference on Computational Intelligence and Computing Research*, pg. 1–7.
28. Malathy Jawahar de , Chandra Babu NK, Vani K. (2019) Sistema de inspeção de visão de máquina para detecção Defeitos de Superfície de Couro, *Journal of American Leather Chemist Association*, vol.114, no.1.
29. Jiang M, Luo YP, Yang SY (2007) Análise de convergência estocástica e seleção de parâmetros do algoritmo de otimização de enxame de partículas padrão. *Inf Process Lett* 102:8–16
30. Kaloyan K, Georgieva L (2005) Identificação de defeitos de superfície de couro usando lógica fuzzy. *Anais da Conferência Internacional sobre Sistemas e Tecnologias de Computador*, IIAA. 12.
31. Kasi MK, Rao JB, Sahu VK (2014) Identificação de defeitos de couro usando um algoritmo de processamento de imagem de detecção de borda autoadaptável. Em *computação e aplicativos de alto desempenho (ICHPCA)*, Conferência Internacional, IEEE, 1–4.
32. Kayalvizhi M, Kavitha G, Sujatha CM, Ramakrishnan S (2015) Minkowski funcionais baseados no índice do cérebro para o ventrículo para análise da progressão da DA em imagens de RM. *Medição* 74:103–112 33. Kennedy J, Eberhart R (1995) Um novo otimizador usando teoria de enxame de partículas. Nos *processos do IEEE sexto simpósio internacional sobre micromáquinas e ciências humanas*: 39–43
34. Khan SA, Engelbrecht AP (2012) Um algoritmo de otimização de enxame de partículas difusas para comunicações por computador projeto de topologia de rede de cation. *Appl Intel* 36(1):161–177
35. Kornblith, S.; Shlens, J.; Le, QV (2018) Os melhores modelos ImageNet transferem melhor? *arXiv* 2018, arXiv: 1805.08974.
36. Krastev K, Georgieva L (2006) Um método para determinação da qualidade do couro usando redes neurais difusas. *Anais da Conferência Internacional sobre Sistemas e Tecnologias de Computador* 37. Kulkarni RV, Venayagamoorthy GK (2010) Algoritmos bio-inspirados para implantação autônoma e localização de nós sensores. *IEEE Transactions, SMC* 40:663–675 38. Kwak C, Ventura JA, Sazi KT (2000) Uma abordagem de rede neural para identificação e classificação de defeitos em tecidos de couro. *J Intell Manuf* 11:485–499 39. Kwak C, Ventura JA, Sazi KT (2001) Inspeção automatizada de defeitos e classificação de tecidos de couro.
- Análise Inteligente de Dados 5:355–370 40.
- LeCun, Y.; Bengio, Y.; Hinton, G. *Aprendizagem profunda*. *Natureza*, 521, pág. 436-444, 2015.
41. Limas Serafim, AF (1992) Segmentação de imagens naturais com base em pirâmides multiresolução vinculando os parâmetros de um modelo invariante de rotação autorregressivo, *Aplicação à detecção de defeitos de couro*. *Proceedings, 11th IAPR International Conference on Pattern Recognition*. Vol. III. Conferência C: Imagem, Análise de Fala e Sinal, Haia, 41–44.
42. Limas-Serafim, AF (1993). Segmentação de imagens naturais para reconhecimento de padrões usando pirâmides de bordas e sua aplicação nos defeitos do couro. *Eletrônica Industrial, Controle e Instrumentação, Anais do IECON '93. Conferência Internacional sobre*, Maui, HI, 1357-1360.
43. Liong, ST; Gan, Y.; Huang, YC; Yuan, Califórnia; Chang, HC (2019) Segmentação automática de defeitos em couro com aprendizado profundo. *arXiv* 2019, arXiv:1903.12139.
44. Lovergine FP, Branca A, Attolico G, Distante A (1997) Inspeção de couro por análise de textura orientada com abordagem morfológica. *Proceedings of International Conference on Image Processing*, Santa Barbara, CA 2:669–671
45. Maitra M, Chatterjee A (2008a) Um algoritmo PSO baseado em aprendizado cooperativo-compreensivo híbrido para segmentação de imagens usando limiarização multinível. *Expert Syst Appl* 34:1341–1350 46. Maitra M, Chatterjee A (2008b) Uma nova técnica para o limiar de imagem cerebral de ressonância magnética ideal multinível usando forrageamento bacteriano. *Medição* 41:1124–1134 47. Mario MN, Oduvaldo V, Fusco JPA (2005) Sistema automatizado para inspeção de couro: a visão de máquina.
- Soluções Emergentes para Sistemas de Manufatura Futuros 159:387–396 48.
- Mohagheghian E, James LA (2018) Otimização de gás alternado de água de hidrocarboneto no campo Norne: aplicação de algoritmos evolutivos. *Combustível* 223:86–98
49. Nanni, L.; Ghidoni, S.; Brahnam, S *Recursos artesanais versus não artesanais para classificação de visão computacional cation Pattern Recognit*, Vol. 71, pág. 158-172, 2017.

50. Pereira, RF; Medeiros, CM; Rebouças Filho, PP (julho 2018) Classificação da qualidade do couro caprino usando visão computacional e aprendizado de máquina. In Proceedings of the 2018 International Joint Conference on Neural Networks (IJCNN), Rio de Janeiro, Brasil, 8–13; págs. 1–8.
51. Peters S, Koenig A (2007) Um sistema híbrido de análise de textura baseado em kernels não lineares e orientados, otimização de exame de partículas e kNN vs. Support Vector Machines. 7ª Conferência Internacional sobre Sistemas Inteligentes Híbridos, 1–25.
52. Pölzleitner W, Niel A (1994) Inspeção automática de superfícies de couro. Sociedade de Fotoóptica Engenheiros de Instrumentação 2347:50–58
53. Ren R, Hung T, Tan KC, Uma abordagem genérica baseada em aprendizado profundo para inspeção automatizada de superfícies. IEEE Trans Cybern 48, pág. 929-940, 2017.
54. Sathya PD, Kayalvizhi R (2010a) PSO baseado em procedimento de seleção de limiar para segmentação de imagem. International Journal of Computer Applications 5:39–46
55. Sathya PD, Kayalvizhi R (2010b) Um novo método de limiarização multinível usando inteligência de enxame algoritmo para segmentação de imagens. J Intell Learn Syst Appl 2:126–138
56. Sezgin M, Tasaltin R (2000) Uma nova técnica de dicotomização para limiarização multinível dedicada a aplicações de inspeção. Reconhecimento de Padrão Lett 21:151–161
57. Shannon CE (1935) Uma teoria matemática da comunicação. Bell System Technical Journal 27:379–423 58. Sharon, J, Jenifa, L, Jani Anbarasi e Benson Edwin Raj (2018) segmentação baseada em DPSO-FCM e classificação de doenças cardíacas DCM e HCM." 2018 Fifth HCT Information Technology Trends (ITT). IEEE, 2018.
59. Siva S, Sindhu S, Geetha S, Kannan A (2012) Evoluindo regras de decisão otimizadas para detecção de intrusão usando o paradigma de exame de partículas. International Journal of Systems Science 43(12):2334–2350 60. Sorbal JL (2005) Inspeção de couro baseada em wavelets. Conferência Ibérica sobre Reconhecimento de Padrões e Análise de Imagens, LNCS 3523:682–688 61. Sorwar G, Abraham A (2004) Classificação de textura baseada em DCT usando abordagem soft computing. Malays J Comput Sci 17:13–23 62. Sun C, Shrivastava, A.; Singh, S.; Gupta, A. (2017) Revisitando a eficácia irracional dos dados na era do aprendizado profundo. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), Veneza, Itália, 22 a 29 de outubro de 2017; págs. 843-852.
63. Teng, Zhi-Jun, et al. (Setembro de 2018) Algoritmo de otimização de exame de partículas baseado em fator de aceleração dinâmica em rede de sensores sem fio. Jornal de Ocultação de Informações e Processamento de Sinais Multimídia, Volume 9, Número 5
64. Villar, P., Mora, M., Gonzalez, P. Uma nova abordagem para segmentação de defeitos de couro wet blue. In Congresso Ibero-Americano de Reconhecimento de Padrões, Springer Berlin Heidelberg, 2011, 591–598.
65. Wang L, Liu C (1765-1768) Classificação de curtimento de couro usando um método de recurso geométrico estatístico aprimorado. IEEE em Aprendizado de Máquina e Cibernética, Conferência Internacional 3:2007 66. Wang Q, Liu H, Liu J, Wu T (1992) Um novo método para classificação de imagem de textura de couro. Processos de a Conferência do Simpósio Internacional IEEE em Eletrônica Industrial: 304-307
67. Weszka JS, Dyer CR, Rosenfeld A (1976) Um estudo comparativo de medidas de textura para classificação de terreno ção. Transações IEEE em Sistemas, Homem e Cibernética: Sistemas 6:269–285
68. Woo KJ, Choo YY, Choi HH, Cho JM, Kil GS (2004) Desenvolvimento de discriminação de qualidade de couro sistema por análise de textura. Conferência TENCON Região 10: 327–330
69. Xiaohui, H., Yuhui, S., Eberhart, R. (2004) Recentes avanços no exame de partículas. Procedimentos IEEE do Congresso de 2004 sobre Computação Evolutiva, 19–23.
70. Yamille DV, Ganesh KV, Salman M, Jean-Carlos H, Ronald GH (2008) Otimização por enxame de partículas: variantes de conceitos básicos e aplicações em sistemas de potência. Transações IEEE em Computação Evolucionária: 171-195
71. Yeh C, Perng DB (2005) Um padrão de referência de compensação de defeitos para transações de couro. Int J Adv Manuf Technol 25:1197–1204 72. Yin PY (1999) Um esquema rápido para limiar ótimo usando algoritmos genéticos. Signal Process 72:85–95 73. Zweig MH, Campbell G (1993) Gráficos de características de operação do receptor (ROC): uma ferramenta de avaliação fundamental em medicina clínica. Clin Chem 39:561–577

Nota do editor Springer Nature permanece neutro em relação a reivindicações jurisdicionais em mapas publicados e afiliações institucionais.



Malathy Jawahar é o Cientista Principal do Departamento de Tecnologia de Processos de Couro do CSIR- Central Leather Research Institute e um corpo docente honorário da Anna University. Ela recebeu os graus de BE e MS em Ciência da Computação e Engenharia em 1992 e 2003, respectivamente, da Madurai Kamaraj University e Anna University, Chennai, Índia. Suas áreas de especialização incluem processamento de imagens, redes neurais artificiais, desenvolvimento de software de aplicativos, correspondência de cores auxiliada por computador, modelagem matemática, etc. Ela publicou 15 publicações em revistas internacionais e 3 direitos autorais. Ela se junta ao comitê de revisão das publicações IEEE Transactions on Instrumentation and Measurement, Computers in Industry, Coloration technology. Ela recebeu o Young Scientist Award na Asian Leather Conference Taiwan – novembro de 2012 e recebeu prêmios de melhor artigo na IEEE International Conference on Computational Intelligence and Computing Research em 2014 e 2016.



Dr. NK Chandra Babu é o ex-cientista chefe do CSIR – CLRI. Sua área de especialização é ciência e tecnologia do couro. Ele recebeu o Jawaharlal Nehru Memorial Award pela universidade que eu classifco em B.Tech e M.Tech (Couro). Ele também recebeu o prêmio de melhor contribuição para a indústria do couro pela All India Hides and skins Tanners and Merchants Association (AISHTMA). Ele recebeu o J Sinha Roy Memorial Award no Journal of Indian Leather Technologists Association por três anos. Ele também recebeu o prêmio Bry Air Special Commendation pelo design do Mobile Chiller para a cura sem sal de peles e couros.

Ele coordenou com muitas agências governamentais na divulgação de políticas de apoio ao crescimento do setor de couro na Índia. É autor/editor de 5 manuais e 2 capítulos de livros. Para seu crédito, ele registrou 24 patentes e um direito autoral. Publicou mais de 110 artigos de pesquisa.



Dr. K. Vani é Professor no Departamento de Ciência e Tecnologia da Informação, Faculdade de Engenharia Guindy, Universidade Anna, Chennai, Índia. Sua área de especialização é Processamento de Imagens. Ela recebeu ME em Eletrônica e Engg de Comunicação, e Ph.D (Processamento de Imagem) pela Anna University. Ela publicou mais de 35 artigos de pesquisa em revistas internacionais. Ela recebeu o prêmio IGS Best Paper for Young Scientist em 2002, o Faculty Mentor Award pela iniciativa acadêmica da IBM em 2007 e o prêmio de desenvolvimento de carreira do Lunar and Planetary Institute concedido pela Lunar and Planetary Science Conference, EUA em 2010.



L. Jani Anbarasi recebeu o grau de BE pela Manonmanium Sundaranar University em 2000 e ME e Ph.D. diplomas da Anna University em 2005 e 2015, respectivamente. Atualmente, ela é Professora Assistente (Sr) em VIT Chennai, Índia. Possui 11 anos de experiência docente em nível de pós-graduação. Seus interesses de pesquisa incluem Criptografia, Processamento de Imagens e Aplicações Médicas. É membro profissional dos órgãos ISTE, ACM. Ela recebeu prêmios de Melhor Artigo em conferências do IEEE.



Dr. S. Geetha é professor na Escola de Ciência da Computação e Engenharia, Universidade VIT, Campus Chennai, Índia. Ela recebeu o BE e ME, graus em Ciência da Computação e Engenharia da Madurai Kamaraj University, Índia em 2000 e Anna University of Chennai, Índia em 2004, Ph.D. Graduação pela Anna University em 2011, respectivamente. Ela tem uma rica experiência de ensino e pesquisa. Publicou mais de 100 artigos em reputadas conferências internacionais e revistas especializadas. Seus interesses de pesquisa incluem esteganografia, esteganálise, segurança multimídia, sistemas de detecção de intrusão, análise de malware, paradigmas de aprendizado de máquina e forense da informação. Ela recebeu o University Rank e o Academic Topper Award em BE e ME em 2000 e 2004, respectivamente. Ela também possui o Certificate of Appreciation da IBM em 2009, 2010 para Great Mind Challenge, Mentor IBM Academic Initiative Program. Ela também atuou como membro do TPC e membro da revisão de mais de 30 conferências internacionais apoiadas pelo IEEE e Springer, além de mais de 10 periódicos indexados pela SCI revisados por pares. Ela também é a ganhadora do prêmio ASDF Best Academic Researcher Award 2013, ASDF Best Professor Award 2014, Research Award-2016 e High Performer Award - 2016, da VIT University, ISCA - Best Poster Award 2018. Ela atua como membro vitalício no HKCBEEES, ISCA, IACSIT e IAENG.

Afiliações

Malathy Jawahar^{1,2} & NK Chandra Babu^{1,2} & K. Vani³ & L. Jani Anbarasi⁴ & S. Geetha⁴

NK Chandra Babu
babunkc@yahoo.com

K. Vani
vani@anna.edu

L. Jani Anbarasi
janiyanbarasi.l@vit.ac.in

S. Geetha
geetha.s@vit.ac.in

¹ Divisão de Tecnologia de Processo de Couro, CSIR-Central Leather Research Institute, Adyar, Chennai 600020, Índia

² Departamento de Tecnologia do Couro, Anna University, Chennai 600 025, Índia

³ Departamento de Ciência e Tecnologia da Informação, Anna University, Chennai 600 025, Índia

⁴ Escola de Ciência da Computação e Engenharia, Vellore Institute of Technology, Chennai Campus, Chennai 600 127, Índia