

Veja discussões, estatísticas e perfis de autores para esta publicação em: <https://www.researchgate.net/publication/220571625>

Inspeção automatizada de defeitos e classificação de tecido de couro

Artigo em Análise Inteligente de Dados · Novembro de 2001

DOI: 10.3233/IDA-2001-5406 · Fonte: DBLP

CITAÇÕES

38

LÊ

4.544

3 autores, incluindo:



José A. Ventura

Universidade Estadual da Pensilvânia

153 PUBLICAÇÕES 2.695 CITAÇÕES

VER PERFIL

Alguns dos autores desta publicação também estão trabalhando nesses projetos relacionados:



Localização do ponto de permanência AGV [Ver projeto](#)

Inspeção automatizada de defeitos e classificação de tecido de couro

Choonjong Kwaka, Jose A. Ventura *aSchool of Industrial Engineering, Purdue University, West Lafayette, IN 47907-1287, EUA bDepartment of Industrial and Manufacturing Engineering, Pennsylvania State University, University Park, PA 16802, EUA cWestwood Industries, 597 Glasgow Lane, Tupeco, MS 38803, EUA*

Recebido em 18 de outubro de 2000

Revisado em 24 de dezembro de 2000

Aceito em 24 de janeiro de 2001

Abstrato. Este artigo descreve um sistema de visão automatizado para detectar e classificar defeitos superficiais em tecidos de couro.

No processo de inspeção de defeitos, os defeitos visuais são localizados e relatados por meio de um procedimento de segmentação em duas etapas baseado em limiarização e processamento morfológico. No processo de classificação de defeitos, o sistema utiliza características geométricas e estatísticas como seus conjuntos de características; ou seja, uma nova medida de compacidade normalizada e recursos estatísticos de primeira e segunda ordem. Em um esforço para maximizar a eficiência da classificação, um classificador de árvore de decisão sequencial de três estágios é adotado para a classificação de cinco tipos de defeitos: linhas, furos, manchas, desgastes e nós. Se os defeitos de linha são identificados como resultado da classificação, eles são verificados por um algoritmo de combinação de linha para determinar se são partes de defeitos de linha maiores e, nesse caso, são relatados como defeitos de linha combinados. Resultados satisfatórios foram alcançados no teste de classificação com uma acurácia global de 91,25%.

Palavras-chave: Visão de máquina, defeitos de couro, inspeção de couro, inspeção de defeitos, classificação de defeitos

1. Introdução

A inspeção visual e a classificação dos defeitos da superfície do couro são muito importantes na fabricação de produtos de couro que exigem qualidade excepcionalmente alta. Essas operações são atualmente realizadas por inspetores humanos que tendem a perder um número considerável de defeitos porque os seres humanos são basicamente inconsistentes e inadequados para tarefas tão simples e repetitivas. Além disso, como a inspeção e classificação manual são tarefas lentas e trabalhosas, elas podem se tornar um gargalo crítico em todo o processo de produção. A inspeção e a classificação automatizadas podem reduzir as cargas de trabalho humanas e os custos de mão de obra, ao mesmo tempo em que aumentam o rendimento. Mais importante, maior precisão pode ser alcançada eliminando o erro humano devido à fadiga.

De fato, muita pesquisa foi realizada na inspeção automatizada de superfícies metálicas, madeira e tecidos têxteis, enquanto relativamente pouco trabalho foi feito na classificação automatizada de defeitos, principalmente devido à natureza difícil do problema. É praticamente impossível construir modelos exatos de defeitos para classificação porque sua aparência e tamanho variam muito. É quase impossível encontrar

✉ Autor correspondente. Tel.: +1 814 865 3841; Fax: +1 814 863 4745; E-mail: jav1@psu.edu.

dois defeitos com a mesma forma e tamanho, mesmo que pertençam à mesma classe de defeitos. No entanto, esse processo de classificação é necessário porque desempenha um papel importante no fornecimento de informações para a prevenção de defeitos. Os defeitos devem ser classificados em classes apropriadas de acordo com sua causa e origem, a fim de localizar a fonte responsável por esses defeitos e tomar ações corretivas.

Zhang e Bresee [11] detectaram imagens defeituosas em tecidos têxteis aplicando individualmente duas abordagens diferentes. Uma classificação um tanto simples foi realizada para discriminar nós de slubs de acordo com a relação entre comprimento e largura. Se o comprimento for mais que o dobro da largura, é classificado como slub. Caso contrário, é considerado um nó.

Brzakovic et al. [1] empregaram um esquema de ligação de pirâmide para localizar defeitos na madeira e um esquema de classificação hierárquica de defeitos para classificar quatro tipos de defeitos de madeira: rachaduras, estrias minerais, buracos de minhoca e nós. No primeiro nível de classificação, a medida de compacidade é usada para primeiro determinar se um defeito pertence a uma classe linear (rachaduras e estrias minerais) ou a uma classe circular (buracos de minhoca e nós) e depois, mais especificamente, atribuí-lo a uma das quatro classes de defeitos se o valor for tão óbvio que nenhuma classificação adicional seja necessária. Caso contrário, o classificador utiliza, no segundo nível de classificação, a área ou largura do defeito conforme o defeito seja linear ou circular, respectivamente. Se as medidas acima não forem suficientes para a classificação, as variações de intensidade dentro do defeito são usadas no terceiro nível. Mas, esta abordagem tem dois problemas em termos de classificação porque depende muito da forma e das características geométricas dos defeitos. Primeiro, as características geométricas e de forma são muito sensíveis ao resultado da segmentação, o que afeta negativamente o desempenho da classificação, embora algum grau de erro de segmentação seja inevitável em problemas reais. Em segundo lugar, foi observado em nossa pesquisa que a medida de compacidade causa um problema crítico para a classificação de defeitos lineares.

Este artigo descreve um sistema automatizado de inspeção e classificação de defeitos para tecidos de couro. Que usa um procedimento de segmentação de duas etapas para inspeção com base em limiarização e processamento morfológico. Esta pesquisa propõe o uso de características geométricas e estatísticas como seus conjuntos de características para a classificação de defeitos de couro. Normalmente, o conhecimento específico do domínio é usado no problema de classificação para extrair boas características dos dados brutos. Como o problema de classificação para esses tipos de defeitos do couro é exclusivo do conhecimento dos autores, a seleção de características apropriadas torna-se muito importante nesta pesquisa. Além disso, uma boa seleção de recursos torna a classificação muito mais fácil.

Neste estudo, um esquema de classificação de três estágios é usado para maximizar a eficiência da classificação. Na primeira etapa, os defeitos de linha, como arranhões, rugas, cortes e rasgos, são classificados aplicando-se uma nova medida de compacidade normalizada que apresenta certas vantagens sobre a medida de compacidade convencional. Com o uso desta medida de compacidade normalizada, os dois problemas descritos por Brzakovic et al. [1] pode ser evitado. Os defeitos de linha identificados nesta etapa passam por um teste de combinação de linhas para verificar se são originalmente partes de defeitos maiores, pois os defeitos de linha geralmente aparecem fragmentados após a segmentação. Se este for o caso, eles são relatados juntos como defeitos de linha maiores após o teste de combinação de linhas. As características estatísticas de primeira e segunda ordem são extraídas das regiões com defeitos no segundo e terceiro estágios, respectivamente, e usadas apenas para o estágio de classificação correspondente. Defeitos de furos podem ser facilmente discriminados no segundo estágio fazendo passar tecido de couro sobre uma mesa de luz branca no sistema, de modo que os níveis de cinza no defeito do furo sejam aqueles do rodapé branco da mesa.

Recursos estatísticos de primeira ordem são usados sequencialmente para classificar defeitos de mancha, bem como defeitos de furos no segundo estágio. Os defeitos de nó e desgaste são classificados usando os recursos estatísticos de segunda ordem no terceiro estágio.

Este artigo está organizado da seguinte forma. O processo de inspeção de defeitos, que consiste na aquisição de imagens, segmentação e relatórios, é descrito na próxima seção. Na Seção 3, a lista de defeitos cobertos neste estudo é apresentada pela primeira vez. Esta seção também descreve os conjuntos de recursos e o esquema de classificação junto com um algoritmo de combinação de linhas. Finalmente, os resultados experimentais e as conclusões são apresentados nas Seções 4 e 5, respectivamente.

Tabela

1 A classificação dos tipos de couro. As classes Elegence, Fargo, Regency e Poloma exigem maior qualidade do que outras classes

Finalizado		Inacabado
Aparência aflita	Aparência não aflita	Aparência natural
Captiva	Elegância	
Poloma	Fargo	
Cimarron	Regência	

2. Inspeção de defeitos

Canção et al. [9] dividiram as técnicas de detecção de defeitos em duas categorias de acordo com o fato de envolverem uma fase de treinamento. Um sistema de detecção de defeitos sem uma fase de treinamento localiza defeitos detectando os pixels desviados de seu plano de fundo. No entanto, esse tipo de método tem uma desvantagem, pois pode relatar defeitos, embora na verdade não haja defeito. Por outro lado, um sistema de detecção de defeitos com uma fase de treinamento é treinado em padrões normais e anormais ou, às vezes, no padrão normal apenas para aprender a diferença entre texturas aceitáveis e defeituosas. Às vezes, quando o conhecimento especializado está disponível, esse estágio de treinamento pode ser substituído.

Neste estudo, observamos que os resultados de aquisição e segmentação de imagens são sensíveis ao tipo de couro sob inspeção, principalmente devido às suas propriedades de refletância. De fato, ao contrário de outros materiais, como uma superfície metálica, as propriedades de refletância do couro variam muito de acordo com o tipo de couro. Por esta razão, é muito ineficiente e até impossível em termos de desempenho de segmentação aplicar o mesmo método de segmentação a todos os tipos de couro. Na prática, é aconselhável buscar o método de segmentação específico mais adequado cada vez que a linha de produção adotar um novo tipo de couro e adicioná-lo ao banco de dados de conhecimento especializado, mesmo que as etapas gerais de segmentação para o novo tipo de couro sigam as rotinas básicas deste estudo.

A classificação atual dos tipos de couro usados pela Westwood Industries (Tupeco,MS) é apresentada na Tabela 1. Existem também vários sub-estilos em cada classe. Os valores limite e vários parâmetros do processo de detecção de defeitos são uma função do tipo de couro que está sendo inspecionado e determinado experimentalmente. Observe que outra consideração importante são os padrões de qualidade de cada linha de produção, pois padrões de qualidade diferentes geralmente são estabelecidos por empresas diferentes, dependendo dos níveis de qualidade de seus produtos no mercado.

Considerando as características dos produtos de couro com diversos tipos de couro e padrões de qualidade, três tipos de couro fornecidos pela Westwood Industries foram selecionados para testes nesta pesquisa: as classes regência, poloma e captiva. As classes regência e poloma, em particular, exigem padrões de qualidade muito elevados, enquanto captiva é uma classe comum de couro. Os padrões de textura de couro utilizados nesta pesquisa foram restritos a padrões lisos.

O processo de inspeção de defeitos inclui aquisição de imagens, segmentação e relatórios. Uma imagem em nível de cinza é capturada primeiro. A imagem em nível de cinza adquirida é processada para segmentação e uma cópia dela é salva diretamente para o próximo processo de classificação de defeitos. Depois que a imagem de nível de cinza é limitada, a imagem binária resultante é processada por uma combinação de operações de dilatação e erosão morfológica binária, juntamente com filtros medianos para remover o ruído e preencher os buracos nos defeitos detectados. A análise de componentes conectados binários é então aplicada à imagem binária processada. Por fim, são relatadas as informações obtidas, como o número de defeitos, suas localizações e tamanhos.

2.1. Aquisição de imagem

O sistema de visão utilizado nesta pesquisa é composto por uma câmera colorida CCD de alta resolução Pulnix TMC-74 (768 × 493 pixels de imagem), Sun VideoPix com um quadro de dados capturado em tempo real a 1/30 segundo NTSC como um frame grabber, e Copystand Bencher VP-400 com mesa de 64 cm × 64 cm. A estante tem quatro lâmpadas superiores de 300 watts fixadas a uma altura de 40 cm nos cantos da mesa e um iluminador halogênio de quartzo de 600 watts embutido em um rodapé branco de 40 cm × 40 cm para iluminação de fundo. As quatro lâmpadas superiores foram ajustadas para observar toda a mesa de luz, a fim de obter uma iluminação uniforme em todo o campo de visão. O iluminador base não foi utilizado porque não fez diferença significativa. A imagem do tecido de couro sendo inspecionado foi dividida em janelas de aproximadamente 8 cm × 12 cm. Todos os algoritmos escritos em C foram implementados em uma estação SUN SPARC 2 sob SunOS OpenWindows Versão 3.

A iluminação e a distância entre a câmera e o couro são dois fatores importantes no experimento. Claramente, variações significativas na iluminação levam a resultados falsos. A distância entre a câmera e o couro foi ajustada adequadamente por tentativa e erro. Foi observado que uma distância muito grande não consegue extrair características estatísticas satisfatórias de defeitos para bons resultados de classificação. Por outro lado, uma distância muito próxima aumenta a carga de processamento devido à maior quantidade de dados a serem processados na mesma área da superfície do couro. Neste estudo, foi mantida uma distância de 40 cm da lente da câmera à mesa de luz durante todo o experimento.

2.2. Segmentação

Embora a abordagem básica desta etapa assuma que os defeitos de couro podem ser extraídos do fundo (tecido de couro normal) por seus valores de nível de cinza, foi observado no experimento que as distribuições de nível de cinza de defeitos e ruídos muitas vezes se sobrepõem, o que complica a separação de defeitos de ruído usando apenas abordagens convencionais de limiarização baseadas em histograma, como limiar fixo ou limiar adaptativo. As duas únicas diferenças aparentes entre ruído e defeitos são sua densidade e tamanho.

Uma característica do couro é que geralmente é usado para produtos de alta qualidade. Embora esse fato enfatize o controle de qualidade do couro, do ponto de vista da segmentação, ele desempenha o papel de facilitar a segmentação dos defeitos da superfície do couro sob um ambiente de inspeção bem controlado. Isso porque o couro deve manter uma textura uniforme em toda a superfície e uma falha pode ser crítica na

produtos de couro de alta qualidade.

Uma vez que as técnicas de limiarização baseadas em histogramas individuais não são satisfatórias para defeitos de couro em inspeção, um procedimento de duas etapas é proposto para esta etapa motivado pelas observações acima. Primeiro, um esquema de limiar fixo é usado para separar os defeitos da textura normal do couro. Os defeitos aparecem anormalmente mais claros ou mais escuros do que o plano de fundo, de modo que são necessários dois valores de limite. A imagem com limiar, $F_T(i, j)$, é definida como

$$F_T(i, j) = \begin{cases} 0 & \text{se } F(i, j) \leq T_1 \text{ ou } F(i, j) \geq T_2 \\ 255 & \text{caso contrário} \end{cases} \quad (1)$$

onde $F(i, j)$ é a imagem original de 256 níveis de cinza de tamanho 200 × 300 (pixels). Em segundo lugar, as operações morfológicas são adotadas para utilizar duas diferenças aparentes entre ruído e defeitos. Juntamente com um filtro mediano, a operação de abertura é usada para remover o ruído. Os filtros medianos são frequentemente combinados com a operação de abertura para melhorar o efeito de remoção de ruído. Os processos de segmentação para vários

mesa 2

Processos de segmentação para diversos tipos de couro. O número nos processos de remoção de ruído e preenchimento de furos representa o número de operações a serem realizadas

Classe	Cor do estilo	Limites da área testada		Remoção de ruído			Enchimento do furo		
		(cm2)	(T1, T2)	Filtro mediano	Erosão	Dilatação	Dilatação	Preenchimento de furos	Erosão
Regência 1	Cinza claro	4500	(157.188)	2	2	2	3	1	3
	2 Cinza	3000	(178.189)	2	2	2			
Poloma	1 roxo	3000	(132.158)	1	1	1			
Captiva	1 cinza claro	3000	(120.152)	2	2	2			
	2 Amarelo	7200	(130.180)	2	1	1			

diferentes tipos de couro estão resumidos na Tabela 2. A sexta coluna na Tabela 2 mostra uma combinação de filtros medianos, erosões e dilatações suficientes para remover o ruído que pode ocorrer após o limiar mesmo em condições normais sem defeitos para cada tipo de couro. Essas etapas de remoção de ruído estão intimamente relacionados com a escolha dos valores de limiar para cada tipo de couro. Uma vez que as formas de ruído e defeitos são desconhecidos neste momento, uma matriz $3 \times 3 \times 1$ foi usada como elemento estruturante em todos os casos.

Mesmo após a remoção do ruído, manchas brancas indesejáveis nos defeitos (particularmente, manchas e nós) muitas vezes permanecem. Observe que o preenchimento do furo pelo fechamento depende do defeito, ao contrário da remoção de ruído. Ao melhor maneira de proceder neste caso é realizar as operações de fechamento com o mesmo elemento estruturante que quantas vezes forem necessárias até que todos os furos em todos os defeitos sejam preenchidos. Mas, muito uso de morfologia operações distorce a forma dos defeitos. Como alternativa, neste estudo, três operações de dilatação são realizado, em seguida, uma operação de preenchimento de furos segue para preencher todos os furos restantes possíveis e, finalmente, três as operações de erosão são feitas conforme mostrado na última coluna da Tabela 2. A segunda operação de preenchimento do furo é realizado primeiro encontrando 4 pixels de fundo branco conectados na imagem e, em seguida, alterando todos os pixels brancos restantes (pixels de furo) para preto. Essas etapas foram estabelecidas através de defeito de treinamento amostras na fase de treinamento e resultados de segmentação satisfatórios foram obtidos ao distorcer o defeitos o mínimo possível. A Figura 1 mostra um exemplo do processo de segmentação com uma mancha natural no estilo 2 da classe captiva (ver Fig. 2(d)).

2.3. Comunicando

O relatório em tempo real é muito importante no processo de inspeção de defeitos, enquanto a ênfase é colocada na precisão em vez de tempo de processamento no processo de classificação de defeitos. Por esse motivo, o resultado de a inspeção de defeitos é relatada antes da classificação.

A análise de componentes conectados binários é aplicada à imagem binária segmentada. Em seguida, um filtro de tamanho é usado para remover todos os componentes com menos de $AT = 25$ pixels de tamanho. O número de defeitos, sua locais e tamanhos obtidos pela análise são imediatamente relatados e salvos como recursos geométricos para o seguinte processo de classificação de defeitos. Além disso, a imagem binária segmentada é usada para obter máscaras de nível de cinza dos defeitos quando os recursos estatísticos no processo de classificação são computados.

3. Classificação de defeitos

3.1. Defeitos no couro

Apesar da crescente necessidade de sistemas automatizados de classificação de defeitos, relativamente pouco trabalho tem sido desenvolvido. feito nesta área. Isso é atribuído principalmente às características irregulares dos próprios defeitos.

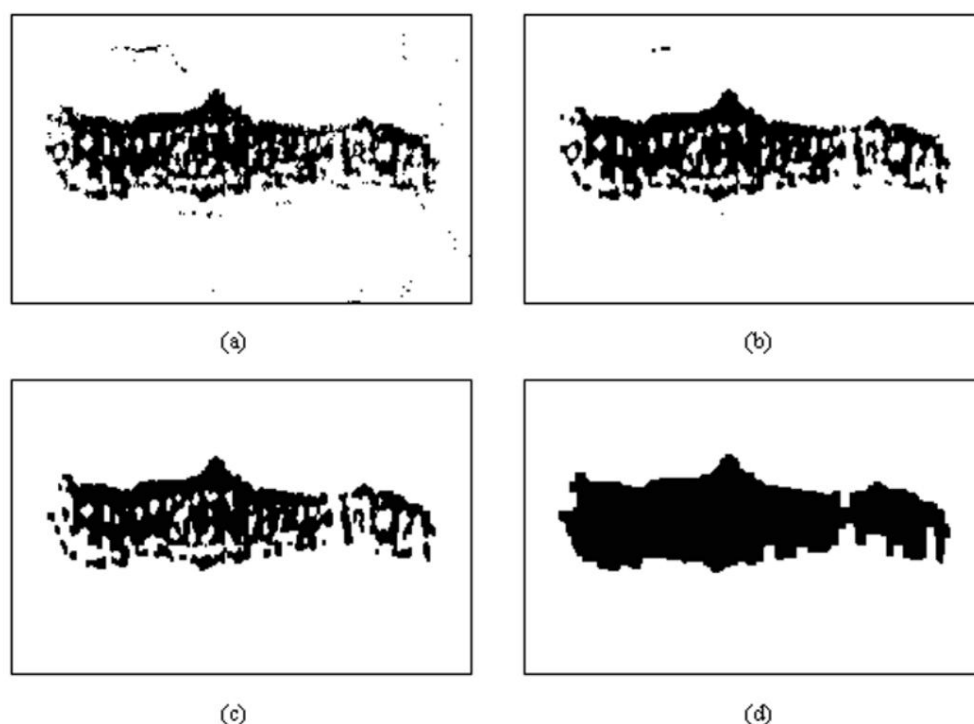


Fig. 1. Processo de filtragem de ruído. (a) Após o limiar. (b) Após 2 filtros medianos. (c) Após 1 operação de abertura. (d) Após a aplicação de 3 dilatações, preenchimento do orifício e depois 3 erosões.

Variações imprevisíveis na aparência e tamanho dos defeitos tornam impossível construir modelos exatos dos defeitos. Muito esforço tem sido colocado na classificação de defeitos usando características geométricas, embora esta abordagem tenha limitações definidas devido às características dos defeitos acima.

Uma característica geométrica, denominada medida de compacidade normalizada, é utilizada nesta pesquisa. No entanto, a análise estatística de textura também é adotada para superar as limitações da abordagem geométrica, aplicando a definição e agrupamento de textura de Rao [8] aos defeitos de couro considerados nesta pesquisa. Rao define textura como 'as marcas de superfície ou aparência 2D de uma superfície', que inclui madeira, wafers semicondutores e têxteis. A textura é caracterizada por propriedades tonais primitivas e relações espaciais entre elas [5]. Rao agrupou texturas em três classes principais: texturas fortemente ordenadas, texturas desordenadas e texturas fracamente ordenadas. Enquanto texturas fortemente ordenadas podem ser caracterizadas por seu padrão repetitivo, texturas desordenadas não mostram repetitividade nem orientação e podem ser descritas com base em sua rugosidade. Texturas fracamente ordenadas são aquelas que exibem algum grau de especificidade de orientação em cada ponto da textura.

Exemplos típicos dos cinco defeitos abordados neste estudo são apresentados na Fig. 2. Defeitos de linha, como rugas, arranhões e rasgos no tecido de couro, geralmente são causados por danos na pele da vaca ou ocorrem durante os estágios de produção e manuseio de materiais. Após a segmentação, esses defeitos de linha aparecem visualmente como linhas longas e estreitas. As manchas abordadas nesta pesquisa são uma espécie de variação natural na textura do couro. Uma mancha natural aparentemente tem muitas manchas brancas em sua região, e o limite de uma mancha não é claro, mas torna-se gradualmente borrado em direção à textura normal do couro. Desgastes causados por atrito e atrito podem ser considerados como uma das texturas desordenadas no agrupamento de Rao. Nós, por outro lado, são um exemplo de texturas fracamente ordenadas. A extensão de um nó inclui uma área um tanto ampla, incluindo

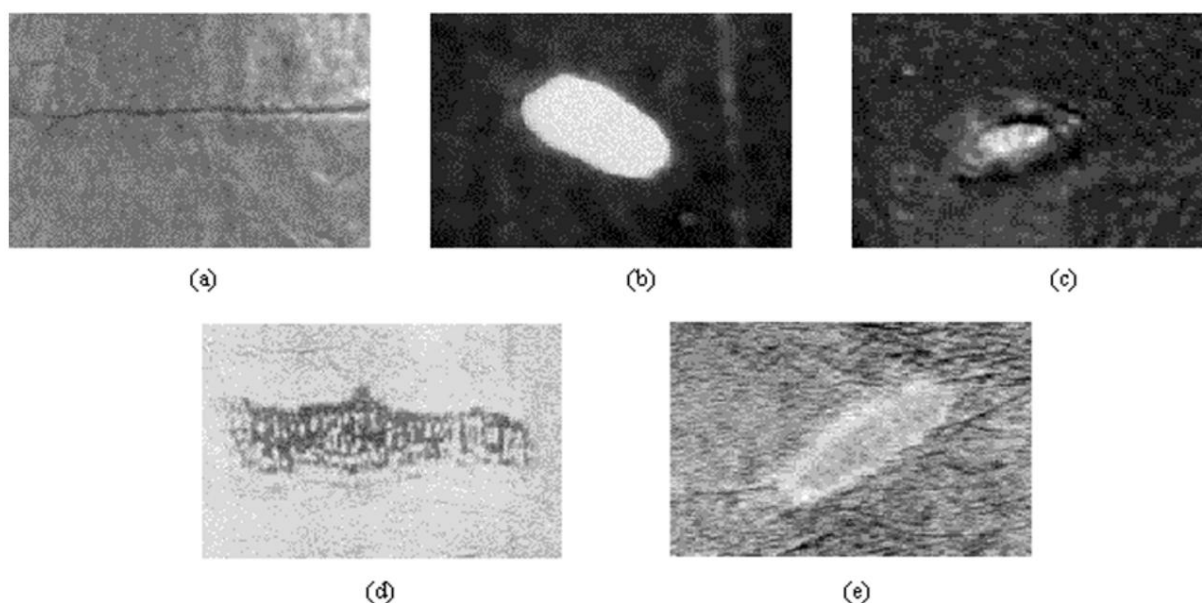


Fig. 2. Defeitos no couro. (a) Linha. (b) Buraco. (c) Nó. (d) Mancha. (e) Desgaste.

sua parte limítrofe, bem como sua parte central que possui uma granulação visualmente indesejável. Enquanto os nós são defeitos puramente biológicos, os desgastes surgem tanto de causas naturais quanto de erros de fabricação como defeitos de linha.

3.2. Medida de compacidade normalizada

A medida convencional de compacidade, $C = P^2/A$, onde P e A são o perímetro e a área de um objeto, respectivamente, encontrou muitas aplicações como um recurso geométrico. Brzakovic et al. [1] utilizaram esta medida de compacidade para a classificação de defeitos de linha na madeira, pois normalmente ela representa bem o grau de excentricidade ou circularidade de um objeto. No entanto, esta medida de compacidade revelou um problema crítico em distinguir defeitos de linha de outros defeitos nesta pesquisa. A Figura 3 mostra um exemplo típico do problema com duas imagens binárias de defeitos reais, das quais uma é a imagem de um defeito de mancha e a outra é a de três defeitos de linha. Neste exemplo, é impossível diferenciar os defeitos de linha do defeito de mancha com a medida tradicional de compacidade, pois esse defeito de mancha apresenta uma excentricidade bastante maior do que os defeitos de linha por seu maior valor na medida de compacidade, ao contrário da expectativa comum.

Para superar este problema, uma nova medida de compacidade normalizada é proposta neste estudo. A medida de compacidade normalizada é definida como $NC = C/A$. A lógica por trás dessa medida é que as comparações podem ser feitas nas mesmas condições, normalizando suas medidas de compacidade em relação à área. Para o exemplo da Fig. 3, a medida de compacidade normalizada classifica com precisão os defeitos de linha com $NC_{threshold}$. De fato, após a aplicação dessa medida de compacidade normalizada, observou-se ao longo de todo o experimento que os defeitos de linha podiam ser claramente discriminados de outros defeitos.

Além disso, a medida de compacidade normalizada tem mais uma vantagem sobre a medida de compacidade convencional. A Figura 4 mostra duas imagens binárias diferentes do mesmo defeito devido aos resultados de boa e má segmentação. Como (a) é uma máscara binária exata do defeito de desgaste utilizado, sabe-se que (b) produz um valor muito maior do que um valor real na medida de compacidade. No entanto, usando




Fig. 3. Comparações da medida de compacidade normalizada e da medida de compacidade. (a) $C = 92,11$, $NC = 0,0067$. (b) (da esquerda) $C = 45,75$, $13,79$ e $20,48$, $NC = 0,4279$, $0,4756$ e $0,6207$.




Fig. 4. Um exemplo de outra vantagem da medida de compacidade normalizada. (a) O resultado de uma boa segmentação. $C = 36,1308$, $NC = 0,0164$. (b) O resultado da má segmentação. $C = 79,3163$, $NC = 0,0459$.

a medida de compacidade normalizada, uma possível classificação incorreta em um defeito de linha pode ser evitada. Em outras palavras, a medida de compacidade normalizada é muito menos sensível ao resultado da segmentação.

3.3. Medidas estatísticas de primeira ordem

Outra classe útil de características que podem ser empregadas para fins de classificação compreende as medidas estatísticas de primeira ordem, como média e variância. As medidas estatísticas de primeira ordem empregadas são definidas da seguinte forma:

– Média:

$$\mu = \frac{1}{N} \sum_{i,j} p(i, j), \quad (2)$$

– Variação:

$$\sigma^2 = \frac{1}{N} \sum_{i,j} [p(i, j) - \mu]^2, \quad (3)$$

onde $p(i, j)$ é o nível de cinza do (i, j) -ésimo elemento de uma imagem $n \times m$ e N é o número total de pixels em uma imagem, ou seja, $N = n \times m$.




Fig. 5. (a) Uma imagem 4 x 4 com quatro níveis de cinza 0, 1, 2 e 3. (b) A matriz de coocorrência 4 x 4 correspondente para $d = (1, 1)$.

3.4. Medidas estatísticas de segunda ordem

A classe final de características a serem utilizadas inclui medidas estatísticas baseadas na matriz de coocorrência de níveis de cinza [4], sob a suposição de que a análise de textura pode explicar os defeitos do couro. Sabe-se que essas medidas estatísticas captam bem a dependência espacial dos valores dos níveis de cinza que contribuem para a percepção da textura.

Seja $d = (\ddot{y}x, \ddot{y}y)$ um vetor no plano (x, y) . A matriz de co-ocorrência de níveis de cinza M_d é definida por $M_d(i, j)$ que é o número de pares de níveis de cinza (i, j) ocorrendo na separação d em uma imagem discreta $f(x, y)$. Se uma imagem tiver m níveis de cinza, o tamanho de sua matriz de coocorrência será $m \times m$. Como um exemplo simples, se a figura é dada como Fig. 5(a) e o vetor de deslocamento d é escolhido como $d = (\ddot{y}x, \ddot{y}y) = (1, 1)$, então sua matriz de coocorrência seria Fig 5(b). Como a imagem dada tem apenas quatro níveis de cinza, sua matriz de coocorrência é uma matriz 4 x 4.

Os elementos de M_d são então normalizados dividindo cada elemento pelo número total de pares de pixels. Na Fig. 5(b), cada elemento é dividido por 9. Este M_d normalizado pode ser considerado como uma função de massa de probabilidade porque os elementos somam 1. Em outras palavras, o $M_d(i, j)$ normalizado é a probabilidade estimada de passar do nível de cinza i para o nível de cinza j dado o vetor deslocamento $d = (\ddot{y}x, \ddot{y}y)$.

Haralick et al. [4] definiram um conjunto de medidas com base na matriz de coocorrência, e Connors et al. [5] constataram que cinco das medidas são realmente úteis para aplicação. Nesta pesquisa, experimentos-piloto mostraram que as seguintes quatro das cinco medidas de Connors são eficazes neste domínio de problema específico:

– Energia:

$$E = \sum_{i,j} n(i, j)^2, \quad (4)$$

– Entropia:

$$ENT = - \sum_{i,j} n(i, j) \log n(i, j), \quad (5)$$

– Inércia:

$$eu = \sum_{i,j} (i - \ddot{y}j)^2 n(i, j), \quad (6)$$

– Homogeneidade:

$$H = \frac{1}{\sum_j \frac{1}{1+(i-j)^2}} n(i, j), \quad (7)$$

onde $n(i, j)$ é o (i, j) -ésimo elemento da matriz $m \times m$ dada dividido pela soma de todos os elementos da matriz.

O vetor de deslocamento d é certamente um fator muito importante na definição da matriz de coocorrência de níveis de cinza. O vetor de deslocamento d mais adequado foi determinado por meio de experimentos piloto para que o poder discriminatório seja maximizado. Neste estudo, os vetores de deslocamento $d = (1, 1), (3, 3), (5, 5), (7, 7)$ e $(9, 9)$ foram utilizados na fase de treinamento.

3.5. Esquema de classificação

Este sistema adota um esquema de classificação de árvore de decisão sequencial para maximizar a eficiência da classificação. O esquema geral é projetado de acordo com os dois princípios gerais das árvores de decisão: (i) a complexidade computacional aumenta da raiz da árvore em direção às folhas e (ii) árvores mais simples são preferidas porque são mais propensas a capturar a estrutura inerente. no problema [7]. Um breve diagrama do classificador de árvore de decisão sequencial é mostrado na Fig. 6.

Uma vez que um defeito é dado ao sistema, o processo de classificação começa na raiz da árvore e uma decisão é tomada em cada nó. O processo continua até que uma folha seja encontrada, momento em que o defeito é atribuído à classe de defeito correspondente e o processo é concluído. Todos os valores limite usados para cada decisão no experimento são apresentados na Tabela 3.

Quando um defeito é identificado, a máscara do defeito é obtida como uma imagem binária em que os pontos do objeto são pretos e os outros pontos de fundo são brancos. Os recursos geométricos, como área, perímetro e localização, são calculados a partir da máscara e salvos para o processo de classificação. Na primeira etapa da classificação, é verificado se o defeito dado é um defeito de linha usando a medida de compacidade normalizada. Se sua medida de compacidade normalizada indicar com $NC < NC_{threshold}$ que não é um defeito de linha, o processo de classificação continua. Mas, antes de entrar no segundo estágio, a máscara de nível de cinza do defeito é obtida primeiro usando a máscara binária e a imagem de nível de cinza original e, em seguida, as medidas estatísticas de primeira ordem são extraídas da máscara de nível de cinza. As estatísticas de segunda ordem são calculadas apenas quando o terceiro estágio é necessário para a eficiência computacional.

Como o tecido de couro que está sendo inspecionado deve passar sobre uma mesa de luz branca em um sistema de inspeção do tipo caixa preta, um defeito de furo tem os mesmos níveis de cinza em sua região que o fundo branco. Como resultado, a distribuição de nível de cinza de um defeito de furo tem um valor médio muito alto e, ao mesmo tempo, um valor de variância muito pequeno. Normalmente, o valor médio de um defeito de furo não é exatamente o mesmo que a distribuição de nível de cinza do fundo branco devido ao sombreamento ao redor do limite do defeito do furo e/ou erro de segmentação. Por outro lado, um defeito de mancha acaba tendo uma variância muito alta, o que parece ser razoável considerando suas características visuais.

Na terceira etapa, os desgastes e nós são classificados usando as características estatísticas de segunda ordem para capturar a diferença do padrão espacial em ambos os defeitos. De fato, observou-se que os desgastes apresentam valores de variância menores do que os nós, mas sua diferença não é suficientemente grande para uso na classificação. Essa observação mostra bem como a seleção de características inadequadas dificulta a classificação. Os nós apresentaram maiores valores de entropia/inércia, mas menores valores de energia/homogeneidade do que os desgastes, o que pode ser explicado pela maior aleatoriedade da textura dos nós em relação aos desgastes.

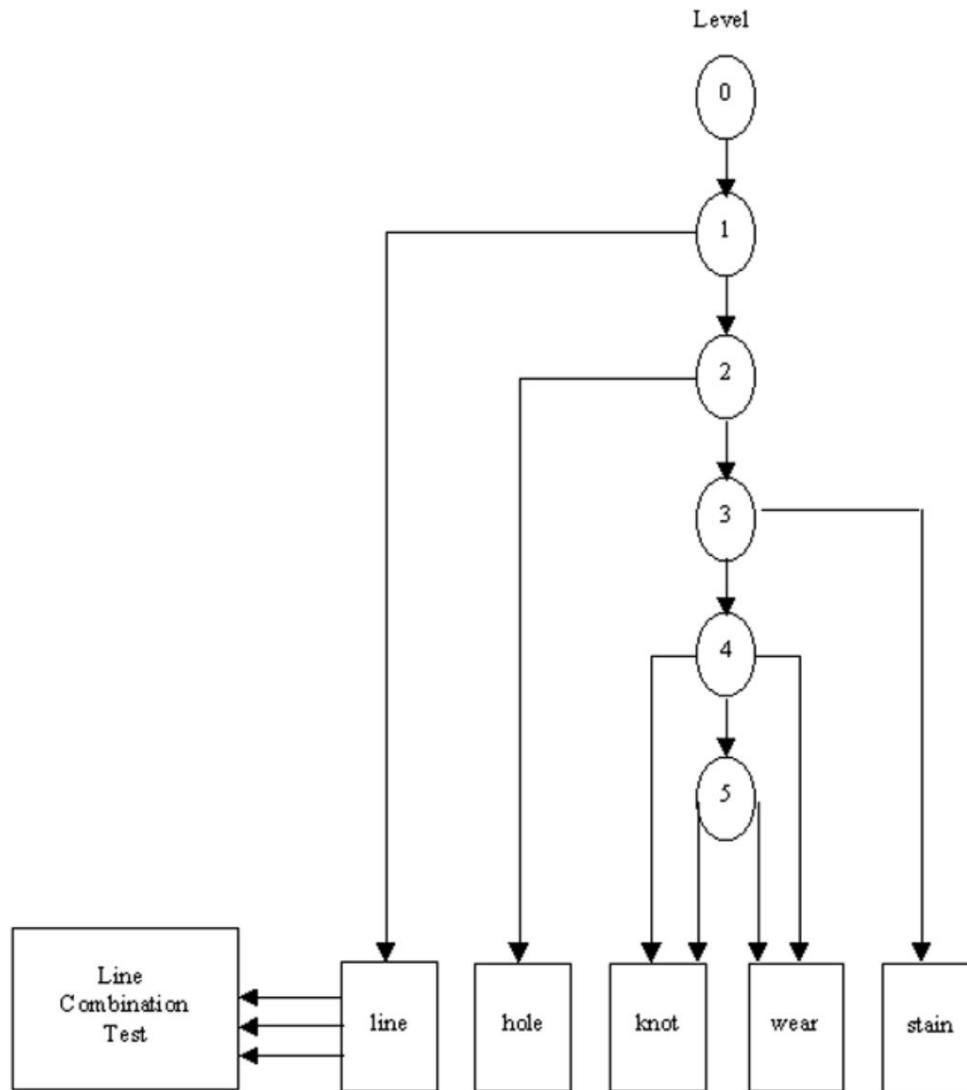


Fig. 6. Um diagrama do esquema geral de classificação.

3.6. Teste de combinação de linhas

Como resultado do processo de classificação sequencial, os defeitos de linha são identificados. Em seguida, eles precisam ser examinados para determinar se originalmente pertenciam a defeitos de linha maiores. Certos tipos de defeitos de linha, como arranhões, rugas, cortes e rasgos, geralmente tendem a aparecer fragmentados após a segmentação devido a contraste irregular, ruído ou resolução da câmera [1].

Suresh et al. [10] utilizaram um processo de três etapas para lidar com esse tipo de problema na inspeção de lajes de aço a quente. Na primeira etapa, para cada componente identificado em uma laje de aço, o retângulo delimitador mínimo é definido e, em seguida, aumentado em uma determinada quantidade. O Algoritmo de Pesquisa de Proximidade é aplicado para encontrar conjuntos de componentes próximos cujos retângulos se tocam. Na segunda etapa, uma regra semântica e uma regra sintática são aplicadas para verificar as relações espaciais e a compatibilidade dos tipos de componentes,

Tabela 3
Valores de limite usados

Condição do Nó de Estágio (Se)	Conclusão (então)
1 NC NClimiar = 0,09 2 MEAN MEANmin	Linha
2 = 200 3 V ARIANCE V ARIANCEmin = 191 4	Buraco
INERTE IA IINERT IAmin = 177 INERTE IA INERTE IAmax =	Mancha
3 160 5 ENT ROP Y ENT ROP Ymin = 5,0 ENT ROP Y ENT ROP	Nó
Ymax = 5,0	Vestem
	Nó
	Vestem

respectivamente. Uma verificação semântica é feita para discriminar entre a condição 'end-to-end' e a condição de 'sobreposição e paralelo', e uma tabela de consulta sintática é usada para verificar o tipo de compatibilidade. Finalmente, todos os componentes correspondentes são agrupados com base nas informações e características obtidas.

Como o método acima é computacionalmente complexo, um algoritmo de combinação de linhas mais eficiente é proposto neste estudo usando as orientações dos defeitos de linha para decidir se eles devem ser combinados. Se as orientações de dois defeitos de linha em exame forem semelhantes, eles serão considerados vir de um único defeito maior. Observe que os defeitos considerados neste teste já foram classificados na etapa anterior como lineares para que tenham uma orientação única.

A orientação de um defeito de linha pode ser representada pela orientação do eixo de alongamento. Desde o eixo do menor segundo momento é comumente usado como eixo de alongamento, o objetivo aqui é encontrar a linha pela qual a soma dos quadrados das distâncias aos pontos no defeito é minimizada. A soma pode ser representada como

$$\bar{y}^2 = \sum_j r_{ij}^2 B(i, j), \quad (8)$$

onde $B(i, j)$ é uma dada imagem binária e r_{ij} é a distância perpendicular de um ponto de defeito (i, j) para a linha [6]. A área A do defeito é dada por $A = B(i, j)$ e a posição do

centro da área (centro de massa), denotado como (\bar{x}, \bar{y}) , é obtido por $\bar{x} = \frac{1}{\sum_j B(i, j)} \sum_j x_{ij} B(i, j)$ e

$\bar{y} = \frac{1}{\sum_j B(i, j)} \sum_j y_{ij} B(i, j)$. A linha procurada pode ser representada em coordenadas polares (ver Fig. 7) como segue:

$$x \sin \bar{y} - \bar{y} \cos \bar{y} + \bar{y} = 0. \quad (9)$$

Resolvendo o problema de minimização,

$$M \sin \bar{y} = \sum_j r_{ij}^2 B(i, j), \quad (10)$$

\bar{y} e \bar{y} podem ser obtidos pelas duas equações a seguir:

$$\bar{y} = \bar{y} \sin \bar{y} + \bar{y} \cos \bar{y}, \quad (11)$$

$$\tan 2\bar{y} = \frac{b}{a - c}, \quad (12)$$




Fig. 7. Representação polar de uma linha. θ é um ângulo entre a linha e o eixo x e ρ é a linha de distância da origem.

Onde

$$a = \sum_j (x_{eu,j})^2 B(i, j), \quad (13)$$

$$b = 2 \sum_{eu,j} x_{ij} y_{ij} B(i, j), \quad (14)$$

$$c = \sum_j (s_{eu,j})^2 B(i, j), \quad (15)$$

$$x = x - \bar{x}, \quad (16)$$

$$y = y - \bar{y}. \quad (17)$$

Os parâmetros \bar{x} e \bar{y} são calculados para cada defeito de linha considerado neste teste e usados para julgar se dois defeitos devem ser agrupados; isto é, se as diferenças em \bar{x} 's e \bar{y} 's forem menores do que o predeterminado valores, $\bar{x}_{\text{threshold}} = 20$ (pixels) e $\bar{y}_{\text{threshold}} = 0,1$ (radianos), respectivamente, os defeitos são combinados.

A lista de entrada neste algoritmo inclui todos os defeitos de linha dentro de uma determinada imagem.

O algoritmo de combinação de linha é descrito da seguinte forma:

Passo 1: Calcule a e b para cada defeito de linha pelas Eqs (11) e (12), respectivamente, e salve-os com seus defeitos de linha.

Etapa 2: Seja L_a o menor defeito de linha indexado. Marque L_a . Se o índice de L_a for o maior na lista de entrada, mova L_a da lista de entrada para a lista de saída e termine. Caso contrário, continue.

Tabela 4

Os resultados de classificação obtidos pelo teste em 80 amostras de defeitos

Entrada	Resultado				
	Precisão de desgaste de nó de mancha de furo de linha				
Linha	10	0 0 10 0 0 18	0	0	100%
Buraco	0	0 0 0 0	0	0	100%
Mancha	0		2	0	90%
Nó	0		18	2	90%
Vestem	0		3	17	85%
Precisão total					91,25%

Passo 3: Seja L_b o menor defeito de linha indexado entre os não marcados. Se não houver defeitos de linha não marcados na lista de entrada, mova L_a da lista de entrada para a lista de saída. Limpar tudo marcas e volte para a Etapa 2. Caso contrário, continue.

Passo 4: Se $|y_a - y_b| < \tilde{y}_{limiar}$ e $|y_a - y_b| < \tilde{y}_{limiar}$, continua. Caso contrário, volte para a Etapa 3.

Passo 5: Calcule os novos valores de \tilde{y} e \tilde{y} pelas Eqs (11) e (12) considerando L_a e L_b juntos.

Re-rotule L_b com o índice original de L_a e salve os novos valores \tilde{y} e \tilde{y} para L_a . Remova L_b da lista de entrada e vá para a Etapa 3.

Uma vez que este algoritmo de combinação de linhas usa apenas dois parâmetros, \tilde{y} e \tilde{y} , é computacionalmente muito eficiente. Obviamente, esta é uma característica atrativa, pois o tempo de processamento é um fator muito importante fator para atender às necessidades de produção em situações reais.

4. Resultados computacionais

O sistema automatizado de classificação de defeitos proposto foi implementado para verificar seu desempenho duas fases: treinamento e teste. Um total de 140 amostras de defeitos obtidas da regência e captiva foram classificadas em cinco classes de defeitos por revisão humana com antecedência. O conjunto de exemplo usado para treinamento foi composto por 60 amostras de defeitos: 12 amostras de defeitos para cada classe. Após o treinamento fase, 80 amostras de defeitos foram executadas pelo sistema para o teste de classificação: 10 amostras de defeitos cada para os defeitos de linha e furo, mais 20 amostras de defeitos cada para as outras três classes de defeitos. Vários os valores limite dos recursos usados para classificação foram determinados na fase de treinamento e são fornecidos na Tabela 3. A fase de treinamento mostrou que o vetor de deslocamento d para a estatística de segunda ordem medidas não tiveram poder discriminatório satisfatório para valores pequenos como $d = (\tilde{y}_x, \tilde{y}_y) = (1, 1)$ e $(3, 3)$. Na fase de teste, o vetor de deslocamento d foi escolhido como $(\tilde{y}_x, \tilde{y}_y) = (9, 9)$.

Os resultados da classificação são tabulados na forma de uma matriz de confusão na Tabela 4. A classificação de defeitos de linha usando a medida de compacidade normalizada acabou sendo muito eficaz. Apenas dois ou três defeitos de coloração mostraram valores relativamente altos (0,06-0,07) da medida de compacidade normalizada, que ainda está longe do valor limite mínimo (0,09) para defeitos de linha. Além disso, defeitos de furos podem facilmente classificados devido à sua alta média e baixa variância.

Uma precisão de classificação de 87,5% para desgastes e nós foi alcançada usando o método de segunda ordem características estatísticas. Isso pode ser aceito como um resultado satisfatório, considerando a natureza difícil da problemas de classificação. Embora o assunto do experimento seja diferente, Dyer et al. [3] perguntou um geólogo e um sujeito ingênuo para classificar 180 amostras de terreno em apenas três classes e relatou sobre 20 por cento de erros para ambos. Isso não é surpreendente porque os seres humanos são basicamente vulneráveis a esses tipos de tarefas simples e repetitivas. A taxa de erro dos revisores humanos provavelmente aumentará devido a fadiga à medida que o experimento continua.

Observou-se que as características estatísticas de segunda ordem foram altamente correlacionadas. Entropia e energia apresentaram correlação negativa, e inércia e homogeneidade também. Assim, durante toda a fase de treinamento, apenas a inércia e a entropia foram escolhidas para classificação em vez de todas as quatro características, pois essas duas características representam bem as características das outras duas.

Além disso, verificou-se que nem todas as quatro características possuem o mesmo poder discriminatório. Na fase de treinamento, inércia e entropia apresentaram melhor desempenho do que homogeneidade e energia em termos de habilidade de classificação. Em particular, a inércia acabou por ter o melhor poder de discriminação. De fato, a análise final dos resultados dos testes indicou que os resultados da classificação poderiam ter sido semelhantes, mesmo que apenas a inércia tivesse sido usada na terceira etapa da classificação.

5. Conclusões

Este artigo descreve o desenvolvimento de um sistema de visão automatizado para identificar e classificar defeitos visuais em tecidos de couro. Embora muito trabalho tenha sido feito na inspeção visual de defeitos em lajes têxteis, de madeira e aço, pouca atenção tem sido dada ao problema de classificação de defeitos, apesar de sua importância, principalmente devido à dificuldade do problema em si.

Neste estudo, a inspeção de defeitos foi realizada por um procedimento de segmentação em duas etapas com operações de limiar e morfológicas para melhorar o desempenho da segmentação. Quando as abordagens de limiarização baseadas em histogramas individuais não são satisfatórias, a adição de operações morfológicas é benéfica para a segmentação, pois elas têm o efeito de agrupamento, bem como a remoção de ruído. Os efeitos de agrupamento são razoáveis porque, embora um defeito seja descontínuo, as peças de couro boas cercadas pelas peças defeituosas descontínuas são úteis de qualquer maneira.

A medida de compacidade normalizada e as características estatísticas de primeira e segunda ordem foram usadas para a classificação de cinco diferentes classes de defeitos em tecidos de couro. Observou-se que as características estatísticas, bem como a medida de compacidade normalizada, capturam bem as diferenças essenciais entre os defeitos. Além disso, foi sugerido que a inércia por si só pode representar as características das quatro características estatísticas de segunda ordem para fins de classificação. Um classificador sequencial de árvore de decisão tem sido usado em um esforço para melhorar a eficiência da classificação. Este sistema tem apresentado desempenho satisfatório. A precisão geral da classificação no conjunto de testes foi de 91,25%.

Inspeção e classificação automatizadas de defeitos são muito importantes porque podem ser alcançadas maior produtividade e maior precisão de classificação. Além disso, os inspetores humanos podem ser removidos desse tipo de tarefa tediosa a longo prazo.

Referências

- [1] D. Brzakovic, H. Beck e N. Sufi, Uma abordagem para detecção de defeitos em materiais caracterizados por texturas complexas, *Reconhecimento de Padrão* 23(1/2) (1990), 99–107.
- [2] RW Connors e CA Harlow, Rumo a um analisador de textura estrutural baseado em métodos estatísticos, *Computação Gráfica e Image Processing* 12(3) (1980), 224-256.
- [3] CR Dyer, JS Weszka e A. Rosenfeld, Experimentos em classificação de terreno em imagens LANDSAT por análise de textura. Laudo Técnico TR-383, Centro de Ciência da Computação, Univ. Maryland, College Park, MD, 1975.
- [4] RM Haralick, K. Shanmugam e I. Dinstein, características texturais para classificação de imagem, *transações IEEE em sistemas, homem e cibernética SMC-3* (6) (1973), 610-621.
- [5] RM Haralick, abordagens estatísticas e estruturais para textura, *Proc. da Conferência IEEE* 67 (1979), 786-804.
- [6] BKP Horn, *Robot vision*, McGraw-Hill, Inc., Nova York, 1986.
- [7] JR Quinlan, Indução de árvores de decisão, *Machine Learning* 1 (1986), 81-106.

- [8] AR Rao, *Uma taxonomia para descrição e identificação de texturas*, Springer-Verlag, Inc., Nova York, 1990.
- [9] KY Song, M. Petrou e J. Kittler, Detecção de defeitos de textura: Uma revisão. Applications of Artificial Intelligence X: Machine Vision and Robotics, *SPIE* **1708** (1992), 99–106.
- [10] BR Suresh, RA Fundakowski, TS Levitt e JE Overland, Um sistema de inspeção visual automatizado em tempo real para lajes de aço quente, *Transações IEEE em Análise de Padrões e Inteligência de Máquina* **PAMI-5(6)** (1983), 563–572.
- [11] YF Zhang e RR Bresee, detecção e classificação de defeitos de tecido usando análise de imagem, *Textile Research Journal* **65(1)** (1995), 1-9.